

뇌를 읽는 방법론 1

뇌영상과 뇌파 분석: 전처리에서 통계적 추론과 재현성까지

신경과학과 임상 신경심리학 연구자를 위해 썼다. 물리·화학·생리 네 권에서 쌓은
신호의 원리 위에서 MRI, fMRI, 확산 MRI, PET, EEG/MEG 데이터를 실제로
처리하고 통계로 판단하는 방법을 익혀, 분석 파이프라인을 스스로 설계하고 방법
절을 비판적으로 읽을 수 있게 하는 것이 목표다.

차례

머리말

분석은 결정의 연속이다
앞 네 권과의 관계
시뮬레이션과 코드
이 책의 상자들
시리즈 안에서 이 책의 자리

1장 데이터, 형식, 좌표계

1.1 영상은 배열이다
1.2 파일 형식
1.3 좌표계
1.4 표준 공간
1.5 아틀라스와 분할
1.6 데이터 관리

2장 영상 분석을 위한 통계 다시 보기

2.1 표본, 모집단, 잡음
2.2 가설 검정과 p값
2.3 효과 크기와 신뢰 구간
2.4 일반 선형 모형의 기하
2.5 반복 측정과 혼합 효과 모형
2.6 베이즈 관점 맛보기

3장 구조 MRI 분석

3.1 전처리: 편향장, 두개골 제거, 강도 정규화
3.2 조직 분할
3.3 정합
3.4 복셀 기반 형태 분석(VBM)
3.5 표면 기반 분석
3.6 세분화된 구조, 종단 분석, 뇌 나이
3.7 혼입 요인: 움직임과 스캐너

4장 fMRI 전처리

4.1 왜 전처리를 하는가
4.2 시간 축
4.3 움직임 보정
4.4 왜곡 보정과 정합
4.5 평활화
4.6 잡음 제거
4.7 파이프라인 도구와 품질 보고
4.8 움직임과 집단 차이의 혼입

5장 fMRI 일반 선형 모형

5.1 신호 모형: 자극 시간표와 HRF의 합성곱
5.2 설계 행렬
5.3 추정과 대비
5.4 시간 자기상관과 선백화

- 5.5 설계 효율
- 5.6 집단 분석
- 5.7 확장: 같은 틀에서 다른 질문

6장 다중비교와 통계적 추론

- 6.1 문제의 크기
- 6.2 가족 오류율: 본페로니와 무작위장 이론
- 6.3 거짓 발견률
- 6.4 군집 수준 추론
- 6.5 비모수 순열 검정과 TFCE
- 6.6 관심 영역 분석과 순환성
- 6.7 결과를 정직하게 보고하기

7장 기능 연결성과 뇌 네트워크

- 7.1 휴지기 fMRI
- 7.2 연결성 측정
- 7.3 데이터 기반 방법: ICA와 이중 회귀
- 7.4 그래프 이론
- 7.5 동적 연결성과 그 함정
- 7.6 효과적인 연결성
- 7.7 혼입 요인

8장 확산 MRI 분석

- 8.1 전처리: 원자료에서 쓸 수 있는 영상까지
- 8.2 텐서 적합과 스칼라 지도
- 8.3 집단 분석: TBSS와 트랙 프로파일
- 8.4 섬유 방향 모형
- 8.5 트랙토그래피
- 8.6 구조 연결체
- 8.7 미세구조 모형

9장 EEG/MEG 전처리

- 9.1 기록 설계
- 9.2 필터
- 9.3 나쁜 채널, 보간, 재기준
- 9.4 인공물
- 9.5 ICA로 인공물 분리하기
- 9.6 MEG 특유의 처리
- 9.7 에포크, 기저선 보정, 시행 거부, 표준화
- 9.8 임상 EEG와 연구 EEG

10장 ERP와 시간-주파수 분석

- 10.1 ERP: 평균으로 꺼내는 반응
- 10.2 ERP 통계
- 10.3 스펙트럼 분석
- 10.4 비주기 성분과 봉우리
- 10.5 시간-주파수 분석
- 10.6 진동의 함정

11장 EEG/MEG 연결성과 소스 수준 분석

- 11.1 센서 수준 연결성과 체적 전도

- 11.2 위상 기반 측정
- 11.3 진폭 기반 측정
- 11.4 방향성: 그레이저 인과
- 11.5 소스 수준 파이프라인
- 11.6 교차 주파수 결합

12장 PET 분석과 다중 모달 결합

- 12.1 PET 전처리: 움직임, 정합, 영역
- 12.2 정량 지도: SUVR, 동적 모형, 파라메트릭 지도
- 12.3 부분 용적 보정
- 12.4 아밀로이드·타우 PET 분석
- 12.5 동시 EEG-fMRI
- 12.6 다중 모달 융합

13장 기계학습, 재현성, 열린 과학

- 13.1 예측 모형
- 13.2 교차 검증과 데이터 누설
- 13.3 표본 크기와 효과 크기
- 13.4 분석 유연성
- 13.5 재현 가능한 작업
- 13.6 임상 적용의 조건

머리말

분석은 결정의 연속이다

같은 fMRI 데이터를 70개 연구팀에게 주고 같은 가설을 검정하게 했더니, 팀마다 다른 결론이 나왔다 (NARPS, Botvinik-Nezer 외 2020). 데이터가 잘못된 것도, 연구자가 부주의했던 것도 아니다. 평활화 폭, 움직임 처리, 통계 문턱, 관심 영역 같은 수십 가지 결정이 합리적인 범위 안에서 달랐을 뿐이다.

이 책은 그 결정들을 다룬다. 영상과 뇌파 데이터가 스캐너와 증폭기를 떠나 논문의 그림이 되기까지 거치는 단계를 순서대로 따라간다. 단계마다 왜 하는지, 무엇을 가정하는지, 어떤 선택지가 있고 그 선택이 결과를 어떻게 바꾸는지, 흔히 어떤 실수를 하는지를 적었다.

앞 네 권과의 관계

물리 1·2권, 화학 1권, 생리 1권은 신호가 어디서 오는지를 다뤘다. BOLD가 탈산소헤모글로빈에서, EEG가 피라미드 뉴런의 시냅스 전류에서, 확산 MRI가 물 분자의 무작위 걸음에서 온다는 것을 알았다. 이 책은 그 지식을 전제로, 신호를 처리하고 판단하는 방법을 쌓는다. 원리가 필요한 곳에서는 "물리 2권 8장"처럼 앞 권을 가리킨다.

시뮬레이션과 코드

이 책의 그림은 대부분 합성 데이터로 만든 시뮬레이션이다. 정답을 아는 데이터에 방법을 적용해야 방법이 무엇을 하고 어디서 실패하는지 볼 수 있기 때문이다. 일부 장에는 numpy와 scipy만으로 돌릴 수 있는 짧은 Python 코드를 실었다. 특정 소프트웨어의 명령어는 버전마다 바뀌므로 이름과 역할만 소개한다.

이 책의 상자들

앞 권과 같은 상자에 하나를 더했다.

방법 절 점검표

장 끝마다 논문의 방법 절을 읽을 때, 또는 자신의 분석을 설계할 때 확인할 항목을 정리했다.



뇌로 가는 다리

방법이 실제 연구와 임상 어디에 쓰이는지, 그리고 잘못 쓰였을 때 어떤 결론이 나왔는지 보여 준다.

흔한 오해

방법론 논쟁과 자주 하는 실수를 짚는다.

시리즈 안에서 이 책의 자리

1. 물리 1: 고전 물리와 전기
2. 화학 1: 생명을 위한 일반화학
3. 생리 1: 뉴런에서 혈류까지
4. 물리 2: 현대물리와 영상의 물리
5. **방법론 1: 뇌영상과 뇌파 분석 (이 책)**

1장 데이터, 형식, 좌표계

이 장에서 배울 것 영상이 숫자 배열이라는 것, 그 배열을 담은 파일 형식(DICOM, NIfTI, GIFTI/CIFTI, EEG 형식, BIDS), 배열의 번호를 머리 속 mm 좌표로 바꾸는 4×4 아핀 행렬, 표준 공간과 아틀라스, 그리고 데이터를 안전하고 재현 가능하게 관리하는 법. **뇌 연구자에게 왜 필요한가** 분석의 첫 단계에서 생긴 실수는 뒤 단계에서 보이지 않는다. 좌우가 뒤바뀐 영상, 잘못 읽힌 슬라이스 시각, 다른 버전의 MNI 템플릿은 그럴듯한 결과를 그대로 내놓는다. 이 장의 내용은 모든 파이프라인의 바닥이다.

📖 중고등 복습: 좌표평면과 행렬 곱

좌표평면의 점 (x, y) 를 오른쪽으로 3, 위로 2만큼 옮기면 $(x + 3, y + 2)$ 가 된다. 이것이 **평행이동**이다. 모든 좌표를 2배 하면 그림이 커지고, x 에 -1 을 곱하면 y 축을 거울로 삼아 뒤집힌다. 이런 조작은 행렬 곱으로 한꺼번에 쓸 수 있다. 2×2 행렬 $\begin{pmatrix} a & b \\ c & d \end{pmatrix}$ 에 열벡터 (x, y) 를 곱하면 $(ax + by, cx + dy)$ 다. 대각선에 2를 두면 확대, -1 을 두면 뒤집기, 코사인과 사인을 두면 회전이다. 물리 1권 2장에서 머리 좌표계 RAS를 배웠다. x 는 오른쪽, y 는 앞쪽, z 는 위쪽으로 갈수록 커진다. 이 장은 "배열의 몇 번째 칸"을 "RAS 좌표 몇 mm"로 바꾸는 방법을 다룬다. 확대, 회전, 뒤집기, 평행이동을 행렬 하나에 담는 것이 핵심이다.

1.1 영상은 배열이다

복셀, 차원, 자료형

컴퓨터에게 MRI 영상은 사진이 아니라 숫자가 든 상자들의 격자다. 상자 하나를 **복셀(voxel, volume element)**이라 한다. 2차원 영상의 화소(pixel)에 두께가 붙은 것이다. 복셀마다 숫자가 하나 들어 있고, 그 숫자를 회색 농도로 칠한 것이 우리가 보는 영상이다([그림 1.1](#)).

배열의 모양을 **차원(dimension)**으로 말한다. T1 강조 구조 영상은 3차원 배열로, 예컨대 $176 \times 256 \times 256$ 이다. fMRI는 시간 축이 붙은 4차원 배열로, $64 \times 64 \times 36 \times 300$ 이라면 36장짜리 볼륨을 300번 찍은 것이다. 확산 MRI의 4번째 축은 시간이 아니라 확산 방향이다. 축이 무엇을 뜻하는지는 배열 자체에 적혀 있지 않고 헤더(1.2절)에 적힌다.




그림 1.1 영상은 숫자 배열이다. (가) 64×64 합성 단면. (나) 빨간 상자 안 6×6 복셀의 실제 값. 회백질(약 450)과 백질(약 700)이 그냥 정수로 들어 있다. (다) fMRI에서는 같은 복셀이 4번째 차원을 따라 시계열을 갖는다. 블록 과제에 따라 1-2% 오르내린다.

숫자를 저장하는 방식이 **자료형(data type)** 이다. 영상에서 흔한 것은 셋이다. **uint8**은 0-255의 정수를 1바이트에, **int16**은 -32768-32767의 정수를 2바이트에, **float32**는 소수점이 있는 실수를 4바이트에 담는다. 스캐너가 내보내는 원 영상은 대개 int16이고, 전처리를 거친 영상과 통계 지도는 float32다.

예제 1.1 파일 크기 어림

(가) $64 \times 64 \times 36$ 볼륨 300개를 int16으로 저장하면 몇 MB인가? float32로 바꾸면? (나) HCP 휴지기 fMRI 한 번($104 \times 90 \times 72$, 1200 볼륨)을 int16으로 저장하면?

풀이 (가) 복셀 수는 $64 \times 64 \times 36 \times 300 = 4.42 \times 10^7$ 개다. 2바이트씩이면 8.85×10^7 바이트, 약 88 MB다. float32로 바꾸면 두 배인 약 177 MB가 된다. 전처리 중간 산출물이 원본보다 훨씬 큰 이유다. (나) $104 \times 90 \times 72 \times 1200 \times 2 = 1.62 \times 10^9$ 바이트, 약 1.6 GB다. 참가자 1000명이 네 번씩 찍으면 원본만 6 TB를 넘는다. 압축(.gz)은 배경의 0 덕분에 크기를 절반 안팎으로 줄여 준다.

강도 눈금

복셀 값에는 단위가 있을 수도 없을 수도 있다. CT의 값은 하운스필드 단위로, 물이 0, 공기가 -1000이 되게 정한 물리량이다(물리 2권 4장). 보정을 마친 PET의 값은 kBq/mL다(물리 2권 3장). 반면 MRI의 값은 **임의 단위(arbitrary unit)** 다. 코일, 수신 증폭, 재구성 설정에 따라 같은 사람의 같은 조직이 500도 되고 1500도 된다. 그래서 MRI에서는 값 자체보다 비율(% 신호 변화)이나 조직 사이 대비를 쓴다.

자료형은 값을 조용히 바꿀 수 있다(그림 1.2). FA(0-1의 실수) 지도를 정수형으로 저장하면 소수점 아래가 잘려 거의 모두 0이 된다. 0-1000의 값을 uint8로 바꾸면 255를 넘는 순간 0으로 되감긴다. 이를 막으려고 NIfTI 헤더에는 **눈금 계수(scl_slope, scl_inter)** 가 있다. 저장된 정수에 기울기를 곱하고 절편을 더해 실제 값을 복원한다. 읽는 도구가 이 계수를 무시하면 값이 통째로 틀린다.




그림 1.2 자료형이 값을 바꾸는 두 방식. (가) 0.15~0.75의 FA 단면을 눈금 계수 없이 int16에 넣으면 모두 0이 된다. 계수 1/32767을 함께 저장하면 원래 값과 구별되지 않는다. (나) 0~1000의 강도를 uint8로 변환하면 255마다 0으로 되감기고, 잘라 넣으면 255에서 포화된다.

흔한 오해: MRI 밝기 값끼리 직접 비교할 수 있다

T1 영상에서 환자군의 백질 평균이 820, 대조군이 760이라는 결과는 그 자체로 아무 뜻이 없다. 두 집단을 다른 날, 다른 코일 설정으로 찍었다면 그 차이는 스캐너에서 왔을 수 있다. 같은 사람 안에서도 수신 코일에 가까운 피질은 밝고 먼 곳은 어둡다(편향장, 3장). 밝기를 비교하려면 강도 정규화를 하거나, T1 값 자체를 채는 정량 영상을 쓰거나, 백질 대비 회백질처럼 같은 영상 안의 비를 써야 한다.

1.2 파일 형식

DICOM: 스캐너가 내보내는 형식

DICOM(Digital Imaging and Communications in Medicine) 은 병원 영상 장비의 표준 형식이다. 대개 슬라이스 하나, 또는 볼륨 하나가 파일 하나다. 3분짜리 fMRI 한 번이 수천 개 파일이 되기도 한다. 각 파일 머리에는 **태그(tag)** 수백 개가 붙는다. 환자 이름과 생년월일, 촬영 날짜, TR과 TE, 복셀 간격(PixelSpacing), 슬라이스 위치(ImagePositionPatient), 슬라이스 방향(ImageOrientationPatient) 등이다. 제조사마다 표준 밖의 **사설 태그(private tag)** 에 슬라이스 획득 시각이나 확산 경사 방향 같은 중요한 정보를 숨겨 두기도 한다.

분석 도구는 대부분 DICOM을 직접 읽지 않는다. 먼저 **변환 도구**(dcm2nii가 사실상 표준이다)로 NIfTI와 JSON으로 바꾼다. 이 단계의 가정은 "필요한 메타데이터가 모두 옮겨졌다"는 것이다. 사설 태그를 해석하지 못하면 슬라이스 시각이나 위상 부호화 방향이 빠지고, 그 뒤의 전처리는 기본값으로 조용히 진행된다.

NIfTI: 분석의 공용어

NIfTI(Neuroimaging Informatics Technology Initiative) 는 볼륨 하나 또는 4차원 시계열 하나를 파일 하나(.nii, 압축하면 .nii.gz)에 담는다. 앞의 348바이트(NIfTI-1)가 헤더이고 나머지가 배열이다. 헤더의 주요 항목은 다음과 같다.

- **dim**: 각 축의 길이. 예: 64, 64, 36, 300.
- **pixdim**: 각 축의 간격. 예: 3, 3, 3 mm와 TR 2 s.
- **datatype**: 자료형. int16, float32 등.
- **scl_slope, scl_inter**: 위의 눈금 계수.
- **qform과 sform**: 배열 번호를 mm 좌표로 바꾸는 두 가지 방법(1.3절). 각각에 **코드**가 붙어 그 좌표가 어떤 공간인지 말한다. 1은 스캐너 좌표, 2는 다른 영상에 정렬된 좌표, 3은 탈라이라크, 4는 MNI152다.

qform은 회전, 복셀 크기, 평행이동만 담는다. 머리를 찌그러뜨리지 않는 변환이다. sform은 12개 숫자로 된 일반적인 아핀 변환을 담아 표준 공간으로의 선형 정합처럼 늘림과 기울임도 표현한다. 두 변환이 서로 다르면 도구마다 어느 쪽을 쓰는지가 달라질 수 있다. NIfTI의 선배 형식인 Analyze는 방향 정보가 사실상 없어서(orient 필드가 있지만 도구들이 대개 무시했다), 좌우를 프로그램의 관례에 맡겼다. 오래된 데이터에서 좌우 사고가 잦은 이유다.

표면과 그레이오디네이트: GIFTI와 CIFTI

피질은 2-4 mm 두께의 구겨진 판이다. 이 판을 삼각형 그물로 나타낸 것이 **표면(surface)** 이다(3장). **GIFTI** 는 표면을 담는 형식으로, 꼭짓점 좌표, 삼각형 목록, 그리고 꼭짓점마다의 값(피질 두께, 활성 등)을 저장한다. **CIFTI** 는 피질 꼭짓점과 피질하 복셀을 한 행렬에 함께 담는다. 이 둘을 묶어 **그레이오디네이트(grayordinate)** 라 한다. HCP 표준에서는 피질 꼭짓점 59,412개와 피질하 복셀 31,870개, 모두 91,282개다. 시계열이라면 $91,282 \times$ 시간점 수 행렬 하나가 된다.

EEG와 MEG 형식

전기생리 데이터는 영상이 아니라 채널 $\times$ 시간 행렬이다. 64채널을 1000 Hz로 1시간 기록하면 2.3억 개 값, int16으로 약 461 MB다. 형식은 제조사와 분야에 따라 갈린다.

- **EDF/EDF+**: 임상 EEG와 수면 연구의 표준. 채널마다 16비트 정수와 물리 범위를 저장한다.
- **BDF**: EDF의 24비트판. 같은 범위를 256배 세밀하게 담는다.
- **BrainVision**: 헤더(.vhdr), 이벤트 표시(.vmrk), 자료(.eeg) 세 파일이 한 묶음이다. 파일 이름을 하나만 바꾸면 묶음이 깨진다.
- **FIF**: MEG 장비 계열의 형식으로, MNE-Python의 기본 형식이기도 하다. 센서 위치와 머리 좌표 정합 정보를 함께 담는다.
- **EEGLAB .set**: MATLAB 기반 EEGLAB의 작업 형식.

예제 1.2 EDF의 진폭 해상도

EDF는 16비트 정수 65,536단계로 물리 범위를 나눈다. (가) 물리 범위를 $-3200 \mu\text{V} \sim +3200 \mu\text{V}$ 로 두면 한 단계는 몇 μV 인가? (나) 실수로 $-50 \text{ mV} \sim +50 \text{ mV}$ 로 두면? 진폭 2-5 μV 인 ERP 성분을 생각하라.

풀이 (가) $6400 \mu\text{V} / 65535 \approx 0.098 \mu\text{V}$ 다. 두피 EEG(10-100 μV)를 담기에 충분하다. (나) $100,000 \mu\text{V} / 65535 \approx 1.5 \mu\text{V}$ 다. 몇 μV 짜리 성분이 1.5 μV 계단으로 잘게 썰린다. 평균을 많이 하면 일부 회복되지만, 내보내기 설정 하나로 자료의 질이 떨어진 셈이다. 24비트 BDF라면 같은 범위에서 한 단계가 약 0.006 μV 다.

BIDS: 폴더 구조가 곧 메타데이터

같은 실험실 안에서도 파일 이름은 사람마다 제각각이다. **BIDS(Brain Imaging Data Structure)** 는 폴더 구조와 파일 이름 규칙, 그리고 메타데이터를 담은 JSON 사이드카를 정한 표준이다(Gorgolewski 외 2016). 참가자(sub-), 세션(ses-), 영상 종류(anat, func, dwi, fmap, eeg), 과제(task-)가 이름에 들어간다(그림 1.3). 영상마다 같은 이름의 .json 파일이 붙어 TR, 슬라이스 시각, 위상 부호화 방향 같은 획득 변수를 기계가 읽을 수 있게 담는다. 과제의 자극 시각은 events.tsv에 들어간다.




그림 1.3 BIDS 데이터셋의 뼈대. 왼쪽: 참가자, 영상 종류, 과제가 폴더와 파일 이름에 들어간다. 전처리 결과는 원자료와 섞지 않고 derivatives/ 아래에 둔다. 오른쪽: BOLD 영상 옆의 JSON 사이드카. 슬라이스 타이밍 보정과 왜곡 보정(4장)이 이 값을 그대로 읽는다.

BIDS의 이득은 기계가 읽는다는 데 있다. fMRIPrep, MRIQC 같은 BIDS 앱은 폴더 하나만 주면 나머지를 스스로 찾는다. 검증 도구(BIDS validator)는 빠진 필드와 이름 오류를 미리 잡는다. 대가는 처음 정리하는 수고다. 그리고 JSON의 값이 틀리면 모든 도구가 같은 틀린 값을 믿는다.

뇌로 가는 다리: 사이드카 한 줄이 전처리를 바꾼다

TR 2 s, 교차 순서 36장인 fMRI에서 SliceTiming이 빠지면 슬라이스 타이밍 보정은 건너뛰어지거나 순차 순서로 가정된다. 교차 순서를 순차로 잘못 가정하면 슬라이스 시각이 최대 약 1 s 틀린다. HRF의 정점이 4-6 s임을 생각하면 사건 관련 설계의 추정에 영향을 준다(4장, 5장). PhaseEncodingDirection의 부호가 틀리면 왜곡 보정이 왜곡을 되돌리지 않고 두 배로 키운다. 안와전두 피질 근처에서 1 cm 가까이 밀릴 수 있다(물리 2권 8장). 이런 오류는 오류 메시지를 내지 않는다. 그래서 변환 직후 JSON의 핵심 필드를 스캐너 프로토콜 출력물과 대조하는 습관이 중요하다.

1.3 좌표계

복셀 좌표와 세계 좌표

배열의 칸 번호 (i, j, k) 를 **복셀 좌표(voxel coordinate)**라 한다. 대부분의 도구에서 0부터 센다(MATLAB 기반 도구는 1부터 센다). 복셀 좌표만으로는 그 칸이 머리의 어디인지 모른다. 배열의 첫 축이 왼쪽에서 오른쪽으로 가는지, 그 반대인지, 머리가 기울어 찍혔는지는 배열에 없다.

머리 속 실제 위치를 mm로 적은 것이 **세계 좌표(world coordinate)**다. NIfTI의 세계 좌표는 RAS를 따른다. 원점은 스캐너 좌표라면 자석 중심 근처, MNI 공간이라면 대략 앞맞교차(AC)다.

4 × 4 아핀 행렬

복셀 좌표에서 세계 좌표로 가는 변환은 확대(복셀 크기), 회전(기울어진 슬라이스), 뒤집기, 평행이동의 조합이다. 이것을 **아핀 변환(affine transform)**이라 하고, 행렬 하나로 쓴다.

$$\begin{pmatrix} x \\ y \\ z \\ 1 \end{pmatrix} = \begin{pmatrix} m_{11} & m_{12} & m_{13} & t_x \\ m_{21} & m_{22} & m_{23} & t_y \\ m_{31} & m_{32} & m_{33} & t_z \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} i \\ j \\ k \\ 1 \end{pmatrix}$$

왼쪽 위 3×3 블록 M 이 확대, 회전, 뒤집기를 담는다. 오른쪽 열 t 는 평행이동, 곧 복셀 $(0, 0, 0)$ 의 세계 좌표다. 맨 아래 줄과 벡터 끝의 1은 평행이동까지 행렬 곱 하나로 쓰기 위한 장치다. M 의 각 열의 길이가 그 축의 복셀 크기다. M 의 행렬식이 음수면 배열 축 중 하나가 거울상으로 놓였다는 뜻이다(그림 1.4).




그림 1.4 2차원으로 줄여 그린 아핀 변환. (가) 배열 안에서 복셀은 번호만 갖는다. (나) 아핀 행렬이 3 mm 복셀 크기, 15° 기울임, i 축 뒤집기, 평행이동을 한꺼번에 적용해 복셀 (5, 2)를 세계 좌표 (-4.0, -7.1) mm로 보낸다. i 가 커질수록 왼쪽으로 간다.

예제 1.3 MNI 2 mm 템플릿의 아핀

MNI152 2 mm 템플릿($91 \times 109 \times 91$)의 아핀은 $M = \text{diag}(-2, 2, 2)$, $t = (90, -126, -72)$ 다. (가) 복셀 (45, 63, 36)의 세계 좌표는? (나) 세계 좌표 (-48, 16, 12)는 몇 번 복셀인가? (다) 행렬식의 부호는 무엇을 말하는가?

풀이 (가) $x = -2 \times 45 + 90 = 0$, $y = 2 \times 63 - 126 = 0$, $z = 2 \times 36 - 72 = 0$ 이다. 원점(AC 부근)이다. (나) 거꾸로 푼다. $i = (x - 90)/(-2) = 69$, $j = (16 + 126)/2 = 71$, $k = (12 + 72)/2 = 42$ 다. 오른쪽 반구의 대칭점 (48, 16, 12)는 $i = 21$ 이다. 왼쪽 점의 i 가 더 크다. (다) $\det M = -8 < 0$ 이다. 첫 배열 축이 오른쪽이 아니라 왼쪽으로 커진다. 축 방향을 글자로 쓰면 LAS다. 데이터는 틀리지 않았다. 헤더가 이 사실을 알고 있는 한 좌우는 안전하다.

같은 계산을 numpy로 하면 다음과 같다. 배열 축 방향 글자를 얻는 함수도 넣었다.

```

import numpy as np

# MNI152 2 mm 템플릿(91 × 109 × 91)의 아핀 행렬
A = np.array([[-2.0, 0, 0, 90],
               [ 0, 2, 0, -126],
               [ 0, 0, 2, -72],
               [ 0, 0, 0, 1]])

def vox2world(A, ijk):
    return (A @ np.append(ijk, 1.0))[:3]

def world2vox(A, xyz):
    return (np.linalg.inv(A) @ np.append(xyz, 1.0))[:3]

def axcodes(A):
    """각 배열 축이 머리의 어느 쪽으로 커지는지 (RAS 기준)"""
    pos, neg = "RAS", "LPI"
    M = A[:3, :3]
    return "".join(pos[k] if M[k, c] > 0 else neg[k]
                   for c, k in enumerate(np.abs(M).argmax(axis=0)))

print(vox2world(A, [45, 63, 36]))      # [0. 0. 0.]
print(world2vox(A, [-48, 16, 12]))     # [69. 71. 42.]
print(axcodes(A), round(np.linalg.det(A[:3, :3]), 3))  # LAS -8.0

```

RAS와 LPS, 화면 관례

물리 1권 2장에서 본 것처럼 좌표 약속은 둘이다. NIfTI와 FSL, FreeSurfer의 좌표는 RAS를 쓴다. DICOM과 ITK 계열 도구(ANTs 등)는 **LPS**를 쓰고, AFNI도 기본 표시 좌표는 DICOM 순서(RAI, 부호로는 LPS와 같다)다. 같은 점의 두 좌표는 x 와 y 의 부호만 다르다.

$$(x, y, z)_{\text{RAS}} = (-x, -y, z)_{\text{LPS}}$$

변환 행렬을 한 도구에서 만들어 다른 도구에 넘길 때 이 부호를 빠뜨리면 영상이 뒤집히거나 엉뚱한 곳으로 옮겨진다.

화면에 그리는 관례도 둘이다. **신경과 관례(neurological convention)**는 환자의 왼쪽을 화면 왼쪽에, **방사선과 관례(radiological convention)**는 환자를 마주 보듯 환자의 왼쪽을 화면 오른쪽에 둔다. 두 관례 모두 헤더가 옳으면 문제가 없다. 문제는 배열이 뒤집혔는데 헤더가 그 사실을 모를 때다(그림 1.5). 뇌는 거의 좌우 대칭이어서 눈으로 알아채기 어렵다.




그림 1.5 같은 축상면을 세 가지로 표시했다. 빨간 점은 왼쪽 하전두 활성이고, 머리 오른쪽 바깥의 흰 점은 촬영 때 붙인 비타민 E 표지다. (가)와 (나)는 관례만 다르게 둘 다 옳다. (다)는 변환 중 배열만 뒤집히고 헤더가 그대로인 경우다. 활성이 오른쪽 반구에 있는 것처럼 보이고, 표지가 반대편에 나타나 오류가 드러난다.

🧠 뇌로 가는 다리: 좌우 사고와 언어 편재

수술 전 fMRI의 핵심 질문은 "언어가 어느 반구에 있는가"다. 흔히 **편재 지수(lateralization index) $LI = (L - R) / (L + R)$** 로 요약한다. L, R 은 각 반구의 문턱을 넘은 복셀 수다. 왼쪽 120개, 오른쪽 40개면 $LI = 0.5$ 로 왼쪽 우세다. 배열이 뒤집힌 영상에서는 같은 자료가 $LI = -0.5$, 오른쪽 우세가 된다. 수술 계획을 뒤집을 수 있는 오류이고, 통계는 아무 이상도 알려 주지 않는다. 예방법은 단순하다. 촬영 때 한쪽에 표지를 붙이고, 변환과 정합의 각 단계 뒤에 표지가 같은 쪽에 있는지 본다. 연구용 데이터라면 원본 DICOM과 변환된 NIfTI를 같은 뷰어에서 겹쳐 보고, 축 방향 글자(예: RAS, LAS)를 기록한다. 집단 연구에서 한 사이트만 좌우가 뒤집혀도 편재 효과는 희석되어 "효과 없음"으로 나온다.

1.4 표준 공간

왜 표준 공간인가

사람마다 뇌의 크기와 모양이 다르다. 여러 사람의 결과를 복셀 단위로 합치거나 다른 연구와 좌표를 비교하려면 모두를 공통의 틀로 옮겨야 한다. 그 틀이 **표준 공간(standard space)** 이고, 옮기는 일이 공간 정규화다(3장, 4장). 가정은 "정합 뒤 같은 좌표는 같은 해부 구조"라는 것이다. 이 가정은 고랑과 이랑 수준에서는 대체로 맞지만, 개인 차가 큰 영역의 경계 수준에서는 깨진다.

탈라이라크, MNI, fsaverage

탈라이라크 공간(Talairach space) 은 60세 여성 한 명의 사후 뇌를 바탕으로 한 아틀라스에서 나왔다 (Talairach와 Tournoux 1988). AC와 뒷맞교차(PC)를 잇는 선을 기준으로 뇌를 상자에 맞춘다. 한 사람의 뇌이고, 한쪽 반구만 자세히 그렸다는 한계가 있다.

MNI 공간 은 몬트리올 신경학 연구소가 여러 사람의 MRI를 평균해 만들었다. 305명을 평균한 MNI305에 이어, 152명의 고해상도 영상으로 만든 **MNI152**가 표준이 되었다. 문제는 MNI152가 여러 버전이라는

것이다. 선형 정합으로 평균한 판, FSL이 기본으로 쓰는 6세대 비선형 판, fMRIPrep이 기본으로 쓰는 2009c 비선형 비대칭 판 등이 있다. 버전마다 경계가 mm 단위로 다르다.

MNI 뇌는 탈라이라크 뇌보다 크다. 그래서 MNI 좌표를 탈라이라크 아틀라스에서 찾으면 엉뚱한 구조가 나온다. 두 공간 사이의 근사 변환이 여럿 제안되었다. **그림 1.6** 은 그중 하나(Brett의 변환)로 본 어긋남이다.




그림 1.6 MNI 좌표와 그 탈라이라크 근사 좌표의 차이. (가) 정중 시상면에서 어긋남의 크기(색)와 방향(화살표, 2배로 늘려 그림). AC 근처는 1-2 mm로 작고, 위쪽 끝과 AC 아래(측두엽, 소뇌)는 6-10 mm에 이른다. (나) 대표 좌표 다섯 곳의 어긋남. 표가 어느 공간의 좌표인지 모르면 이만큼 자리를 잘못 찾는다.

표면 분석에는 **fsaverage**가 표준 공간 역할을 한다. FreeSurfer가 40명의 표면을 평균해 만든 구 모양 좌표계로, 정이십면체를 잘게 나눈 그물이다. 반구마다 꼭짓점이 163,842개(fsaverage), 40,962개(fsaverage6), 10,242개(fsaverage5)다. HCP 계열은 좌우 반구 꼭짓점이 서로 대응하는 fs_LR 32k(반구당 32,492개)를 쓴다.

예제 1.4 좌표 보고의 함정

한 논문이 피크를 (0, -10, 65)로 보고했다. 공간이 MNI인지 탈라이라크인지는 적혀 있지 않다. MNI 좌표라고 보고 Brett의 근사 변환(위쪽 절반: $x' = 0.99x$, $y' = 0.9688y + 0.0460z$, $z' = -0.0485y + 0.9189z$)을 적용하면 탈라이라크 좌표는 어떻게 되는가?

풀이 $x' = 0$, $y' = 0.9688 \times (-10) + 0.0460 \times 65 = -6.7$, $z' = -0.0485 \times (-10) + 0.9189 \times 65 = 60.2$ 다. 차이는 $\sqrt{3.3^2 + 4.8^2} \approx 5.8$ mm다. 보조운동영역 피크로서는 같은 구조 안이지만, 메타분석에서 5.8 mm는 평활화 핵의 FWHM과 맞먹는 오차다. 이런 근사 변환 자체도 평균적 관계일 뿐이다. 좌표를 보고할 때는 공간의 이름과 템플릿 버전을 함께 적어야 한다.

1.5 아틀라스와 분할

해부 아틀라스와 기능 아틀라스

아틀라스(atlas) 는 표준 공간의 복셀이나 꼭짓점마다 영역 이름표를 붙인 지도다. 뇌를 겹치지 않는 영역으로 나눈 것을 **분할(parcelation)** 이라 한다. ROI 분석, 연결성 행렬의 노드(7장), 좌표에 이름 붙이기가 모두 아틀라스에 기댄다.

해부 아틀라스는 고랑과 이랑 같은 거시 해부로 경계를 정한다. 단일 피험자 MNI 영상에 116개 영역을 그린 **AAL**(Tzourio-Mazoyer 외 2002), 여러 사람의 수작업 분할을 확률로 합친 **Harvard-Oxford**(피질 48개, 피질하 21개), FreeSurfer가 개인 표면에 자동으로 붙이는 **Desikan-Killiany**(반구당 34개, Desikan 외 2006)와 더 잘게 나눈 Destrieux(반구당 74개)가 대표적이다.

기능 아틀라스는 휴지기 fMRI의 연결 패턴이나 다중 모달 정보로 경계를 정한다. 1000명의 휴지기 자료로 피질을 7개 또는 17개 네트워크로 나눈 **Yeo 7/17**(Yeo 외 2011), 이를 바탕으로 100-1000개 영역을 고를 수 있게 한 **Schaefer**(Schaefer 외 2018), 구조, 기능, 연결, 지형 정보를 함께 써서 반구당 180개 영역을 정한 **Glasser HCP-MMP**(Glasser 외 2016)가 많이 쓰인다.

확률 아틀라스

세포구축학 아틀라스(예: 율리히 아틀라스)나 Harvard-Oxford는 복셀마다 "이 영역일 확률"을 준다. 브로드만 44 영역이 70%인 복셀은 열 명 중 일곱 명에서 그 영역이었다는 뜻이다. ROI로 쓰려면 문턱을 정해야 하고, 문턱이 영역의 크기를 바꾼다. 25%로 자르면 넓지만 이웃 영역이 섞이고, 50%로 자르면 좁지만 순수하다. 같은 이름의 ROI라도 문턱이 다르면 다른 ROI다.

아틀라스 선택이 결과를 바꾼다

ROI 분석은 영역 안의 값을 평균한다. 그 평균은 효과가 경계와 어떻게 겹치는지에 달려 있다. **그림 1.7** 는 같은 합성 자료를 세 분할로 요약한 시뮬레이션이다. 효과가 한 영역 한가운데 들면 영역 평균이 0.27이다. 같은 격자를 20 mm 옮겨 경계가 효과 중심을 지나게 하면, 효과가 네 영역으로 나뉘고 잡음에 묻혀 -0.03이 된다. 작은 영역 40개로 나누면 효과를 거의 담은 영역이 생겨 0.47이 된다.




그림 1.7 같은 자료, 다른 분할. 왼쪽은 참 효과(최대 1, 실선은 절반 높이)에 공간적으로 매끄러운 잡음을 더한 120×120 mm 피질 조각이다. 오른쪽 셋은 영역마다 평균을 칠했다. 효과가 같아도 경계의 자리와 영역의 크기에 따라 효과 중심 영역의 평균이 0.27, -0.03, 0.47로 달라진다.

뇌로 가는 다리: 아틀라스는 분석 결정이다

휴지기 연결성 연구에서 노드를 AAL 116개로 잡을 때와 Schaefer 400개로 잡을 때, 그래프의 군집 계수, 경로 길이, 허브의 위치가 달라진다. 노드 수 자체가 그래프 지표의 기준값을 바꾸기 때문이다(7장). 그래서 같은 질환을 다룬 연구들이 서로 다른 허브를 보고하는 일이 흔하다. 해부 아틀라스로 기능 효과를 요약할 때도 주의가 필요하다. AAL의 "중심앞이랑"은 손, 얼굴, 다리 운동 영역을 한 덩어리로 묶는다. 손가락 운동 과제의 효과는 이 큰 영역 평균에서 희석된다. 가능하면 질문에 맞는 해상도의 아틀라스를 미리 정하고(사전 등록, 6장), 결과가 다른 아틀라스에서도 유지되는지 민감도 분석으로 보고한다.

1.6 데이터 관리

익명화와 얼굴 제거

DICOM 헤더에는 이름, 생년월일, 병원 번호가 들어 있다. NIfTI로 변환하면 대부분 사라지지만, JSON 사이드카에 촬영 날짜나 기관 이름이 남을 수 있다. 공유 전에 헤더와 사이드카를 모두 검사한다.

헤더만으로는 부족하다. 1 mm 해상도의 T1 영상을 3차원으로 그리면 얼굴이 나온다. 상용 얼굴 인식 소프트웨어가 MRI로 재구성한 얼굴 84개 중 70개(83%)를 사진과 맞췄다는 보고가 있다(Schwarz 외 2019). 그래서 공개 데이터에서는 **얼굴 제거(defacing)** 도구로 코, 입, 귀 부위의 픽셀을 지운다. 얼굴 제거는 두개골 제거나 정합에 영향을 줄 수 있어, 원본을 안전한 곳에 따로 보관하고 공개본에만 적용하는 것이 보통이다. 얼굴 제거를 해도 개인 식별 가능성이 0이 되지는 않는다. 데이터 사용 협약과 동의서의 범위가 함께 필요하다.

품질 점검

전처리 전에 원자료의 품질을 숫자로 본다. **MRQC**(Esteban 외 2017) 같은 도구는 BIDS 데이터셋에서 영상마다 **영상 품질 지표(IQM, image quality metric)**를 계산한다. 구조 영상에서는 SNR, 회백질-백질 대비, 엔트로피, 배경의 고스트, fMRI에서는 시간 신호 대 잡음비(tSNR), 평균 틀별 변위(FD, 4장), DVARS 등이다.

지표의 절대 기준은 장비와 프로토콜마다 다르다. 그래서 같은 데이터셋 안에서 이상치를 찾는 것이 실용적이다. 평균과 표준편차는 이상치 자체에 끌려가므로, **중앙값과 중앙 절대 편차(MAD)**를 쓴 강건한 기준이 흔하다. 정규분포에서 표준편차와 맞추려면 MAD에 1.4826을 곱한다.




그림 1.8 합성 참가자 60명의 품질 지표. (가) 평균 FD와 tSNR에 중앙값 + 3 MAD(tSNR은 중앙값 - 3 MAD) 기준을 적용하면 빨간 원 네 명이 걸린다. 셋은 움직임이 크고, 하나는 움직임은 작지만 tSNR이 낮아 코일 문제를 의심하게 한다. (나) 환자군의 FD 중앙값(0.23 mm)은 대조군(0.11 mm)의 약 두 배다. 걸러 낸 네 명이 모두 환자군이다.

그림 1.8의 오른쪽은 품질 점검이 통계 문제이기도 하다는 것을 보여 준다. 환자, 소아, 노인은 대체로 더 움직인다. 품질 기준으로 사람을 빼면 환자군에서 증상이 심한 사람이 더 많이 빠지고, 남은 사람의 움직임도 여전히 집단마다 다르다. 제외 기준은 자료를 보기 전에 정하고, 집단별 제외 수와 남은 움직임의 집단 차이를 보고해야 한다(4장).

버전 관리와 기록

분석 결과는 자료, 코드, 소프트웨어 버전, 설정의 함수다. 코드는 git 같은 버전 관리 도구로, 대용량 자료는 DataLad 같은 자료 버전 관리 도구로 관리할 수 있다. 소프트웨어는 컨테이너(Docker, Apptainer)로 고정하면 몇 년 뒤에도 같은 결과를 낸다. 방법 절에는 도구의 이름과 정확한 버전, 템플릿의 이름과 버전, 바꾼 기본 설정을 적는다. 같은 도구라도 버전이 바뀌면 기본값이 바뀌는 일이 흔하다(13장).

🧠 뇌로 가는 다리: 원자료는 읽기 전용이다

BIDS가 derivatives/를 따로 두는 이유는 원자료를 고치지 않기 위해서다. 전처리 중 실수로 원본 NIfTI를 덮어쓰면, 그 뒤의 모든 결과가 어떤 자료에서 나왔는지 추적할 수 없다. 실용적인 규칙은 셋이다. 원자료 폴더를 읽기 전용으로 만든다. 모든 산출물은 그것을 만든 스크립트와 짝을 짓는다. 수작업 편집(예: 표면 수정, 성분 분류)도 파일로 기록한다. 다기관 연구나 종단 연구처럼 수년에 걸친 데이터에서는 이 규칙이 결과의 신뢰를 지킨다.

핵심 정리

핵심 정리

- 영상은 복셀 값의 배열이다. 축의 뜻, 복셀 크기, 자료형, 눈금 계수는 헤더에 있다. MRI 값은 임의 단위라 비율이나 대비로 쓴다.
- 자료형은 값을 바꿀 수 있다. 실수를 정수에 넣으면 잘리고, 범위를 넘으면 되감기거나 포화된다. 눈금 계수를 무시하면 값이 통째로 틀린다.
- DICOM은 스캐너 형식, NIfTI는 분석의 공용어, GIFTI/CIFTI는 표면과 그레이오디네이트, EDF/BDF/BrainVision/FIF는 전기생리 형식이다. BIDS는 폴더 구조와 JSON 사이드카로 메타데이터를 기계가 읽게 한다.
- 4×4 아핀 행렬이 복셀 좌표 (i, j, k) 를 세계 좌표 (x, y, z) mm로 보낸다. 왼쪽 위 3×3 은 크기·회전·뒤집기, 오른쪽 열은 평행이동이다. 행렬식이 음수면 축 하나가 거울상이다.
- NIfTI는 RAS, DICOM과 ITK 계열은 LPS를 쓴다. 신경과 관례와 방사선과 관례는 표시의 차이일 뿐이고, 진짜 위험은 배열과 헤더가 어긋날 때다.
- 탈라이라크와 MNI는 다른 공간이고 MNI152도 여러 버전이다. 좌표는 공간과 템플릿 버전을 함께 보고한다. 두 공간의 차이는 수 mm에서 1 cm 가까이이다.
- 아틀라스 선택(해부/기능, 영역 수, 확률 문턱)은 ROI 값과 네트워크 지표를 바꾸는 분석 결정이다.
- 공유 전 헤더 익명화와 얼굴 제거, 강건한 기준의 품질 점검, 원자료 보존과 버전 기록이 재현 가능한 분석의 바닥이다.

방법 절 점검표

방법 절 점검표

- 원자료를 무엇으로 변환했는가(DICOM → NIfTI 변환 도구와 버전)? 슬라이스 시각, 위상 부호화 방향 같은 메타데이터를 어디서 얻었는가?
- 데이터가 BIDS로 정리되었는가? 공개되었다면 어디에, 얼굴 제거를 했는가?
- 좌우 방향을 어떻게 확인했는가? 그림의 표시 관례(신경과/방사선과)가 적혀 있는가?
- 보고한 좌표는 어느 공간인가? MNI라면 어떤 템플릿 버전인가?
- ROI나 노드를 어떤 아틀라스로 정했는가? 확률 아틀라스라면 문턱은 얼마인가? 그 선택은 자료를 보기 전에 정해졌는가?
- 품질 점검 지표와 제외 기준은 무엇이고, 집단별로 몇 명이 빠졌는가?
- 소프트웨어, 템플릿, 아틀라스의 이름과 버전, 바꾼 기본 설정이 모두 적혀 있는가?

확인 문제

확인 문제

- 1 mm 등방성, $176 \times 256 \times 256$ T1 영상을 int16과 float32로 저장하면 각각 몇 MB인가?
- 범위가 0-4095인 int16 영상을 어떤 도구가 uint8로 바꿔 저장했다. 값 1000인 복셀은 몇이 되는가 (되감김을 가정)? 이런 사고를 막는 헤더 항목은 무엇인가?
- 아핀 행렬이 $M = \text{diag}(3, 3, 3.3)$, $t = (-96, -96, -60)$ 인 fMRI 볼륨에서 복셀 (32, 40, 18)의 세계 좌표는? 이 영상의 축 방향 글자와 행렬식의 부호는?
- ITK 계열 도구가 보고한 점 (20, -15, 40)(LPS)의 RAS 좌표는? 이 점은 어느 반구에 있는가?
- 한 집단 연구에서 30명 중 6명의 영상이 좌우가 뒤집힌 채 분석되었다. 왼쪽 우세 효과(모두 $LI = 0.5$ 라 하자)의 집단 평균 LI는 얼마가 되는가?
- 탈라이라크 아틀라스에서 이름을 찾으려고 MNI 좌표 (20, -62, -30)을 그대로 넣었다. 왜 문제인가? [그림 1.6](#) 을 근거로 오차의 크기를 말하라.
- [그림 1.7](#) 에서 (나)의 영역 평균이 0 근처로 떨어진 이유를 설명하고, 이런 문제를 줄이는 방법을 두 가지 들어라.

확인 문제 풀이

확인 문제 풀이

1. 복셀 수는 $176 \times 256 \times 256 = 1.15 \times 10^7$ 개다. int16이면 약 23 MB, float32면 약 46 MB다.
2. $1000 = 3 \times 256 + 232$ 이므로 232가 된다. 255보다 큰 값은 모두 이렇게 되감겨 영상이 띠무늬가 된다. 헤더의 datatype과 눈금 계수(scl_slope, scl_inter)를 써서 넓은 범위를 정수에 담거나, 처음부터 형식을 바꾸지 않아야 한다.
3. $x = 3 \times 32 - 96 = 0$, $y = 3 \times 40 - 96 = 24$, $z = 3.3 \times 18 - 60 = -0.6$ mm다. 대각선이 모두 양수이므로 축 방향은 RAS이고 행렬식은 양수($3 \times 3 \times 3.3 = 29.7$)다. 복셀 부피가 29.7 mm^3 라는 뜻이기도 하다.
4. $(-20, 15, 40)_{\text{RAS}}$ 다. x 가 음수이므로 왼쪽 반구다. LPS 좌표의 $x = 20$ 을 RAS로 착각하면 오른쪽 반구로 잘못 읽는다.
5. 24명은 0.5, 6명은 -0.5이므로 평균은 $(24 \times 0.5 - 6 \times 0.5)/30 = 0.3$ 이다. 효과가 40% 줄어든다. 사이트 하나 전체가 뒤집히면 더 심하다.
6. MNI 뇌가 탈라이라크 뇌보다 커서 같은 숫자가 다른 해부 위치를 가리킨다. 소뇌 좌표 (20, -62, -30)은 근사 변환으로 약 (19.8, -61.3, -22.2)가 되어 7.9 mm 어긋난다. AC 아래와 뇌 가장자리는 어긋남이 크다. 변환을 쓰거나, 처음부터 MNI 공간에 만든 아틀라스를 쓴다.
7. 격자를 옮기면 경계가 효과 중심을 지나 효과가 네 영역으로 나뉜다. 각 영역에는 효과의 4분의 1만 남고, 효과가 없는 넓은 부분과 평균되어 잡음 수준이 된다. 줄이는 방법: 질문에 맞는 해상도의 아틀라스를 미리 고른다. 독립 자료(국소화기 과제)로 개인별 기능 ROI를 정한다(6장). 여러 아틀라스로 민감도 분석을 해 결과가 유지되는지 보고한다.

다음 장으로

이 장에서는 데이터가 어떤 모양으로 저장되고, 배열의 칸이 머리의 어디에 놓이는지를 정했다. 이제 그 숫자들로 판단을 내려야 한다. 2장에서는 영상 분석에 필요한 통계를 다시 본다. 측정의 신뢰도, p값과 검정력, 효과 크기, 그리고 이후 모든 장의 뼈대가 될 일반 선형 모형을 그림으로 먼저 이해한다.

2장 영상 분석을 위한 통계 다시 보기

이 장에서 배울 것 측정 신뢰도(ICC)와 잡음, p값과 1종·2종 오류와 검정력, 효과 크기와 신뢰 구간, 일반 선형 모형(GLM)을 투영으로 보는 기하, 반복 측정과 혼합 효과 모형, 그리고 베이지 관점으로 귀무 결과를 읽는 법. 뇌 연구자에게 왜 필요한가 5장의 fMRI 분석, 3장의 형태 분석, 10장의 ERP 통계는 모두 같은 GLM 위에 서 있다. 6장의 다중비교 보정과 13장의 재현성 논쟁도 이 장의 p값과 검정력이 무엇인지 알아야 따라갈 수 있다. 정식 증명과 분포 이론은 수학 시리즈에 맡기고, 여기서는 합성 데이터로 직관을 세운다.

📌 중고등 복습: 평균, 분산, 정규분포

값 n 개의 **평균(mean)** $\bar{x}$ 는 합을 n 으로 나눈 것이다. 각 값이 평균에서 떨어진 거리를 제곱해 평균한 것이 **분산(variance)** 이고, 그 제곱근이 **표준편차(standard deviation, SD)** 다. 표본에서 분산을 구할 때는 n 대신 $n - 1$ 로 나눈다. 많은 작은 요인이 더해져 생기는 값은 종 모양의 **정규분포(normal distribution)** 를 따른다. 평균 ± 1 SD 안에 약 68 %, ± 2 SD(정확히는 1.96 SD) 안에 약 95 %가 들어간다. 표본 평균도 표본마다 흔들린다. 그 흔들림의 표준편차가 **표준오차(standard error, SE)** 이고, $SE = s/\sqrt{n}$ 이다. 물리 2권 7장에서 시행을 N 번 평균하면 잡음이 $1/\sqrt{N}$ 로 준다고 한 것과 같은 규칙이다. 두 변수가 함께 움직이는 정도는 **상관계수(correlation coefficient)** r 로 잰다. -1 에서 $+1$ 사이 값이고, r^2 은 한 변수의 분산 가운데 다른 변수로 설명되는 비율이다.

2.1 표본, 모집단, 잡음

우리가 재는 것은 참값 + 오차다

연구에서 알고 싶은 것은 **모집단(population)**의 성질이다. 예를 들어 "경도 인지장애 환자의 해마 부피는 정상인보다 작은가"다. 실제로 재는 것은 그 가운데 뽑힌 **표본(sample)**이다. 표본의 평균은 모집단 평균의 추정값이고, 표본을 다시 뽑으면 달라진다.

여기에 측정 잡음이 더해진다. 한 사람의 해마 부피를 오늘과 다음 주에 재면 같은 값이 나오지 않는다. 분할 알고리즘의 흔들림, 머리 위치, 수분 상태가 매번 다르다. 그래서 측정값은 대략 이렇게 쓸 수 있다.

$$\text{측정값}_{ij} = \text{참값}_i + \text{오차}_{ij}$$

i 는 사람, j 는 측정 회차다. 참값의 분산 σ_b^2 (사람 사이, between)과 오차의 분산 σ_w^2 (사람 안, within)이 이 장 전체에서 되풀이해 나온다.

신뢰도: 급내 상관계수

사람 사이 차이를 연구하려면 측정이 사람을 일관되게 줄 세워야 한다. 이 정도를 재는 지표가 **급내 상관계수(intraclass correlation coefficient, ICC)**다. 가장 단순한 꼴은 전체 분산 가운데 사람 사이 분산의 몫이다.

$$ICC = \frac{\sigma_b^2}{\sigma_b^2 + \sigma_w^2}$$

ICC가 1이면 두 회차의 값이 같은 선 위에 놓이고, 0이면 회차마다 줄 세운 순서가 제멋대로다(그림 2.1). 흔히 0.5 아래를 낮음, 0.75 위를 좋음, 0.9 위를 매우 좋음으로 읽는다. ICC에는 여러 꼴이 있다. 회차 사이의 체계적 차이(예: 두 번째 스캔이 늘 조금 크다)를 오차로 칠지에 따라 "일치도"와 "일관도"가 갈린다. 논문이 어떤 꼴(ICC(2,1), ICC(3,1) 등)을 썼는지 확인해야 한다.




그림 2.1 같은 40명을 두 번 잰 합성 데이터. (가) 사람 사이 표준편차 0.30, 측정 오차 0.10이면 점이 대각선에 붙는다 (ICC 0.90). (나) 사람 사이 차이는 같은데 오차가 0.40이면 1회차에 높던 사람이 2회차에 낮게 나오기 일쑤다(ICC 0.36). 집단 평균은 두 경우 모두 똑같이 잘 추정된다.

캡션의 마지막 문장이 중요하다. ICC가 낮아도 집단 평균은 정확히 잴 수 있다. 오차는 사람마다 위아래로 흩어져 평균에서 지워지기 때문이다. 낮은 신뢰도가 망가뜨리는 것은 **개인 차이** 연구다. 측정값과 행동 점수의 상관은 두 측정의 신뢰도만큼 깎인다. 이를 **감쇠(attenuation)** 라 한다.

$$r_{\text{관측}} = r_{\text{참}} \sqrt{\text{신뢰도}_1 \times \text{신뢰도}_2}$$

예제 2.1 신뢰도가 상관을 얼마나 깎는가

과제 fMRI의 편도체 β 값이 사람 사이 표준편차 0.3 %, 회차 사이 오차 표준편차 0.4 %를 가진다. 불안 척도의 검사-재검사 신뢰도는 0.8이다. (가) β 값의 ICC는? (나) 참 상관이 0.5라면 기대되는 관측 상관은? (다) 양측 $\alpha = 0.05$, 검정력 80 %로 상관을 찾으려면 참 상관 0.5일 때와 관측 상관일 때 각각 몇 명이 필요한가 (피셔 z 근사)?

풀이 (가) $0.09 / (0.09 + 0.16) = 0.36$ 이다. (나) $0.5 \times \sqrt{0.36 \times 0.8} \approx 0.27$ 이다. 참 상관의 절반 남짓만 보인다. (다) 필요한 표본은 $n \approx [(1.96 + 0.84) / \text{atanh}(r)]^2 + 3$ 이다. $r = 0.5$ 이면 약 29명, $r = 0.27$ 이면 약 107명이다. 신뢰도가 낮은 측정 하나 때문에 필요한 표본이 네 배 가까이 는다.

🧠 뇌로 가는 다리: 과제 fMRI의 낮은 신뢰도

엘리엇(Elliott) 연구진은 2020년 메타분석에서 흔히 쓰는 과제 fMRI 지표의 검사-재검사 ICC가 평균 약 0.4라고 보고했다. 휴지기 기능 연결의 개별 연결(엣지)도 평균 ICC가 약 0.3 수준으로 낮다는 보고가 있다(Noble 외 2019, 7장). 반면 T1 영상의 피질 두께나 피질하 부피는 같은 스캐너에서 대개 0.9를 넘는다(3장). 과제 fMRI는 "이 과제가 이 영역을 활성화하는가"라는 집단 질문에는 강하지만, "활성화가 큰 사람이 증상도 심한가"라는 개인 차이 질문에는 약하다. 개인 차이 연구를 설계한다면 스캔 시간을 늘리거나(회차 평균은 σ_w^2 를 줄인다), 신뢰도가 확인된 지표를 고르거나, 13장의 대규모 표본으로 가야 한다.

신호 대 잡음

영상 분야에서는 같은 생각을 **신호 대 잡음비(SNR)** 로도 쓴다. 물리 2권 10장의 tSNR은 한 복셀 시계열의 평균을 시간 방향 표준편차로 나눈 값이었다. 1 % BOLD 변화를 tSNR 100인 복셀에서 찾는 것은 효과 크기 1(1 % ÷ 1 %)짜리 차이를 시점마다 한 번씩 재는 것과 같다. 통계에서 말하는 효과 크기와 영상에서 말하는 SNR은 같은 비율의 다른 이름이다(2.3절).

2.2 가설 검정과 p값

p값의 뜻

귀무가설(null hypothesis) H_0 은 "효과가 없다"는 가정이다. 검정 통계량(예: t)을 계산하고, H_0 가 참이라면 이만큼 또는 이보다 극단적인 값이 나올 확률을 구한다. 이것이 **p값**이다. p값은 "효과가 없다는 가정 아래에서 데이터가 얼마나 놀라운가"를 잴다. "효과가 없을 확률"이 아니다.

H_0 가 참이면 p값은 0과 1 사이에 고르게 퍼진다(그림 2.2 가). 그래서 문턱 $\alpha = 0.05$ 를 쓰면 효과가 없는데도 5 %에서 "유의하다"고 판정한다. 이것이 **1종 오류(type I error)**의 비율이다. 효과가 있는데 놓치는 것은 **2종 오류(type II error)**이고, 그 비율을 β 라 쓴다. 효과가 있을 때 잡아낼 확률 $1 - \beta$ 가 **검정력(power)**이다.




그림 2.2 두 집단 t 검정을 1만 번 되풀이했을 때 p값의 분포. 빨간 막대가 $p < 0.05$ 구간이다. (가) 효과가 없으면 p값은 고르게 퍼져 어느 구간이든 5 %씩이다. (나) 참 효과 $d = 0.5$, 집단당 20명이면 p값이 0 쪽으로 몰리지만 유의한 것은 약 34 %뿐이다. (다) 집단당 64명이면 약 80 %가 유의하다.

이 그림을 만드는 코드는 짧다. 귀무가설 쪽은 $d = 0$ 으로 바꾸면 된다.

```
import numpy as np
from scipy import stats

rng = np.random.default_rng(0)
n, d, reps = 20, 0.5, 10000 # 집단당 표본 수, 참 효과 크기, 되풀이 횟수
a = rng.normal(0, 1, (reps, n)) # 대조군
b = rng.normal(d, 1, (reps, n)) # 환자군 (평균이 d만큼 다르다)
p = stats.ttest_ind(a, b, axis=1).pvalue
print("검정력:", (p < 0.05).mean()) # 약 0.34
```

이 사실 하나가 6장 다중비교의 출발점이다. 복셀 10만 개가 모두 귀무가설을 따르면, 보정 없이 $p < 0.05$ 를 쓸 때 약 5000개 복셀이 우연히 "활성화"된다.

검정력은 표본 수와 효과 크기로 정해진다

검정력은 세 가지에 달려 있다. 효과 크기, 표본 수, 문턱 α 다. 두 집단 비교에서 Cohen의 관례인 작은 (0.2), 중간(0.5), 큰(0.8) 효과에 검정력 80 %를 얻으려면 집단당 각각 394명, 64명, 26명이 필요하다 (그림 2.3 가). 한 집단 설계(예: 과제 대 기저선의 집단 활성화)라면 199명, 34명, 15명이다. 계산은 G*Power나 statsmodels, 또는 위 코드 같은 모의 실험으로 한다.




그림 2.3 (가) 두 집단 t 검정(양측 $\alpha = 0.05$)의 검정력과 집단당 표본 수. 점은 검정력 80 %에 이르는 지점이다. (나) 참 효과 $d = 0.5$ 일 때, 유의한 결과만 모아 효과 크기를 평균하면(빨강) 표본이 작을수록 참값보다 크게 나온다. 모든 결과의 평균(파랑)은 참값 근처에 있다.

검정력이 낮을 때의 문제는 효과를 놓치는 데서 끝나지 않는다. 낮은 검정력 아래에서 우연히 문턱을 넘은 결과는 대개 잡음이 효과 쪽으로 쏠린 경우다. 그래서 유의한 결과의 효과 크기는 부풀려진다(그림 2.3 나). 참 효과 0.5를 집단당 20명으로 연구하면, 유의한 연구만의 평균 효과 크기는 약 0.87이다. 이를 **승자의 저주(winner's curse)**라 한다. 후속 연구가 처음 보고한 효과를 재현하지 못하는 흔한 이유다.

예제 2.2 유의한 결과가 참일 확률

어떤 분야에서 검정하는 가설의 25 %가 실제로 참이라고 하자. $\alpha = 0.05$ 일 때 (가) 검정력이 20 %인 연구와 (나) 80 %인 연구에서, 유의한 결과가 실제로 참일 확률(양성 예측도)은 각각 얼마인가?

풀이 가설 100개 가운데 참이 25개, 거짓이 75개다. 거짓 75개에서 $75 \times 0.05 = 3.75$ 개가 우연히 유의하다. (가) 참 25개 중 $25 \times 0.2 = 5$ 개만 잡힌다. 유의한 결과 8.75개 중 참은 5개, 약 57 %다. (나) $25 \times 0.8 = 20$ 개가 잡혀 $20/23.75 \approx 84$ %다. 같은 $p < 0.05$ 라도 검정력이 낮은 분야의 결과는 믿을 만한 정도가 다르다.

🧠 뇌로 가는 다리: 신경과학의 검정력

버튼(Button) 연구진은 2013년 신경과학 메타분석들을 모아 연구들의 검정력 중앙값을 약 21 %로 추정했다. 2000년대 fMRI 연구는 집단당 10-20명이 흔했다. [그림 2.3](#)에 따르면 집단당 15명으로 $d = 0.5$ 인 집단 차이를 찾을 검정력은 약 26 %다. 이런 연구에서 "환자군에서 전전두 활성화가 감소했다"는 결과가 나왔다면, 효과 크기는 실제보다 클 가능성이 높고 재현될 확률은 낮다. 뇌와 행동의 개인 차이 상관은 대개 이보다 훨씬 작아서, 수천 명이 필요하다는 분석도 있다(13장).

흔한 오해: $p = 0.03$ 이면 가설이 참일 확률이 97 %다

p 값은 H_0 가 참이라는 가정 아래에서 계산한 데이터의 확률이다. 가설이 참일 확률은 예제 2.2처럼 사전 확률과 검정력에 달려 있어 p 값만으로는 알 수 없다. 비슷한 오해가 몇 가지 더 있다.

- " $p > 0.05$ 이므로 효과가 없다." 유의하지 않음은 증거가 부족하다는 뜻이다. 효과가 없다는 증거가 되려면 신뢰 구간이 좁거나(2.3절) 베이지 인자가 귀무 쪽을 가리켜야 한다(2.6절).
- "A 영역은 유의하고 B 영역은 유의하지 않으므로 A와 B가 다르다." 두 영역의 차이를 직접 검정해야 한다. $p = 0.04$ 와 $p = 0.06$ 은 거의 같은 결과다. 니우엔하위스(Nieuwenhuis) 연구진은 2011년 이런 비교가 필요했던 신경과학 논문의 약 절반이 잘못된 방식을 썼다고 보고했다. 환자군에서만 유의하고 대조군에서는 유의하지 않다는 것도 집단 $\times$ 조건 상호작용의 증거가 아니다.
- " p 값이 작을수록 효과가 크다." p 값은 효과 크기와 표본 수를 함께 반영한다. 1만 명이면 아주 작은 효과도 $p < 10^{-10}$ 이 된다.

2.3 효과 크기와 신뢰 구간

Cohen의 d

효과 크기(effect size)는 차이의 크기를 잡음 단위로 잰다. 가장 흔한 것은 평균 차이를 표준편차로 나눈 Cohen의 d 다.

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s}$$

s 는 두 집단을 합친 표준편차다. $d = 0.5$ 는 두 분포의 평균이 표준편차의 절반만큼 떨어져 있다는 뜻이다. 이때도 두 분포는 대부분 겹친다. 한 집단 설계에서는 $d = \bar{x}/s$ 이고, t 값과 $d = t/\sqrt{n}$ 의 관계가 있다. 표본이

커지면 t 는 계속 커지지만 d 는 참값 근처에 머문다. 그래서 d 가 연구 사이 비교와 검정력 계산에 쓰인다.

신뢰 구간

신뢰 구간(confidence interval, CI) 은 추정값이 얼마나 흔들릴 수 있는지를 범위로 보여 준다. 평균의 95 % 신뢰 구간은 대략 $\bar{x} \pm t_{0.975} \times SE$ 다. 해석에는 주의가 필요하다. 같은 실험을 많이 되풀이해 구간을 매번 만들면, 그 구간들의 95 %가 참값을 덮는다(그림 2.4). 이미 얻은 구간 하나가 참값을 포함할 확률이 95 %라는 뜻은 엄밀히는 아니다(그 해석은 2.6절의 베이지 신용 구간에 가깝다).




그림 2.4 같은 실험(25명, 참 평균 0.5 % 신호 변화, 사람 사이 표준편차 0.6 %)을 30번 되풀이해 얻은 95 % 신뢰 구간. 구간의 위치와 폭이 실험마다 달라지고, 대략 20번에 한 번꼴로 참값(점선)을 놓친다(빨강). 0을 덮지 않는 구간은 $p < 0.05$ 인 실험과 같다.

신뢰 구간은 p 값이 주는 정보를 모두 담고 더 많은 것을 준다. 95 % 구간이 0을 덮지 않으면 $p < 0.05$ 다. 구간이 0을 덮더라도 그 폭이 "의미 있는 효과가 없다"고 말할 만큼 좁은지 볼 수 있다.

영상에서의 효과 크기: % 신호 변화

fMRI의 β 값은 단위가 제각각이다. 스캐너 강도의 임의의 단위에, 소프트웨어마다 다른 전체 평균 척도화(SPM은 100, FSL은 10000 근처로 맞춘다)와 회귀자 높이가 곱해진다. 그래서 β 를 기저 신호에 대한 백분율로 바꾼 **% 신호 변화(percent signal change)** 를 보고한다. 계산은 " $\beta \times$ 회귀자 높이 $\div$ 기저 신호 $\times 100$ "이다. 회귀자의 높이가 사건 길이와 HRF 정규화 방식에 따라 달라지므로(5장), 같은 데이터라도 정의에 따라 값이 다르다. 논문을 비교할 때는 어떤 회귀자 기준인지 확인한다.

예제 2.3 % 신호 변화에서 d 와 신뢰 구간까지

25명의 일차 시각 피질에서 과제 대 기저선 반응을 잴다. 평균 0.5 %, 사람 사이 표준편차 0.6 %다. (가) 한 집단 d 와 t 는? (나) 95 % 신뢰 구간은? (다) 다른 연구가 25명에서 $t = 4.0$ 만 보고했다면 d 는?

풀이 (가) $d = 0.5/0.6 \approx 0.83$ 이다. $SE = 0.6/\sqrt{25} = 0.12$ %이므로 $t = 0.5/0.12 \approx 4.17$ 이다. (나) 자유도 24에서 $t_{0.975} \approx 2.064$ 다. $0.5 \pm 2.064 \times 0.12$, 곧 약 0.25-0.75 %다. (다) $d = 4.0/\sqrt{25} = 0.8$ 이다. 다만 뇌 전체에서 가장 높은 복셀의 t 로 계산한 d 는 승자의 저주로 부풀려져 있다. 6장의 순환성 문제와 같은 뿌리다.

2.4 일반 선형 모형의 기하

하나의 틀

t 검정, 분산분석, 상관, 회귀, 공분산분석은 모두 **일반 선형 모형(general linear model, GLM)**의 특수한 경우다. 데이터 벡터 $\mathbf{y}$ 를 몇 개의 설명 변수의 가중합과 오차로 쓴다.

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$$

$\mathbf{y}$ 는 관측 n 개를 세운 열 벡터다. fMRI 1수준 분석이면 한 복셀의 시계열이고, 집단 분석이면 사람마다의 대비 값이다. $\mathbf{X}$ 는 **설계 행렬(design matrix)**이다. 열 하나가 회귀자 하나이고, 행 하나가 관측 하나다. $\boldsymbol{\beta}$ 는 각 회귀자의 가중치, $\mathbf{e}$ 는 모형이 설명하지 못한 잔차다.

적합은 투영이다

최소제곱(least squares)은 잔차 제곱합 $\|\mathbf{e}\|^2$ 을 가장 작게 하는 $\boldsymbol{\beta}$ 를 고른다. 답은 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 다. 이 식보다 그림이 더 많은 것을 말한다(그림 2.5).

관측이 n 개면 $\mathbf{y}$ 는 n 차원 공간의 화살표 하나다. 회귀자도 각각 화살표다. 회귀자들의 가중합으로 만들 수 있는 모든 화살표는 평면(일반적으로 부분공간)을 이룬다. 최소제곱 적합 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 는 $\mathbf{y}$ 에서 그 평면에 수직으로 내린 그림자, 곧 **투영(projection)**이다. 수직일 때 잔차가 가장 짧다. 따라서 잔차는 모든 회귀자와 직교한다. 선형대수의 자세한 내용은 수학 시리즈에서 다룬다.




그림 2.5 (가) 블록 설계 fMRI 시계열의 합성 예. 데이터(파랑)를 상수와 과제 회귀자의 가중합(빨강)으로 적합하고, 남은 것(회색 선)이 잔차다. (나) 같은 적합을 기하로 본 도식. 관측이 n 개면 데이터와 회귀자는 모두 n 차원 공간의 화살표다. 두 회귀자 x_1, x_2 가 펼치는 평면에 데이터 $\mathbf{y}$ 를 수직으로 내린 그림자가 적합값 $\hat{\mathbf{y}}$ 이고, 잔차는 평면에 수직이다.

이 그림에서 두 가지가 바로 나온다. 첫째, 회귀자를 더할수록 평면이 넓어져 잔차가 줄어든다. 의미 없는 회귀자를 더해도 적합은 좋아 보인다. 대신 자유도 $n - p$ (p 는 회귀자 수)가 줄어든다. 둘째, 회귀자 두 개가

거의 같은 방향을 가리키면 평면이 정해지기는 해도 그 안에서 $\hat{\mathbf{y}}$ 를 두 회귀자로 나누는 방식이 불안정하다. 이것이 공선성이다(아래).

대비, t, F

각 회귀자의 β 를 바로 해석하기보다는 **대비(contrast)** 벡터 $\mathbf{c}$ 로 β 의 조합을 묻는다. 조건 A와 B가 있으면 $\mathbf{c} = [1, -1]$ 은 "A - B"다. t 통계량은 그 조합을 표준오차로 나눈 값이다.

$$t = \frac{\mathbf{c}^\top \hat{\boldsymbol{\beta}}}{\sqrt{\hat{\sigma}^2 \mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c}}}$$

$\hat{\sigma}^2$ 은 잔차 제곱합을 자유도 $n - p$ 로 나눈 잔차 분산이다. 분모의 $\mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c}$ 는 설계가 그 질문에 얼마나 효율적인지를 담는다. 같은 잡음이라도 설계에 따라 t가 달라진다. 5장의 설계 효율이 이 항이다.

F 검정은 여러 대비를 한꺼번에 묻는다. "세 조건 중 어디든 차이가 있는가"처럼 방향이 없는 질문이다. 대비가 하나면 $F = t^2$ 이다. 기하로 보면 F는 회귀자 몇 개를 빼서 평면을 좁혔을 때 잔차가 얼마나 늘어나는지를 잔차 분산 단위로 잰다.

예제 2.4 두 조건 대비의 t

한 복셀에서 조건 A와 B의 스캔을 10개씩 얻었다. 설계 행렬은 A 표시 열과 B 표시 열 두 개다(0 또는 1). 추정 결과 $\hat{\beta}_A = 2.0$, $\hat{\beta}_B = 1.0$, 잔차 표준편차 $\hat{\sigma} = 1.0$ 이다. 대비 $[1, -1]$ 의 t와 자유도는?

풀이 두 열이 겹치지 않으므로 $\mathbf{X}^\top \mathbf{X}$ 는 대각 성분이 10, 10인 대각 행렬이다. $\mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c} = 1/10 + 1/10 = 0.2$ 다. $t = 1.0/\sqrt{0.2} \approx 2.24$, 자유도는 $20 - 2 = 18$ 이다. 양측 $p \approx 0.038$ 이다. 각 조건의 스캔을 40개로 늘리면 분모가 절반이 되어 $t \approx 4.5$ 가 된다.

공변량, 공선성, 직교화

집단 분석에는 나이, 성별, 두개 내 부피(TIV, 3장) 같은 **공변량(covariate)**을 넣는다. 공변량을 넣으면 관심 효과는 "공변량을 같게 맞췄을 때의 효과"로 바뀐다. 공변량이 관심 변수와 상관성이 크면 두 회귀자가 같은 변이를 놓고 다툰다. 이것이 **공선성(collinearity)**이다. 상관이 r 인 두 회귀자에서 β 의 분산은 $1/(1 - r^2)$ 배로 커진다. 이 배수를 **분산 팽창 계수(variance inflation factor, VIF)**라 한다. $r = 0.8$ 이면 VIF 약 2.8, $r = 0.9$ 면 약 5.3이고 표준오차는 약 2.3배가 된다(그림 2.6 가).




그림 2.6 (가) 두 회귀자의 상관 r 이 커지면 β 의 표준오차가 $1/\sqrt{1-r^2}$ 배로 커진다. 점은 $n = 100$ 인 모의 실험이다. (나) 직교화의 기하. x_2 에서 x_1 방향 성분(회색 점선 아래의 몫)을 빼면 x_1 에 수직인 회귀자(빨강)가 남는다. 그 공유 몫은 x_1 의 β 로 넘어간다.

공선성의 처방으로 한 회귀자를 다른 회귀자에 대해 **직교화(orthogonalization)** 하는 경우가 있다. 직교화는 공유된 변이를 한쪽에 몰아주는 선택일 뿐 공선성을 "해결"하지 않는다. x_2 를 x_1 에 대해 직교화하면 x_2 의 β 와 t 는 그대로이고 x_1 의 β 만 바뀐다(그림 2.6 나). 공유 몫을 x_1 의 효과로 친 것이다. 이 선택이 연구 질문에 맞는지 설명할 수 없다면 직교화하지 않는 편이 낫다는 지적이 있다(Mumford 외 2015). SPM의 매개 변조 회귀자는 기본 설정에서 순서대로 직교화되므로(5장) 회귀자 순서가 결과를 바꿀 수 있다.

공변량을 **중심화(centering)** 하는 것도 해석을 바꾼다. 나이를 그대로 넣으면 상수항은 "0세의 값"이 되고, 평균 나이를 빼서 넣으면 "평균 나이의 값"이 된다. 집단마다 따로 중심화할지, 전체로 할지에 따라 집단 차이의 뜻도 달라진다.

2.5 반복 측정과 혼합 효과 모형

분산은 두 층에 있다

뇌영상 데이터는 거의 언제나 층을 이룬다. 시행은 사람 안에, 사람은 집단 안에, 때로는 사이트 안에 있다. 2.1절의 사람 안 분산 σ_w^2 과 사람 사이 분산 σ_b^2 이 다시 나온다. 집단 수준 질문("환자는 평균적으로 반응이 작을까")의 표본 단위는 시행이 아니라 사람이다. 시행 2000개를 독립 관측으로 다루면 자유도와 t 가 크게 부풀어 오른다. 이것을 **유사 반복(pseudoreplication)** 이라 한다.

예제 2.5 시행을 독립으로 세면

20명이 각자 시행 100개를 했다. 시행 잡음 표준편차는 1.0, 사람 사이 참 효과의 표준편차는 0.3이다. (가) 사람마다 평균을 낸 뒤 20명으로 계산한 집단 평균의 표준오차는? (나) 시행 2000개를 독립으로 보고 계산한 표준오차는? (다) t는 몇 배 부풀려지는가?

풀이 (가) 개인 평균의 분산은 $0.3^2 + 1.0^2/100 = 0.10$ 이다. 표준오차는 $\sqrt{0.10/20} \approx 0.071$ 이다. (나) 시행 하나의 전체 분산은 $0.09 + 1.0 = 1.09$ 이고, $\sqrt{1.09/2000} \approx 0.023$ 이다. (다) 약 3.0배다. 자유도도 19에서 1999로 부풀어, 같은 효과가 훨씬 유의하게 보인다.

고정 효과와 무작위 효과

혼합 효과 모형(mixed-effects model) 은 두 층의 분산을 함께 모형에 넣는다. **고정 효과(fixed effect)** 는 모든 사람에게 공통인 효과다. 조건 차이, 집단 차이, 나이 효과가 여기에 든다. **무작위 효과(random effect)** 는 사람마다 다른 편차로, 그 편차가 분포(보통 정규분포, 분산 τ^2)를 따른다고 본다. 사람마다 다른 절편(무작위 절편)과 다른 조건 효과(무작위 기울기)를 줄 수 있다.

용어가 헷갈리는 것은 fMRI 분야의 관행 때문이다. 오래된 "고정 효과 집단 분석"은 사람 사이 분산을 무시하고 모든 사람의 데이터를 이어 붙여 분석한다. 그 결론은 "이 표본의 이 사람들에서"로 제한된다. 모집단으로 일반화하려면 사람 사이 분산을 넣는 **무작위 효과 분석**이 필요하다. 개인별 대비 값을 모아 2수준에서 t 검정하는 **요약 통계 방법**이 그 단순한 꼴이고, FSL의 FLAME, AFNI의 3dMEMA는 개인별 추정의 불확실성까지 반영한다(5장). 일반적인 혼합 효과 모형은 R의 lme4, Python의 statsmodels, AFNI의 3dLME 등으로 적합한다.

부분 풀링과 수축

혼합 효과 모형이 개인 효과를 추정하는 방식에는 쓸모 있는 성질이 있다. 각 사람의 추정은 그 사람의 평균과 집단 평균 사이의 가중 평균이 된다.

$$\hat{\theta}_j = w_j \bar{y}_j + (1 - w_j) \hat{\mu}, \quad w_j = \frac{\tau^2}{\tau^2 + \sigma^2/n_j}$$

$\bar{y}_j$ 는 사람 j 의 평균, n_j 는 그 사람의 시행 수, σ^2 은 시행 잡음 분산, $\hat{\mu}$ 는 집단 평균이다. 시행이 많아 개인 평균이 정확하면 w_j 가 1에 가까워 자기 평균을 거의 그대로 쓴다. 시행이 적어 개인 평균이 흔들리면 집단 평균 쪽으로 당겨진다. 이것을 **부분 풀링(partial pooling)** 또는 **수축(shrinkage)** 이라 한다(그림 2.7).




그림 2.7 사람마다 시행 수가 다른 합성 데이터(12명, 시행 4~60개). (가) 개인 평균(파랑)을 혼합 효과 모형으로 추정하면 (빨강) 집단 평균 쪽으로 당겨진다. 점 크기는 시행 수이고, 시행이 적은 사람일수록 많이 당겨진다. (나) 2000번 되풀이한 모의 실험에서 참값과의 오차. 시행이 적은 사람에서 수축 추정의 오차가 뚜렷이 작다.

예제 2.6 얼마나 당겨지는가

사람 사이 표준편차 $\tau = 0.3$, 시행 잡음 표준편차 $\sigma = 1.0$ 이다. 시행이 5개, 10개, 40개인 사람의 가중치 w_j 는? 시행 10개인 사람의 평균이 1.2이고 집단 평균이 0.5라면 수축 추정은?

풀이 $w = 0.09 / (0.09 + 1/n_j)$ 이다. 5개면 약 0.31, 10개면 약 0.47, 40개면 약 0.78이다. 시행 10개인 사람은 $0.47 \times 1.2 + 0.53 \times 0.5 \approx 0.83$ 으로 당겨진다. 이 값은 개인 평균 1.2보다 덜 극단적이지만, 평균적으로는 참값에 더 가깝다.

🧠 뇌로 가는 다리: 환자 데이터는 균형이 맞지 않는다

임상 영상 연구에서는 사람마다 쓸 수 있는 데이터 양이 다르다. 움직임이 큰 환자는 스크러빙(4장) 뒤 남은 시점이 적고, ERP 연구에서는 인공물로 버리는 시행 수가 사람마다 다르며(9장), 종단 연구에서는 방문 횟수가 다르다. 개인 평균을 그대로 2수준에 넣으면 데이터가 적어 흔들리는 사람이 똑같은 무게를 가진다. 혼합 효과 모형은 이런 불균형을 자연스럽게 다루고, 방문이 빠진 사람도 버리지 않는다. 다만 결측이 병의 경과와 관련 있으면(예: 악화된 환자가 추적에서 빠진다) 어떤 모형도 편향을 다 지우지 못한다.

2.6 베이즈 관점 맛보기

사전, 가능도, 사후

베이즈 추론(Bayesian inference) 은 질문을 뒤집는다. "효과가 없다면 이 데이터가 얼마나 놀라운가" 대신 "이 데이터를 보았을 때 효과는 어느 크기일 가능성이 큰가"를 묻는다. 데이터를 보기 전의 믿음을 **사전분포(prior)** 로 쓰고, 데이터가 각 효과 크기를 얼마나 지지하는지(**가능도, likelihood**)를 곱해 **사후분포(posterior)** 를 얻는다. 2.5절의 수축 추정은 사실 이 계산이다. 집단 분포가 각 개인 효과의 사전분포 구실을 한다.

베이즈 인자와 귀무 결과

베이즈 인자(Bayes factor) 는 두 가설이 데이터를 예측한 정도의 비다. BF_{01} 은 "효과 없음"이 "효과 있음"보다 데이터를 몇 배 잘 예측했는지를 말한다. 3보다 크면 귀무가설 쪽 증거가 어느 정도 있다고, 10보다 크면 강하다고 흔히 읽는다. p 값과 달리 귀무가설을 지지하는 증거를 셀 수 있다는 것이 장점이다 (그림 2.8).




그림 2.8 유의하지 않은 두 결과를 베이즈로 읽기. 효과 크기에 사전분포 $N(0, 0.5^2)$ (회색 점선)를 두고 정규 근사로 계산했다. (가) 20명에서 관측 $d = 0.10$: 사후분포가 넓고 BF_{01} 약 2.3으로 어느 쪽 증거도 약하다. (나) 200명에서 관측 $d = 0.05$: 사후분포가 0 근처에 몰리고 BF_{01} 약 5.6이다. 초록 띠는 $|d| < 0.2$ 인 "무시할 만한 효과" 구간이다.

두 결과 모두 $p > 0.4$ 이므로 p 값으로는 둘 다 "유의하지 않음"일 뿐이다. 베이즈 관점에서는 다르다. 20명 연구에서 무시할 만한 효과($|d| < 0.2$)의 사후 확률은 약 63 %여서, 중간 크기의 효과도 아직 배제되지 않는다. 200명 연구에서는 약 98 %다. 사전분포를 바꾸면 수치가 달라지므로, 베이즈 분석은 사전분포를 밝히고 다른 사전분포에서도 결론이 유지되는지(민감도 분석) 함께 보고한다. JASP, R의 BayesFactor 같은 도구가 있다. SPM의 사후 확률 지도와 DCM(7장)도 베이즈 틀을 쓴다.

빈도주의 쪽에도 귀무 결과를 다루는 도구가 있다. **동등성 검정(equivalence test)** 은 "효과가 미리 정한 구간(예: $|d| < 0.2$) 안에 있다"를 대립가설로 놓고 검정한다. 신뢰 구간 전체가 그 구간 안에 들어오면 동등하다고 판정한다. 어느 쪽이든 핵심은 같다. "차이가 없다"고 말하려면 그것을 보이는 분석을 따로 해야 한다.

🧠 뇌로 가는 다리: '해마 부피에 차이가 없었다'

임상 영상 논문에는 "두 집단의 해마 부피에 유의한 차이가 없었다"는 문장이 흔하고, 이것이 "이 질환은 해마를 침범하지 않는다"로 인용되곤 한다. 집단당 20명이라면 그림 2.3 에서 $d = 0.5$ 인 차이를 찾을 검정력은 약 34 %다. 이 결과는 해마 위축이 없다는 증거라기보다 연구가 그것을 볼 수 없었다는 기록이다. 신뢰 구간(예: d 가 $-0.3-0.9$), 베이즈 인자, 또는 동등성 검정을 함께 보고해야 귀무 결과가 정보가 된다.

핵심 정리

핵심 정리

- 측정값은 참값 + 오차다. $ICC = \sigma_b^2 / (\sigma_b^2 + \sigma_w^2)$ 는 측정이 사람을 일관되게 줄 세우는 정도다. 과제 fMRI 지표의 ICC는 평균 약 0.4로 낮고, 구조 지표는 대개 0.9를 넘는다.
- 낮은 신뢰도는 집단 평균보다 개인 차이 연구를 망가뜨린다. 관측 상관은 $\sqrt{\text{신뢰도}_1 \times \text{신뢰도}_2}$ 배로 깎이고, 필요한 표본은 크게 늘어난다.
- p값은 귀무가설 아래에서 데이터가 얼마나 극단적인지를 잴다. 귀무가설이 참이면 p값은 고르게 퍼지며, 효과가 있을 때 $p < \alpha$ 인 비율이 검정력이다.
- 두 집단 비교에서 검정력 80 %에는 $d = 0.2, 0.5, 0.8$ 에 대해 집단당 약 394, 64, 26명이 필요하다. 검정력이 낮으면 유의한 효과가 부풀려지고(승자의 저주) 유의한 결과가 참일 확률도 낮다.
- 효과 크기(d , % 신호 변화)와 신뢰 구간을 함께 보고한다. "유의 대 비유의"는 차이의 증거가 아니며, 차이를 직접 검정해야 한다.
- GLM $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ 의 최소제곱 적합은 데이터를 설계 행렬이 펼치는 공간에 투영한 것이다. 대비 $\mathbf{t}$ 의 분모에는 잡음과 함께 설계 효율 $\mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c}$ 가 들어 있다.
- 공선성은 β 의 분산을 $VIF = 1/(1 - r^2)$ 배로 키운다. 직교화는 공유 변수를 한쪽에 몰아줄 뿐 해결책이 아니다.
- 반복 측정 데이터의 표본 단위는 사람이다. 시행을 독립 관측으로 세면 t 가 부풀려진다. 혼합 효과 모형은 사람 안·사람 사이 분산을 함께 다루고, 데이터가 적은 사람의 추정을 집단 평균 쪽으로 수축시킨다.
- 베이지 인자와 동등성 검정은 "효과가 없다"는 주장을 검정할 수 있게 한다. 유의하지 않은 결과만으로는 효과가 없다고 말할 수 없다.

방법 절 점검표

방법 절 점검표

- 표본 수의 근거가 있는가? 사전 검정력 분석이라면 어떤 효과 크기를 가정했고, 그 값은 어디서 왔는가 (작은 선행 연구의 부풀려진 효과는 아닌가)?
- 주된 지표의 신뢰도(ICC)가 알려져 있는가? 개인 차이나 상관을 주장하는 연구라면 특히 확인한다.
- 효과 크기와 신뢰 구간을 보고했는가? % 신호 변화라면 어떤 회귀자 기준으로 계산했는가?
- 설계 행렬에 무엇이 들어갔는가? 공변량의 선택 근거, 중심화 방식, 회귀자 사이 상관(VIF), 직교화 여부와 순서를 밝혔는가?
- 집단 추론이 사람을 표본 단위로 하는가(무작위 효과)? 시행이나 스캔을 독립 관측으로 센 곳은 없는가?
- "A에서는 유의, B에서는 비유의"를 차이의 증거로 쓰지 않았는가? 집단 $\times$ 조건 상호작용을 직접 검정했는가?
- 귀무 결과를 "차이 없음"으로 해석했다면 검정력, 신뢰 구간, 베이지 인자 또는 동등성 검정으로 뒷받침했는가?
- 혼합 효과 모형이라면 무작위 효과 구조(절편만인가, 기울기도인가)와 사용한 소프트웨어를 밝혔는가?

확인 문제

확인 문제

1. 피질 두께의 사람 사이 표준편차가 0.15 mm, 반복 측정 오차의 표준편차가 0.05 mm다. ICC는 얼마인가? 이 지표와 ICC 0.4인 과제 fMRI 지표 중 어느 것이 같은 행동 점수와 더 큰 관측 상관을 보이겠는가(참 상관이 같다고 가정)?
2. 귀무가설이 참인 복셀 5만 개에서 보정 없이 $p < 0.001$ 을 쓰면 몇 개가 우연히 유의하게 나오는가? 이것이 6장의 문제와 어떻게 이어지는가?
3. 한 집단 설계에서 $d = 0.5$ 인 효과를 검정력 80 %로 찾으려면 약 몇 명이 필요한가? 두 집단 비교에서 같은 효과라면 전체 몇 명이 필요한가?
4. 어떤 분야에서 가설의 10 %가 참이고 연구들의 검정력이 30 %다($\alpha = 0.05$). 유의한 결과가 참일 확률은 얼마인가?
5. 한 집단 연구 16명에서 $t = 3.2$ 를 보고했다. d 는 얼마인가? 이 값이 뇌 전체에서 고른 피크 복셀의 값이라면 왜 조심해야 하는가?
6. 과제 회귀자와 반응 시간 회귀자의 상관이 0.7이다. VIF와 표준오차 배수는? 반응 시간 회귀자를 과제 회귀자에 대해 직교화하면 어느 회귀자의 β 가 바뀌는가?
7. 사람 사이 표준편차 0.3, 시행 잡음 표준편차 1.0일 때 시행 20개인 사람의 수축 가중치 w 는? 개인 평균 0.0, 집단 평균 0.5라면 수축 추정은?
8. 한 논문이 "환자군 15명과 대조군 15명 사이에 편도체 반응 차이가 없었다($p = 0.4$)"고 썼다. 이 결론을 받아들이기 전에 무엇을 더 보아야 하는가?

확인 문제 풀이

확인 문제 풀이

1. $0.0225/(0.0225 + 0.0025) = 0.9$ 다. 행동 점수의 신뢰도를 R 이라 하면 관측 상관은 $r_{\text{참}}\sqrt{0.9R}$ 대 $r_{\text{참}}\sqrt{0.4R}$ 이므로 피질 두께 쪽이 $\sqrt{0.9/0.4} = 1.5$ 배 크다.
2. $50000 \times 0.001 = 50$ 개다. 문턱을 낮춰도 검정 수가 많으면 우연한 양성이 수십 개 남는다. 6장의 FWE·FDR 보정과 군집 추론은 이 수를 통제하는 방법이다.
3. 한 집단 설계는 약 34명이다. 두 집단은 집단당 64명, 전체 128명이다. 두 집단 비교는 두 평균이 모두 흔들리므로 표본이 훨씬 많이 든다.
4. 가설 100개 중 참 10개에서 3개, 거짓 90개에서 4.5개가 유의하다. $3/7.5 = 40\%$ 다. 유의한 결과의 절반 넘게가 거짓 양성이다.
5. $d = 3.2/\sqrt{16} = 0.8$ 이다. 수많은 복셀 중 가장 큰 값을 골랐으므로 잡음이 효과 쪽으로 쏠린 값일 가능성이 크다(승자의 저주, 순환성). 독립 데이터나 미리 정한 ROI에서 다시 재야 한다(6장).
6. $VIF = 1/(1 - 0.49) \approx 1.96$, 표준오차는 약 1.4배다. 반응 시간 회귀자를 과제 회귀자에 대해 직교화하면 반응 시간 회귀자의 β 는 그대로이고, 공유 몫을 넘겨받은 과제 회귀자의 β 가 바뀐다.
7. $w = 0.09/(0.09 + 1/20) = 0.09/0.14 \approx 0.64$ 다. 수축 추정치는 $0.64 \times 0.0 + 0.36 \times 0.5 \approx 0.18$ 이다.
8. 집단당 15명이면 $d = 0.5$ 에 대한 검정력이 약 26%에 불과하다. 효과 크기와 신뢰 구간(상당히 큰 차이까지 덮을 가능성이 크다), 베이지 인자나 동등성 검정, 사전 검정력 분석의 근거를 보아야 한다. 그것이 없다면 "차이를 찾지 못했다"로 읽는다.

다음 장으로

이 장에서는 영상 분석의 통계가 서 있는 땅을 다졌다. 측정은 참값과 오차의 합이고, p값과 검정력은 표본 수와 효과 크기에 묶여 있으며, 거의 모든 분석은 데이터를 설계 행렬의 공간에 투영하는 GLM이고, 반복 측정은 두 층의 분산으로 다룬다. 이제 이 도구를 실제 영상에 적용한다. 3장에서는 구조 MRI에서 출발한다. T1 영상의 편향장을 고치고, 회백질과 백질을 나누고, 개인의 뇌를 표준 공간에 맞추는 뒤, 복셀과 피질 표면마다 GLM을 세워 집단 차이를 묻는다. 여기서 본 TIV 공변량, 신뢰도, 표본 크기의 문제가 거기서 구체적인 숫자로 다시 나온다.

3장 구조 MRI 분석

이 장에서 배울 것 T1 강조 영상 한 장이 회백질 부피 지도와 피질 두께 지도가 되기까지의 단계를 순서대로 따라간다. 편향장 보정, 두개골 제거, 혼합 가우스 모형을 이용한 조직 분할, 정합과 비용 함수, 복셀 기반 형태 분석(VBM), 표면 기반 피질 두께, 피질하 구조와 종단 분석, 그리고 움직임과 스캐너 차이라는 혼입 요인을 다룬다. 뇌 연구자에게 왜 필요한가 "회백질 부피가 줄었다", "피질이 얇아졌다"는 결론은 측정값이 아니라 여러 모형을 거친 추정값이다. 각 단계의 가정이 어디서 깨지는지 알아야 위축과 인공물을 구별할 수 있다. 이 장의 분할과 정합은 4장 이후의 fMRI, 확산, PET 분석에서도 해부 기준으로 다시 쓰인다.

중고등 복습: 평균, 표준편차, 정규분포

시험 점수 여러 개의 **평균**은 합을 개수로 나눈 값이고, **표준편차**는 점수가 평균에서 대략 얼마나 떨어져 있는지를 나타낸다. 많은 측정값은 평균 근처에 몰리고 멀어질수록 드물어지는 종 모양으로 퍼진다. 이것이 **정규분포(normal distribution)** 다. 평균 μ , 표준편차 σ 인 정규분포에서 값의 약 68%는 $\mu \pm \sigma$ 안에, 약 95%는 $\mu \pm 2\sigma$ 안에 들어온다. 두 반의 점수를 한 히스토그램에 섞어 그리면 봉우리가 둘인 모양이 된다. 점수 하나만 보고 어느 반 학생인지 맞히려면 두 봉우리의 위치, 폭, 그리고 각 반의 인원을 함께 따져야 한다. 이 장의 조직 분할이 정확히 이 문제다. 반 대신 회백질, 백질, 뇌척수액이 있고, 점수 대신 복셀의 밝기가 있다.

구조 MRI 분석은 대개 다음 순서를 밟는다. (1) 편향장 보정, (2) 두개골 제거, (3) 조직 분할, (4) 표준 공간으로의 정합, (5) VBM 또는 표면 재구성, (6) 복셀이나 꼭짓점마다의 통계(5-6장). 이 장의 그림은 모두 정답을 아는 2차원 합성 뇌로 만들었다. 픽셀은 1 mm이고, 피질 두께는 약 3 mm, T1 강조 밝기는 백질 0.80, 회백질 0.50, 뇌척수액 0.15다. 각 픽셀에는 조직이 섞인 비율(부분 용적)이 들어 있다.

3.1 전처리: 편향장, 두개골 제거, 강도 정규화

같은 백질이 다른 밝기로 찍힌다

MRI의 밝기에는 조직의 성질(물리 2권 6장의 T1, T2, 양성자 밀도)과 함께 장비의 성질이 곱해진다. 수신 코일은 코일에 가까운 조직의 신호를 더 세게 받는다. 송신 RF의 세기 B_1 도 머릿속에서 고르지 않다. 7 T에서는 RF 파장이 머리보다 짧아서 이 불균일이 특히 크다(물리 2권 5장). 그 결과 같은 백질이 머리 위쪽에서는 밝고 아래쪽에서는 어둡게 찍힌다. 이 느리게 변하는 곱셈 인자를 **편향장(bias field)** 또는 **강도 불균일(intensity non-uniformity)**이라 한다.

받은 영상 I 를 다음처럼 모형화한다.

$$I(\mathbf{x}) = b(\mathbf{x}) u(\mathbf{x}) + n(\mathbf{x})$$

u 는 조직만 반영하는 참 밝기, b 는 편향장, n 은 잡음이다. 잡음을 무시하고 로그를 취하면 $\log I = \log b + \log u$ 가 되어 곱셈이 덧셈으로 바뀐다. 보정은 $\log b$ 를 추정해서 빼는 일이다.

무엇을 가정하는가

가정은 둘이다. 첫째, 편향장은 공간적으로 **매끄럽다**. 수 cm에 걸쳐 천천히 변하고, 해부 구조처럼 mm 단위로 바뀌지 않는다. 둘째, 같은 조직은 참 밝기가 거의 같다. 그래서 보정이 잘 되면 히스토그램의 봉우리가 날카로워진다.

대표 방법인 **N4**(Tustison 외 2010)는 이 두 번째 가정을 그대로 쓴다. 로그 밝기 히스토그램을 날카롭게 만드는 보정을 구하고, 그 보정을 B-스플라인이라는 매끄러운 곡면으로 맞추기를 되풀이한다. **그림 3.1**는 같은 생각을 줄인 판이다. 밝기를 세 무리로 나누고, 각 복셀 밝기를 소속 무리의 평균으로 나눈 로그 잔차를 3차 다항식 곡면으로 맞췄다. 8번 되풀이하자 추정된 편향장이 참 편향장과 뇌 안에서 약 $\pm 2\%$ 안으로 일치했다.




그림 3.1 편향장과 그 보정. (가) 참 영상에 뇌 안에서 0.83~1.17배로 변하는 매끄러운 곱셈 장을 곱했다. 아래쪽 백질이 위쪽 백질보다 밝다. (나) 조직 평균에 대한 로그 잔차를 다항식 곡면으로 맞춰 추정된 편향장. (다) 받은 영상을 (나)로 나눈 결과. (라) 보정 전(회색)에는 백질 봉우리가 넓게 퍼져 회백질 쪽으로 번진다. 보정 후(파랑)에는 봉우리가 다시 좁아진다.

백질 밝기의 변동 계수(표준편차/평균)는 보정 전 9.0%에서 보정 후 3.8%로, 잡음만 있는 참 영상의 값까지 줄었다. 다만 전체 밝기 눈금은 조금 달라졌다(백질 약 0.75). 편향장의 전체 크기는 영상만으로 정할 수 없기 때문이고, 이 문제는 강도 정규화가 맡는다.

예제 3.1 편향장이 조직을 뒤바꾸는 크기

백질 참 밝기 0.80, 회백질 0.50이다. (가) 편향장이 뇌 안에서 0.83~1.17배로 변하면, 가장 어두운 곳의 백질과 가장 밝은 곳의 회백질은 각각 얼마로 찍히는가? (나) 편향장의 최대/최소 비가 얼마를 넘으면 어두운 백질이 밝은 회백질보다 어두워지는가?

풀이 (가) 백질 $0.80 \times 0.83 = 0.664$, 회백질 $0.50 \times 1.17 = 0.585$ 다. 원래 0.30이던 간격이 0.08로 좁아졌다. 잡음 표준편차가 0.03이면 두 조직의 분포가 겹치기 시작한다(**그림 3.1** (라)의 회색). (나) $0.80 b_{\min} = 0.50 b_{\max}$ 에서 $b_{\max}/b_{\min} = 1.6$ 이다. 다채널 머리 코일의 표면 근처나 7 T 영상에서는 보정 전 비가 이 정도에 이르기도 한다. 이때 문턱 하나로 조직을 나누면 결과가 영상 위치를 따라 체계적으로 틀린다.

대표 도구는 ANTs의 N4, 편향장을 분할과 함께 추정하는 FSL FAST와 SPM, FreeSurfer의 강도 정규화다. 편향장 모형이 너무 유연하면 실제 해부 대비(예: 시상의 밝기)까지 지우고, 너무 뻣뻣하면 7 T

측두엽 아래쪽처럼 급하게 어두워지는 곳을 놓친다. 보정한 영상과 추정된 편향장을 함께 보는 것이 가장 빠른 점검이다.

두개골 제거

두개골 제거(skull stripping) 는 두피, 뼈, 눈, 경막을 지워 뇌 마스크를 만든다. 분할과 정합이 뇌 밖 조직에 끌려가지 않게 하려는 것이다. 표면을 부풀려 뇌 경계에 멈추게 하는 방법(FSL BET), 주형의 마스크를 옮기는 방법(ANTs), 학습한 딥러닝 방법이 있다. 뇌와 바깥 사이에 뚜렷한 밝기 경계가 있다고 가정하는데, 이 가정은 경막과 정맥동에서 약하다. 시상정맥동이 남으면 회백질로 분할되어 두정엽 피질이 두껍게 나오고, 마스크가 좁으면 정수리 피질이 잘린다. 마스크 윤곽을 원영상에 겹쳐 여러 단면에서 확인한다.

강도 정규화

MRI 밝기에는 절대 단위가 없다. 수신 이득이 바뀌면 숫자 전체가 달라진다. 그래서 백질 봉우리를 정해진 값에 맞추거나, 히스토그램을 기준에 맞추거나, z-점수로 바꾼다. 조직 평균을 영상마다 추정하는 분할에는 덜 중요하지만, 밝기를 특징으로 쓰는 기계학습(13장)에서는 결정적이다.

뇌로 가는 다리: 7 T 구조 영상과 MP2RAGE

3 T에서 편향장은 뇌 안에서 대략 10~30%다. 7 T에서는 측두엽 아래쪽과 소뇌가 가운데보다 절반 가까이 어둡기도 하다. 이때는 속임각 자체가 위치마다 달라 백질과 회백질의 밝기 비율, 곧 대비까지 바뀌므로 곱셈 인자 하나로 되돌릴 수 없다. 그래서 7 T 연구는 MP2RAGE(물리 2권 9장)를 즐겨 쓴다. TI가 다른 두 영상의 비를 취하면 수신 코일의 곱셈 인자가 약분되어 편향장이 획득 단계에서 대부분 사라진다. 영상 획득 방법이 전처리의 부담을 바꾸는 예다.

3.2 조직 분할

히스토그램을 가우스의 합으로 본다

편향장을 보정하면 뇌 안 밝기 히스토그램에 봉우리 셋이 보인다(그림 3.1 (라)). 각 조직의 밝기가 잡음 때문에 정규분포로 퍼진다고 보면, 히스토그램 전체는 정규분포 세 개의 가중합이다. 이것이 **혼합 가우스 모형(Gaussian mixture model, GMM)** 이다.

$$p(x) = \sum_{k=1}^K w_k \mathcal{N}(x; \mu_k, \sigma_k)$$

x 는 복셀 밝기, k 는 조직(CSF, GM, WM), w_k 는 조직 k 가 차지하는 비율(합이 1), μ_k 와 σ_k 는 그 조직 밝기의 평균과 표준편차, $\mathcal{N}$ 은 정규분포 밀도다. 모수를 알면 베イズ 정리(2장)로 각 복셀이 조직 k 일 **사후 확률(posterior probability)** 을 구한다.

$$P(k | x) = \frac{w_k \mathcal{N}(x; \mu_k, \sigma_k)}{\sum_j w_j \mathcal{N}(x; \mu_j, \sigma_j)}$$

모수는 **기댓값 최대화(expectation-maximization, EM)** 로 구한다. 지금 모수로 복셀마다 사후 확률을 계산하고(E 단계), 그 확률을 가중치로 각 조직의 평균, 표준편차, 비율을 다시 계산한다(M 단계). 이것을 수렴할 때까지 되풀이한다. 아래 코드가 전부다.

```
import numpy as np

def gmm_em(x, mu, sd, w, n_iter=200):
    """x: 뇌 안 복셀 밝기(1차원 배열). mu, sd, w: 조직별 초깃값."""
    for _ in range(n_iter):
        lik = w * np.exp(-0.5 * ((x[:, None] - mu) / sd) ** 2) / sd
        r = lik / lik.sum(axis=1, keepdims=True)      # E: 복셀별 사후 확률
        nk = r.sum(axis=0)                             # M: 가중 평균과 분산
        w = nk / len(x)
        mu = (r * x[:, None]).sum(axis=0) / nk
        sd = np.sqrt((r * (x[:, None] - mu) ** 2).sum(axis=0) / nk)
    return mu, sd, w, r

# 예: mu, sd, w, r = gmm_em(x, np.array([0.2, 0.5, 0.8]),
#                             np.full(3, 0.1), np.full(3, 1 / 3))
```

합성 뇌에 맞추면 평균은 0.160, 0.500, 0.798로 참값에 가깝다. 비율은 0.113, 0.259, 0.628이고, 참 조직 비율은 0.121, 0.239, 0.638이다. 회백질이 조금 크게 나왔다. 회백질의 표준편차도 0.071로, 참 표준편차 0.03의 두 배가 넘는다. 이유는 다음 절에 있다.




그림 3.2 혼합 가우스 모형으로 한 조직 분할. (가) 뇌 안 밝기 히스토그램(열은 파랑)과 EM으로 맞춘 세 성분, 그 합(점선). 회백질과 백질 봉우리 사이(보라 띠)에는 두 조직이 섞인 부분 용적 복셀이 깔려 있다. (나) 밝기에 따른 사후 확률. 회백질과 백질 사이의 0.7 근처에서 확률은 급하게 바뀌지만 실제 회백질 비율(빨간 점선)은 직선으로 바뀐다. (다) 회백질 사후 확률 지도의 일부.

부분 용적: 한 복셀에 두 조직

피질 두께는 2-4 mm이고 구조 영상의 복셀은 1 mm다. 피질은 두께 방향으로 복셀 두세 개에 걸치고, 그 경계 복셀에는 회백질과 백질, 또는 회백질과 뇌척수액이 함께 들어 있다. 이것이 **부분 용적(partial volume)** 이다(물리 2권 3장에서 PET의 해상도 문제로 처음 보았다). 합성 뇌에서는 뇌 안 복셀의 12.6%가 회백질 5-95%를 담은 섞인 복셀이다.

회백질 비율이 f 인 GM/WM 복셀은 $f\mu_{GM} + (1-f)\mu_{WM}$ 으로 찍힌다. 그래서 봉우리 사이가 채워진다(그림 3.2 (가)의 보라 띠). 순수한 세 정규분포만 가정한 GMM은 이 복셀들을 회백질 성분을 부풀려 받아들인다. 회백질 표준편차와 비율이 커진 이유다.

예제 3.2 사후 확률과 부분 용적 비율

맞춘 모수가 회백질 $\mu = 0.50$, $\sigma = 0.071$, $w = 0.26$, 백질 $\mu = 0.80$, $\sigma = 0.032$, $w = 0.63$ 이다. 밝기 0.65인 복셀에 대해 (가) 회백질 사후 확률과 (나) 선형 혼합으로 본 회백질 비율을 구하라.

풀이 (가) 회백질의 $z = (0.65 - 0.50)/0.071 = 2.11$, 백질의 $z = (0.65 - 0.80)/0.032 = -4.69$ 다. 가중 우도는 $w e^{-z^2/2}/\sigma$ 로 회백질 $0.26 \times e^{-2.23}/0.071 = 0.393$, 백질 $0.63 \times e^{-10.99}/0.032 = 0.00033$ 이다. 사후 확률은 $0.393/(0.393 + 0.00033) = 0.999$ 다. 뇌척수액의 기여는 무시할 만하다. (나) $0.65 = 0.50f + 0.80(1-f)$ 에서 $f = 0.50$ 이다. 모형은 "99.9% 확실히 회백질"이라 말하지만 실제로는 절반만 회백질이다. 이런 복셀이 피질 경계마다 깔려 있으므로, 사후 확률을 그대로 더하면 합성 뇌의 회백질 부피는 참값(5124 mm²)보다 8.3% 큰 5550 mm²가 된다.

흔한 오해: 회백질 확률 지도의 값은 회백질의 양이다

분할 결과의 "GM 지도"는 대개 사후 확률이다. 확률 0.6은 "이 복셀의 60%가 회백질"이 아니라 "이 복셀이 통째로 회백질일 가능성이 60%"라는 뜻이다. 그림 3.2 (나)에서 보듯 사후 확률은 경계에서 계단처럼 바뀌고, 비율은 밝기를 따라 고르게 바뀐다. VBM이 이 지도의 합을 부피로 쓰는 것은 근사다. 혼합 성분을 따로 두어 비율을 직접 추정하는 도구도 있어서, 도구에 따라 부피의 절대값이 몇 % 달라진다. 같은 도구 안의 집단 비교에서는 이 편향이 대부분 상쇄되지만, 도구가 다른 연구의 절대 부피를 비교하면 안 된다.

공간 정보와 통합 분할

밝기만 보는 GMM은 밝기가 같은 다른 구조를 구별하지 못한다. 창백핵은 T1 강조에서 백질처럼 밝고, 백질 고신호 병변은 회백질처럼 어둡다. 잡음 때문에 백질 한가운데 회백질 점이 흩뿌려지기도 한다.

그래서 실제 도구는 두 가지를 더한다. 하나는 수백 명의 분할을 표준 공간에서 평균해 위치마다 사전 확률 $w_k(\mathbf{x})$ 를 주는 **조직 확률 지도(tissue probability map)** 이고, 다른 하나는 이웃 복셀이 같은 조직일 가능성이 크다는 **마르코프 무작위장(Markov random field)** 사전 지식이다. SPM의 **통합 분할(unified segmentation)** 은 편향장 보정, 확률 지도로의 정합, 분할을 한 확률 모형 안에서 번갈아 푼다(Ashburner와 Friston 2005). 세 문제가 서로의 답을 필요로 하기 때문이다. FSL FAST, ANTs Atropos, FreeSurfer, 딥러닝 분할 도구도 같은 문제를 다른 방식으로 푼다.

사전 확률은 그것을 만든 집단을 닮는다. 성인 지도를 영아, 고령자, 큰 병변이 있는 뇌에 쓰면 분할이 체계적으로 틀린다. 소아에는 나이에 맞는 주형을 쓰고, 백질 고신호가 많은 고령자에서는 병변을 따로

분할해 채우거나 마스크한다.

3.3 정합

얼마나 자유롭게 움직일 것인가

정합(registration)은 움직이는 영상을 고정 영상에 겹치는 공간 변환을 찾는 일이다. 같은 사람의 T1과 fMRI, 개인 뇌와 MNI 주형(1장), 두 시점의 영상이 모두 정합으로 이어진다.

첫 번째 선택은 자유도다. **강체(rigid)** 변환은 이동 3개와 회전 3개, 6개 모수로 모양과 크기를 그대로 둔다(물리 1권 2장). 같은 사람의 영상끼리 쓴다. **아핀(affine)** 변환은 축마다의 배율과 기울임을 더해 12개 모수로, 머리 크기와 전체 모양의 차이를 흡수한다. **비선형(nonlinear)** 변환은 위치마다 다른 변위를 허용한다. 5 mm 간격 제어점으로 성인 뇌 상자(180 × 220 × 180 mm)를 덮으면 제어점이 61,605개, 방향 셋을 곱해 약 18만 개 모수다. 1 mm 복셀마다 변위를 두는 방법은 2천만 개가 넘는다.

비용 함수: 무엇을 "잘 맞았다"고 할 것인가

정합은 두 영상이 얼마나 잘 맞는지를 재는 **비용 함수(cost function)**를 가장 좋게 만드는 모수를 찾는 최적화다. 같은 대비의 영상끼리는 **차이 제곱 평균(mean squared difference)**이나 상관 계수가 자연스럽다. 맞으면 밝기가 같아지기 때문이다. 대비가 다른 영상에서는 이 가정이 깨진다. T1 강조에서 어두운 뇌척수액이 T2 강조에서는 밝다. 잘 맞을수록 밝기 차이가 오히려 커진다.

이때 쓰는 것이 **상호 정보량(mutual information, MI)**이다. 두 영상에서 같은 위치의 밝기 쌍을 모아 **결합 히스토그램(joint histogram)**을 그린다(그림 3.3 (가)). 잘 맞으면 T1의 "밝음"이 T2의 "어두움"과 짝지어지듯 조직마다 몇 개의 덩어리로 모인다. 어긋나면 덩어리가 줄무늬로 흩어진다(같은 그림 (나)). 상호 정보량은 한 영상의 밝기를 알 때 다른 영상의 밝기에 대한 불확실성이 얼마나 줄어드는지를 잴다.

$$MI(A, B) = H(A) + H(B) - H(A, B), \quad H = - \sum p \log_2 p$$

H 는 히스토그램의 **엔트로피(entropy)**로, 분포가 얼마나 퍼졌는지를 비트로 잰 양이다(물리 1권 5장의 "가능한 배치 수의 로그"와 같은 생각이다). $H(A, B)$ 는 결합 히스토그램의 엔트로피다. 결합 히스토그램이 몇 덩어리로 모일수록 $H(A, B)$ 가 작아지고 MI가 커진다. 밝기 사이의 관계가 직선일 필요도, 증가 함수일 필요도 없다. 일대일 대응이면 충분하다.




그림 3.3 대비가 다른 영상의 회전 정합. (가) T1 강조(가로)와 T2 강조(세로)가 맞을 때의 결합 히스토그램(로그 눈금). 조직마다 덩어리로 모이고 MI는 1.57 비트다. (나) 8° 어긋나면 덩어리가 가로세로 줄무늬로 흩어져 MI가 0.49 비트로 떨어진다. (다) 회전 각도에 따른 MI(파랑)와 차이 제곱 평균(회색). MI는 0°에서 뚜렷한 최댓값을 갖지만 ±13°에도 작은 봉우리가 있다. 차이 제곱 평균은 오히려 0°에서 가장 크다.

그림 3.3 (다)는 두 가지 교훈을 준다. 첫째, 대비가 다른 영상에 차이 제곱 평균을 쓰면 정답(0°)이 최악의 자리가 된다. 같은 대비에는 차이 제곱 평균이나 상관, 다른 대비에는 상호 정보량(Maes 외 1997), 정규화 상호 정보량, 상관비를 쓴다. fMRI의 EPI를 T1에 맞출 때는 회백질-백질 경계의 대비를 직접 쓰는 경계 기반 정합이 더 정확하다(4장).

둘째, MI 곡선에는 ±13°에도 봉우리가 있다. 합성 뇌의 고랑이 28개라서, 한 고랑 간격($360^\circ/28 \approx 12.9^\circ$) 만큼 돌리면 고랑이 다른 고랑과 겹쳐 부분적으로 맞는다. 출발점이 이 근처라면 최적화는 이 **국소 최적(local optimum)**에 멈춘다. 그래서 실제 도구는 크게 흐린 낮은 해상도에서 출발해 점점 세밀하게 맞추고, 머리 중심을 미리 맞춘다. 정합이 크게 돌아간 채 끝나는 사고는 대개 헤더의 방향 정보(1장)가 틀렸거나 출발점이 멀었던 경우다.

비선형 정합과 야코비안

아핀 변환으로 머리 크기를 맞춰도 뇌실 크기, 고랑의 위치와 깊이는 사람마다 다르다. **그림 3.4**의 개인 뇌는 주형보다 8% 작고 뇌실 면적은 1.65배다. 뇌 마스크 면적의 비로 배율(0.921)을 추정해 아핀 정합을 하면 바깥 윤곽은 맞지만 뇌실은 여전히 크다. 이어서 위치마다의 변위장을 찾는 비선형 정합을 하면 뇌실까지 주형에 겹친다.

비선형 정합의 핵심은 **정칙화(regularization)**다. 변위를 아무렇게나 허용하면 잡음까지 맞추고 조직을 접는 변환이 나오므로, 변위장이 매끄러워야 한다는 별점을 더한다. 그림의 데몬스 방식은 밝기 차이를 밝기 기울기 방향의 힘으로 바꿔 변위를 조금씩 움직이고, 매번 변위장을 가우스로 매끄럽게 한다. 현대 도구는 접히지 않고 되돌릴 수 있음을 보장하는 **미분동형(diffeomorphic)** 변환을 쓴다. ANTs의 SyN(Avants 외 2008), SPM의 DARTEL(Ashburner 2007)이 대표적이고, FSL FNIRT는 야코비안이 양수로 남도록 제약을 둔다. 여러 비선형 정합 도구를 비교한 연구에서는 도구 사이의 정확도 차이가 컸다(Klein 외 2009).




그림 3.4 아핀 정합과 비선형 정합. 빨간 윤곽은 주형(고정 영상)의 조직 경계다. (가) 개인 뇌는 주형보다 작고 뇌실이 크다. (나) 크기를 맞춘 아핀 정합 뒤에도 뇌실이 주형 윤곽을 넘는다. (다) 비선형 정합 뒤에는 뇌실과 피질이 윤곽에 겹친다. (라) 비선형 변환의 야코비안 행렬식 J . 뇌실 자리(빨강)는 주형의 1 mm^2 가 아핀 정합한 개인 뇌에서 평균 1.24 mm^2 였다는 뜻이다.

변환이 각 자리를 얼마나 늘렸는지는 **야코비안 행렬식(Jacobian determinant) J** 가 알려 준다. 주형의 작은 부피 하나가 개인 뇌에서 몇 배의 부피였는지를 나타내는 국소 배율이다. $J > 1$ 이면 그 자리가 개인 뇌에서 더 컸고, $J < 1$ 이면 더 작았다. $J \leq 0$ 이면 변환이 공간을 접었다는 뜻이라 정합 실패의 신호다. 합성 뇌의 뇌실 자리에서 비선형 부분의 J 는 평균 1.24이고 전체 범위는 0.72–1.36으로 모두 양수다. 야코비안은 다음 절 VBM의 변조와 **텐서 기반 형태 분석(tensor-based morphometry)**의 재료가 된다.

정합 품질은 주형 윤곽을 정합한 영상에 겹쳐 여러 단면에서 보고, 뇌실, 중심고랑, 해마 같은 표지 구조를 확인하며, 수작업 분할이 있으면 다이소 계수로 겹침을 재고, 야코비안의 극단값을 찾아 점검한다.

뇌로 가는 다리: 병변이 있는 뇌의 정합

뇌졸중이나 종양 환자의 영상을 주형에 맞추면, 비선형 정합은 병변의 어두운 구멍을 주형의 정상 조직에 맞추려고 주변을 끌어당긴다. 병변이 크면 반대쪽 반구까지 일그러진다. 그래서 병변 안의 복셀을 비용 계산에서 빼는 **비용 함수 마스킹(cost function masking)**을 쓰거나, 병변을 반대쪽 정상 조직으로 채운 뒤 정합한다. 병변-증상 지도화 연구는 수백 명의 병변을 MNI 공간에 겹친다. 정합 오차 수 mm가 가는 백질 경로의 손상 여부를 뒤바꿀 수 있으므로, 방법 절에서 병변 마스킹과 정합 점검 방법을 확인한다.

3.4 복셀 기반 형태 분석(VBM)

단계

복셀 기반 형태 분석(voxel-based morphometry, VBM)은 모든 참가자의 회백질 지도를 같은 공간에 모아 복셀마다 집단 차이나 상관을 검정한다(Ashburner와 Friston 2000). 단계는 (1) 조직 분할, (2) 집단 주형 만들기과 비선형 정합, (3) 변조, (4) 평활화, (5) 복셀별 일반 선형 모형(5장)과 다중비교 보정(6장)이다. 가설 없이 뇌 전체를 볼 수 있고 표면 재구성보다 단순하다. 그래서 피질하 구조와 소뇌까지 함께 본다.

변조: 농도인가 부피인가

정합은 개인 뇌를 주형 모양으로 늘이거나 줄인다. 위축된 해마도 주형의 해마 크기로 늘어나 그 자리를 회백질 확률로 채운다. 정합이 완벽할수록 모든 사람의 지도가 같아진다(그림 3.5 (나)). 그러면 VBM은 아무것도 찾지 못한다.

변조(modulation) 는 정합으로 늘어나거나 줄어든 만큼을 야코비안으로 되돌려 곱한다.

$$m(\mathbf{x}) = p(\varphi(\mathbf{x})) \cdot J(\mathbf{x})$$

p 는 개인 공간의 회백질 값, φ 는 주형 공간의 점을 개인 공간으로 보내는 변환, J 는 그 야코비안이다. 변조한 지도를 주형 공간에서 적분하면 개인 공간의 회백질 부피와 같다. 변조하지 않은 지도는 "정합 뒤 남은 회백질의 농도", 변조한 지도는 "원래 그 구조에 있던 회백질의 양"을 본다. 위축 연구는 대개 변조한 지도를 쓴다.




그림 3.5 1차원 VBM. (가) 회백질 띠가 10 mm인 A(위축)와 14 mm인 B를 12 mm 주형 띠(열은 파랑)에 맞춘다. (나) 비선형 정합 뒤 변조하지 않으면 두 사람의 지도가 똑같아진다. (다) 야코비안 $J = 10/12 = 0.83$ 과 $14/12 = 1.17$ 을 곱하면 (점선) 원래 부피 10 mm와 14 mm가 보존된다. FWHM 8 mm로 평활화하면(실선) 정점은 0.77과 1.08이 된다.

평활화

VBM 지도는 대개 FWHM 8-12 mm 가우스로 평활화한다. 이유는 셋이다. 정합의 잔여 오차를 흡수하고, 복셀 값을 정규분포에 가깝게 만들어 모수 통계를 쓸 수 있게 하며, 무작위장 이론(6장)의 가정을 맞춘다. 대가는 해상도다. 8 mm 평활화는 표준편차 3.4 mm의 가우스와 같다. 그 결과는 "이 복셀의 회백질"이 아니라 "이 복셀 둘레 1 cm 남짓에 모인 회백질의 양"이다. 그림 3.5 (다)에서 두께 차이 4 mm가 넓고 낮은 봉우리 차이로 바뀌는 것이 그 모습이다. 그래서 VBM 결과가 피질 두께의 변화인지, 면적의 변화인지, 고랑 모양의 변화인지, 정합 오차인지는 VBM만으로 가를 수 없다. 정합이 체계적으로 다른 두 집단에서 VBM 차이가 정합 차이를 반영할 수 있다는 비판(Bookstein 2001)도 여기서 나왔다.

머리 크기 보정

큰 머리는 대부분의 구조가 크다. 머리 크기의 지표로는 **두개내 총용적(total intracranial volume, TIV)**을 쓴다. 회백질, 백질, 뇌척수액 부피의 합으로, 성인에서 대략 1.2~1.7 L다. 보정 방법은 셋이다. (1) 각 지도를 TIV로 나누는 비례 보정, (2) TIV를 GLM의 공변량으로 넣는 방법, (3) 아핀 부분을 뺀 비선형 부분의 야코비안만으로 변조하는 방법이다. 세 번째는 머리 크기 차이를 정합의 아핀 단계에서 이미 걸러 낸 셈이다. 구조 부피는 TIV에 정확히 비례하지 않으므로 비례 보정과 공변량 보정의 결과가 다를 수 있다. 성별 비교처럼 TIV 차이가 큰 연구에서 특히 그렇다.

예제 3.3 변조와 TIV

(가) 어떤 사람의 해마 영역 3.0 mL가 비선형 정합으로 주형의 3.6 mL 영역에 맞춰졌다. 정합 뒤 회백질 값이 0.9였다면 변조한 값은? (나) TIV가 1.3 L인 사람과 1.6 L인 사람의 해마 부피가 각각 3.2 mL와 3.9 mL다. TIV로 나누는 비례 보정 값을 비교하라.

풀이 (가) $J = 3.0/3.6 = 0.833$ 이다. 변조한 값은 $0.9 \times 0.833 = 0.75$ 다. 변조하지 않으면 0.9 그대로라서 위축이 보이지 않는다. (나) $3.2/1300 = 2.46 \times 10^{-3}$, $3.9/1600 = 2.44 \times 10^{-3}$ 이다. 원부피는 22% 차이가 나지만 머리 크기에 비례한 몫은 거의 같다. TIV 보정을 빼면 머리 크기 차이(예: 남녀)가 그대로 "해마 차이"로 보고된다.

🧠 뇌로 가는 다리: 택시 운전사의 해마

VBM을 널리 알린 연구 하나가 런던 택시 운전사 연구다(Maguire 외 2000). 운전사들은 대조군보다 해마 뒷부분의 회백질이 많고 앞부분이 적었으며, 뒷부분의 양은 운전 경력과 상관이 있었다. 경험이 성인 뇌의 구조를 바꿀 수 있다는 주장으로 주목받았다. 이 장의 관점에서 확인할 것이 있다. 결과가 변조한 지도에서 나왔는가? 평활화를 거친 신호가 해마 안의 앞뒤 차이를 얼마나 갈라낼 수 있는가? 해마 모양의 개인 차가 정합에서 다르게 처리되지 않았는가? 이후 연구는 다른 대조군과 수습생을 추적하는 종단 설계로 이 질문의 일부에 답했다. VBM의 발견은 다른 방법으로 다시 확인할 가설로 읽는 것이 안전하다.

3.5 표면 기반 분석

피질을 종이처럼 펼친다

피질은 두께 2~4 mm의 주름진 판이다. 고랑 양쪽 벽은 3차원 공간에서는 수 mm 떨어져 있지만 피질을 따라가면 수 cm 떨어진 곳이다. 부피 공간의 가우스 평활화는 이 벽을 가로질러 섞는다. **표면 기반 분석(surface-based analysis)**은 피질을 2차원 면으로 다루어 이 문제를 피한다.

FreeSurfer의 표면 재구성은 백질을 분할하고 위상 결합(구멍과 손잡이)을 고쳐 닫힌 **백질 표면(white surface)**을 삼각형 그물로 만든 뒤, 이 면을 밝기 경계를 따라 밀어 회백질과 뇌척수액의 경계인 **연질막 표면(pial surface)**을 만든다. 반구마다 꼭짓점이 대략 15만 개다. 이 면을 공 모양으로 부풀려 고랑 무늬를 기준으로 표준 표면(fsaverage, 반구당 꼭짓점 163,842개, 1장)에 맞춘다.

피질 두께의 정의

피질 두께(cortical thickness) 는 두 표면 사이의 거리다. 거리를 어떻게 재는지가 정의의 일부다. 대표적인 정의는 백질 표면의 각 점에서 가장 가까운 연질막 표면까지의 거리와, 연질막 표면에서 가장 가까운 백질 표면까지의 거리를 평균한 것이다(Fischl과 Dale 2000). 두 표면을 라플라스 방정식의 유선으로 잇는 정의도 있다. 어느 쪽이든 핵심은 표면에 **수직인** 방향으로 잴다는 것이다.




그림 3.6 피질 두께는 두 표면 사이의 거리다. (가) 넓은 이랑 마루와 좁고 깊은 고랑을 가진 피질 단면. 참 두께는 마루에서 약 3 mm, 고랑 바닥에서 약 2 mm다(검은 화살표). 고랑 벽에서 영상 격자의 세로 방향으로 재면(회색 점선) 피질을 비스듬히 지나가 훨씬 길게 나온다. (나) 가로 위치에 따른 참 두께(검정)와 세로 격자 방향 길이(회색 점선). 벽이 가파른 곳에서는 격자 방향 길이가 8 mm를 넘는다.

그림 3.6 는 왜 표면이 필요한지 보여 준다. 영상 격자 한 방향으로 회백질 복셀을 세면, 표면이 격자에 대해 θ 만큼 기울어진 곳에서 길이가 대략 $1/\cos\theta$ 배로 늘어난다. 30° 에서 1.15배, 60° 에서 2배다. 그림의 고랑 벽은 70° 넘게 기울어져, 참 두께 2.7 mm가 격자 방향으로로는 8.5 mm가 된다. 그림은 또 하나의 사실을 담았다. 실제 뇌에서도 피질은 이랑 마루에서 두껍고 고랑 바닥에서 얇다. 두께 지도에서 마루와 바닥이 다른 것은 오차가 아니라 해부다.

두께 외에도 꼭짓점마다 **표면적(surface area)**, 회백질 부피(대략 두께 $\times$ 면적), 주름 정도(**국소 이랑화 지수**), 곡률을 잰다. 두께와 면적은 발달과 노화에서 다르게 변하고 유전적 영향도 상당 부분 다르므로, VBM의 "부피" 차이는 둘 중 무엇인지 가려 읽어야 한다. 표면 평활화는 표면을 따라 FWHM 10-20 mm를 흔히 쓰며, 고랑 맞은편 벽과 섞이지 않는다.

예제 3.4 두께와 검정력

(가) 1 mm 복셀 영상에서 두께 2.5 mm인 피질은 수직 방향으로 복셀 몇 개에 걸치는가? 표면이 격자에 대해 60° 기울어진 곳에서 격자 방향으로 재면 몇 mm가 나오는가? (나) 두 집단의 평균 두께 차이가 0.025 mm(약 1%)이고 집단 안 표준편차가 0.15 mm다. 양측 $\alpha = 0.05$, 검정력 80%로 이 차이를 찾으려면 집단마다 몇 명이 필요한가?

풀이 (가) 2.5개다. 경계 복셀 둘은 대개 섞인 복셀이라 "순수한 회백질" 복셀은 한두 개뿐이다. 60°에서는 $2.5 / \cos 60^\circ = 5.0$ mm다. (나) 효과 크기 $d = 0.025 / 0.15 \approx 0.167$ 이다. 두 집단 비교의 표준 근사식 $n \approx 2(z_{1-\alpha/2} + z_{1-\beta})^2 / d^2 = 2(1.96 + 0.84)^2 / 0.167^2$ 에 넣으면 집단마다 약 565명이다. 이 크기의 차이는 같은 사람을 다시 찍을 때의 측정 오차와 비슷하다. 작은 표본의 피질 두께 연구가 재현되지 않는 흔한 이유다.

3.6 세분화된 구조, 종단 분석, 뇌 나이

피질하 구조와 해마 하위 영역

해마, 편도체, 시상, 꼬리핵 같은 피질하 구조는 아틀라스 기반 분할(FreeSurfer)이나 모양 모형(FSL FIRST)으로 부피를 잰다. 성인의 해마는 한쪽에 대략 3-4 mL다. 해마 하위 영역(CA1, CA3, 치아이랑, 해마이행부)의 경계는 mm 이하의 층 구조로 정해져 1 mm T1 영상에서는 거의 보이지 않는다. 그런 영상의 하위 영역 분할은 대부분 아틀라스의 사전 확률이 정한다. 신뢰할 만한 연구는 해마 장축에 수직인 고해상도 T2 강조 영상(면내 약 0.4 mm)을 따로 찍고, 작은 영역일수록 낮은 재검사 신뢰도(2장의 ICC)를 보고한다.

종단 분석

건강한 고령자의 해마는 1년에 대략 1-1.5%, 알츠하이머병 환자는 대략 3-5% 준다. 해마 3.5 mL의 1%는 35 μ L다. 시점마다 따로 분석하면 측정 오차가 이 변화를 덮는다. 그래서 종단 처리는 한 사람의 모든 시점을 강체 정합으로 모아 **개인 내 주형(within-subject template)**을 만들고, 각 시점을 이 주형에서 출발해 처리한다(FreeSurfer 종단 처리, Reuter 외 2012). 중요한 원칙은 모든 시점을 **똑같이** 다루는 것이다. 기준 시점을 주형으로 삼고 추적 시점만 그쪽으로 보간하면, 보간으로 흐려진 추적 영상만 체계적으로 위축되어 보이는 편향이 생긴다. 뇌 전체 위축률은 두 시점 사이 뇌 경계의 이동을 직접 재는 방법(FSL SIENA)으로도 구한다.

뇌 나이

건강한 사람으로 학습한 나이 예측 모형에서 예측 나이와 실제 나이의 차이를 **뇌 나이 차이(brain-age gap)**라 한다. 함정은 **평균으로의 회귀**다. 완벽하지 않은 모형은 극단을 가운데로 끌어당긴다. 학습 집단 평균이 50세이고 예측이 실제 나이 변화의 80%만 따라간다면, 30세는 34세로, 70세는 66세로 예측된다. 아무 이상이 없어도 젊은 사람은 +4년, 나이 든 사람은 -4년의 "뇌 나이 차이"를 갖는다. 그래서 차이를 나이에 대해 보정하거나 나이를 공변량으로 넣어야 한다(Smith 외 2019). 이 보정의 계수는 학습 데이터에서만 추정해야 한다. 시험 데이터로 추정하면 13장에서 다룰 데이터 누설이 된다.

3.7 혼입 요인: 움직임과 스캐너

움직임은 피질을 얇게 만든다

5-10분짜리 3D 구조 영상을 찍는 동안 머리가 움직이면 영상이 흐려지고 고스트가 생긴다(물리 2권 8장, 9장). 이런 영상은 피질 두께와 회백질 부피가 작게 추정된다(Reuter 외 2015). 눈으로 보기에 멀쩡한 영상에서도 같은 경향이 있었다.

문제는 움직임이 집단과 엉킨다는 것이다. 소아, 고령자, 여러 환자 집단은 대조군보다 더 움직이므로 "환자의 피질이 얇다"는 결과의 일부는 움직임일 수 있다. 대응은 세 겹이다. 스캔 중 움직임을 줄이거나 실시간으로 보정하고, 품질 지표(1장의 MRIQC, 표면의 위상 결함 수를 나타내는 오일러 수)와 시각 평가로 나쁜 영상을 거르며, 남은 품질 차이를 공변량으로 넣는다.

뇌로 가는 다리: 발달 연구와 움직임

소아의 피질은 자라며 얇아진다. 그런데 어린 아이일수록 더 움직인다. 움직임이 피질을 얇게 추정하게 만들면 어린 아이의 피질이 실제보다 얇게 나와, 발달에 따른 얇아짐이 작게 보이고 발달 곡선이 휜다. 대규모 발달 코호트는 그래서 모의 스캐너 연습, 영화 시청, 실시간 움직임 추적과 재촬영을 쓴다. 분석에서는 품질 점수로 영상을 거르되, 걸러진 아이들이 특정 나이나 진단에 몰리지 않았는지 확인한다. 거르기 자체가 표본을 편향시킬 수 있다.

스캐너가 다르면 숫자가 다르다

장 세기, 제조사, 코일, 시퀀스 설정, 소프트웨어 버전이 바뀌면 같은 사람의 피질 두께가 0.1 mm 단위로 달라질 수 있다(물리 2권 9장). 여러 기관의 데이터를 모으면 이 차이가 **기관 효과(site effect)**가 된다. 기관마다 평균이 다른 가산 효과와, 측정의 퍼짐이 다른 곱셈 효과가 함께 있다.

ComBat은 유전체 연구에서 실험 묶음의 차이를 지우려고 만든 방법(Johnson 외 2007)을 피질 두께 같은 영상 지표에 옮긴 것이다(Fortin 외 2018). 각 지표 y 를 다음처럼 모형화한다.

$$y_{ij} = \alpha + \mathbf{x}_{ij}^T \boldsymbol{\beta} + \gamma_i + \delta_i \varepsilon_{ij}$$

i 는 기관, j 는 참가자, α 는 전체 평균, $\mathbf{x}\boldsymbol{\beta}$ 는 보존할 생물학적 공변량(나이, 성별, 진단)의 효과, γ_i 는 기관 i 의 가산 효과, δ_i 는 곱셈 효과다. 공변량 효과를 그대로 둔 채 γ_i 를 빼고 δ_i 로 나눈다. 원래 ComBat은 여기에 **경험적 베이즈(empirical Bayes)** 수축을 더한다. 여러 지표(예: 68개 영역)에서 추정한 기관 효과를 서로 빌려 써서, 기관의 표본이 작아도 추정이 흔들리지 않게 한다.




그림 3.7 ComBat식 조화. (가) 세 기관의 평균 피질 두께(합성 자료). 기관 2는 평균이 0.12 mm 높고 퍼짐이 1.6배이며 나이 든 사람이 많다. 기관마다 따로 그은 회귀선이 서로 떨어져 있다. (나) 나이 효과를 보존하며 기관의 평균과 퍼짐을 맞추면 뒤에는 세 회귀선이 겹친다. (다) 환자가 기관 1에 80%, 기관 2에 20% 몰린 설계에서 추정된 환자 효과(참값 -0.10 mm, 400회 반복 평균). 기관을 무시하면 -0.040, 진단을 공변량으로 넣지 않고 조화하면 -0.064로 줄고, 진단을 넣고 조화해야 -0.100을 되찾는다.

그림 3.7 (가)에서 나이에 따른 두께 기울기를 기관 구분 없이 구하면 1년에 -0.0027 mm로, 참값 -0.0050 mm의 절반쯤이다. 나이 든 사람이 많은 기관 2의 평균이 높아서 나이 효과를 가린 것이다. 조화한 뒤에는 -0.0051 mm로 돌아온다.

예제 3.5 기관과 진단이 영킬 때

두 기관에서 같은 수를 모았다. 기관 1은 환자 80%, 기관 2는 환자 20%다. 참 환자 효과는 -0.10 mm, 기관 1의 기관 효과는 +0.10 mm다. (가) 기관을 무시하고 환자와 대조의 평균을 비교하면 기댓값은? (나) 진단을 공변량으로 넣지 않고 기관 평균만 맞추면?

풀이 (가) 환자의 80%, 대조의 20%가 기관 1에 있다. 기관 효과가 환자 쪽에 $0.10 \times (0.8 - 0.2) = 0.06$ mm 더 실린다. 기댓값은 $-0.10 + 0.06 = -0.04$ mm다. (나) 기관 평균을 빼면 각 사람의 진단 값도 "기관 평균 환자 비율"만큼 빠진다. 환자가 속한 기관의 평균 환자 비율은 $0.8 \times 0.8 + 0.2 \times 0.2 = 0.68$, 대조는 $0.2 \times 0.8 + 0.8 \times 0.2 = 0.32$ 다. 남은 진단 차이는 $1 - 0.68 + 0.32 = 0.64$ 이므로 효과는 $-0.10 \times 0.64 = -0.064$ mm다. 기관 효과와 함께 진단 효과의 36%가 지워졌다. 두 값 모두 **그림 3.7** (다)의 시뮬레이션과 일치한다.

ComBat의 흔한 실수는 셋이다. 첫째, 보존할 공변량을 빼먹으면 그 효과의 일부가 함께 지워진다(예제 3.5). 둘째, 기계학습에서 학습과 시험 데이터를 합쳐 조화하면 시험 정보가 학습으로 샌다(13장). 조화 모수는 학습 데이터에서만 추정한다. 셋째, 조화는 평균과 분산만 맞춘다. 기관마다 분할이 실패하는 방식이 다르면 그 차이는 남는다. 같은 사람을 여러 기관에서 찍은 **여행하는 피험자(traveling subjects)** 자료가 있으면 조화의 효과를 직접 확인할 수 있다.

핵심 정리

핵심 정리

- 편향장은 매끄러운 곱셈 인자로, 같은 조직의 밝기가 같다는 가정으로 추정한다. 합성 뇌에서 백질 변동 계수가 9.0%에서 3.8%로 줄었다. 밝기에는 절대 단위가 없다.
- 조직 분할은 히스토그램을 가우스의 합으로 보는 GMM과 EM에서 출발해 조직 확률 지도와 이웃 관계를 더한다. 통합 분할은 편향장, 정합, 분할을 함께 푼다.
- 부분 용적 때문에 사후 확률은 분율이 아니다. 밝기 0.65인 GM/WM 반반 복셀의 GM 사후 확률은 0.999였다.
- 정합은 자유도(강제 6, 아핀 12, 비선형 수십만 이상)와 비용 함수를 고르는 일이다. 대비가 다르면 상호 정보량을 쓰고, 국소 최적을 피하려 거친 해상도에서 출발한다. 야코비안 J 는 국소 부피 배율이고 $J \leq 0$ 은 실패다.
- VBM은 분할, 정합, 변조($\times J$), 평활화(FWHM 8-12 mm), 복셀별 GLM이다. 변조해야 부피가 보존되고, TIV 보정 방법이 결과를 바꾼다.
- 피질 두께는 두 표면 사이를 표면에 수직으로 잴 거리다. 격자 방향으로 재면 $1/\cos\theta$ 배 길어진다.
- 종단 분석은 시점을 대칭으로 다룬다. 뇌 나이 차이는 나이에 대한 편향을 보정해야 한다.
- 움직임은 피질을 얇게 추정하게 만들고 집단과 엉킨다. ComBat 조화에는 보존할 공변량을 넣고, 모수는 학습 데이터에서만 추정한다.

방법 질 점검표

방법 질 점검표

- 구조 영상의 시퀀스, 해상도, 장 세기, 기관과 스캐너 수가 적혀 있는가? 집단마다 스캐너 분포가 같은가?
- 편향장 보정, 두개골 제거, 분할에 쓴 도구와 버전, 그리고 결과를 시각적으로 점검한 절차가 있는가?
- 정합의 자유도, 비용 함수, 주형(나이와 집단에 맞는가)이 명시되어 있는가? 병변이 있다면 마스킹했는가?
- VBM이라면 변조 여부, 평활화 FWHM, TIV 보정 방법이 적혀 있는가?
- 표면 분석이라면 두께, 면적, 부피 중 무엇을 보았고 표면 평활화 폭은 얼마인가?
- 움직임과 영상 품질을 어떻게 평가하고 걸렀는가? 걸러진 비율이 집단마다 같은가?
- 여러 기관 자료라면 조화 방법과 보존한 공변량이 무엇이며, 예측 모형에서는 조화 모수를 학습 데이터에서만 추정했는가?
- 종단 연구라면 시점을 대칭으로 처리했는가? 뇌 나이라면 나이 편향 보정을 했는가?

확인 문제

확인 문제

1. 편향장 보정이 "같은 조직은 참 밝기가 같다"고 가정한다. 이 가정이 깨지는 해부 구조를 하나 들고, 보정 모형이 너무 유연할 때 그 구조에 무슨 일이 생기는지 설명하라.
2. 밝기 0.62인 복셀이 있다. 예제 3.2의 모수를 쓰면 회백질 사후 확률은 거의 1이다. 선형 혼합으로 본 회백질 분율은 얼마인가? 이 차이가 회백질 부피 추정에 어느 방향의 편향을 주는가?
3. T1 강조 영상을 같은 사람의 T1 강조 영상에 맞출 때와 FLAIR 영상에 맞출 때 각각 어떤 비용 함수가 알맞은가? 이유를 [그림 3.3](#) 으로 설명하라.
4. 비선형 정합 뒤 어떤 영역의 야코비안이 0.8이다. 이 영역의 회백질 값이 정합 뒤 0.7이라면 변조한 값은? 야코비안 지도에 음수가 있다면 무엇을 뜻하는가?
5. 두 집단의 VBM에서 변조하지 않은 지도로는 차이가 없고 변조한 지도로는 차이가 있었다. 무엇을 말해 주는가?
6. 표면이 영상 격자에 대해 45° 기울어진 곳에서 두께 2.8 mm인 피질을 격자 방향으로 재면 몇 mm인가?
7. 학습 집단 평균 나이가 60세이고 예측 나이가 실제 나이 변화의 70%만 따라가는 뇌 나이 모형이 있다. 실제 나이 40세와 80세인 건강한 사람의 뇌 나이 차이는 각각 얼마로 나오는가?
8. 환자는 모두 기관 A에서, 대조는 모두 기관 B에서 모았다. ComBat으로 기관 효과를 조화할 수 있는가?

확인 문제 풀이

확인 문제 풀이

1. 깊은 회백질이 예다. 시상과 창백핵은 피질보다 밝고, 창백핵은 백질에 가깝게 밝다. 편향장 모형이 이 크기의 구조를 따라갈 만큼 유연하면 그 밝기 차이를 편향장으로 보고 지워, 경계가 흐려지고 분할이 틀린다. 그래서 편향장 모형의 매끄러움은 수 cm 규모로 둔다.
2. $0.62 = 0.50f + 0.80(1 - f)$ 에서 $f = 0.60$ 이다. 사후 확률이 약 1이므로 이 복셀은 회백질 1로 셈해진다. 넓게 부푼 회백질 성분이 섞인 복셀을 많이 가져가므로 회백질 부피는 과대 추정된다(합성 뇌에서 +8.3%).
3. 같은 T1끼리는 밝기가 같아지므로 차이 제공 평균이나 상관 계수를 쓴다. T1과 FLAIR는 뇌척수액 대비가 반대이고 밝기 관계가 직선이 아니므로 상호 정보량(또는 정규화 상호 정보량)을 쓴다. [그림 3.3](#) (다)처럼 대비가 다른 영상에 차이 제공 평균을 쓰면 정답 자리가 오히려 나쁜 값을 갖는다.
4. $0.7 \times 0.8 = 0.56$ 이다. 음수 야코비안은 변환이 공간을 뒤집어 접었다는 뜻이다. 물리적으로 불가능하므로 정칙화가 약하거나 정합이 실패한 것이고, 그 자리의 VBM 결과는 믿을 수 없다.
5. 정합 뒤 회백질 농도는 같지만, 주형에 맞추려고 늘리거나 줄인 정도가 다르다는 뜻이다. 곧 차이는 국소 부피에 있다. 정합이 좋을수록 정보가 야코비안으로 옮겨 가므로 자연스러운 결과다. TIV 보정 방법에 따라 그 일부는 머리 크기일 수 있다.
6. $2.8 / \cos 45^\circ = 2.8 \times 1.414 = 3.96$ mm, 약 4.0 mm다.
7. 40세는 $60 + 0.7 \times (40 - 60) = 46$ 세로 예측되어 +6년, 80세는 $60 + 0.7 \times 20 = 74$ 세로 예측되어 -6년이다. 아무 이상이 없어도 나이에 따라 체계적인 차이가 생기므로 나이에 대한 보정이 필요하다.

8. 없다. 기관과 진단이 완전히 겹치면 γ_i 와 진단 효과를 구별할 정보가 자료에 없다. 진단을 공변량으로 넣으면 모형이 풀리지 않고, 빼면 진단 효과까지 지운다. 설계 단계에서 기관마다 두 집단을 함께 모으거나, 여행하는 피험자나 팬텀 자료로 기관 차이를 따로 재야 한다.

다음 장으로

이 장에서는 T1 강조 영상을 조직 지도, 표준 공간의 회백질 지도, 피질 표면으로 바꾸는 단계를 따라갔다. 이 결과는 구조 분석에서 끝나지 않는다. 4장의 fMRI 전처리는 이 장의 백질 표면으로 EPI를 경계 기반 정합하고, 비선형 변환으로 기능 영상을 표준 공간에 옮기며, 백질과 뇌척수액 마스크에서 잡음 성분을 뺀다. 다음 장에서는 시간 축이 더해진 4차원 영상에서 슬라이스 타이밍, 움직임 보정, 왜곡 보정, 잡음 제거가 어떤 가정을 깔고 있는지 본다.

4장 fMRI 전처리

이 장에서 배울 것 스캐너에서 나온 4차원 EPI 영상이 통계 분석에 들어가기까지 거치는 단계를 실제 파이프라인 순서대로 본다. 처음 볼륨 버리기, 슬라이스 타이밍 보정, 움직임 보정과 FD·DVARs, 왜곡 보정과 정합, 평활화, 잡음 제거(움직임 회귀, CompCor, ICA, 생리 잡음, 전역 신호, 스크러빙, 대역 통과 필터), 그리고 품질 보고다. **뇌 연구자에게 왜 필요한가** BOLD 효과는 1-2%인데 머리가 0.3 mm만 움직여도 경계 복셀의 신호가 몇 % 바뀐다. 전처리는 이 차이를 다루는 단계다. 단계마다 선택이 있고, 그 선택이 결과를 바꾼다. 방법 절의 "FD > 0.5 mm 볼륨 제거, 24 파라미터와 aCompCor 5개 회귀, 6 mm FWHM"이 무엇을 가정하고 무엇을 잃는지 알아야 결과를 믿을지 판단할 수 있다.

중고등 복습: 평균, 표준편차, 그리고 '빠기'

측정값이 $x_1, \dots, x_n$ 이면 평균은 $\bar{x} = \frac{1}{n} \sum x_i$ 이고, 표준편차는 평균에서 떨어진 정도의 제곱 평균에 제곱근을 씌운 값이다. 잡음이 서로 독립이면 n 개를 평균할 때 표준편차가 $1/\sqrt{n}$ 로 준다(물리 2권 7장). 잡음을 줄이는 방법은 두 가지다. 하나는 **평균하기**다. 이웃 복셀이나 여러 시점을 섞으면 무작위 잡음이 상쇄된다. 다른 하나는 **빠기**다. 잡음의 모양을 알면 그 모양을 데이터에 맞춘 뒤 뺀다. 저울의 영점을 맞추는 것과 같다. 이 장의 평활화와 대역 통과 필터는 앞의 방법이고, 움직임 회귀와 CompCor는 뒤의 방법이다. 뒤의 방법은 2장의 회귀(GLM)로 "잡음 모양에 맞는 성분"을 계산한다. 두 방법 모두 대가가 있다. 평균하면 세부가 흐려지고, 빠면 그 모양에 우연히 닮은 신호까지 함께 빠진다.

4.1 왜 전처리를 하는가

fMRI 원자료는 시점마다 찍은 3차원 EPI 볼륨의 연속이다. 3 mm 복셀, TR 2 s, 10분이면 볼륨 300개, 복셀 수십만 개다. 분석은 이 복셀 하나하나의 시계열이 "같은 뇌 조직의 신호를 같은 시각에 켜 것"이라고 가정한다. 원자료는 이 가정을 거의 모든 점에서 어긴다.

- 같은 볼륨의 슬라이스는 서로 다른 시각에 찍힌다(4.2절).
- 머리가 움직이면 같은 복셀 좌표에 다른 조직이 들어온다(4.3절).
- EPI는 부비동 근처에서 찌그러져 구조 영상과 맞지 않는다(4.4절, 물리 2권 9장).
- 심박, 호흡, 표류 같은 잡음이 BOLD보다 크다(4.6절, 물리 2권 10장).

전처리는 이 위반을 하나씩 줄여 가정에 가깝게 만드는 일이다. 물리 2권 10장에서 본 것처럼 3 T의 3 mm 복셀은 이미 생리 잡음이 tSNR의 천장을 정한다. 그래서 전처리의 이득은 대부분 열 잡음이 아니라 **구조화된 잡음(structured noise)**, 곧 시간과 공간에 모양이 있는 잡음을 다루는 데서 나온다.

표준적인 순서는 다음과 같다. 처음 볼륨 제거 → 움직임 추정 → 슬라이스 타이밍 보정 → 왜곡 보정 → 구조 영상 정합과 표준 공간 정규화 → (과제 fMRI) 평활화 → 잡음 회귀와 필터 → 품질 점검. 순서에는 이유가 있다. 각 절에서 그 이유를 같이 본다.

4.2 시간 축

처음 볼륨 버리기

스캔을 시작하면 세로 자화가 정상 상태(물리 2권 6장)에 이르기까지 몇 TR이 걸린다. 그동안의 볼륨은 뒤의 볼륨보다 밝다. 정상 상태와의 차이는 TR마다 $E = \cos \alpha e^{-TR/T_1}$ 배로 준다. 회백질 $T_1 \approx 1.35$ s에서 TR 2 s, 숙임각 77° 이면 $E \approx 0.05$ 여서 두 볼륨 뒤 차이가 1% 아래로 떨어진다. TR 0.8 s, 숙임각 52° 이면 $E \approx 0.34$ 이고 네 볼륨이 필요하다. 많은 장비가 이런 **더미 스캔(dummy scan)** 을 자동으로 버리지만, 버렸는지는 장비와 시퀀스마다 다르다. fMRIPrep 같은 파이프라인은 처음 몇 볼륨의 밝기를 보고 비정상 상태 볼륨을 찾아 표시한다.

슬라이스 타이밍

2차원 EPI는 슬라이스를 한 장씩 찍는다. TR 2 s에 36장이면 한 장에 약 55.6 ms가 걸리고, 마지막 슬라이스는 첫 슬라이스보다 약 1.94 s 늦다. 이웃 슬라이스 간섭을 피하려고 홀수 번째를 먼저 찍는 교차 순서를 쓰면, 바로 붙은 두 슬라이스가 약 1 s 차이가 난다(그림 4.1 (가), 물리 2권 8장).

GLM은 모든 복셀이 볼륨의 기준 시각에 찍혔다고 보고 모형을 만든다. 실제 획득 시각이 어긋나면 모형의 HRF(생리 1권 9장)가 데이터보다 앞서거나 뒤쳐진다. 어긋남이 적합을 얼마나 깎는지는 설계에 달려 있다. 사건 관련 설계는 반응이 짧아서 1 s 어긋나면 설명 분산의 약 27%를 잃는다. 20 s 블록 설계는 반응이 길게 평평해서 약 3%만 잃는다(그림 4.1 (나)).




그림 4.1 (가) TR 2 s에 36장을 찍을 때 슬라이스별 획득 시각. 순차 순서(회색 선)는 위로 갈수록 늦고, 교차 순서(파랑)는 이웃 슬라이스가 약 1 s 차이 난다. 다중 대역 4(보라, TR 0.8 s)는 9장 간격으로 같은 시각을 공유하고 최대 차이가 0.71 s다. (나) 모형과 실제 획득 시각이 어긋날 때 설명된 분산 비율. 사건 관련 설계(파랑)는 1 s에 0.73, 2 s에 0.26으로 떨어지지만 블록 설계(회색)는 거의 잃지 않는다. 모형에 HRF의 시간 미분을 넣으면(빨강 점선) 1 s 안쪽의 어긋남은 대부분 흡수된다.

슬라이스 타이밍 보정(slice-timing correction) 은 각 슬라이스의 시계열을 시간 축에서 보간해 기준 시각의 값으로 옮긴다. 보통 싱크(sinc) 보간이나 푸리에 위상 이동(물리 2권 7장의 이동 ↔ 위상 기울기)을

쓴다. 기준은 첫 슬라이스 또는 가운데 슬라이스다. 기준을 가운데로 잡으면 보간 거리가 최대 TR의 절반으로 준다.

- **가정:** 신호가 TR보다 느리게 변해 보간이 정확하다. TR이 길수록 이 가정이 약해진다. 또 머리가 움직이지 않아 한 슬라이스가 계속 같은 조직을 본다고 가정한다.
- **도구:** SPM, FSL, AFNI 모두 보정 기능이 있다. 필요한 것은 슬라이스별 획득 시각 목록이다. BIDS의 JSON 사이드카(1장)에 **SliceTiming**으로 들어 있다.
- **흔한 실수:** 슬라이스 순서를 잘못 넣는 것이다. 일부 장비는 슬라이스 수가 짝수일 때 교차 순서를 짝수 번째부터 시작한다. 사이드카의 실제 시각을 쓰고 순서를 짐작하지 않는다. 다른 실수는 기준 슬라이스와 GLM의 시간 기준을 다르게 두는 것이다. 가운데 슬라이스로 보정했으면 모형도 TR/2만큼 옮겨야 한다.

움직임 보정과 순서도 선택이다. 움직임이 크면 슬라이스가 다른 조직을 보게 되어 어느 쪽을 먼저 해도 완전하지 않다. fMRIPrep은 원자료에서 움직임 파라미터를 먼저 추정해 두고, 슬라이스 타이밍을 보정한 뒤, 움직임·왜곡·정합 변환을 하나로 합쳐 한 번만 다시 표본화한다. 보간할 때마다 영상이 조금씩 흐려지기 때문이다.

예제 4.1 슬라이스는 언제 찍혔나

TR 2 s, 36장, 홀수 먼저인 교차 순서다. (가) 2번 슬라이스와 35번 슬라이스의 획득 시각은? (나) 같은 36장을 다중 대역 4, TR 0.8 s로 찍으면 최대 시간 차이는?

풀이 (가) 한 장에 $2/36 = 55.6$ ms다. 홀수 18장(1, 3, ..., 35)이 먼저이므로 35번은 18번째, 곧 $17 \times 55.6 = 944$ ms에 찍힌다. 2번은 19번째로 $18 \times 55.6 = 1000$ ms다. 바로 옆 1번(0 ms)과 1 s 차이다. (나) 4장씩 동시에 들뜨므로 들뜸은 $36/4 = 9$ 번, 간격 $800/9 = 88.9$ ms다. 최대 차이는 $8 \times 88.9 = 711$ ms다. 사건 관련 설계에서 0.7 s 어긋남은 **그림 4.1** (나)에서 설명 분산의 약 14%에 해당한다. 작지만 0은 아니다.

🧠 뇌로 가는 다리: 다중 대역 시대의 슬라이스 타이밍

HCP 휴지기 프로토콜(TR 720 ms, 다중 대역 8)처럼 TR이 1 s보다 짧으면 슬라이스 사이 시간 차이가 HRF의 폭(반치폭 약 5 s)에 비해 작다. 그래서 HCP 최소 전처리는 슬라이스 타이밍 보정을 하지 않는다. 휴지기 연결성은 0.1 Hz 아래 신호를 보므로 0.7 s 어긋남은 위상으로 약 25°이고 상관에 주는 영향이 작다. 반대로 TR 2-3 s의 사건 관련 과제 fMRI에서는 보정하거나, 모형에 시간 미분을 넣어 지연을 흡수해야 한다. 집단 간 비교에서 HRF 지연이 다르다고 결론 내리려면 슬라이스 타이밍을 어떻게 다루었는지 먼저 확인해야 한다. 노인과 혈관 질환 환자는 HRF 자체가 늦을 수 있어서(생리 1권 9장) 두 지연이 섞인다.

4.3 움직임 보정

강제 6 파라미터

머리는 모양이 변하지 않는 **강체**로 근사한다. 강체의 자세는 평행이동 3개와 회전 3개, 곧 6 파라미터로 정해진다(물리 1권 2장). **움직임 보정(realignment, head-motion correction)**은 볼륨마다 6 파라미터를 바꿔 가며 기준 볼륨과의 차이(보통 강도 차의 제곱합)가 가장 작아지는 값을 찾는다. 기준은 첫

볼륨, 가운데 볼륨, 평균 볼륨, 또는 다중 대역 시퀀스가 함께 주는 대비가 좋은 **단일 대역 기준 영상(SBRef)**이다.

- **가정:** 머리 전체가 한 덩어리로 움직인다. 볼륨 안에서는 움직임이 없다. 강도는 움직임과 무관하다.
- **도구:** FSL MCFLIRT, SPM Realign, AFNI 3dvolreg가 대표다. 결과로 볼륨 $\times$ 6의 파라미터 표가 나온다. 도구마다 회전 단위(라디안 또는 도)와 열 순서가 달라서, 파일을 직접 다룰 때 가장 흔한 실수가 여기서 나온다.

세 가정은 모두 조금씩 틀린다. 슬라이스를 찍는 사이에 머리가 움직이면 볼륨 안에서 슬라이스마다 자세가 다르다. 머리가 움직이면 스핀 이력과 B_0 분포가 바뀌어 강도 자체가 변한다(물리 2권 10장). 그래서 영상을 맞춘 뒤에도 움직임에 묶인 신호 변화가 남고, 이것을 4.6절에서 회귀로 다시 다룬다.

틀별 변위 FD

6 파라미터는 단위가 섞여 있어 한눈에 보기 어렵다. Power 등(2012)은 회전각을 반지름 50 mm 구 위의 호 길이 $s = r\theta$ 로 바꾸어 mm로 맞추고, 연속한 두 볼륨 사이 변화량의 절댓값을 모두 더했다. 이것이 **틀별 변위(FD, framewise displacement)** 다.

$$FD_t = |\Delta x_t| + |\Delta y_t| + |\Delta z_t| + r(|\Delta \alpha_t| + |\Delta \beta_t| + |\Delta \gamma_t|), \quad r = 50 \text{ mm}$$

Δx_t 는 볼륨 t 와 $t-1$ 사이 x 평행이동의 차이(mm), $\Delta \alpha_t$ 등은 회전의 차이(라디안)다. 50 mm는 머리 중심에서 대뇌 피질까지의 대략적인 거리다. FD는 "얼마나 멀리 갔나"가 아니라 "한 TR 사이에 얼마나 빨리 움직였나"를 잴다(그림 4.2). 천천히 가라앉는 머리는 파라미터 그래프에서는 크게 보여도 FD는 작다. 순간 움직임은 갔다가 돌아오므로 FD가 연속한 두 볼륨에서 쌓으로 된다.

FD에는 다른 정의도 있다. FSL 계열이 쓰는 Jenkinson의 정의는 회전과 평행이동을 행렬로 합쳐 뇌 안 점들의 평균 제곱근 변위를 계산한다. 값의 크기가 Power의 FD와 달라서 같은 문턱을 쓸 수 없다. 방법 절에서 FD를 볼 때는 어느 정의인지부터 확인한다.

TR이 1 s보다 짧은 다중 대역 자료에서는 호흡(0.2-0.3 Hz)이 움직임 파라미터에 진동으로 묻어 나온다. 숨을 쉬면 가슴의 공기가 머리 속 B_0 를 바꾸고, EPI가 위상 방향으로 미세하게 밀려 정합 알고리즘이 이것을 움직임으로 읽는다. 실제 머리는 거의 움직이지 않았는데 FD가 부풀려진다. 이런 자료는 파라미터에서 호흡 대역을 걸러 낸 뒤 FD를 계산하기도 한다.




그림 4.2 합성 움직임 10분(TR 2 s, 300 볼륨). (가) 6 파라미터. 머리가 z 방향으로 약 0.4 mm 가라앉고 피치가 약 0.35° 숙여지는 느린 표류 위에, 침 삼킴 같은 순간 움직임 다섯 번이 한 볼륨씩 된다. (나) 같은 자료의 FD. 표류는 FD에 거의 보이지 않고(평균 0.13 mm), 순간 움직임은 0.5 mm를 넘는 봉우리 쌍으로 나타난다. 0.2 mm 문턱을 넘는 볼륨은 12개, 0.5 mm를 넘는 볼륨은 9개다.

예제 4.2 6 파라미터에서 FD 계산

볼륨 $t-1$ 에서 t 로 가는 동안 평행이동이 $(\Delta x, \Delta y, \Delta z) = (0.12, -0.08, 0.25)$ mm, 회전이 피치 0.2° , 롤 -0.1° , 요 0.05° 바뀌었다. (가) FD는? (나) 문턱 0.5 mm와 0.2 mm에 대해 이 볼륨은 어떻게 처리되는가? (다) 이 볼륨 다음에 머리가 원래 자리로 돌아갔다면 다음 볼륨의 FD는?

풀이 (가) 평행이동 뒀은 $0.12 + 0.08 + 0.25 = 0.45$ mm다. 회전은 라디안으로 바꿔 50 mm를 곱한다. $0.2^\circ = 0.00349$ rad이므로 $50 \times 0.00349 = 0.175$ mm, 같은 방법으로 0.1° 는 0.087 mm, 0.05° 는 0.044 mm다. 회전 뒀은 0.305 mm이고 FD는 $0.45 + 0.305 = 0.755$ mm다. (나) 두 문턱을 모두 넘는다. 0.2° 는 작아 보이지만 회전 뒀이 FD의 40%를 차지한다. 회전 중심에서 80 mm 떨어진 후두엽 피질은 이 피치만으로 0.28 mm 움직인다. (다) 모든 변화량의 부호만 바뀌므로 FD는 다시 0.755 mm다. 순간 움직임 하나가 FD 봉우리 두 개를 만든다(그림 4.2 (나)).

DVARs와 카펫 그림

FD는 머리의 움직임을 재고, **DVARs**는 그 결과로 영상이 얼마나 바뀌었는지를 잴다. 뇌 안 모든 복셀에서 볼륨 t 와 $t-1$ 의 신호 차이를 구하고, 그 제곱 평균의 제곱근을 취한다(D는 시간 미분, VARs는 복셀 사이 분산). 움직임 말고도 스파이크 잡음, 갑작스러운 호흡 변화처럼 영상을 한꺼번에 바꾸는 사건을 잡는다. 단위가 데이터 눈금에 달려 있어서, 보통 신호를 % 또는 "평균 1000"으로 맞춘 뒤 계산하거나 표준화한 값을 보고한다.

FD와 DVARs를 코드로 쓰면 이렇다. 마지막 줄에 예제 4.2의 숫자를 넣었다. 회전 단위를 라디안으로 맞추는 줄이 가장 중요하다.

```
import numpy as np

def framewise_displacement(p, radius=50.0):
    """p: (볼륨 수, 6) = x, y, z 평행이동(mm)과 회전 3개(라디안)."""
    d = np.abs(np.diff(p, axis=0))
    d[:, 3:] *= radius # 회전 → 50 mm 구 위의 호 길이
    return np.concatenate([[0.0], d.sum(axis=1)])

def dvars(Y):
    """Y: (복셀 수, 볼륨 수), % 신호 단위. 볼륨 사이 차이의 제곱 평균 제곱근."""
    dY = np.diff(Y, axis=1)
    return np.concatenate([[0.0], np.sqrt((dY ** 2).mean(axis=0))])

p = np.zeros((4, 6))
p[2] = [0.12, -0.08, 0.25, *np.deg2rad([0.2, -0.1, 0.05])]
print(framewise_displacement(p).round(3)) # [0. 0. 0.755 0.755]
```

카펫 그림(carpet plot) 은 뇌 안 복셀 수백-수천 개의 시계열을 한 줄씩 회색조로 쌓은 그림이다. 회색 그림(grayplot)이라고도 한다. 위에 FD와 DVARs를 같은 시간 축으로 붙이면 문제의 성격이 보인다(그림 4.3). 순간 움직임은 모든 조직에 걸친 세로 띠로, 깊은 숨은 회백질 전체가 몇십 초 동안 함께 어두워지는 넓은 띠로 나타난다. 이런 넓은 띠는 전역 신호의 주성분이고, 4.6절의 전역 신호 회귀 논쟁이 바로 이것을 지울지에 관한 것이다.




그림 4.3 합성 휴지기 자료의 카펫 그림. 위에서부터 FD, DVARs, 그리고 회백질 420개, 백질 150개, 뇌척수액 80개 복셀의 시계열(복셀마다 z 점수)이다. 순간 움직임에서 FD와 DVARs가 함께 튀고(DVARs 중앙값 0.9%에서 최대 4.7%로) 아래에 세로 띠가 생긴다. 185번 볼륨 근처의 깊은 숨은 FD에는 보이지 않지만 회백질을 20초 가까이 함께 어둡게 만든다.

흔한 오해: 움직임 보정을 했으니 움직임 문제는 끝났다

움직임 보정은 영상의 위치만 맞춘다. 움직임이 만든 강도 변화, 곧 스핀 이력 효과, 자화율 왜곡의 변화, 볼륨 안 움직임, 보간 오차는 그대로 남는다. 그래서 정합을 마친 자료에서도 FD가 된 볼륨의 DVARS가 함께 된다 (그림 4.3). 움직임 보정은 잡음 제거의 시작이지 끝이 아니다. 4.6절의 회귀, 스크러빙, ICA는 이 잔여 효과를 다룬다. 또 하나의 오해는 "평균 FD가 작으면 괜찮다"는 것이다. 평균 0.13 mm인 그림 4.2 의 자료에도 0.5 mm를 넘는 볼륨이 9개 있다. 평균과 함께 문턱을 넘은 볼륨 수를 본다.

4.4 왜곡 보정과 정합

왜곡 보정

EPI는 위상 방향의 줄당 대역폭이 수십 Hz/픽셀로 낮아서, 공기와 조직의 경계에서 생긴 수십-100 Hz의 장 어긋남이 영상을 수 mm 밀어낸다(물리 2권 9장). 안와전두 피질과 하측두엽이 앞뒤로 늘어나거나 줄어들고, 일부는 신호가 사라진다. 이 상태로 구조 영상에 맞추면 피질 신호가 백질이나 두개골 바깥으로 간다.

왜곡 보정(susceptibility distortion correction) 은 복셀마다 장 어긋남 Δf 를 알아내 위상 방향으로 되민다. 방법은 셋이다.

- **필드맵:** TE가 다른 그라디언트 에코 두 장의 위상 차이로 Δf 를 잰다. SPM의 FieldMap, FSL의 FUGUE가 이 방식이다.
- **역위상 부호화 쌍:** 위상 방향만 반대로 찍은 짧은 EPI 쌍(AP와 PA)은 왜곡이 정반대다. FSL topup이나 AFNI의 같은 역할 도구가 두 영상을 같게 만드는 변위장을 추정한다.
- **필드맵 없는 보정:** 둘 다 없으면 EPI를 T1 영상 쪽으로 위상 방향으로만 비선형 정합해 왜곡을 어렵힌다. fMRIPrep의 선택지 중 하나다. 앞의 두 방법보다 부정확하다.

가정은 장 어긋남이 시간에 따라 변하지 않는다는 것이다. 실제로는 머리가 움직이면 B_0 분포도 바뀌므로, 필드맵을 찍은 뒤 많이 움직이면 보정이 틀어진다. 신호가 사라진 영역은 어느 방법으로도 되살리지 못한다.

예제 4.3 왜곡은 몇 mm인가

3 T EPI의 에코 간격이 0.5 ms, 위상 방향이 64줄, 복셀이 3 mm다. 안와전두 피질 근처 복셀의 장 어긋남이 80 Hz다. (가) 가속 없이 몇 mm 밀리는가? (나) GRAPPA 2를 쓰면?

풀이 (가) 위상 방향 줄당 대역폭은 $1/(0.5 \text{ ms} \times 64) = 31.25 \text{ Hz/픽셀}$ 이다. 밀림은 $80/31.25 = 2.56 \text{ 픽셀}$, 곧 $2.56 \times 3 = 7.7 \text{ mm}$ 다. 회백질 두께의 2-3배다. (나) 읽는 줄이 32줄로 줄어 대역폭이 62.5 Hz/픽셀이 되고, 밀림은 1.28 픽셀, 약 3.8 mm로 절반이 된다. 그래도 보정 없이는 피질을 벗어난다.

구조 영상과의 정합과 표준 공간

다음 단계는 기능 영상(EPI)을 같은 참가자의 T1 영상에 맞추는 **동일인 정합(coregistration)** 이다. 두 영상은 대비가 다르므로(EPI에서는 뇌척수액이 밝다) 상호 정보량 같은 비용 함수(3장)를 쓴다. 더 정확한

방법은 **경계 기반 정합(BBR, boundary-based registration)** 이다. T1에서 찾은 회백질-백질 경계면을 EPI 위에 올려, 경계 양쪽의 EPI 밝기 차이가 가장 커지도록 6 또는 9 파라미터를 고른다. FreeSurfer의 bbbregister와 FSL FLIRT의 BBR 비용 함수가 이 방식이다. 경계 근처의 밝기만 보므로 EPI 대비가 약하거나 왜곡이 남은 곳에도 비교적 강하다.

마지막으로 T1 영상을 MNI 표준 공간(1장)에 비선형으로 맞추고(3장, ANTs SyN 등), 움직임 → 왜곡 → 동일인 정합 → 표준 공간의 변환을 하나로 합쳐 EPI 원자료에 한 번만 적용한다. 출력 복셀 크기를 원래보다 작게(예: 3 mm 자료를 2 mm로) 잡는 경우가 많은데, 이것은 해상도를 올리지 않고 파일만 키운다(물리 2권 8장의 영 채움과 같은 이유다).

뇌로 가는 다리: 안와전두 피질과 편도체는 정합에서 먼저 무너진다

보상, 정서, 사회 인지 연구가 관심을 두는 안와전두 피질, 복내측 전전두 피질, 편도체, 측두극은 부비동과 귀 바로 옆이다. 예제 4.3처럼 이곳은 왜곡 보정 없이 수 mm 밀리고, 신호의 일부가 아예 사라진다. 집단 지도의 이 영역에 "활성 없음"이나 "집단 차이 없음"이 나왔을 때 먼저 확인할 것은 세 가지다. 왜곡 보정을 했는가, 집단 평균 뇌 마스크가 이 영역을 덮는가, 참가자별 tSNR이 충분한가. 표준 공간 마스크를 참가자 전원의 교집합으로 잡으면 신호 손실이 가장 큰 참가자 하나 때문에 안와전두 피질 아래쪽이 통째로 빠지기도 한다.


4.5 평활화

공간 평활화(spatial smoothing) 는 각 볼륨을 3차원 가우스 커널로 합성곱해 이웃 복셀을 가중 평균한다. 커널 폭은 **반치폭(FWHM)** 으로 말하며 $FWHM = 2\sqrt{2\ln 2}\sigma \approx 2.355\sigma$ 다. 물리 2권 7장에서 본 것처럼 평활화는 공간 저역 통과 필터다.

평활화를 하는 이유는 셋이다. 첫째, 독립 잡음을 평균해 SNR을 높인다. 둘째, 참가자 사이에 남은 해부 차이를 흡수해 집단 분석에서 겹침을 늘린다. 셋째, 6장의 무작위장 이론이 요구하는 매끈함을 확보한다.

얼마나 크게 할지는 **정합 필터 원리(matched filter theorem)** 가 알려 준다. 찾으려는 신호와 같은 모양, 같은 폭의 커널이 SNR을 가장 크게 만든다. [그림 4.4](#) 에서 FWHM 5 mm 활성화는 5 mm 커널에서 기대 z가 1.6에서 4.1로 가장 크게 오르고, 14 mm에서는 2.1로 다시 떨어져 문턱 아래로 내려간다. FWHM 12 mm 활성화는 12 mm 커널에서 z 6.7로 가장 크다. 커널이 활성화보다 크면 신호는 주변의 0과 섞여 깎이고, 잡음은 더 이상 크게 줄지 않는다. 결국 커널 크기는 "어떤 크기의 효과를 찾을지"에 대한 사전 선택이다.

(가) 가운데 단면의 z 지도 (점선: 실제 활성)



(나) 커널 $\approx$ 활성 크기일 때 z 가 최대




그림 4.4 2 mm 복셀 3차원 합성 볼륨에서 평활화의 효과. (가) 백색 잡음 위의 작은 활성(왼쪽 점선, FWHM 5 mm)과 큰 활성(오른쪽 점선, FWHM 12 mm)의 가운데 단면 z 지도. 빨강은 양의 z 다. 커널이 커질수록 큰 활성은 뚜렷해지지만 작은 활성은 흐려지고 큰 덩어리에 묻힌다. (나) 커널 FWHM에 따른 활성 중심의 기대 z . 각 곡선은 커널이 활성 크기와 같을 때 (점) 최대이고, 그보다 크면 다시 떨어진다. 점선은 $z = 3.1$ ($p \approx 0.001$)이다.

- **가정:** 효과가 커널보다 넓고 매끈하다. 이웃 복셀은 같은 조직, 같은 기능 영역이다.
- **기본 설정:** 과제 fMRI의 체적 분석은 4-8 mm(복셀 크기의 2-3배)가 흔하다. 다중 복셀 패턴 분석(MVPA, RSA), 고해상도 7 T, 층별 fMRI는 평활화를 하지 않거나 아주 작게 한다. HCP 방식의 표면 분석은 피질 표면을 따라 2 mm 안팎으로만 평활화한다. 표면을 따르면 고랑 맞은편 벽이나 백질의 신호가 섞이지 않는다.
- **흔한 실수:** 집단 비교에서 집단마다 다른 커널을 쓰는 것, 평활화한 자료로 작은 구조(편도체 하위핵, 해마 하위 영역)의 결론을 내리는 것, 봉우리 좌표를 해부 위치로 그대로 읽는 것이다. 큰 커널은 봉우리를 큰 이웃 쪽으로 끌어간다.

예제 4.4 실제 평활도는 커널보다 크다

원자료가 이미 FWHM 3 mm 정도로 매끈하다(복셀 크기, 재구성, 보간 때문이다). 6 mm 커널로 평활화하면 결과의 평활도는?

풀이 가우스 두 개를 합성곱하면 분산이 더해진다. FWHM은 표준편차에 비례하므로 $\sqrt{3^2 + 6^2} = 6.7$ mm다. 6장의 무작위장 이론과 군집 추론은 커널 크기가 아니라 잔차에서 추정된 이 실제 평활도를 쓴다. 방법 절의 "6 mm FWHM"은 커널이고, 결과 지도의 평활도는 그보다 크다.

4.6 잡음 제거

움직임 회귀: 6에서 24로

가장 단순한 방법은 6 파라미터를 GLM의 회귀자로 넣는 것이다(5장). 움직임과 신호 변화의 관계는 선형이 아니고 시간 지연도 있으므로, Friston 등(1996)은 6 파라미터, 한 볼륨 전의 값 6개, 그리고 이

12개의 제곱을 합친 **24 파라미터 모형**을 제안했다. Satterthwaite 등(2013)은 여기에 백질, 뇌척수액, 전역 신호의 평균과 그 확장 항을 더한 36 파라미터 모형을 썼다. 회귀자는 많을수록 잡음을 더 지우지만 자유도를 그만큼 쓴다.

CompCor: 잡음을 데이터에서 배운다

호흡과 심박이 만드는 잡음은 모양을 미리 알기 어렵다. Behzadi 등(2007)의 **CompCor**는 신경 신호가 거의 없는 곳에서 잡음의 모양을 배운다. **aCompCor**는 백질과 뇌척수액 마스크(마스크를 침식해 회백질과 겹치지 않게 한다) 안 복셀 시계열의 주성분 분석(PCA)으로 상위 성분을 뽑고, 이것을 회백질 시계열에서 회귀로 뺀다. **tCompCor**는 시간 표준편차가 가장 큰 복셀(보통 혈관과 뇌척수액 근처)에서 같은 일을 한다. 성분 수는 5개로 고정하거나, 누적 설명 분산 50%에 이르는 만큼 고른다.

그림 4.5 는 그 효과를 보여 준다. 합성 자료에서 서로 다른 네트워크에 속해 실제로는 상관이 없는 회백질 복셀 쌍이, 공유 잡음 때문에 보정 전 상관 중앙값 0.39를 보인다. aCompCor 5개를 회귀하면 0.00이 된다. 같은 네트워크 쌍의 상관은 0.73에서 0.61로 덜 줄어든다. 공유 잡음이 부풀렸던 몫만 빠진 것이다.




그림 4.5 합성 휴지기 자료(TR 2 s, 300 볼륨)에서 aCompCor. (가) 회백질 복셀 하나의 시계열. 보정 전(회색)은 호흡 변동, 집힌 심박, 움직임, 표류가 섞여 참 신경 신호(초록 점선)와의 상관이 0.49다. 백질·뇌척수액 주성분 5개를 회귀한 뒤 (파랑) 0.77로 오른다. (나) 백질·뇌척수액 시계열의 주성분별 설명 분산. 상위 5개(보라)가 65%를 설명한다. (다) 서로 다른 네트워크에 속한 회백질 복셀 쌍의 상관 분포. 보정 전 중앙값 0.39인 가짜 연결이 보정 뒤 0 근처로 모인다.

가정은 백질과 뇌척수액에 신경 신호가 없고, 그곳의 잡음이 회백질의 잡음과 같은 모양이라는 것이다. 마스크가 회백질에 닿으면 신경 신호까지 지운다. 백질에도 BOLD 신호가 약하게 있다는 보고가 늘고 있어 마스크 침식이 중요하다.

ICA 기반 정리

독립 성분 분석(ICA) 으로 자료를 공간 지도와 시계열의 쌍 수십 개로 나누면, 움직임과 생리 잡음 성분은 모양이 특이하다. 뇌 가장자리의 고리 모양, 뇌척수액에 물린 지도, 높은 주파수의 시계열이다. **ICA-AROMA**(Pruim 등 2015)는 고주파 성분 비율, 뇌척수액 비율, 가장자리 비율, 움직임 파라미터와의 상관이라는 네 특징으로 움직임 성분을 자동 분류해 뺀다. 미리 학습시킬 필요가 없다. FSL의 **FIX**는 사람이 분류한 자료로 학습한 분류기를 쓴다. HCP 자료처럼 같은 프로토콜의 학습 자료가 있으면 정확하지만, 새 프로토콜에서는 다시 학습해야 한다.

생리 잡음 기록

맥박 산소계와 호흡 벨트로 심박과 호흡을 함께 기록하면 잡음을 직접 모형화할 수 있다. **RETROICOR**(Glover 등 2000)는 각 볼륨이 찍힌 순간의 심장 주기 위상과 호흡 주기 위상을 계산해, 그 위상의 사인·코사인 몇 차항을 회귀자로 넣는다. TR 2 s의 표본화는 심박(약 1-1.2 Hz)과 호흡(0.2-0.3 Hz)보다 느려서 이 잡음이 저주파로 접혀 들어온다(그림 4.6, 물리 2권 7장). 접힌 뒤에는 필터로 가를 수 없지만, 위상을 알면 접히기 전의 모양으로 뺄 수 있다. 호흡의 깊이와 심박수의 느린 변화가 만드는 잡음은 이와 별도로, 호흡량과 심박수 시계열을 반응 함수와 합성곱한 회귀자로 다룬다.

전역 신호 회귀

전역 신호 회귀(GSR, global signal regression) 는 뇌 전체 평균 시계열을 회귀자로 넣는다. 그림 4.3의 깊은 숨처럼 뇌 전체를 함께 바꾸는 잡음은 전역 신호에 크게 실리므로, GSR은 이런 넓은 인공물을 가장 강하게 지운다. 움직임과 연결성의 관계를 가장 많이 줄이는 방법 중 하나라는 보고도 많다.

반대 근거도 분명하다. 수학적으로 전역 평균을 빼면 모든 복셀 쌍의 상관 합이 0 근처로 밀리므로, 원래 없던 음의 상관이 생길 수 있다(Murphy 등 2009). 전역 신호에는 각성 수준과 관련된 신경 성분도 있다. 집단마다 전역 신호의 크기가 다르면(예: 조현병 환자에서 다르다는 보고) GSR이 집단 차이를 만들거나 지운다.

뇌로 가는 다리: 디폴트 모드 네트워크의 '역상관'은 실재하는가

디폴트 모드 네트워크와 과제 양성 네트워크가 서로 반대로 요동한다는 역상관 결과는 휴지기 fMRI의 대표 발견이었다. 이 음의 상관은 GSR을 한 자료에서 특히 크게 나왔다. GSR 없이 CompCor 같은 다른 방법으로 정리하면 음의 상관은 약해지지만 일부는 남는다. 결론은 "GSR을 했는가"에 따라 결과의 부호까지 바뀔 수 있다는 것이다. 그래서 요즘은 GSR을 한 결과와 하지 않은 결과를 함께 보고하는 것을 권한다. 7장에서 연결성 측정과 함께 다시 본다.

스크러빙과 대역 통과 필터

스크러빙(scrubbing) 또는 **검열(censoring)** 은 FD나 DVARS가 문턱을 넘는 볼륨을 분석에서 뺀다(Power 등 2012). 움직임의 영향이 몇 볼륨 이어지므로 흔히 앞 1개, 뒤 2개 볼륨도 함께 뺀다. 볼륨마다 그 볼륨만 1인 **스파이크 회귀자**를 넣는 것도 같은 효과다. 남은 자료가 너무 적으면(예: 5분 미만) 참가자를 제외한다.

휴지기 fMRI는 이어서 **대역 통과 필터**로 0.01-0.1 Hz(또는 0.008-0.08 Hz)만 남긴다. 아래쪽은 스캐너 표류를, 위쪽은 접힌 심박과 호흡과 열 잡음을 깎는다(그림 4.6). 합성 자료에서 필터는 참 신경 신호와의 상관을 0.55에서 0.90으로 올린다. 다만 이 그림에서 효과가 큰 것은 신경 신호를 0.01-0.1 Hz에 두고 만들었기 때문이다. 실제 BOLD 요동이 0.1 Hz 위에도 있다는 보고가 있어, 위쪽 차단을 두지 않는 파이프라인도 있다. 과제 fMRI는 신호가 과제 주파수에 있으므로 고역 통과 필터(예: 128 s)만 쓴다(5장).




그림 4.6 합성 시계열(TR 2 s)의 대역 통과 필터. (가) 파워 스펙트럼. 1.15 Hz 심박과 0.30 Hz 호흡이 나이퀴스트 주파수 0.25 Hz 위에 있어 각각 0.15 Hz와 0.20 Hz로 접혀 붐우리를 만든다. 0.01-0.1 Hz 통과 필터(회색 띠)는 표류와 두 붐우리를 깎는다. (나) 필터 전후의 시계열과 참 신경 신호. 필터 뒤 참 신호와의 상관이 0.55에서 0.90으로 오른다.

단계의 순서가 중요하다. 필터를 먼저 하고 회귀를 나중에 하면, 회귀가 필터로 지운 주파수 성분을 회귀자를 통해 다시 들어온다(Hallquist 등 2013). 회귀자에도 같은 필터를 걸거나, 필터와 회귀를 한 모형에서 동시에 한다. 스크리빙도 필터보다 먼저 하면 빈 볼륨이 시계열을 끊고, 필터 뒤에 하면 이미 스파이크가 주변 볼륨으로 번진 뒤다. 그래서 검열한 볼륨을 보간으로 메운 뒤 필터하고 다시 빼는 방식을 쓰기도 한다.

예제 4.5 잡음 제거는 자유도를 쓴다

10분, TR 2 s, 300 볼륨의 휴지기 자료에 0.01-0.1 Hz 통과 필터, 36 파라미터 회귀, 스파이크 회귀자 33개를 쓴다. (가) 남는 유효 자유도는 대략 얼마인가? (나) 상관계수의 표준오차는 자유도가 297일 때와 비교해 어떻게 되는가?

풀이 (가) 주파수 축은 0부터 0.25 Hz까지이고 통과 대역 폭은 0.09 Hz다. 각 주파수 성분은 자유도를 거의 같은 몫씩 가지므로 남는 몫은 $0.09/0.25 = 36\%$, 약 108이다. 여기서 회귀자 36개와 스파이크 33개를 빼면 약 39가 남는다. 300 볼륨이 독립 표본 40개 남짓이 된 셈이다. (나) 피쳐 z 의 표준오차는 대략 $1/\sqrt{\text{자유도} - 3}$ 이다. $1/\sqrt{36} = 0.17$ 로, 자유도 297일 때의 $1/\sqrt{294} \approx 0.058$ 보다 세 배 크다. 자유도를 잘못 쓰면 연결성의 유의성이 크게 부풀려진다. 또 참가자마다 지운 볼륨 수가 다르면 연결성 추정의 정밀도도 참가자마다 다르다.

4.7 파이프라인 도구와 품질 보고

도구

전처리하는 여러 패키지의 조합이다. 역할로 정리하면 다음과 같다.

- **통합 패키지:** SPM, FSL(FEAT), AFNI(afni_proc.py)는 각자 전처리에서 GLM까지의 흐름을 갖췄다.
- **표준화된 전처리 파이프라인:** **fMRIPrep**(Esteban 등 2019)은 BIDS 자료를 받아 위 패키지들과 ANTs, FreeSurfer의 가장 좋은 부분을 엮는다. 사람이 손대지 않아도 다양한 자료에서 돌아가도록 설계했고, 단계마다 그림이 든 HTML 보고서를 만든다. fMRIPrep은 평활화와 잡음 회귀를 하지 **않는다**. 대신 FD, DVARS, CompCor, 전역 신호 등 회귀자 후보를 표로 내놓고, 무엇을 쓸지는 분석자에게 맡긴다.
- **잡음 제거 후처리:** 회귀자 표를 받아 회귀, 검열, 필터를 한 번에 하는 도구들이 있다(XCP-D, Nilearn의 해당 기능 등).
- **품질 지표:** MRIQC(1장)가 tSNR, FD, DVARS, 고스트 비율 같은 지표를 계산하고 대규모 자료와 비교해 준다.

눈으로 확인할 것

자동 지표만으로는 부족하다. 참가자마다 최소한 다음을 본다. 정합 결과(구조 영상 위에 EPI 경계를 겹친 그림), 왜곡이 남은 영역, tSNR 지도, 카펫 그림, 회귀자 표. 연구 시작 전에 제외 기준(예: 평균 FD 0.25 mm 초과, 또는 검열 후 남은 시간 5분 미만)을 정하고 지킨다. 결과를 본 뒤 기준을 고르면 분석 유연성(13장)이 생긴다.

4.8 움직임과 집단 차이의 혼입

2012년 무렵 세 연구진(Power 등 2012, Satterthwaite 등 2012, Van Dijk 등 2012)이 거의 동시에 같은 사실을 보고했다. 머리를 많이 움직인 참가자일수록 가까운 영역 사이 연결은 강하게, 먼 영역 사이 연결은 약하게 나온다. 움직임 잡음이 이웃 영역에 함께 실려 가까운 쌍의 상관을 올리고, 먼 쌍의 참 상관은 서로 다른 잡음에 묻혀 희석되기 때문이다. 이 **거리 의존 인공물**은 0.5 mm 아래의 작은 움직임에서도 나타났다(그림 4.7).

뇌로 가는 다리: 소아, 노인, 환자 연구의 움직임 혼입

어린이, 노인, ADHD, 조현병, 자폐 스펙트럼 참가자는 대조군보다 평균적으로 더 많이 움직인다. 그러면 [그림 4.7](#)의 모양이 그대로 "집단 차이"가 된다. 발달 연구에서 "나이가 들수록 짧은 거리 연결은 약해지고 긴 거리 연결은 강해진다"는 결과의 일부가 어린 참가자의 움직임 때문이었다는 재분석이 대표 사례다(Power 등 2012, Satterthwaite 등 2012). 대응은 여러 겹이다. 집단 사이 평균 FD를 맞추거나 공변량으로 넣는다. 스크러빙과 강한 잡음 제거를 쓰고, 검열 뒤 남은 볼륨 수가 집단마다 비슷한지 확인한다. 연결성과 참가자별 평균 FD의 상관(QC-FC)이 거리에 따라 남아 있는지 보고한다. 임상 신경심리학 연구에서 환자군의 "연결성 감소"를 볼 때, 집단별 평균 FD와 제외된 참가자 수가 표에 있는지부터 확인한다.




그림 4.7 움직임의 거리 의존 인공물(합성 자료). 관심 영역 150개, 참가자 40명씩 두 집단(평균 FD 0.12 mm 대 0.37 mm). 각 점은 영역 쌍 하나의 집단 간 상관 차이이고, 빨간 선은 거리 구간 평균이다. (가) 움직임 잡음이 남아 있으면 30 mm 안쪽 쌍은 평균 0.04 강하게, 100 mm 넘는 쌍은 평균 0.02 약하게 나온다. (나) 움직임 잡음을 70% 줄이면 기울기가 3분의 1 남짓으로 줄어든다.

핵심 정리

핵심 정리

- 전처리하는 "같은 조직을 같은 시각에 켜 시계열"이라는 분석의 가정에 원자료를 가깝게 만드는 일이다. 순서는 처음 볼륨 제거 → 움직임 추정 → 슬라이스 타이밍 → 왜곡 보정 → 정합·정규화 → 평활화 → 잡음 제거 → 품질 점검이고, 공간 변환은 합쳐서 한 번에 적용한다.
- 교차 순서로 TR 2 s에 36장을 찍으면 이웃 슬라이스가 약 1 s 차이 난다. 사건 관련 설계는 1 s 어긋남에 설명 분산의 약 27%를 잃고, 블록 설계는 거의 잃지 않는다. TR이 1 s 아래면 보정의 중요성이 작다.
- 움직임 보정은 강체 6 파라미터를 추정한다. FD는 연속 볼륨 사이 변화의 절댓값 합(회전은 50 mm 호 길이)이고, DVARs는 영상 전체 신호 변화의 제곱 평균 제곱근이다. 카펫 그림은 둘을 시계열과 함께 보여 준다.
- 왜곡 보정은 필드맵이나 역위상 부호화 쌍으로 위상 방향 밀림을 되돌린다. 기능 영상은 BBR로 구조 영상에, 구조 영상은 비선형으로 표준 공간에 맞춘다.
- 평활화 커널은 찾으려는 효과의 크기에 맞을 때 SNR이 가장 크다. 실제 평활도는 커널보다 크다($\sqrt{3^2 + 6^2} = 6.7$ mm).
- 잡음 제거에는 24 파라미터 회귀, CompCor, ICA-AROMA-FIX, RETROICOR, GSR, 스크러빙, 대역 통과 필터가 있다. 모두 자유도를 쓰고, 필터와 회귀는 함께 해야 한다.
- 움직임은 가까운 연결을 올리고 먼 연결을 낮추는 거리 의존 인공물을 만든다. 움직임이 많은 집단과의 비교에서 집단 차이로 오인된다.

방법 절 점검표

방법 절 점검표

- 더미 볼륨을 몇 개 버렸는가? 슬라이스 타이밍 보정을 했는가, 기준 슬라이스는 무엇이고 순서는 사이드카에서 가져왔는가?
- 움직임 지표는 어느 FD 정의이고 문턱은 얼마인가? 참가자 제외 기준(평균 FD, 검열 후 남은 시간)이 미리 정해졌는가?
- 왜곡 보정을 했는가(필드맵, 역위상 쌍, 없음)? 정합 방법(BBR 등)과 표준 공간 템플릿은 무엇인가?
- 평활화 FWHM은 얼마이고, 분석의 공간 규모(작은 구조, 패턴 분석)와 맞는가?
- 잡음 회귀자는 무엇인가(6/24/36 파라미터, CompCor 성분 수, ICA, 생리 기록)? GSR을 했는가, 하지 않은 결과도 있는가?
- 필터 대역과 회귀·검열의 순서는? 남은 자유도나 볼륨 수가 보고되었는가?
- 집단별 평균 FD, 검열된 볼륨 수, 제외된 참가자 수가 표에 있고, 움직임이 공변량이나 맞춤으로 통제되었는가?
- 어떤 파이프라인(fMRIPrep 등)의 어느 버전을 썼고, 품질 보고서를 공개했는가?

확인 문제

확인 문제

1. TR 2.5 s, 40장, 홀수 먼저 교차 순서다. 한 장의 시간, 3번 슬라이스와 4번 슬라이스의 획득 시각을 구하라.
2. 연속한 두 볼륨 사이 평행이동 변화가 $(-0.05, 0.10, -0.15)$ mm, 회전 변화가 피치 0.3° , 롤 0° , 요 -0.1° 다. Power의 FD를 구하고, 회전을 라디안으로 바꾸지 않고 도 그대로 더했다면 FD가 얼마나 잘못 나오는지 계산하라.
3. 머리가 10분 동안 천천히 2 mm 가라앉았고 그 밖의 움직임은 없었다. TR 2 s일 때 FD는 대략 얼마인가? 이 참가자의 자료에 남을 수 있는 문제는 무엇인가?
4. 에코 간격 0.6 ms, 위상 방향 80줄, 복셀 2.5 mm인 EPI에서 장 어긋남 50 Hz인 복셀은 몇 mm 밀리는가?
5. 원자료 평활도가 FWHM 2.5 mm이고 8 mm 커널로 평활화했다. 결과의 평활도는? 지름 약 5 mm인 구조의 활성을 찾으려 할 때 이 선택의 문제는?
6. aCompCor의 백질 마스크를 침식하지 않고 그대로 쓰면 어떤 일이 생기는가?
7. TR 0.72 s 자료에서 1.1 Hz 심박은 몇 Hz로 접혀 보이는가? 0.01-0.1 Hz 필터가 이것을 지우는가?
8. 환자군의 평균 FD가 0.30 mm, 대조군이 0.12 mm이고, 환자군에서 짧은 거리 연결이 더 강하고 긴 거리 연결이 더 약했다. 이 결과를 해석하기 전에 확인할 것 세 가지를 들어라.

확인 문제 풀이

확인 문제 풀이

1. $2500/40 = 62.5$ ms다. 홀수 20장이 먼저이므로 3번은 두 번째로 62.5 ms에, 4번은 짝수의 두 번째, 곧 전체 22번째로 $21 \times 62.5 = 1312.5$ ms에 찍힌다.
2. 평행이동 뒀은 $0.05 + 0.10 + 0.15 = 0.30$ mm다. 회전은 $50 \times (0.3 + 0.1) \times \pi/180 = 0.349$ mm다. FD ≈ 0.65 mm다. 도 그대로 더하면 $50 \times 0.4 = 20$ mm가 더해져 FD가 20.3 mm로 나온다. 모든 볼륨이 문턱을 넘어 참가자가 통째로 제외될 것이다. 반대로 라디안으로 나온 값을 도로 여기고 한 번 더 라디안으로 바꾸면 회전 뒀이 약 57분의 1로 줄어 움직임을 놓친다.
3. 볼륨 300개에 2 mm이므로 볼륨당 약 0.007 mm다. FD로는 거의 보이지 않는다. 그러나 끝에서는 조직 경계가 2 mm, 곧 복셀의 3분의 2가량 밀려 있다. 움직임 보정으로 위치는 맞추지만, 슬라이스 위치 변화에 따른 스핀 이력과 왜곡 변화가 느린 표류로 남는다. 고역 필터와 움직임 회귀자가 이것을 다룬다. FD만 보고 깨끗한 자료라고 판단하면 안 된다.
4. 대역폭은 $1/(0.6 \text{ ms} \times 80) = 20.8$ Hz/픽셀이다. $50/20.8 = 2.4$ 픽셀, 곧 약 6.0 mm다.
5. $\sqrt{2.5^2 + 8^2} \approx 8.4$ mm다. 정합 필터 원리로 보면 5 mm 구조에는 비슷한 크기의 커널이 가장 좋다. 8.4 mm 평활도는 신호를 주변과 섞어 기대 z를 깎고, 근처의 큰 활성화에 묻히게 하며, 봉우리 위치를 옮긴다.
6. 경계의 회백질 복셀이 마스크에 들어가 신경 신호가 주성분에 섞인다. 그 성분을 회귀하면 회백질의 참 신호까지 지워 연결성과 활성화가 약해진다.
7. 표본화 주파수는 $1/0.72 = 1.39$ Hz, 나이퀴스트는 0.69 Hz다. $1.39 - 1.1 = 0.29$ Hz로 접힌다. 0.1 Hz 위이므로 필터가 지운다. 다만 심박수가 바뀌면 접힌 주파수도 바뀌므로, 심박이 약 1.29-1.49 Hz일 때는 0.1 Hz 아래로 접힐 수 있다. 생리 기록이 있으면 RETROICOR가 더 확실하다.
8. (가) 움직임을 공변량으로 넣거나 집단의 FD를 맞추었는가. (나) 스크리빙 문턱, 검열된 볼륨 수와 제외된 참가자 수가 집단마다 어떤가. (다) QC-FC가 거리에 따라 남아 있는지, 잡음 제거 방법(GSR 유무 포함)을 바꾸어도 결과가 유지되는지. 이 패턴은 [그림 4.7](#)의 움직임 인공물과 모양이 같다.

다음 장으로

이 장에서 원자료를 "같은 조직, 같은 시각, 구조화된 잡음을 줄인 시계열"로 만들었다. 이제 이 시계열에 모형을 맞출 차례다. 5장에서는 자극 시계열과 HRF의 합성곱으로 기대 신호를 만들고, 이 장의 움직임 회귀자와 고역 필터를 설계 행렬 안에 함께 넣는다. 남은 시간 자기상관을 어떻게 다루는지, 그리고 집단 수준으로 어떻게 올라가든지 본다. 휴지기 자료의 연결성은 7장에서 다시 만난다.

5장 fMRI 일반 선형 모형

이 장에서 배울 것 과제 fMRI의 1수준 분석이 실제로 하는 일. 자극 시간표를 HRF와 합성곱해 회귀자를 만들고, 잡음 회귀자와 함께 설계 행렬을 세우고, 복셀마다 β 를 추정해 대비의 t 를 계산한다. 그 t 가 믿을 만하려면 시간 자기상관을 어떻게 다뤄야 하는지, 설계를 어떻게 짜야 효율이 높은지, 피험자 결과를 어떻게 모아 집단 결론을 내는지도 본다. **뇌 연구자에게 왜 필요한가** 과제 fMRI 논문의 작성 지도는 모두 이 장의 계산을 거친 결과다. "표준 HRF와 시간 미분, 움직임 24 파라미터, 128 s 고역 필터, AR(1) 선백화, 요약 통계 방법"이라는 방법 절의 한 줄은 결정 여섯 개를 담고 있다. 각 결정이 결과를 어떻게 바꾸는지 알아야 논문을 비판적으로 읽고 자신의 실험을 설계할 수 있다.

☞ 중고등 복습: 추세선과 연립방정식

산점도에 직선을 하나 긋는다고 하자. 점들이 직선에서 위아래로 벗어난 거리를 **잔차**라 한다. 잔차의 제곱을 모두 더한 값이 가장 작아지는 직선이 **최소제곱 추세선**이다. 엑셀의 "추세선 추가"가 하는 일이 이것이다. 직선 $y = ax + b$ 의 미지수는 a 와 b 두 개다. 점이 두 개면 연립방정식으로 직선 하나가 정확히 정해진다. 점이 200개면 모든 점을 지나는 직선은 없다. 대신 잔차를 가장 작게 하는 a 와 b 를 고른다. fMRI의 GLM도 같다. 한 복셀의 시계열(점 200개)을 "과제 반응 $\times$ 얼마 + 표류 $\times$ 얼마 + 상수"로 설명하고, 그 "얼마"들을 최소제곱으로 고른다. 미지수가 두 개가 아니라 수십 개라는 것만 다르다. 2장에서 이것을 투영으로 보았다.

5.1 신호 모형: 자극 시간표와 HRF의 합성곱

왜 하는가

과제 fMRI의 질문은 "이 복셀의 신호가 과제에 따라 오르내리는가"다. 신호를 그대로 과제 시간표와 비교할 수는 없다. 생리 1권 9장에서 본 것처럼 BOLD는 자극보다 수 초 늦게, 둥글게 번진 모양으로 나타난다. 그래서 먼저 "이 시간표라면 BOLD가 이렇게 보여야 한다"는 예측을 만든다. 이 예측을 **회귀자 (regressor)**라 한다.

무엇을 가정하는가

예측은 자극 시간표와 HRF의 합성곱이다(물리 2권 7장, 생리 1권 9장).

$$x(t) = \sum_k s(t_k) h(t - t_k)$$

s 는 자극이 있는 동안 1, 없는 동안 0인 상자 함수이고, h 는 표준 HRF다. 이 식에는 가정 세 개가 들어 있다. 첫째, BOLD는 선형 시간 불변이다. 사건 두 개의 반응은 각각의 반응의 합이다. 둘째, HRF의 모양은 모든 복셀과 피험자에서 같다. 셋째, 신경 활동은 자극이 있는 동안 일정하다. 셋 다 근사다. 사건 간격이 3-4 s보다 짧으면 선형성이 깨지고, HRF 정점은 사람과 부위에 따라 1-2 s씩 다르다.




그림 5.1 (가) 사건 시간표(회색 상자)를 표준 이중 감마 HRF와 합성곱하면 예측 BOLD(파랑)가 되고, 이것을 TR마다 표본화한 점들이 설계 행렬의 한 열이 된다. 가까운 사건의 반응은 겹쳐 더해지고, 8 s짜리 긴 사건은 더 큰 반응을 만든다. (나) 실제 반응이 표준 HRF보다 2 s 늦으면 표준 HRF 하나로는 정점을 0.80으로 과소 추정한다. 시간 미분을 함께 넣으면 0.97까지 회복된다. (다) 두 기저 함수의 모양.

합성곱은 TR보다 촘촘한 시간 격자에서 계산한 다음 TR마다 표본화한다(그림 5.1 가). 분석 도구는 TR을 16개 안팎의 작은 칸으로 나눠 계산한다. 이때 어느 칸에서 표본을 뽑을지가 슬라이스 획득 시각과 맞아야 한다. 4장의 슬라이스 타이밍 보정을 했다면 기준 슬라이스의 시각에, 하지 않았다면 대략 볼륨의 가운데 시각에 맞춘다. 둘이 어긋나면 회귀자가 TR의 절반만큼 밀려 β 가 작아진다.

대표 도구와 기본 설정

SPM, FSL(FEAT), AFNI(3dDeconvolve) 모두 이중 감마 꼴의 표준 HRF를 기본으로 쓴다. 정점은 약 5-6 s, 언더슈트는 약 15 s 무렵이다. 도구마다 모양과 크기 조정이 조금씩 다르다. 사건 길이도 결정 사항이다. 0 s(순간 사건)로 둘지, 실제 자극 길이나 반응 시간으로 둘지에 따라 회귀자의 높이와 모양이 바뀐다.

β 를 % 신호 변화로 바꾸기

β 는 "회귀자 한 단위당 신호가 얼마나 변하는가"다. 그래서 β 의 크기는 회귀자의 높이에 따라 달라진다. 같은 반응이라도 회귀자 정점을 1로 맞추면 β 가 작고, 0.17로 두면 β 가 그만큼(약 6배) 커져야 같은 반응을 만든다. 분석 도구마다 HRF의 크기 조정이 다르므로 β 를 그대로 도구 사이에 비교하면 안 된다. % 신호 변화는 다음처럼 계산한다.

$$\% \text{신호 변화} = 100 \times \frac{\hat{\beta} \times (\text{회귀자의 기준 높이})}{\text{기저 신호}}$$

기준 높이로는 보통 고립된 사건 하나에 대한 회귀자의 정점, 또는 블록의 고원 높이를 쓴다. 어느 것을 썼는지 밝혀야 숫자가 뜻을 가진다(2장).

예제 5.1 β 를 % 신호 변화로

1 s짜리 사건 회귀자의 정점이 0.17이 되도록 만들어졌다. 한 복셀에서 $\hat{\beta} = 7.4$ 이고 기저 신호(상수항의 β)는 1000이다. (가) 사건 하나에 대한 반응의 % 신호 변화는? (나) 누군가 $\hat{\beta}$ 를 기저 신호로 나누기만 했다면 몇 %라고 보고했겠는가?

풀이 (가) $100 \times 7.4 \times 0.17/1000 \approx 0.13$ %다. 짧은 사건 하나의 BOLD 반응으로 그럴듯한 크기다. (나) $100 \times 7.4/1000 = 0.74$ %다. 실제보다 약 6배 크다. 회귀자 높이를 빼먹으면 이런 차이가 생긴다. 블록 고원 높이를 기준으로 하면 같은 β 가 또 다른 숫자가 된다.

5.2 설계 행렬

열 하나가 설명 하나다

설계 행렬(design matrix) X 는 행이 시점(볼륨), 열이 회귀자인 표다(그림 5.2). TR 2 s로 400 s를 찍으면 행이 200개다. 열은 네 종류로 나뉜다.

1. **조건 회귀자**: 관심 있는 조건마다 한 열이다. 아래 예에서는 조건 A와 B의 16 s 블록이다.
2. **기저 함수 확장**: 표준 HRF의 시간 미분이나 분산 미분이다. 정점이 1-2 s 어긋나도 반응을 흡수한다(그림 5.1 나). 2 s 지연까지는 정점의 대부분을 회복하지만, 3 s 지연이면 미분을 넣어도 0.83 정도만 회복된다.
3. **잡음 회귀자**: 4장의 움직임 파라미터 6개(또는 미분과 제곱까지 24개), CompCor 성분, 스파이크 지시 변수 등이다.
4. **표류와 상수**: 스캐너 표류를 지우는 느린 코사인 함수들과 상수항이다. SPM은 128 s 고역 필터를 이산 코사인 변환(DCT) 회귀자로 넣는다. 400 s 스캔이면 코사인 6개다. FSL은 회귀 전에 데이터와 설계에 같은 고역 필터를 걸고, AFNI는 다항식 회귀자를 넣는다.

무엇을 가정하는가

GLM은 설계 행렬에 들어간 것만 안다. 모형에 넣지 않은 사건은 모두 **암묵적 기저선(implicit baseline)**에 섞인다. 지시문 화면, 반응 버튼, 오류 시행을 모형에서 뺐다면 그 시간의 신호가 "기저"가 된다. 그러면 "A > 기저"의 뜻이 바뀐다. 관심 없는 사건도 따로 회귀자를 주는 것이 원칙이다.




그림 5.2 GLM $y = X\beta + e$ 의 모습. 한 복셀의 시계열 y (200 시점)를 설계 행렬 X 와 β 의 곱, 그리고 잔차 e 로 나눈다. X 의 열은 왼쪽부터 조건 A, B, 각각의 시간 미분, 움직임 6개, 표류 코사인 6개, 상수다(빨간 선이 묶음의 경계). 각 열은 최솟값이 검정, 최댓값이 흰색이 되도록 따로 눈금을 맞췄다. 오른쪽 β 칸에는 관심 회귀자 네 개의 추정값만 색으로 보였다(참값 $A = 12$, $B = 4$).

고역 필터도 가정이다. 128 s 필터는 주기가 128 s보다 긴 성분을 표류로 보고 지운다. 과제의 주기가 그보다 길면 과제 신호까지 지워진다(물리 2권 7장의 예제 7.5). 블록 설계라면 한 주기(켜짐 + 꺼짐)가 필터 차단 주기보다 확실히 짧아야 한다.

흔한 실수

- 움직임 회귀자가 과제와 상관한다. 말하기나 손 움직임 과제에서는 머리 움직임이 과제에 묶여 있다. 움직임 회귀자가 과제 신호의 일부를 가져가 β 가 작아진다. 2장의 공선성 문제다. 회귀자 사이 상관이나 VIF를 확인한다.
- 한 런(run) 안에서 조건이 한 번씩만 나온다. 조건과 표류를 구별할 수 없다.
- 여러 런을 한 설계에 이을 때 런마다 상수항과 표류 회귀자를 따로 주지 않는다.

🧠 뇌로 가는 다리: 혈관이 다른 환자의 HRF

생리 1권 9장에서 본 것처럼 노화, 경동맥 협착, 소혈관 질환은 HRF를 늦추고 낮춘다. 뇌졸중 병변 주변에서는 정점이 수 초 늦어지거나 부호가 뒤집히기도 한다. 표준 HRF 하나만 쓰면 이런 복셀의 β 가 과소 추정되어 "활성 저하"로 보인다. 위 그림에서 2 s 지연만으로도 정점 추정이 20 % 깎였다. 환자군과 대조군을 비교하는 연구라면 시간 미분을 넣고, 미분 β 까지 포함한 크기를 비교하거나, 모양을 가정하지 않는 **FIR(finite impulse response)** 기저로 시점마다 반응을 따로 추정한다. FIR은 사건 뒤 0, 2, 4, ..., 20 s의 반응을 각각 β 로 두는 방식이다. 모양 가정이 없는 대신 미지수가 많아 잡음에 약하고, 사건 간격이 충분히 섞여 있어야 추정된다. 숨 참기 과제로 켄 뇌혈관 반응성(CVR)을 공변량으로 쓰는 방법도 있다.

5.3 추정과 대비

β 는 최소제곱으로, t 는 대비로

복셀마다 최소제곱으로 $\hat{\beta} = (X^T X)^{-1} X^T y$ 를 구한다. 2장에서 본 투영이다. **그림 5.3**은 앞 설계 행렬로 만든 가상 복셀이다. 참 반응은 A 1.2 %, B 0.4 %이고, 표류와 움직임이 그보다 훨씬 크다. 원자료(가)에서는 과제 반응이 거의 보이지 않는다. 잡음 회귀자가 설명한 몫을 빼고 나서야 블록마다 오르내리는 반응이 보인다(나). 추정값은 A 1.26 %(표준오차 0.09 %), B 0.38 %(0.10 %)이고, 95 % 구간이 둘 다 참값을 덮는다(다).




그림 5.3 가상 복셀 하나의 1수준 적합. (가) 원자료(회색)와 전체 모형의 적합값(검정). 느린 표류와 움직임이 신호 변화의 대부분을 차지한다. (나) 원자료에서 움직임, 표류, 미분 회귀자가 설명한 몫을 뺀 나머지와, 조건 A·B 회귀자가 설명하는 성분(파랑). (다) β 를 % 신호 변화로 바꾼 추정값과 95 % 구간(이 그림의 잡음은 백색이라 OLS 구간이 맞다). 가로 막대가 참값 1.2 %와 0.4 %다.

질문은 **대비(contrast)** 벡터 c 로 묻는다. t 의 식은 2장과 같다.

$$t = \frac{c^T \hat{\beta}}{\sqrt{\hat{\sigma}^2 c^T (X^T X)^{-1} c}}$$

$c = [1, 0, 0, \dots]$ 는 "A > 기저", $[1, -1, 0, \dots]$ 는 "A > B", $[0.5, 0.5, 0, \dots]$ 는 "두 조건의 평균 > 기저"다. 잡음 회귀자 자리는 0이다. 평균 대비에서 합을 1로 맞추면 대비 값이 % 신호 변화 단위로 남는다.

같은 데이터라도 대비에 따라 지도가 완전히 달라진다(**그림 5.4**). 두 조건에 똑같이 반응하는 영역 3은 평균 대비에서 가장 강하지만 A - B 대비에서는 사라진다. A를 선호하는 영역 1과 B를 선호하는 영역 2는 A - B 지도에서 부호가 반대로 나온다.




그림 5.4 가상 슬라이스(48×48 복셀)에서 복셀마다 GLM을 맞춘 결과. (가) 대비 벡터. 파랑은 양, 빨강은 음의 가중치다. (나) 두 조건 평균의 t 지도. 세 영역이 모두 보인다. (다) A - B의 t 지도. A를 선호하는 영역 1은 양(t 약 6), B를 선호하는 영역 2는 음(t 약 -6)이고, 두 조건에 같게 반응하는 영역 3은 사라진다(t 약 0.2). 검은 윤곽은 $|t| = 3.34$ (양측 $p = 0.001$, 자유도 191)다.

F 대비는 여러 행을 가진 대비 행렬로 "이 중 어느 것이든 0이 아닌가"를 묻는다. 표준 HRF와 시간 미분을 함께 쓴 경우 두 β 를 함께 F로 검정하면 정점이 어긋난 반응도 잡는다. 방향은 알려 주지 않는다.

예제 5.2 대비의 분산에는 공분산이 들어간다

그림 5.3의 복셀에서 % 신호 변화 단위로 $\hat{\beta}_A = 1.26$, $\hat{\beta}_B = 0.38$ 이고, 추정값의 분산은 $\text{Var}(\hat{\beta}_A) = 0.0088$, $\text{Var}(\hat{\beta}_B) = 0.0100$, 공분산은 0.0028이다. A - B 대비의 t 는?

풀이 대비 값은 $1.26 - 0.38 = 0.88$ 이다. 분산은 $\mathbf{c}^T \text{Cov}(\hat{\beta}) \mathbf{c} = 0.0088 + 0.0100 - 2 \times 0.0028 = 0.0132$ 이므로 표준오차는 약 0.115다. $t = 0.88 / 0.115 \approx 7.7$ 이다. 공분산을 무시하고 두 분산만 더하면 표준오차가 0.137이 되어 t 를 약 6.4로 과소평가한다. 두 β 가 표류 같은 공통 잡음을 함께 받아 같은 방향으로 흔들리면 차이는 오히려 안정해진다. $\mathbf{c}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{c}$ 가 이 공분산을 자동으로 계산한다.

직접 맞춰 보기

아래 코드는 numpy와 scipy만으로 블록 설계 복셀 하나를 만들고 GLM을 맞춘다. 참 효과는 기저선의 1%다. 실행하면 % 신호 변화 약 0.99, t 약 13이 나온다. 잡음 표준편차를 바꾸거나 표류 열을 빼 보면 t 가 어떻게 변하는지 볼 수 있다.

```

import numpy as np
from scipy.stats import gamma, t as tdist

TR, n = 2.0, 200
hrf = gamma.pdf(np.arange(0, 32, TR), 6) - gamma.pdf(np.arange(0, 32, TR), 16) / 6
box = (np.arange(n) * TR % 40 < 20).astype(float) # 20 s 켜짐 / 20 s 꺼짐
x = np.convolve(box, hrf)[:n]
x = x / x.max() # 회귀자 고원 높이 = 1
X = np.column_stack([x, np.linspace(-1, 1, n), np.ones(n)]) # 과제, 선형 표류, 상수

rng = np.random.default_rng(0)
y = X @ [10.0, 5.0, 1000.0] + rng.normal(0, 5, n) # 참 효과 = 기저선의 1 %

b = np.linalg.lstsq(X, y, rcond=None)[0] # 최소제곱 추정
e = y - X @ b # 잔차
df = n - X.shape[1] # 자유도 197
c = np.array([1.0, 0.0, 0.0]) # 대비: 과제 > 기저
se = np.sqrt(e @ e / df * (c @ np.linalg.inv(X.T @ X) @ c))
tval = c @ b / se
p = 2 * tdist.sf(abs(tval), df) # 양측 p
print(f"% 신호 변화 {100 * b[0] / b[2]:.2f}, t = {tval:.1f}, p = {p:.1e}")

```

이 코드는 잡음을 백색으로 만들었다. 실제 fMRI 잡음은 그렇지 않다. 다음 절의 주제다.

5.4 시간 자기상관과 선백화

왜 문제인가

fMRI 잡음은 이웃한 시점끼리 닮았다. 느린 생리 요동, 표류의 남은 몫, HRF로 번진 자발 활동 때문이다. 한 시점의 잡음이 바로 앞 시점 잡음의 ρ 배에 새 잡음을 더한 것이라는 모형을 **1차 자기회귀(AR(1))** 라 한다. ρ 는 TR 2 s에서 보통 0.1-0.4이고, TR이 짧을수록 커진다.

자기상관이 있어도 OLS의 β 는 치우치지 않는다. 문제는 표준오차다. OLS 식은 시점 200개가 독립이라고 보지만, 서로 닮은 시점들은 그보다 정보가 적다. 블록 회귀자처럼 느린 회귀자에서는 유효 시점 수가 대략 $N(1 - \rho)/(1 + \rho)$ 로 줄고, t 는 $\sqrt{(1 + \rho)/(1 - \rho)}$ 배쯤 부풀려진다. $\rho = 0.3$ 이면 약 1.36배다.

그림 5.5 은 효과가 전혀 없는 가상 복셀 3000개로 이것을 확인한다. $\rho = 0.3$ 에서 OLS의 t 는 표준편차가 1.33으로, 1이어야 할 값보다 크다. 그 결과 $p < 0.05$ 로 "유의"한 복셀이 13 %다. 명목 5 %의 두 배가 넘는다. $\rho = 0.5$ 면 22 %다.

선백화

해법은 **선백화(whitening)** 다. 자기상관을 추정한 다음, 데이터와 설계 행렬에 똑같이 "앞 시점의 $\hat{\rho}$ 배를 빼는" 필터를 걸어 잡음을 백색으로 만든다. 그다음 OLS를 하면 표준오차가 맞는다. 데이터에만 걸고 설계 행렬에 걸지 않으면 모형이 어긋난다.




그림 5.5 효과가 없는 가상 복셀에 AR(1) 잡음을 넣고 20 s/20 s 블록 회귀자로 GLM을 맞췄다(복셀 3000개). (가) $\rho = 0.3$ 일 때 잔차의 자기상관. OLS 잔차는 시차 1에서 약 0.24로, 참값 0.3보다 작게 나온다. 선택화 뒤에는 거의 0이다. (나) 거짓 양성률. OLS는 ρ 와 함께 커져 0.3에서 13 %, 0.5에서 22 %다. 잔차로 추정한 $\hat{\rho}$ 로 선택화하면 6~8 %로 줄고, 참 ρ 를 알면 5 %에 붙는다.

그림의 파란 선이 5 %에 딱 붙지 않는 이유도 배울 거리다. 잔차의 자기상관은 참 자기상관보다 작게 나온다. 회귀자를 맞추면서 잔차의 일부 구조가 함께 빠지기 때문이다. 그래서 도구들은 추정을 보정하거나, 이웃 복셀의 추정을 모아 안정시킨다.

대표 도구와 기본 설정

- SPM은 AR(1) + 백색 잡음 모형을 쓰고, 활성이 큰 복셀들에서 모은 하나의 자기상관 구조를 뇌 전체에 적용한다. 계산은 안정적이지만 복셀마다 다른 자기상관을 놓친다.
- FSL(FILM)은 복셀마다 잔차의 자기상관을 추정하고, 매끄럽게 깎은 뒤 공간적으로 평활해서 쓴다 (Woolrich 외 2001).
- AFNI(3dREMLfit)는 복셀마다 ARMA(1,1) 모형을 맞춘다.

방법들의 차이는 작지 않다. 공개 데이터 여러 개를 비교한 연구는 짧은 TR에서 뇌 전체에 하나의 단순한 자기상관 모형을 쓰면 거짓 양성이 늘고, 복셀마다 유연하게 추정할수록 낮다고 보고했다(Olszowy 외 2019). 다중 대역 EPI로 TR이 1 s 아래가 되면 자기상관이 더 길게 이어지므로 이 차이가 커진다.

예제 5.3 자기상관을 무시한 t

TR 2 s, 시점 200개 블록 설계에서 OLS로 $t = 2.5$ (자유도 192, 양측 $p \approx 0.013$)를 얻었다. 잡음의 AR(1) 계수는 0.3이다. (가) 유효 시점 수는 대략 얼마인가? (나) 자기상관을 고려한 t는 대략 얼마인가? 여전히 유의한가?

풀이 (가) $200 \times 0.7/1.3 \approx 108$ 이다. 200개 중 실제로 독립인 정보는 절반 남짓이다. (나) 부풀림 배수는 $\sqrt{1.3/0.7} \approx 1.36$ 이므로 $t \approx 2.5/1.36 \approx 1.83$ 이다. 자유도를 약 107로 잡으면 양측 $p \approx 0.07$ 로 0.05를 넘는다. 이 설계 행렬로 정확히 계산한 배수는 1.34로 어렵과 거의 같다.

5.5 설계 효율

같은 시간, 다른 검정력

2장에서 t 의 분모에 $\mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c}$ 가 있다고 했다. 이 값은 데이터를 얻기 전에 설계만으로 계산된다. 그 역수를 **설계 효율(design efficiency)**이라 한다.

$$\text{효율} = \frac{1}{\mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c}}$$

잡음이 같다면 효율이 4배인 설계는 표준오차가 절반이다. 효율은 대비마다 다르다. "A > 기저"에 좋은 설계가 "A > B"에도 좋은 것은 아니다.

그림 5.6 는 400 s 동안 1 s짜리 시행을 다섯 가지로 배치해 효율을 계산한 것이다. "A > 기저"에서는 블록 설계(100)가 압도적이다. 시행 간격(SOA)을 4 s로 고정한 빠른 사건 설계는 3에 불과하다. 시행 수는 블록과 비슷하지만 반응이 겹쳐 거의 일정한 높이의 회귀자가 되고, 그것이 상수항과 구별되지 않기 때문이다. 같은 평균 간격이라도 간격을 무작위로 흔들면(**지터**, jitter) 19로, 2 s 격자의 절반을 비워 두는 **널 사건(null event)**을 섞으면 30으로 오른다. 회귀자가 크게 오르내려야 효율이 높다.

"A > B"는 이야기가 다르다. 4 s 고정 간격이라도 A와 B를 무작위 순서로 섞으면 두 회귀자의 차이는 크게 오르내린다. 효율이 29로, 지터(27)나 널 사건(30) 설계와 비슷하다. 차이만 묻는 실험이라면 빠른 고정 간격도 괜찮다. 기저선 대비 반응이 필요하다면 지터나 널 사건이 필요하다.




그림 5.6 (가) 400 s 실험의 다섯 가지 시행 배치 중 처음 120 s. 회색 눈금이 1 s짜리 시행, 파랑이 예측 BOLD다(모든 줄에 같은 눈금). 빠른 고정 설계의 예측 BOLD는 거의 평평하다. (나) 상대 설계 효율(블록 = 100, 백색 잡음 가정, 무작위 배치는 100번 평균). 시행 수는 위에서부터 100, 24, 95, 80, 87개다. "A - 기저"(파랑)에서는 빠른 고정 설계가 3으로 가장 나쁘지만, A와 B를 무작위로 섞은 "A - B"(빨강)에서는 29로 지터나 널 사건 설계와 비슷하다.

효율만이 기준은 아니다

블록 설계가 효율이 높다고 늘 블록을 쓰지는 않는다.

- **검출과 추정의 맞바꿈:** 블록 설계는 반응이 있는지는 잘 찾지만 HRF의 모양은 거의 알려 주지 않는다. 지터를 준 사건 설계는 검출력이 낮은 대신 모양을 잘 추정한다(Liu 외 2001).
- **심리적 문제:** 블록 안에서는 다음 자극을 예측할 수 있고, 습관화와 전략이 생긴다. 시행마다 반응(정답, 오류, 기억 성공)에 따라 나누는 분석은 사건 설계라야 가능하다.
- **선형성:** 간격이 아주 짧으면 BOLD가 선형 예측보다 작다. 효율 계산은 선형을 가정하므로 짧은 SOA의 이득을 과대평가한다.
- **잡음 색:** 위 계산은 백색 잡음을 가정했다. 실제 잡음은 저주파가 강하므로 아주 느린 블록(주기 수 분)은 표류와 함께 지워진다.

설계 도구들은 시행 순서와 간격을 수천 번 무작위로 만들어 원하는 대비의 효율이 가장 높은 것을 고른다. 이론적으로 좋은 순서열(m-수열 등)을 쓰는 방법도 있다.

예제 5.4 효율을 스캔 시간으로 환산하기

그림 5.6 의 값을 쓴다. (가) 빠른 고정 설계로 "A > 기저"의 표준오차를 블록 설계와 같게 하려면 스캔 시간이 몇 배 필요한가? (나) 널 사건 설계라면? (다) 표준오차는 각각 블록의 몇 배인가?

풀이 효율은 스캔 시간에 대략 비례하므로 (가) $100/3.3 \approx 30$ 배, (나) $100/30.5 \approx 3.3$ 배다. (다) 표준오차는 효율의 제곱근에 반비례하므로 $\sqrt{30} \approx 5.5$ 배, $\sqrt{3.3} \approx 1.8$ 배다. 빠른 고정 설계로 기저선 대비 활성을 보고한 연구는 검정력이 매우 낮았을 가능성이 크다.

🧠 뇌로 가는 다리: 수술 전 언어 지도와 블록 설계

뇌종양이나 뇌전증 수술 전에 언어 우세 반구와 언어 영역의 위치를 fMRI로 확인한다. 이때 대부분의 기관은 20-30 s 블록의 동사 생성, 문장 완성 같은 과제를 쓴다. 한 사람에게서, 짧은 시간 안에, 확실하게 활성을 검출해야 하기 때문이다. 위 계산처럼 블록 설계는 같은 시간에 사건 설계보다 몇 배 높은 효율을 준다. 환자는 과제 수행이 고르지 않으므로 과제 수행을 확인하고, 종양 주변에서는 혈관 반응성이 떨어져 BOLD가 작게 나올 수 있다는 점(생리 1권 9장)을 판독에 반영한다. 연구용 사건 설계 결과를 개인 수준 임상 판단에 그대로 쓰면 안 되는 이유다.

5.6 집단 분석

요약 통계 방법

1수준 GLM이 끝나면 피험자마다 대비 값 지도가 하나씩 생긴다. 집단 질문("사람들은 평균적으로 A에 더 반응하는가")은 이 지도들을 2수준 GLM에 넣어 묻는다. 피험자 20명이면 y 는 대비 값 20개이고, 설계 행렬은 상수 한 열이면 단일 표본 t 검정이 된다. 두 집단 비교, 공변량(나이, 성별, 수행 점수)도 같은 2수준 설계 행렬의 열로 들어간다. 이것을 **요약 통계 방법(summary statistics approach)** 이라 한다(Holmes와 Friston 1998).

이 방법의 핵심은 피험자 사이 변이를 오차로 쓴다는 것이다(2장의 무작위 효과). 그림 5.7 가는 가상 피험자 20명이다. 개인마다 피험자 내 잡음의 95 % 구간(파란 가로선)은 좁지만, 사람 사이 차이가 그보다 훨씬 크다. 모든 시계열을 이어 붙인 **고정 효과** 분석은 피험자 내 잡음만 보아 $t = 7.7$ 을 낸다. 요약 통계

방법은 $t = 3.5$ 다. 앞의 숫자는 "이 20명에게서"라는 결론에만 맞고, 모집단에 대한 결론은 뒤의 숫자로 내려야 한다.




그림 5.7 두 수준 분석의 합성 예(참 집단 평균 0.4 %, 피험자 간 표준편차 0.6 %, 피험자 내 표준오차 약 0.3 %). (가) 피험자 20명의 대비 추정값과 피험자 내 95 % 구간. 아래 두 점은 집단 평균이다. 피험자 사이 변이를 무시한 고정 효과(보라)의 구간은 좁고 $t = 7.7$ 이며, 요약 통계 방법(빨강)은 $t = 3.5$ 다. (나) 피험자 수에 따른 기대 집단 t . 스캔 시간을 4배로 늘려도(초록 점선) t 는 조금만 오른다. 사람 사이 변이가 지배하기 때문이다. 피험자 간 차이가 없다고 보는 고정 효과의 기대 t (보라 점선)는 현실과 동떨어지게 크다.

혼합 효과 모형

단순한 요약 통계 방법은 피험자마다 추정의 정밀도가 달라도 모두 같은 무게로 센다. FSL의 FLAME과 AFNI의 3dMEMA는 1수준의 분산(피험자 내 불확실성)까지 2수준에 넘겨, 잡음이 큰 피험자의 무게를 줄이는 **혼합 효과** 추정을 한다. SPM은 기본적으로 대비 값만 넘기는 방식이다. 시뮬레이션 비교에서는 피험자 내 분산이 사람마다 크게 다르지 않는 한 단순한 방법도 거짓 양성을 잘 통제한다고 알려져 있다(Mumford와 Nichols 2009). 이득은 주로 일부 피험자가 유난히 잡음이 큰 경우에 생긴다.

무엇을 가정하는가, 혼한 실수

- 2수준에 넣는 것은 대비 값(β 조합)이다. 1수준 t 지도를 넣으면 효과 크기 대신 "그 사람의 데이터가 얼마나 깨끗했나"를 평균하게 된다.
- 모든 피험자의 회귀자 크기 조정과 대비가 같아야 한다. 어떤 피험자는 오류 시행 때문에 조건이 하나 빠졌다면 대비의 뜻이 바뀐다.
- 공변량은 중심화 방식(전체 평균 또는 집단별 평균)에 따라 집단 효과의 뜻이 바뀐다(2장).
- 반복 측정 설계(조건 세 개 이상, 집단 $\times$ 조건)는 분산 구조를 바르게 지정해야 한다. 가능하면 1수준에서 차이 대비를 만들어 2수준에서는 단순한 t 검정으로 묻는 편이 안전하다.

예제 5.5 집단 t와 표본 수

피험자 20명의 A > B 대비 값이 평균 0.52 %, 표준편차 0.66 %다. (가) 집단 t와 p는? (나) 효과 크기 d는? (다) 피험자 간 표준편차 0.6 %, 피험자 내 표준오차 0.3 %, 참 평균 0.4 %일 때 기대 t를 20명, 40명, 그리고 20명이 스캔 시간을 4배로 늘린 경우로 비교하라.

풀이 (가) 표준오차는 $0.66/\sqrt{20} \approx 0.148$ 이고 $t \approx 0.52/0.148 \approx 3.5$, 자유도 19에서 양측 $p \approx 0.0024$ 다. (나) $d = 0.52/0.66 \approx 0.79$ 다. (다) 개인 대비 값의 분산은 $0.6^2 + 0.3^2 = 0.45$ 다. 20명이면 $t = 0.4/\sqrt{0.45/20} \approx 2.67$, 40명이면 ≈ 3.77 이다. 스캔 시간 4배면 피험자 내 분산이 0.09/4로 줄어 $t = 0.4/\sqrt{0.3825/20} \approx 2.89$ 다. 같은 스캔 시간의 총량을 쓴다면 사람을 늘리는 쪽이 훨씬 낫다. 다만 개인의 지도가 중요한 연구(정밀 fMRI, 수술 전 지도)는 사정이 다르다.

흔한 오해: 1수준 t가 크면 그 사람의 반응이 크다

1수준 t는 효과 크기와 그 사람의 데이터 품질을 함께 담는다. 움직임이 적고 스캔이 긴 사람은 반응이 작아도 t가 크다. 그래서 "환자의 t가 대조군보다 작다"는 결과는 반응이 작다는 뜻일 수도, 환자가 더 움직였다는 뜻일 수도 있다. 개인 사이를 비교하거나 행동 점수와 상관을 볼 때는 t가 아니라 % 신호 변화로 바꾼 대비 값을 쓰고, 움직임 지표(FD)를 공변량으로 확인한다. 같은 이유로 집단 분석에 1수준 t 지도를 넣는 것도 피한다.

5.7 확장: 같은 틀에서 다른 질문

GLM의 틀은 그대로 두고 회귀자만 바꿔서 다른 질문을 할 수 있다.

- **매개 변조(parametric modulation):** 시행마다 다른 값(난이도, 보상 크기, 반응 시간)을 곱한 회귀자를 하나 더 넣는다. "반응이 이 값에 따라 커지는가"를 묻는다. 변조 값은 평균을 빼서 넣는다. SPM은 기본 설정에서 변조 회귀자를 앞 회귀자에 대해 순서대로 직교화하므로, 회귀자 순서가 결과를 바꾼다. 2장에서 본 대로 직교화는 공유 몫을 한쪽에 몰아줄 뿐이다.
- **정신생리 상호작용(PPI, psychophysiological interaction):** 씨앗 영역의 시계열, 과제 회귀자, 그리고 둘의 곱을 넣는다. 곱의 β 는 "씨앗과의 결합이 과제에 따라 달라지는가"를 묻는다(Friston 외 1997). 곱은 BOLD가 아니라 신경 수준에서 만들어야 하므로 씨앗 시계열을 역합성곱한 뒤 곱하고 다시 HRF와 합성곱한다. 조건이 여럿이면 조건마다 곱 항을 주는 일반화 PPI를 쓴다. 검정력이 낮고 씨앗과 과제의 주효과를 함께 넣지 않으면 해석이 틀린다. 7장의 기능 연결성과 이어진다.
- **단일 시행 추정:** 다변량 패턴 분석에는 시행마다 β 가 필요하다. 시행마다 회귀자를 하나씩 주는 방법(LSA)은 빠른 사건 설계에서 이웃 회귀자끼리 공선성이 커 β 가 불안정하다. 한 번에 한 시행만 따로 두고 나머지를 한 열로 묶어 시행 수만큼 GLM을 되풀이하는 **LSS(least squares-separate)**가 이를 줄인다(Mumford 외 2012).
- **표상 유사성 분석(RSA):** 조건이나 시행마다의 β 패턴 사이 거리를 행렬로 만들고, 이를 모형이 예측하는 거리 행렬과 비교한다(Kriegeskorte 외 2008). 활성의 크기 대신 패턴의 구조를 본다. 13장의 기계학습과 이어진다.

🧠 뇌로 가는 다리: 과제 fMRI 결과 표 읽기

과제 fMRI 논문의 결과 표는 보통 영역 이름, 반구, MNI 좌표(x, y, z, mm), 피크 t 또는 Z, 군집 크기 k로 이루어진다. 읽을 때 확인할 것은 다음과 같다. 첫째, 좌표가 피크 하나일 뿐이라는 점이다. 군집 크기가 2,000 voxel이고 voxel이 2 mm 등방이면 부피는 16 mL로, 여러 해부 영역에 걸친다. 피크 하나의 해부 이름표가 군집 전체의 이름이 아니다. 둘째, k의 단위다. voxel 수인지 mm³인지, 어떤 voxel 크기로 다시 표본화한 뒤인지 확인한다. 1수준 3 mm voxel과 표준 공간 2 mm voxel에서 같은 부피의 k는 3.4배 다르다. 셋째, 문턱이다. "p < 0.001 비보정, k > 10"과 "군집 형성 p < 0.001, 군집 수준 FWE p < 0.05"는 전혀 다른 보증이다(6장). 넷째, 어느 대비의 표인가. "A > 기저" 표에 나온 영역이 "A > B"에서도 나온다는 보장은 없다(그림 5.4). 다섯째, 좌표계와 템플릿이다. Talairach 좌표와 MNI 좌표를 섞으면 수 mm가 어긋난다(1장).

핵심 정리

핵심 정리

- 회귀자는 자극 시간표를 표준 HRF와 합성곱해 TR마다 표본화한 것이다. 선형 시간 불변, 모든 voxel에서 같은 HRF, 자극 동안 일정한 신경 활동을 가정한다.
- 설계 행렬은 조건 회귀자, 기저 함수 확장(시간 미분), 잡음 회귀자(움직임 등), 표류(128 s DCT 등)와 상수로 이루어진다. 모형에 넣지 않은 사건은 암묵적 기저선에 섞인다.
- β 의 크기는 회귀자의 높이 조정에 달려 있다. % 신호 변화는 $\beta \times \text{기준 높이} / \text{기저 신호}$ 로 계산하고 기준을 밝힌다.
- 대비 t의 분산에는 β 사이의 공분산이 들어간다. 같은 데이터라도 대비에 따라 지도가 완전히 달라진다.
- 시간 자기상관을 무시하면 t가 부풀려진다. $\rho = 0.3$ 에서 거짓 양성률이 약 13 %, t 배수는 약 1.36이다. 선택화는 데이터와 설계 행렬에 같은 필터를 건다.
- 설계 효율 $1/\mathbf{c}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{c}$ 는 데이터 없이 계산된다. 기저선 대비에는 블록 설계가 가장 효율적이고, 빠른 고정 간격 사건 설계는 가장 나쁘며, 지터와 널 사건이 이를 개선한다. A - B는 무작위 순서만으로도 효율이 높다.
- 집단 분석은 피험자별 대비 값을 2수준 GLM에 넣는 요약 통계 방법이 기본이다. 혼합 효과 방법은 피험자 내 분산까지 반영한다. 집단 t를 키우는 것은 스캔 시간보다 피험자 수다.
- 매개 변조, PPI, LSS, RSA는 모두 같은 GLM 틀에서 회귀자를 바꾼 확장이다.

방법 절 점검표

방법 절 점검표

- 어떤 HRF와 기저 함수(표준, 미분, FIR)를 썼는가? 사건 길이는 0 s인가, 실제 길이나 반응 시간인가? 환자나 노인 집단이라면 HRF 차이를 어떻게 다뤘는가?
- 설계 행렬에 무엇이 들어갔는가? 오류 시행, 지시문, 반응 같은 관심 밖 사건을 모형에 넣었는가? 움직임 회귀자는 몇 개이고 과제와 얼마나 상관하는가?
- 고역 필터 차단 주기와 과제 주기가 맞는가? 블록 한 주기가 차단 주기보다 짧은가?
- 시간 자기상관을 어떤 모형(AR(1), 복셀별 추정, ARMA)으로 다뤘는가? TR이 짧은 다중 대역 자료라면 특히 확인한다.
- 설계 효율이나 시행 간격 분포를 보고했는가? 빠른 사건 설계에서 기저선 대비를 주장한다면 지터나 널 사건이 있었는가?
- 대비가 정확히 무엇인가? " $A > \text{기저}$ "와 " $A > B$ " 중 어느 결과인가? % 신호 변화는 어떤 기준 높이로 계산했는가?
- 집단 분석이 무작위 효과(요약 통계 또는 혼합 효과)인가? 2수준에 넣은 것이 대비 값인가, t 지도인가? 공변량과 중심화 방식은?
- 결과 표의 문턱, 군집 크기 단위, 좌표계, 대비가 명시되어 있는가?

확인 문제

확인 문제

1. 80 s 켜짐 / 80 s 꺼짐 블록 설계를 SPM 기본값 128 s 고역 필터로 분석했다. 무슨 일이 일어나는가? 어떻게 고쳐야 하는가?
2. 사건 회귀자의 정점이 0.5가 되도록 만들어졌고, $\hat{\beta} = 3.0$, 기저 신호는 800이다. 사건 하나의 % 신호 변화는?
3. 조건 A, B, C가 있고 각각 표준 HRF와 시간 미분 두 열을 가진다(열 순서: A, A', B, B', C, C', 그 뒤 잡음 회귀자). " $A > B$ 와 C의 평균"을 묻는 대비 벡터를 써라. 세 조건의 반응 중 어디든 차이가 있는지 방향 없이 묻고 싶다면 어떤 검정을 쓰는가?
4. 잡음의 AR(1) 계수가 0.4인 복셀에서 OLS로 $t = 3.0$ 을 얻었다. 자기상관을 고려하면 t는 대략 얼마인가? 유효 시점 수는(시점 200개)?
5. 어떤 사건 설계의 " $A > \text{기저}$ " 효율이 블록 설계의 30 %다. 같은 표준오차를 얻으려면 스캔 시간이 몇 배 필요한가? 그런데도 이 사건 설계를 고를 이유는 무엇인가?
6. 피험자 16명의 대비 값이 평균 0.30 %, 표준편차 0.50 %다. 집단 t와 p는? 같은 데이터를 고정 효과로 분석해 $t = 9$ 를 얻었다면 두 결과는 각각 무엇에 대한 결론인가?
7. 빠른 사건 설계 데이터로 시행별 패턴 분류를 하려 한다. 시행마다 회귀자를 하나씩 둔 GLM의 β 가 불안정한 이유와 대안을 말하라.

확인 문제 풀이

확인 문제 풀이

1. 과제 주기가 160 s이므로 기본 주파수는 $1/160 \approx 0.0063$ Hz다. 128 s 필터는 $1/128 \approx 0.0078$ Hz보다 느린 성분을 지우므로 과제 신호의 대부분이 표류로 지워진다. 블록을 20-30 s로 줄여 다시 설계하는 것이 가장 좋고, 이미 찍었다면 필터 차단 주기를 과제 주기보다 충분히 길게(예: 과제 주기의 1.5-2배 이상) 잡는다. 그 대가로 느린 표류가 더 남는다.
2. $100 \times 3.0 \times 0.5/800 \approx 0.19$ %다.
3. $\mathbf{c} = [1, 0, -0.5, 0, -0.5, 0, 0, \dots]$ 다. 미분 열과 잡음 회귀자 자리는 0이다. 방향 없이 세 조건 사이의 어떤 차이든 묻는다면 $A - B$ 와 $B - C$ (필요하면 미분 열까지) 두 행 이상으로 이루어진 F 대비를 쓴다.
4. 배수는 $\sqrt{1.4/0.6} \approx 1.53$ 이므로 $t \approx 3.0/1.53 \approx 1.96$ 이다. 유효 시점 수는 $200 \times 0.6/1.4 \approx 86$ 이다. 자유도 약 85의 양측 0.05 임계값(약 1.99)에 못 미친다. OLS로는 $p \approx 0.003$ 으로 보였던 결과다.
5. $100/30 \approx 3.3$ 배다. 그래도 사건 설계를 고르는 이유는 시행을 반응(정답, 오류, 기억 성공)에 따라 나눠 분석할 수 있고, 자극을 예측할 수 없어 습관화와 전략이 줄며, HRF 모양을 추정할 수 있기 때문이다.
6. 표준오차 $0.50/\sqrt{16} = 0.125$, $t = 2.4$, 자유도 15에서 양측 $p \approx 0.03$ 이다. 요약 통계 방법은 사람 사이 변이를 오차로 쓰므로 모집단에 대한 결론이다. 고정 효과의 $t = 9$ 는 피험자 내 잡음만으로 계산한 것으로 "이 16명에서"라는 결론에만 맞는다.
7. SOA가 짧으면 이웃 시행의 회귀자가 크게 겹쳐 공선성이 커지고(2장의 VIF), 시행마다의 β 분산이 커진다. 한 시행만 따로 두고 나머지를 한 열로 묶어 시행 수만큼 GLM을 되풀이하는 LSS를 쓰거나, 설계 단계에서 SOA를 늘린다.

다음 장으로

이 장의 끝에서 우리는 복셀마다 t 하나씩, 뇌 전체에 걸쳐 10만 개 가까운 t 를 손에 쥐었다. 효과가 전혀 없어도 그중 5 %, 약 5000개는 $p < 0.05$ 를 넘는다. 6장에서는 이 다중비교 문제를 다룬다. 본페로니와 무작위장 이론으로 FWE를 통제하는 방법, FDR, 군집 수준 추론과 그 논쟁, 순열 검정과 TFCE, 그리고 관심 영역 분석의 순환성까지, 이 장에서 만든 t 지도를 "어디가 정말 활성화인가"라는 결론으로 바꾸는 단계를 본다.

6장 다중비교와 통계적 추론

이 장에서 배울 것 복셀 수만 개에서 동시에 검정할 때 생기는 거짓 양성(양성)의 규모, 가족 오류율(FWE)을 통제하는 본페로니 보정과 무작위성 이론, 거짓 발견률(FDR), 군집 수준 추론과 그 논쟁, 순열 검정과 TFCE, 관심 영역 분석의 순환성, 그리고 결과를 정직하게 보고하는 법. 뇌 연구자에게 왜 필요한가 5장의 GLM은 복셀마다 t 지도를 만든다. 그 지도에서 어디를 "활성화"라고 부를지는 이 장의 선택으로 정해진다. 같은 지도도 문턱 방법에 따라 결과 표가 크게 달라지고, 잘못된 선택은 죽은 언어에서도 활성화를 찾아낸다. 논문의 결과 표와 그림을 믿을 수 있는지 판단하려면 그 표가 어떤 추론에서 나왔는지 읽을 줄 알아야 한다.

5 중고등 복습: '적어도 한 번'의 확률

서로 영향을 주지 않는 사건들을 독립(independent)이라 한다. 독립 사건이 모두 일어날 확률은 각 확률의 곱이다. 동전 두 개가 모두 앞면일 확률은 $\frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$ 다. "적어도 한 번 일어날 확률"은 여사건(complementary event)으로 구하는 것이 쉽다. 한 번도 일어나지 않을 확률을 1에서 빼다. 주사위를 네 번 던져 6이 적어도 한 번 나올 확률은 $1 - (5/6)^4 \approx 0.52$ 다. 한 번에 1/6밖에 안 되는 일도 네 번 시도하면 절반이 넘는다. 확률 p 인 일을 n 번 시도하면 평균적으로 np 번 일어난다. 이것을 기댓값(expected value)이라 한다. 2장에서 본 것처럼 귀무가설이 참이면 p 값은 0과 1 사이에 고르게 퍼지므로, 검정을 n 번 하면 $p < 0.05$ 가 평균 0.05 n 번 나온다. 이 장 전체가 이 두 계산에서 출발한다.

6.1 문제의 크기

10만 번의 동전 던지기

2 mm 복셀로 뇌를 덮으면 복셀이 대략 10만-20만 개다. 5장의 GLM은 복셀마다 대비 t를 하나씩 계산한다. 결국 같은 질문을 10만 번 던지는 셈이다. 어느 복셀에도 참 효과가 없다고 하자. 보정 없이 $p < 0.05$ 를 쓰면 기댓값으로 $100\,000 \times 0.05 = 5000$ 개 복셀이 우연히 "유의"하다. $p < 0.001$ 로 엄격하게 해도 100개가 남는다.

검정 하나하나의 1종 오류율 α 는 그대로다. 문제는 연구 전체의 오류다. 검정 m 개 가운데 하나라도 거짓 양성이 나올 확률을 가족 오류율(familywise error rate, FWER)이라 한다. 검정이 독립이면

$$\text{FWER} = 1 - (1 - \alpha)^m$$

이다. $\alpha = 0.05$ 에서 검정 14개면 FWER가 이미 51 %이고, 100개면 99.4 %다(그림 6.1). 복셀 10만 개에서는 사실상 1이다. 거짓 양성이 하나라도 나오는 것은 확실하고, 문제는 몇 개냐일 뿐이다.




그림 6.1 (가) 독립 검정 m 개 중 하나라도 거짓 양성일 확률. $\alpha = 0.05$ 에서는 검정 14개면 절반을 넘고 100개면 99 %를 넘는다. 회색은 본페로니 문턱 $0.05/10^5$ 로, 10만 개에서도 5 % 아래에 머문다. (나) 보정하지 않을 때 거짓 양성의 기댓값 $m\alpha$. 복셀 10만 개에서 $p < 0.001$ 로도 100개가 남는다.

평활한 잡음은 덩어리를 만든다

실제 영상의 잡음은 복셀마다 독립이 아니다. 4장의 공간 평활화와 영상 자체의 점 퍼짐 때문에 이웃 복셀이 함께 오르내린다. 그래서 거짓 양성도 날개의 점이 아니라 그럴듯한 덩어리로 나온다. **그림 6.2** 는 신호가 전혀 없는 2차원 잡음장을 FWHM 8픽셀로 평활화한 것이다. 보정 없이 $p < 0.05$ 로 자르면 픽셀의 약 4 % (기댓값은 5 %)가 20개의 덩어리로 칠해진다. 논문의 활성화 그림처럼 보인다. $p < 0.001$ 로 올리면 덩어리가 하나로 준다. 그러나 이것도 "보정했다"는 뜻은 아니다. 지도를 여러 장 만들면 대부분에서 한두 개는 나온다.




그림 6.2 신호가 없는 128×128 잡음장을 FWHM 8픽셀 가우스로 평활화하고 분산을 1로 맞췄다. (나) 보정 없이 $z > 1.64$ 로 자르면 거짓 양성이 둥근 덩어리 20개로 나타난다. (다) $z > 3.09$ 로 올려도 우연한 덩어리가 남는다. 평활한 잡음은 활성화처럼 생긴 모양을 쉽게 만든다.

예제 6.1 보정하지 않은 지도의 거짓 양성

뇌 마스크 안에 복셀이 10만 개 있고, 참 효과는 어디에도 없다. (가) $p < 0.05$ 와 $p < 0.001$ 에서 거짓 양성 복셀의 기댓값은? (나) 복셀이 독립이라면 FWER를 5 %로 묶는 복셀당 문턱은 얼마이고, 단측 z 로는 얼마인가?

풀이 (가) $10^5 \times 0.05 = 5000$ 개, $10^5 \times 0.001 = 100$ 개다. (나) $(1 - \alpha')^{10^5} = 0.95$ 에서 $\alpha' \approx 0.05/10^5 = 5 \times 10^{-7}$ 이다. 표준 정규분포에서 위쪽 넓이가 5×10^{-7} 인 점은 $z \approx 4.89$ 다. 보정 없는 $p < 0.05$ 문턱($z = 1.64$)의 세 배 가까이 된다.

🧠 뇌로 가는 다리: 죽은 언어의 사회 인지

베넷(Bennett)과 동료들은 2009년 학회 포스터에서 죽은 대서양 언어를 스캐너에 넣고, 사회적 상황의 사진을 보여 주며 "사진 속 사람의 감정을 판단하라"는 과제를 주었다. 보정 없이 $p < 0.001$, 3복셀 이상 군집이라는 당시 흔한 기준으로 분석하자 언어의 뇌 안에서 "활성화" 군집이 나왔다. FDR이나 FWE로 보정하자 하나도 남지 않았다. 언어 실험은 농담처럼 보이지만 요점은 진지하다. 수만 개 복셀에서 보정 없는 문턱을 쓰면, 생물학적으로 불가능한 곳에서도 그럴듯한 결과가 나온다. 이 포스터는 이후 다중비교 보정을 빼먹은 전뇌 결과를 경계하는 상징이 되었고, 지금은 보정 없는 전뇌 결과를 주된 결론으로 쓰면 심사에서 거의 받아들여지지 않는다.

6.2 가족 오류율: 본페로니와 무작위장 이론

본페로니 보정

가장 단순한 방법은 **본페로니 보정(Bonferroni correction)** 이다. 원하는 FWER를 검정 수로 나눈 α/m 을 복셀당 문턱으로 쓴다. 검정이 독립이든 아니든 FWER가 α 를 넘지 않는다는 것이 보장된다. 확률의 합이 합집합의 확률보다 작지 않다는 사실만 쓰기 때문이다.

문제는 보수성이다. 이웃 복셀이 함께 움직이면 "실질적으로 독립인 검정"의 수는 복셀 수보다 훨씬 적다. 그런데 본페로니는 복셀 수로 나눈다. 필요 이상으로 엄격한 문턱을 써서 참 효과를 놓친다. [그림 6.3](#)에서 픽셀 16,384개 잡음장의 FWE 5 % 문턱을 시뮬레이션으로 구하면, 평활화하지 않았을 때 $z = 4.50$ 으로 본페로니(4.52)와 거의 같다. FWHM 8픽셀이면 4.00, 16픽셀이면 3.63으로 내려간다. 본페로니는 여전히 4.52를 요구한다.

본페로니를 조금 개선한 **홀름(Holm) 방법**도 있다. p 값을 작은 것부터 $\alpha/m, \alpha/(m-1), \dots$ 과 차례로 비교하다가 처음 실패하는 곳에서 멈춘다. FWER 보장은 같으면서 언제나 본페로니 이상을 찾는다. 다만 복셀 수만 개에서는 차이가 작다.

무작위장 이론과 해상 요소

평활한 지도를 위한 해법은 **무작위장 이론(random field theory, RFT)** 이다. 워슬리(Worsley)와 동료들이 1990년대에 영상에 맞게 정리했고, SPM이 이것으로 FWE 보정을 한다. 생각의 줄기는 다음과 같다.

첫째, 지도를 높은 문턱 z 로 자르면 남는 것은 대개 서로 떨어진 작은 섬들이다. 섬의 수를 세는 위상수학의 양이 **오일러 특성(Euler characteristic, EC)** 이다. 구멍 없는 섬 하나는 1, 구멍이 하나 뚫린 도넛 모양은 0이다. 문턱이 높으면 구멍이 거의 없어서 EC가 섬의 수와 같다.

둘째, 문턱이 높으면 섬이 두 개 이상 생기는 일은 드물다. 그래서 "섬이 하나라도 있을 확률", 곧 최댓값이 z 를 넘을 확률이 EC의 기댓값과 거의 같다.

셋째, 가우스 무작위장의 EC 기댓값은 식으로 계산된다. 3차원에서 문턱이 높을 때의 주향은

$$P(\max Z > z) \approx E[EC] \approx R \frac{(4 \ln 2)^{3/2}}{(2\pi)^2} (z^2 - 1) e^{-z^2/2}$$

이다. R 은 **해상 요소(resolution element, RESEL)**의 수로, 탐색 부피를 평활도의 FWHM 세제곱으로 나눈 값이다. 대략 "FWHM 크기의 정육면체가 몇 개 들어가는가"다. 복셀 수 대신 RESEL 수가 검정의 실질적인 수 노릇을 한다. 평활할수록 RESEL이 적고 문턱이 낮아진다(그림 6.3 보라색). 실제 구현은 경계 효과를 반영하는 낮은 차원의 향도 더한다.




그림 6.3 픽셀 16,384개 잡음장에서 장 전체 최댓값의 95번째 백분위(FWE 5 % 문턱)를 평활화 정도에 따라 구했다. 시뮬레이션(파랑)은 평활할수록 내려가고, 무작위장 이론(보라)은 FWHM이 약 4픽셀 이상에서 시뮬레이션과 잘 맞는다. 평활도가 낮으면 이론값이 본페로니보다 높아져 보수적이 된다. 위 눈금은 RESEL 수다.

가정과 함정

RFT의 가정은 세 가지다. 지도가 가우스 무작위장을 잘 근사할 것, 평활도가 공간에서 대략 일정할 것, 그리고 평활도가 복셀 크기에 비해 충분할 것(경험적으로 FWHM이 복셀의 약 3배 이상)이다. 셋째가 깨지면 이론값이 지나치게 보수적이 된다. 그림 6.3 에서 FWHM 2픽셀일 때 이론 문턱 4.72는 본페로니보다도 높다. SPM이 RFT 문턱과 본페로니 문턱 가운데 작은 쪽을 쓰는 이유다.

평활도는 연구자가 준 커널이 아니라 GLM 잔차에서 추정한다. 6 mm 커널로 평활화해도 영상 자체의 흐림과 생리 잡음이 더해져 실제 평활도는 그보다 크다. FSL의 smoothest, AFNI의 3dFWHMx가 이

추정을 한다. 대표 도구로 보면 SPM은 피크 수준과 군집 수준의 FWE를 RFT로 보고하고, FSL FEAT도 군집 추론에 같은 이론을 쓴다.

예제 6.2 RESEL로 문턱 구하기

MNI 공간의 2 mm 복셀 20만 개(약 1.6 L)를 탐색한다. 잔차에서 추정된 평활도는 FWHM 8 mm다. (가) RESEL 수는? (나) 위 식으로 FWE 5 % 문턱을 구하고 본페로니와 비교하라. (다) 평활도가 FWHM 4 mm라면?

풀이 (가) $R = 1.6 \times 10^6 \text{ mm}^3 / 8^3 \text{ mm}^3 = 3125$ 다. (나) $E[EC] = 0.05$ 가 되는 z 를 수치로 풀면 $z \approx 4.91$ ($p \approx 4.6 \times 10^{-7}$)이다. 복셀 20만 개의 본페로니는 $p = 2.5 \times 10^{-7}$, $z \approx 5.03$ 이다. 문턱이 0.12만큼 낮아진다. 3차원 전뇌에서 이득은 생각보다 작다. (다) $R = 25000$ 이 되고 $z \approx 5.35$ 로 본페로니보다 높다. 평활도가 복셀의 두 배뿐이라 RFT의 근사가 깨진 경우다. 이때는 본페로니 문턱 5.03을 쓴다.

6.3 거짓 발견률

무엇을 통제하는가

FWE는 "거짓 양성"이 하나라도 있으면 실패"로 보는 기준이다. 뇌 전체에서 효과를 탐색할 때는 이 기준이 지나치게 엄격할 수 있다. 활성화가 넓게 퍼진 과제라면, 유의하다고 표시한 복셀 1000개 가운데 몇십 개가 틀려도 결론은 크게 다치지 않는다.

거짓 발견률(false discovery rate, FDR)은 이런 관점의 기준이다. 유의하다고 선언한 것 가운데 거짓의 비율, 곧 **거짓 발견 비율(false discovery proportion)**의 기댓값이다. 선언한 것이 없으면 비율을 0으로 둔다. FDR $q = 0.05$ 로 통제한다는 것은 "이 방법을 반복해서 쓰면, 유의 목록에 섞인 거짓의 비율이 평균 5 % 이하"라는 뜻이다.

벤야미니-호흐베르크 절차

벤야미니(Benjamini)와 호흐베르크(Hochberg, 1995)의 절차는 간단하다.

1. p 값 m 개를 작은 순서로 정렬한다: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$.
2. $p_{(k)} \leq \frac{k}{m} q$ 를 만족하는 가장 큰 k 를 찾는다.
3. $p_{(1)}, \dots, p_{(k)}$ 를 모두 유의하다고 선언한다.

순위가 오를수록 허용 문턱도 같이 오른다. 그래서 진짜 효과가 많을수록 문턱이 너그러워진다. 이 절차는 검정이 독립이거나 서로 양의 상관관계를 가질 때 FDR을 보장한다. 평활한 영상의 복셀들이 대체로 이 조건에 든다.

FDR의 문턱은 데이터에 따라 움직인다. 참 효과가 하나도 없으면 BH는 본페로니에 가까운 문턱을 쓴다 (이때 FDR과 FWER가 같아진다). 효과가 많으면 $p < 0.001$ 보다 너그러울 수도 있다. 같은 q 라도 과제마다, 연구마다 실제 문턱이 다르다는 뜻이다.

예제 6.3 손으로 하는 BH

10개 영역의 p 값이 0.0001, 0.0008, 0.0021, 0.0040, 0.0062, 0.011, 0.020, 0.041, 0.18, 0.62다. 본페로니, 흠, BH($q = 0.05$)로 각각 몇 개가 유의한가?

풀이 본페로니 문턱은 $0.05/10 = 0.005$ 다. 0.0040까지 4개가 유의하다. 흠은 $0.05/10, 0.05/9, \dots$ 곧 0.005, 0.0056, 0.0063, 0.0071, 0.0083, 0.01, $\dots$ 과 차례로 비교한다. 다섯째 $0.0062 \leq 0.0083$ 까지 통과하고 여섯째 $0.011 > 0.01$ 에서 멈춘다. 5개다. BH의 문턱은 $0.005k$ 다. 일곱째 $0.020 \leq 0.035$ 는 통과하고 여덟째 $0.041 > 0.040$ 은 실패한다. 그 뒤로도 통과하는 것이 없으므로 $k = 7$, 7개가 유의하다. 0.041은 보정 전에는 유의했지만 어느 방법에서도 살아남지 못한다.

세 방법을 같은 지도에서 비교한다

그림 6.4 은 피험자 20명의 합성 대비 지도에 크기가 다른 참 효과 세 개를 심고, 단일 표본 t 검정을 한 결과다. 참 신호가 있는 픽셀은 1,135개다. 본페로니는 61개, 순열 최대 통계량(6.5절)은 86개를 찾았고 거짓 양성은 둘 다 없었다. BH는 문턱이 $p \leq 0.0019$ 로 내려와 360개를 찾았다. 그중 27개(약 7.5 %)가 참 신호 밖이다. FDR 통제는 평균에 대한 약속이므로 한 번의 분석에서 5 %를 조금 넘는 것은 이상하지 않다. 거짓 발견은 주로 참 군집의 가장자리에 붙어 있다. 평활한 지도에서 FDR이 틀리는 전형적인 모양이다.




그림 6.4 피험자 20명, 96×96 합성 지도. 파란은 참 양성, 빨강은 거짓 양성 픽셀이다. (다) 정렬한 p 값이 BH 선 qk/m 아래에 머무는 마지막 순위가 $k = 360$ 이다. 본페로니(라)와 순열 최대 t (마)는 거짓 양성 없이 참 효과의 중심만 찾고, BH(바)는 훨씬 많이 찾는 대신 가장자리에 거짓 발견이 섞인다.

흔한 오해: FDR 5 %면 유의 복셀 하나하나가 틀릴 확률이 5 %다

FDR은 목록 전체에 대한 평균 비율이다. 개별 복셀에 대한 약속이 아니다. 목록 안에서도 p값이 아주 작은 피크 복셀은 거의 확실히 참이고, 문턱 근처의 복셀은 틀릴 확률이 훨씬 높다. 또 FDR은 "활성화가 하나라도 있는가"라는 질문에는 답하지 않는다. 작은 군집 하나가 결론의 전부인 연구라면, 그 군집이 거짓일 위험은 FDR 수치보다 클 수 있다. 결론이 특정 위치 하나에 걸려 있다면 FWE를, 넓은 패턴의 탐색이라면 FDR을 고르는 것이 기준에 맞다.

6.4 군집 수준 추론

두 단계 문턱

복셀 하나하나를 FWE로 보정하면 넓고 약한 효과를 놓친다. 그런 효과는 피크가 높지 않아도 넓은 영역에 퍼져 있다. **군집 수준 추론(cluster-level inference)**은 이 점을 이용한다.

1. 먼저 **군집 형성 문턱(cluster-forming threshold, CDT)**으로 지도를 자른다. 예를 들어 $z > 3.1$ ($p < 0.001$)이다.
2. 남은 복셀 가운데 이웃끼리 붙은 덩어리를 군집으로 묶고 크기(복셀 수)를 잰다.
3. 귀무가설 아래에서 "지도 전체의 가장 큰 군집"이 얼마나 큰지의 분포를 구한다. 그 95번째 백분위보다 큰 군집만 FWE 5 %로 유의하다고 한다.

3단계의 분포는 RFT로 계산하거나(SPM, FSL), 같은 평활도의 잡음장을 시뮬레이션하거나(AFNI 3dClustSim), 순열로 만든다(6.5절). 군집 추론은 복셀 수준보다 검정력이 높아 과제 fMRI에서 가장 널리 쓰였다.

군집 형성 문턱이 결과를 바꾼다

그림 6.5은 같은 z 지도를 두 CDT로 분석한 것이다. 왼쪽 위에 가까운 두 봉우리가 있고, 오른쪽 아래에 넓고 낮은 언덕이 있다. $z > 2.3$ 에서는 귀무 지도의 최대 군집이 커서 임계 크기가 74픽셀이다. 두 봉우리는 사이의 골짜기까지 문턱을 넘어 278픽셀짜리 군집 하나로 합쳐진다. $z > 3.1$ 에서는 임계 크기가 26픽셀로 줄고, 두 봉우리가 100픽셀과 53픽셀의 군집으로 나뉜다. 넓은 언덕은 두 문턱 모두에서 살아남지만 크기가 165픽셀에서 66픽셀로 준다.

여기서 군집 추론의 본질적인 한계가 보인다. 유의한 군집이 말해 주는 것은 "이 군집 안 어딘가에 참 신호가 있다"뿐이다. 군집 안의 모든 복셀이 활성이라는 뜻이 아니다. 낮은 CDT에서 군집 하나가 해부 영역 서너 개에 걸쳐 있으면, 그중 어느 영역에 효과가 있는지 이 검정으로는 말할 수 없다. 이것을 **공간 특이성(spatial specificity)**의 손실이라 한다. 큰 군집의 피크 좌표 하나만 표에 적고 그 위치에 해석을 거는 일이 흔한데, 군집 추론은 그 해석을 뒷받침하지 않는다.




그림 6.5 같은 z 지도(128×128 , FWHM 6픽셀)의 군집 추론. 초록 원은 참 신호의 경계, 파랑은 FWE 5 %로 살아남은 군집(숫자는 픽셀 수), 빨강은 임계 크기보다 작아 버려진 군집이다. 낮은 문턱(가)에서는 가까운 두 봉우리가 한 군집으로 합쳐진다. (다) 신호 없는 지도 1000장에서 구한 최대 군집 크기의 분포와 95번째 백분위.

흔한 오해: 유의한 군집의 모든 복셀이 활성화되었다

군집의 p 값은 군집 전체에 대한 것이다. 300복셀 군집이 $p_{FWE} = 0.01$ 이라면, 그 300개 중 적어도 일부에 효과가 있다는 증거가 강하다는 뜻이다. 군집 가장자리의 특정 복셀에 대해서는 아무것도 보장하지 않는다. 군집이 섬엽과 하전두이랑에 걸쳐 있을 때 "두 영역 모두 활성화되었다"고 쓰려면, 각 영역에서 따로 복셀 수준 추론이나 미리 정한 ROI 검정이 필요하다.

🧠 뇌로 가는 다리: 군집 실패 논쟁(Eklund 2016)

에클룬드(Eklund)와 동료들(2016)은 건강한 성인 499명의 휴지기 fMRI를 귀무 데이터로 썼다. 휴지기 데이터에 가짜 과제 설계를 덮어씌우면 참 효과가 없어야 한다. 무작위로 집단을 뽑아 집단 분석을 수백만 번 반복하고, SPM, FSL, AFNI의 기본 파라메트릭 군집 추론이 FWE 5 %를 지키는지 보았다. CDT $p = 0.01$ ($z \approx 2.3$)에서는 실제 FWER가 설정에 따라 최대 약 70 %에 이르렀다. CDT $p = 0.001$ 에서는 훨씬 나아졌지만 일부 설정에서 여전히 명목보다 높았다. 원인은 실제 fMRI 잡음의 공간 자기상관이 가우스 모양보다 꼬리가 길다는 것, 곧 RFT와 시뮬레이션의 가정이 맞지 않는다는 것이었다. AFNI의 군집 시뮬레이션 프로그램에는 이와 별도로 결과를 부풀리는 오류도 있었다(2015년 수정). 반면 순열 검정은 대체로 명목 수준에 가까웠고, 복셀 수준 FWE는 오히려 보수적이었다. 이후 표준이 바뀌었다. CDT는 $p < 0.001$ 또는 그보다 엄격하게 잡고, AFNI는 꼬리가 긴 자기상관 모형을 도입했으며, 순열 기반 추론을 쓰는 연구가 늘었다. 2016년 이전 논문에서 " $p < 0.01$, 군집 보정"이라는 문장을 보면 결과를 한 단계 낮춰 읽는 것이 안전하다.

6.5 비모수 순열 검정과 TFCE

데이터로 귀무 분포를 만든다

RFT는 지도가 가우스 무작위장이라고 가정한다. **순열 검정(permutation test)**은 그런 가정 없이, 데이터를 섞어서 귀무 분포를 직접 만든다. 필요한 가정은 **교환 가능성(exchangeability)** 하나다. 귀무가설이 참이라면 데이터의 이름표를 바꿔 달아도 분포가 같아야 한다.

두 집단 비교라면 환자와 대조군의 이름표를 무작위로 섞는다. 한 집단에서 대비가 0인지 묻는 단일 표본 검정이라면 피험자마다 대비 지도의 **부호를 무작위로 뒤집는다(sign flipping)**. 귀무가설 아래에서 대비가 0을 중심으로 대칭이라면, 부호를 뒤집은 지도도 원래 지도만큼 그럴듯하기 때문이다. 피험자 20명이면 서로 다른 부호 조합이 $2^{20} = 1,048,576$ 가지다. 보통은 그중 수천 개를 무작위로 뽑는다.

최대 통계량이 FWE를 준다

다중비교 보정의 열쇠는 순열마다 지도 전체의 **최댓값 하나만** 모으는 것이다. 그 최댓값들의 분포에서 95번째 백분위를 문턱으로 쓰면, 귀무 지도의 최댓값이 문턱을 넘을 확률이 5 %다. 곧 FWER가 5 %다. 평활도, 자기상관의 모양, 비정규성이 모두 데이터 자체에 들어 있으므로 따로 모형화할 필요가 없다. 군집 크기의 최댓값을 모으면 군집 수준 FWE가 된다.

그림 6.6에서 회색은 순열 한 번의 모든 픽셀 t 값이다. 0 근처에 모여 있다. 파랑은 순열 2000번 각각의 최대 t다. 오른쪽으로 크게 밀려 있다. 이 분포의 95번째 백분위 5.36이 FWE 문턱이고, 본페로니(5.91)보다 낮다. 픽셀들이 평활해서 실질적인 검정 수가 적기 때문이다.




그림 6.6 부호 뒤집기 순열 검정. 회색은 순열 1회의 픽셀별 t 분포, 파랑은 순열 2000회 각각에서 지도 전체 최댓값만 모은 분포다. 최댓값 분포의 95번째 백분위($t = 5.36$)가 FWE 5 % 문턱이다. 본페로니($t = 5.91$)보다 낮고, 비보정 $p < 0.001$ ($t = 3.58$)보다 훨씬 높다.

아래 코드는 이 절차 전체다. numpy와 scipy만으로 돌아간다.

```

import numpy as np
from scipy import ndimage

rng = np.random.default_rng(0)
n, shape = 20, (64, 64)          # 피험자 20명, 64×64 지도
X = ndimage.gaussian_filter(rng.standard_normal((n, *shape)), (0, 2.5, 2.5))
X /= X.std()                     # 신호 없는 대비 지도들
X[:, 20:26, 20:26] += 1.2       # 작은 참 효과를 심는다

def tmap(Y):
    return Y.mean(0) / (Y.std(0, ddof=1) / np.sqrt(len(Y)))

t_obs = tmap(X)
max_null = np.empty(5000)
for i in range(max_null.size):
    flip = rng.choice([-1.0, 1.0], size=n)[: , None, None] # 피험자별 부호 뒤집기
    max_null[i] = tmap(X * flip).max()                    # 지도 전체의 최댓값만 모은다

t_crit = np.quantile(max_null, 0.95)                    # FWE 5 % 문턱
srt = np.sort(max_null)
p_fwe = (1 + srt.size - np.searchsorted(srt, t_obs)) / (1 + srt.size)
print(f"문턱 t = {t_crit:.2f}, 유의 픽셀 {(p_fwe < 0.05).sum()}개")
print(f"최소 p_FWE = {p_fwe.min():.4f}")

```

실행하면 문턱이 $t \approx 4.91$ 로 나오고, 심어 둔 6×6 효과 36픽셀이 모두 유의하다. 보정된 p값의 분자와 분모에 1을 더한 것은 실제 데이터 자체도 순열의 하나로 세기 때문이다. 그래서 순열 5000번으로 얻을 수 있는 가장 작은 p는 $1/5001 \approx 0.0002$ 다.

실제 분석에서는 FSL randomise, PALM, SnPM, AFNI 3dttest++의 순열 선택지가 이 일을 한다. 공변량이 있는 GLM에서는 잔차를 섞는 방법(Freedman-Lane 등)을 쓴다. EEG/MEG의 군집 순열 검정도 같은 원리이며 10장에서 다시 만난다.

예제 6.4 순열 횟수와 p값의 해상도

(가) 피험자 8명의 단일 표본 부호 뒤집기에서 가능한 순열은 몇 가지이고, 얻을 수 있는 가장 작은 p는? (나) 피험자 20명, 무작위 순열 5000번으로 p_{FWE} 를 0.05 근처에서 추정할 때 몬테카를로 표준오차는 얼마인가?

풀이 (가) $2^8 = 256$ 가지다. 원래 데이터도 그중 하나이므로 가장 작은 p는 $1/256 \approx 0.0039$ 다. 표본이 이렇게 작으면 p값이 $1/256$ 간격으로만 나와 문턱 근처의 판단이 거칠다. (나) 이항 분포의 표준오차 $\sqrt{0.05 \times 0.95/5000} \approx 0.003$ 이다. $p_{FWE} = 0.048$ 과 0.052 를 구별하기 어렵다. 결과가 문턱에 걸려 있으면 순열 수를 늘린다.

순열 검정에도 가정이 있다. 교환 가능성이 깨지면 보장도 깨진다. 집단 간 분산이 크게 다르거나, 가족 구조가 있는 데이터(쌍둥이, 형제)처럼 관측이 묶여 있으면 아무렇게나 섞을 수 없다. 가족 구조는 묶음 단위로 섞는 방법이 따로 있다. 단일 표본 부호 뒤집기는 대칭성을 가정하므로 오차 분포가 심하게 치우치면 조심해야 한다. 계산 비용도 있다. 복셀 20만 개, 순열 5000번이면 GLM을 10억 번 적합하는 셈이다.

TFCE: 문턱을 고르지 않는 군집 추론

군집 추론의 약점은 CDT를 하나 골라야 한다는 것이다. [그림 6.5](#)에서 본 것처럼 CDT가 결과를 바꾸고, 고르는 기준은 자의적이다. **문턱 없는 군집 강화(threshold-free cluster enhancement, TFCE)**는 스미스(Smith)와 니컬스(Nichols, 2009)가 제안한 해법으로, 모든 문턱을 한꺼번에 쓴다.

각 복셀 v 의 TFCE 점수는 높이 h 를 0부터 그 복셀의 값까지 올리면서, 각 높이에서 "그 복셀이 속한 덩어리의 크기 $e(h)$ "와 높이 h 를 곱해 더한 것이다.

$$\text{TFCE}(v) = \int_0^{h_v} e(h)^E h^H dh$$

적분은 "얇은 층마다 넓이를 더한 것"으로 읽으면 된다. 기본값은 $E = 0.5$, $H = 2$ 다. 넓게 퍼진 지지(e)와 높은 봉우리(h)가 모두 점수를 올리되, 높이에 더 큰 가중을 준다.

[그림 6.7](#) (가)는 좁고 높은 봉우리와 넓고 낮은 언덕의 단면이다. 문턱 하나를 2.5로 그으면 언덕은 사라진다. TFCE에서는 봉우리가 35, 언덕이 13점을 받는다(나). 언덕도 상당한 점수를 받고, 두 덩어리 모두 원래 모양과 피크 위치를 지킨다. 2차원 지도(라)에서도 TFCE는 가까운 두 봉우리를 하나로 뭉개지 않는다. TFCE 점수 자체에는 단위나 분포가 없다. 그래서 반드시 순열로 최대 TFCE의 귀무 분포를 만들어 FWE p값을 얻는다. FSL randomise와 PALM이 TFCE를 지원하며, 표면 데이터에서는 기본값이 다르다($E = 1$).




그림 6.7 TFCE의 원리. (가) 높이 h 마다 문턱을 그어 각 점이 속한 덩어리의 폭 $e(h)$ 를 잴다. (나) $e(h)^{0.5} h^2$ 을 높이에 걸쳐 더한 TFCE 점수. 좁고 높은 봉우리와 넓고 낮은 언덕이 모두 점수를 받고 모양이 보존된다. (다, 라) [그림 6.5](#)과 같은 z 지도와 그 TFCE 지도. 가까운 두 봉우리가 따로 남는다.

TFCE도 공간 특이성 문제를 완전히 없애지는 않는다. 넓은 군집 가장자리의 복셀은 이웃의 지지를 받아 점수가 오른다. 그래도 각 복셀이 자기 높이까지만 적분하므로, 낮은 CDT 군집 추론보다는 위치 정보가 훨씬 잘 남는다.

6.6 관심 영역 분석과 순환성

ROI 분석은 다중비교를 줄인다

뇌 전체 대신 미리 정한 몇 개 영역만 검정하면 다중비교의 짐이 크게 준다. **관심 영역(region of interest, ROI)** 분석이다. 편도체 하나에 대한 가설이라면 편도체 평균 신호 하나로 검정 한 번을 하면 된다. 영역이 다섯 개면 본페로니로 $0.05/5 = 0.01$ 을 쓴다. 신호를 영역 안에서 평균하므로 잡음도 준다. 전뇌 분석에서 특정 영역만 따로 보정하는 **소용적 보정(small volume correction, SVC)**도 같은 생각이다.

ROI의 조건은 하나다. **데이터를 보기 전에** 정해야 한다. 해부 아틀라스(1장), 이전 연구의 좌표, 독립된 국소화기 과제가 정당한 출처다.

같은 데이터로 고르고 재면

문제는 ROI를 지금 분석할 데이터에서 고를 때 생긴다. 뇌 전체에서 행동 점수와 상관이 큰 복셀을 찾은 다음, 그 복셀들의 평균으로 상관을 다시 계산해 보고하는 식이다. 이것을 **순환 분석(circular analysis)**, 또는 같은 데이터에 두 번 담근다고 해서 **이중 담그기(double dipping)**라 한다(Kriegeskorte 외 2009).

선택은 잡음을 걸러 내지 않는다. 오히려 효과 쪽으로 우연히 쏠린 잡음을 골라낸다. **그림 6.8**는 뇌 지도도 행동 점수도 순수 잡음인 연구를 1000번 시뮬레이션한 것이다. 피험자 20명에서 행동 점수와 상관이 $r > 0.65$ (단측 $p < 0.001$)인 픽셀을 ROI로 고르면, 보정을 하지 않았으므로 1000개 연구 중 502개에서 ROI가 생긴다. 그 ROI에서 다시 켜 상관은 평균 0.74다. 참 상관은 0이다. 같은 ROI를 새 피험자 20명에게 적용하면 평균 -0.01로 돌아온다.

순환 추정이 선택 문턱 아래로 거의 내려가지 않는다는 점에 주목하자. 이 값은 데이터에 대한 정보가 아니라 문턱에 대한 정보다. 참 효과가 있는 경우에도 같은 일이 일어난다. 고른 복셀의 효과 크기는 참값보다 부풀려진다. 2장에서 본 **승자의 저주**가 공간으로 확장된 것이다.




그림 6.8 순환 분석이 상관을 부풀린다. 뇌 지도(48×48 , FWHM 4픽셀)와 행동 점수가 모두 잡음이다. (가) 한 연구의 상관 지도와, $p < 0.001$ 로 고른 ROI(검은 선). (나) 같은 데이터로 ROI 평균과 행동을 다시 상관하면 $r = 0.80$ (빨강), 새 피험자에게 같은 ROI를 쓰면 0에 가깝다(파랑). (다) ROI가 생긴 502개 연구에서 순환 추정치는 모두 0.65 위에 있다.

예제 6.5 상관의 천장

fMRI 지표의 검사-재검사 신뢰도가 0.7, 성격 척도의 신뢰도가 0.8이다. (가) 참 상관이 1이더라도 관측될 수 있는 상관의 대략적인 상한은? (나) 피험자 20명의 논문이 전뇌에서 찾은 영역의 상관으로 $r = 0.88$ 을 보고했다. 무엇을 의심해야 하는가?

풀이 (가) 2장의 감쇠 공식에서 관측 상관의 상한은 $\sqrt{0.7 \times 0.8} \approx 0.75$ 다. (나) 0.88은 측정 신뢰도가 허락하는 천장을 넘는다. 피험자 20명에서 상관의 표준오차는 0.2 안팎이어서 우연한 흔들림이 크고, 전뇌에서 가장 큰 상관을 골랐다면 선택 문턱(예: $p < 0.001$ 이면 $r > 0.65$) 위의 값만 보고될 수밖에 없다. ROI를 어떻게 정했는지, 독립 데이터에서 다시 켜는지를 확인해야 한다.

🧠 뇌로 가는 다리: '수수께끼처럼 높은 상관'

불(Vul)과 동료들(2009)은 정서, 성격, 사회 인지 fMRI 연구들이 보고한 뇌-행동 상관을 모았다. 측정 신뢰도로 계산한 천장이 약 0.75인데도 0.8을 넘는 상관이 드물지 않았다. 저자들에게 분석 방법을 물어 보니, 상당수가 전뇌에서 상관이 큰 복셀을 고른 뒤 같은 데이터로 상관을 계산해 보고한 것이었다. 같은 해 크리게스코르테(Kriegeskorte)와 동료들은 주요 학술지에 실린 fMRI 논문 134편 중 약 40 %가 적어도 하나의 순환 분석을 담고 있음을 보였다. 순환성은 ROI 상관에만 있지 않다. 활성화가 큰 복셀을 고른 뒤 그 복셀에서 조건 차이를 비교하는 것, 전뇌 군집에서 % 신호 변화를 뽑아 막대그래프를 그리는 것, 디코딩에서 전체 데이터로 특징을 고른 뒤 교차 검증하는 것(13장)이 모두 같은 함정이다. 막대그래프가 선택 기준과 독립인 대비를 보여 주지 않는다면, 그 그래프는 이미 알려진 사실을 다시 그린 것에 불과하다.

순환을 피하는 방법

- **독립 국소화기**: 별도 런이나 과제로 ROI를 정하고(예: 얼굴 대 사물로 방추상 얼굴 영역), 본 과제 데이터로 효과를 켜다.
- **데이터 나누기**: 런을 반으로 나눠 한쪽으로 고르고 다른 쪽으로 켜다. 바꿔서 한 번 더 하고 평균한다.

- **피험자 하나 빼고 고르기:** 각 피험자의 ROI를 나머지 피험자의 집단 지도로 정한다.
- **직교 대비:** 선택 대비와 검정 대비가 설계상 독립이면 같은 데이터로도 편향이 없다. 예를 들어 (A + B) 대 기저선으로 고르고 A 대 B를 쟀다. 단, 두 조건의 시행 수나 분산이 다르면 직교가 깨질 수 있다.
- **아틀라스와 사전 좌표:** 데이터와 무관한 출처로 정하고, 그 근거를 사전 등록에 적는다.

6.7 결과를 정직하게 보고하기

결정은 데이터를 보기 전에

이 장의 모든 방법에는 선택지가 있다. CDT, FWE와 FDR, 복셀 수준과 군집 수준, 탐색 범위, 단측과 양측, 평활화 폭이다. 결과를 본 뒤 유의하게 나오는 조합을 고르면, 각각은 정당한 방법이어도 전체로는 보정이 무너진다. 다섯 가지 합리적인 분석 중 하나라도 유의하면 보고하는 습관은, 예제 6.1의 계산처럼 거짓 양성률을 몇 배로 키운다. 13장에서 다룰 NARPS가 보여 준 분석 유연성의 문제다.

사전 등록(preregistration) 은 가설, ROI, 문턱 방법, 대비를 데이터 수집 전에 공개 기록으로 남기는 것이다. 사전 등록하지 않은 분석도 할 수 있다. 다만 탐색적이라고 밝혀 적는다. 여러 대비를 검정했다면 (예: 양방향, 조건 다섯 개) 대비의 수도 다중비교의 일부다.

지도 전체와 효과 크기를 공유한다

문턱을 넘은 군집만 그린 그림은 정보의 대부분을 버린다. 문턱 바로 아래의 넓은 효과도, 반대 방향의 효과도 보이지 않는다. 결과 표의 피크 t 값은 크기를 말해 주지 않는다. 다음을 함께 보고하는 것이 지금의 권고다.

- 문턱을 넘지 않은 원래 t 지도(또는 z 지도)와 대비 추정 지도. NeuroVault 같은 공개 저장소에 올리면 다른 연구자가 메타 분석에 쓸 수 있다.
- 효과 크기와 신뢰 구간. ROI에서는 % 신호 변화나 Cohen의 d를, 독립적으로 정한 ROI에서 쟀다.
- 추론 방법의 전체 사양: 탐색 범위(전뇌, 마스크), 평활도 추정, CDT, 순열 횟수, 소프트웨어와 버전.
- 귀무 결과의 해석 근거. 2장에서 본 것처럼 "유의하지 않음"은 "활성화 없음"이 아니다.

뇌로 가는 다리: 수술 전 언어 지도의 문턱

뇌종양이나 뇌전증 수술 전에 한 환자의 언어 영역을 fMRI로 찾는 일은 집단 연구와 목적이 다르다. 여기서 더 위험한 오류는 거짓 음성이다. 실제 언어 영역을 "활성 없음"으로 보고 절제하면 영구적인 실어증이 생길 수 있다. 그래서 임상 지도에서는 엄격한 FWE 문턱 하나로 자르지 않고, 문턱을 여러 단계로 바꿔 가며 활성의 범위가 어떻게 변하는지 함께 본다. 신경외과 의사에게는 " $z > 5$ 에서 보이는 영역"과 " $z > 3$ 까지 내려야 보이는 영역"이 모두 정보다. 문턱의 선택은 통계의 규칙이 아니라 어느 오류가 더 비싼가에 대한 판단이며, 연구 논문에서도 그 판단을 밝혀 적어야 한다.

핵심 정리

핵심 정리

- 복셀 10만 개에서 보정 없는 $p < 0.05$ 는 거짓 양성 약 5000개, $p < 0.001$ 은 약 100개를 만든다. 독립 검정 m 개의 FWER는 $1 - (1 - \alpha)^m$ 으로, 14개면 이미 50 %를 넘는다.
- 평활한 잡음은 거짓 양성을 활성화처럼 생긴 덩어리로 만든다. 죽은 언어에서도 보정 없는 문턱은 군집을 찾는다.
- 본페로니(α/m)는 언제나 FWER를 지키지만 평활한 지도에서 보수적이다. 무작위장 이론은 RESEL 수 (부피/FWHM³)와 오일러 특성으로 문턱을 계산하며, 평활도가 복셀의 약 3배 이상일 때 잘 맞는다.
- FDR(벤야미니-호흐베르크)은 유의 목록 속 거짓의 평균 비율을 통제한다. 문턱이 데이터에 따라 움직이고, 개별 복셀의 오류 확률을 말해 주지 않는다.
- 군집 추론은 넓은 효과에 검정력이 높지만 "군집 어딘가에 신호가 있다"만 말한다. 낮은 CDT는 공간 특이성을 잃는다. Eklund 2016은 CDT $p = 0.01$ 의 파라메트릭 군집 추론이 FWER를 최대 약 70 %까지 부풀림을 보였다.
- 순열 검정은 교환 가능성만 가정하고, 순열마다 최대 통계량을 모아 FWE 문턱을 얻는다. TFCE는 모든 문턱의 군집 정보를 합쳐 CDT 선택을 없애며, 순열과 함께 써야 p값이 나온다.
- 같은 데이터로 ROI를 고르고 효과를 재면 효과가 부풀려진다. 순수 잡음에서도 순환 상관은 선택 문턱(예: 0.65) 위에 놓인다. 독립 국소화기, 데이터 나누기, 아틀라스로 ROI를 정한다.
- 분석 결정은 데이터를 보기 전에 정하고, 비문턱 지도와 효과 크기, 추론 사양을 공개한다.

방법 절 점검표

방법 절 점검표

- 추론의 단위가 무엇인가(복셀, 군집, TFCE, ROI)? 보정 방법(FWE, FDR)과 방식(RFT, 순열, 시뮬레이션)을 밝혔는가?
- 탐색 범위는 어디인가(전뇌, 회백질 마스크, 소용적)? 소용적 보정이라면 그 영역을 데이터와 무관하게 정했는가?
- 군집 추론이라면 CDT가 얼마인가? $p < 0.01$ ($z \approx 2.3$)처럼 낮은 문턱이라면 결과를 조심해서 읽는다. 큰 군집의 해석을 피크 좌표 하나에 걸지 않았는가?
- 평활도를 잔차에서 추정했는가? 순열 검정이라면 순열 횟수와 섞는 방식(부호 뒤집기, 잔차 순열, 묶음)을 적었는가?
- ROI는 어디서 왔는가? 같은 데이터에서 고른 ROI의 효과 크기, 상관, 막대그래프를 결론의 근거로 쓰지 않았는가?
- 검정한 대비와 방향의 수가 모두 보고되었는가? 사전 등록한 분석과 탐색적 분석이 구분되어 있는가?
- 비문턱 통계 지도와 효과 크기 지도를 공유했는가(NeuroVault 등)? 효과 크기와 신뢰 구간을 독립적인 방식으로 보고했는가?
- 귀무 결과를 "활성화 없음"으로 해석하지 않았는가?

확인 문제

확인 문제

1. 복셀 5만 개에 참 효과가 없다. 보정 없는 $p < 0.01$ 에서 거짓 양성 복셀의 기댓값은? 같은 지도에서 복셀이 독립이라고 할 때 본페로니 FWE 5 % 문턱(p 값)은?
2. 독립 검정 20개에서 각각 $\alpha = 0.05$ 를 쓰면 FWER는 얼마인가? FWER를 5 %로 묶으려면 검정당 α 를 대략 얼마로 해야 하는가?
3. 탐색 부피가 1.2 L이고 잔차 평활도가 FWHM 10 mm다. RESEL 수는? 같은 부피를 FWHM 5 mm로 평활하면 RESEL 수는 몇 배가 되는가? 문턱은 어느 쪽으로 움직이는가?
4. p 값 여섯 개가 0.001, 0.008, 0.012, 0.030, 0.045, 0.30이다. 본페로니와 BH($q = 0.05$)로 각각 몇 개가 유의한가?
5. 어떤 논문이 "CDT $z > 2.3$, 군집 보정 $p < 0.05$ "로 전두엽에서 섬엽까지 이어진 5000복셀 군집을 보고하고, 피크가 있는 하전두이랑을 "언어 처리 영역"이라고 해석했다. 이 해석의 두 가지 문제는?
6. 피험자 12명의 단일 표본 부호 뒤집기 순열 검정에서 가능한 순열은 몇 가지이고, 가장 작은 p 값은? TFCE 점수만으로 유의성을 판단할 수 없는 이유는?
7. 연구자가 행동 점수와 상관이 큰 복셀을 전뇌에서 골라 ROI를 만들고, 같은 데이터로 ROI 평균과 행동의 상관 $r = 0.82$ 를 보고했다. 이 값이 무엇을 반영하는지 설명하고, 편향 없이 상관을 추정하는 방법 두 가지를 들라.
8. 수술 전 언어 지도에서 FWE 보정한 엄격한 문턱만 쓰는 것이 왜 위험한가? 집단 연구와 무엇이 다른가?

확인 문제 풀이

확인 문제 풀이

1. $50\,000 \times 0.01 = 500$ 개다. 본페로니 문턱은 $0.05/50\,000 = 10^{-6}$ 이다.
2. $1 - 0.95^{20} \approx 0.64$, 약 64 %다. 검정당 $\alpha \approx 0.05/20 = 0.0025$ 를 쓴다(정확히는 $1 - 0.95^{1/20} \approx 0.00256$).
3. $1.2 \times 10^6/10^3 = 1200$ 개다. FWHM이 절반이면 $2^3 = 8$ 배인 9600개가 된다. RESEL이 많을수록 실질적인 검정 수가 많으므로 문턱이 올라간다.
4. 본페로니 문턱은 $0.05/6 \approx 0.0083$ 이므로 0.001과 0.008, 2개다. BH 문턱은 $0.05k/6$, 곧 0.0083, 0.0167, 0.025, 0.0333, 0.0417, 0.05다. 0.001, 0.008, 0.012, 0.030은 통과하고 다섯째 0.045 > 0.0417은 실패한다. 4개다.
5. 첫째, CDT $z > 2.3$ 은 Eklund 2016에서 파라메트릭 군집 추론의 FWER를 크게 부풀린 설정이다. 둘째, 군집 추론은 군집 어딘가에 신호가 있다는 것만 말하므로 5000복셀 군집의 피크 하나에 해석을 걸 수 없다. 하전두이랑에 대한 주장을 하려면 복셀 수준 FWE, TFCE, 또는 미리 정한 ROI 검정이 필요하다.
6. $2^{12} = 4096$ 가지이고 가장 작은 p 는 $1/4096 \approx 0.00024$ 다. TFCE 점수는 단위와 분포가 정해져 있지 않아 값 자체로 크고 작음을 판단할 수 없다. 순열마다 지도 전체의 최대 TFCE를 모아 귀무 분포를 만들어야 FWE p 값을 얻는다.
7. 이 값은 대부분 선택 문턱을 반영한다. 행동과 우연히 크게 상관한 잡음을 골랐으므로, 참 상관이 0이어도 선택 문턱 위의 값이 나온다(그림 6.8). 편향 없는 방법: 피험자나 데이터를 나눠 한쪽으로 ROI를 고르고

다른 쪽으로 상관을 켜다. 또는 아틀라스나 이전 연구의 좌표로 ROI를 미리 정한다. 피험자 하나 빼고 고르기도 된다.

8. 엄격한 문턱은 거짓 양성을 막는 대신 거짓 음성을 늘린다. 수술에서는 실제 언어 영역을 놓쳐 절제하는 거짓 음성이 더 비싸다. 집단 연구는 "이 효과가 존재하는가"를 묻지만, 임상 지도는 "어디를 건드리면 안 되는가"를 묻는다. 그래서 여러 문턱에서 활성의 범위를 함께 보고, 피질 전기 자극 같은 다른 방법으로 확인한다.

다음 장으로

이 장에서는 통계 지도에서 "어디가 유의한가"를 정하는 규칙을 보았다. 거짓 양성의 규모를 알고, FWE와 FDR이 각각 무엇을 약속하는지, 군집과 TFCE가 공간 정보를 어떻게 쓰는지, 그리고 데이터로 고른 영역에서 효과를 다시 재면 왜 부풀려지는지를 알았다. 지금까지의 분석은 과제가 만든 반응을 복셀마다 따로 물었다. 7장에서는 질문을 바꾼다. 과제 없이 쉬고 있는 뇌에서 영역들의 신호가 어떻게 함께 움직이는지, 곧 기능 연결성을 재고 그것을 네트워크로 읽는다. 연결성 행렬은 영역 쌍마다 값을 하나씩 가지므로, 영역 400개면 검정이 약 8만 개다. 이 장의 다중비교 문제가 거기서 새로운 모양으로 다시 나온다.

7장 기능 연결성과 뇌 네트워크

이 장에서 배울 것 휴지기 fMRI에서 영역 사이 "연결"을 재는 방법(씨앗 상관, 부분 상관, ICA와 이중 회귀), 연결 행렬을 요약하는 그래프 지표, 동적 연결성과 방향성 연결성(그레인저 인과, DCM), 그리고 결과를 혼드는 혼입 요인(움직임, 전역 신호, 각성, 신뢰도). **뇌 연구자에게 왜 필요한가** "환자군에서 디폴트 모드 네트워크의 연결성이 줄었다"는 문장 뒤에는 노드 정의, 상관의 종류, 문턱, 잡음 제거 방식 같은 결정이 수십 개 숨어 있다. 각 결정이 무엇을 가정하고 결과를 어느 방향으로 바꾸는지 알아야 연결성 논문을 믿을지 말지 판단할 수 있다.

📌 중고등 복습: 상관계수와 그래프

두 변수의 산점도가 오른쪽 위로 기울어진 띠 모양이면 **양의 상관**, 오른쪽 아래로 기울면 **음의 상관**이다. **상관계수** r 은 -1에서 +1 사이의 값으로 띠가 얼마나 가는지 나타낸다. $r = 0$ 이면 직선 관계가 없다는 뜻이다. 함께 움직이는 두 양이 서로의 원인이라는 보장은 없다. 둘 다 셋째 변수에 끌려갈 수 있다. "상관은 인과가 아니다"라는 말이다. 수학에서 **그래프**는 점(꼭짓점)과 점을 잇는 선(변)의 모음이다. 지하철 노선도가 대표적이다. 역의 실제 위치나 거리는 지우고 "어느 역과 어느 역이 바로 이어져 있는가"만 남긴다. 몇 번 갈아타야 하는지, 환승역이 어디인지는 이 그림으로 충분하다. 이 장은 뇌 영역을 역으로, 영역 사이의 상관을 노선으로 보는 방법을 다룬다.

7.1 휴지기 fMRI

쉬는 뇌도 요동친다

1995년 Biswal 등은 과제 없이 누워 있는 사람의 fMRI에서 왼쪽 운동 피질의 시계열을 뽑았다. 그 시계열과 다른 복셀의 상관을 구하자 오른쪽 운동 피질과 보조 운동 영역이 함께 떠올랐다. 손가락 운동 과제에서 커지는 바로 그 영역들이었다. 요동은 0.1 Hz보다 느렸다. 과제가 없어도 기능적으로 묶인 영역들은 함께 오르내린다는 관찰이다. 이것이 **휴지기 기능 연결성(resting-state functional connectivity)** 연구의 출발점이다.

기능 연결성(functional connectivity) 은 떨어진 영역의 신호 사이의 통계적 의존성, 대개 상관이다. 해부학적 배선(8장의 구조 연결체)과는 다른 개념이다.

무엇이 요동치는가

휴지기 분석이 주로 보는 대역은 약 0.01-0.1 Hz, 주기로는 10-100 s다. 물리 2권 7장에서 본 것처럼 HRF 자체가 이 대역을 통과시키는 저역 필터다. 생리 1권 6장의 동시 기록 연구들은 이 느린 BOLD 요동이 EEG 리듬 자체가 아니라 감마나 알파 파워의 느린 포락선과 맞는다고 보고했다. 휴지기 연결성은 과제와 상관없이 늘 돌아가는 내재적 활동(생리 1권 7장)의 공간 구조를 본다.

같은 대역에 신경과 무관한 요동도 들어온다. 호흡 변화는 동맥혈 CO_2 를 바꿔 뇌 전체의 BOLD를 흔들고(화학 1권 7장), 심장 박동은 낮은 주파수로 접혀 들어오며(물리 1권 4장), 머리 움직임은 가짜 연결을

만든다(7.7절).

휴지기 네트워크

씨앗 상관이나 ICA(7.3절)로 얻은 지도는 사람과 연구실이 달라도 비슷한 몇 개의 묶음으로 정리된다. 이것을 **휴지기 네트워크(resting-state network)** 라 한다. 1000명의 데이터로 피질을 7개 또는 17개 네트워크로 나눈 Yeo 등(2011)의 분할이 널리 쓰인다(1장의 기능 아틀라스). 7개 판의 이름은 시각, 체성감각운동, 배측 주의, 복측 주의, 변연, 전두두정(조절), 디폴트 모드다.

디폴트 모드 네트워크(DMN, default mode network) 는 후대상피질, 췌기앞소엽, 내측 전전두피질, 하두정소엽, 내측 측두엽을 잇는다. 외부 과제 중에는 활성이 줄고 내면을 향한 생각에서 는다.

획득에서 정할 것

휴지기 스캔에도 정할 것이 있다. 눈을 감으면 잠들기 쉬우므로 십자 응시로 눈을 뜨게 하는 경우가 많다. 개인 수준의 신뢰도는 스캔이 길수록 대체로 좋아진다(HCP는 한 사람당 약 1시간). 짧은 TR(물리 2권 8장)은 심장 잡음의 접힘을 줄이지만 볼륨당 SNR이 낮다. 맥박과 호흡을 기록해 두면 4장의 RETROICOR를 쓸 수 있다.

전처리는 4장의 순서를 따르지만, 휴지기에서는 잡음 제거가 결과를 훨씬 많이 바꾼다. 과제 fMRI에서 잡음은 주로 분산을 키우지만, 휴지기 연결성에서는 두 영역에 함께 들어온 잡음이 그대로 "연결"이 되기 때문이다.

뇌로 가는 다리: 과제를 못 하는 환자의 휴지기 지도

수술 전 언어와 운동 영역 지도는 보통 과제 fMRI로 그린다(5장). 그런데 마비, 실어증, 소아, 진정 상태의 환자는 과제를 수행하지 못한다. 휴지기 fMRI는 협조 없이 6-10분 누워 있기만 하면 되므로 이런 환자에서 체성감각운동 네트워크와 언어 네트워크를 그리는 보조 수단으로 쓰인다. 씨앗을 손 운동 영역에 두면 반대쪽 운동 피질과 보조 운동 영역이 떠오르는 Biswal의 관찰이 그대로 임상 도구가 된 셈이다. 다만 종양 주변에서는 신경혈관 결합이 깨져 BOLD 자체가 약해질 수 있다(생리 1권 9장). 휴지기 지도에서 빈 곳이 "기능이 없는 곳"이라는 보장은 없다. 그래서 수술 중 전기 자극 지도와 함께 쓰는 것이 원칙이다.

7.2 연결성 측정

노드부터 정한다

연결성은 "무엇과 무엇 사이"의 양이다. 그래서 먼저 **노드(node)** 를 정해야 한다. 선택지는 셋이다. 복셀 하나하나, 아틀라스의 영역(1장의 AAL, Schaefer 400 등), 또는 ICA 성분(7.3절)이다. 영역을 쓰면 그 안 복셀 시계열의 평균을 노드 시계열로 삼는다.

이때 영역 안의 복셀이 기능적으로 균질하다고 가정한다. 기능 경계를 가로지르는 큰 영역을 쓰면 서로 다른 신호가 평균되어 연결성이 흐려진다.

씨앗 상관

가장 단순한 방법은 **씨앗 기반 상관(seed-based correlation)** 이다. 씨앗 영역의 시계열 x 와 다른 복셀의 시계열 y 사이의 피어슨 상관을 복셀마다 계산해 지도로 그린다.

$$r = \frac{\sum_t (x_t - \bar{x})(y_t - \bar{y})}{\sqrt{\sum_t (x_t - \bar{x})^2} \sqrt{\sum_t (y_t - \bar{y})^2}}$$

x_t, y_t 는 시각 t 의 신호, $\bar{x}, \bar{y}$ 는 평균이다. 두 시계열을 표준화한 뒤 곱의 평균을 낸 값과 같다. 노드가 N 개면 쌍마다 하나씩 $N(N-1)/2$ 개의 상관이 나오고, 이것을 $N \times N$ **연결 행렬**로 쓴다. Schaefer 400 아틀라스라면 79,800개다.

피셔 z 변환

상관계수는 -1과 +1 사이에 갇혀 있어 분포가 비대칭이다. r 이 1에 가까울수록 위쪽으로 움직일 여지가 없다. 그래서 집단 평균을 내거나 t 검정을 하기 전에 **피셔 z 변환(Fisher z-transform)** 을 한다.

$$z = \tanh^{-1} r = \frac{1}{2} \ln \frac{1+r}{1-r}$$

z 의 표준오차는 독립 표본 N 개에서 약 $1/\sqrt{N-3}$ 이다. 문제는 fMRI 시계열의 볼륨들이 독립이 아니라는 점이다. 0.01-0.1 Hz로 대역 통과한 신호는 대역폭이 0.09 Hz이므로, 길이 D 인 기록에 독립 표본이 대략 $2 \times 0.09 \times D$ 개만 들어 있다고 어림할 수 있다.

예제 7.1 볼륨 300개는 표본 300개가 아니다

TR 2 s로 10분(300 볼륨) 찍은 휴지기 데이터를 0.01-0.1 Hz로 대역 통과했다. 두 영역의 상관이 $r = 0.25$ 였다. (가) 피셔 z 는? (나) 볼륨을 독립 표본으로 보면 이 상관의 z 점수는? (다) 유효 표본 수로 다시 계산하면?

풀이 (가) $z = \tanh^{-1} 0.25 \approx 0.255$. (나) $N = 300$ 이면 표준오차는 $1/\sqrt{297} \approx 0.058$ 이고, z 점수는 $0.255/0.058 \approx 4.4$ 다. 양측 $p \approx 1 \times 10^{-5}$ 로 매우 유의해 보인다. (다) 유효 표본은 $2 \times 0.09 \times 600 \approx 108$ 개다. 표준오차는 $1/\sqrt{105} \approx 0.098$, z 점수는 약 2.6, $p \approx 0.009$ 다. 여전히 유의하지만 증거는 훨씬 약하고, 79,800개 연결을 함께 검정하면 6장의 다중비교 보정을 넘기 어렵다.

간접 경로와 부분 상관

상관 행렬의 가장 큰 약점은 직접 연결과 간접 연결을 구별하지 못한다는 것이다. A가 B를 움직이고 B가 C를 움직이면 A와 C 사이에도 상관이 생긴다. D가 E와 F를 함께 움직이면 E와 F도 상관한다. 복습 상자의 "셋째 변수" 문제다.

부분 상관(partial correlation) 은 나머지 모든 노드의 영향을 뺀 뒤 남는 두 노드의 상관이다. 노드가 셋이면 식으로 바로 쓸 수 있다.

$$r_{AC \cdot B} = \frac{r_{AC} - r_{AB} r_{BC}}{\sqrt{(1 - r_{AB}^2)(1 - r_{BC}^2)}}$$

분자는 "A-C 상관 가운데 B를 거쳐 설명되는 몫 $r_{AB}r_{BC}$ 를 뺀 나머지"다. 노드가 많을 때는 상관 행렬 $\mathbf{R}$ 의 역행렬 $\mathbf{P} = \mathbf{R}^{-1}$, 곧 **정밀 행렬(precision matrix)** 을 쓴다. 부분 상관은 $-P_{ij}/\sqrt{P_{ii}P_{jj}}$ 다.

그림 7.1은 $A \rightarrow B \rightarrow C$ 사슬과 $D \rightarrow E, D \rightarrow F$ 공통 입력을 가진 합성 네트워크다. 상관 행렬에서 A-C(0.30)와 E-F(0.28)는 직접 연결 못지않게 뚜렷하다. 부분 상관에서는 각각 0.06과 -0.06으로 거의 사라지고, 직접 연결만 0.4-0.6으로 남는다.




그림 7.1 상관과 부분 상관(합성 데이터, 1200 볼륨, 0.01-0.1 Hz 대역 통과). (가) 참 구조. A-C는 B를 거친 간접 경로, E-F는 D의 공통 입력이다. (나) 상관 행렬에서는 빨간 상자의 두 간접 쌍도 0.3 안팎으로 나타난다. (다) 부분 상관에서는 간접 쌍이 0에 가까워지고 직접 연결만 남는다. 대신 연결 없는 쌍에도 ± 0.2 정도의 추정 잡음이 있다.

예제 7.2 사슬의 끝은 상관하지만 부분 상관은 0이다

그림 7.1의 모형에서 이론적인 상관은 $r_{AB} = 0.573$, $r_{BC} = 0.650$, $r_{AC} = 0.373$ 이다. (가) $r_{AC \cdot B}$ 를 구하라. (나) 그림의 표본 값 $r_{AB} = 0.55$, $r_{BC} = 0.48$, $r_{AC} = 0.30$ 으로 다시 계산하라.

풀이 (가) $r_{AB}r_{BC} = 0.573 \times 0.650 \approx 0.373$ 이다. 분자가 0이 되므로 부분 상관은 0이다. A-C 상관 전부가 B를 거쳐 설명된다. (나) 분자는 $0.30 - 0.55 \times 0.48 = 0.036$, 분모는 $\sqrt{(1 - 0.3025)(1 - 0.2304)} \approx 0.733$ 이다. $r_{AC \cdot B} \approx 0.05$ 다. 그림의 0.06은 B 말고 다른 노드까지 모두 통제해 값이라 조금 다르다.

부분 상관에는 대가가 있다. 첫째, 추정 잡음이 크다. 그림 (다)에서 참 연결이 없는 C-E 쌍에도 -0.23이 나왔다. 둘째, 역행렬을 구하려면 시계열 길이가 노드 수보다 충분히 길어야 한다. 노드 400개에 볼륨 300개면 상관 행렬의 역행렬이 아예 존재하지 않는다. 그래서 축소 추정(Ledoit-Wolf)이나 그래프 라소 같은 **정칙화(regularization)** 를 써서 역행렬을 안정시킨다. Smith 등(2011)의 시뮬레이션은 fMRI에 흔한 조건에서 부분 상관과 정칙화한 정밀 행렬이 직접 연결을 잘 찾고, 시간 지연에 기대는 방법은 잘 못 찾는다고 보고했다(7.6절).

아래 코드는 numpy만으로 상관, 피서 z, 축소된 정밀 행렬과 부분 상관을 계산한다.

```
import numpy as np

def connectivity(ts, shrink=0.1):
    """ts: (블록 수 T, 노드 수 N) 시계열. 상관, 피쳐 z, 부분 상관을 돌려준다."""
    x = (ts - ts.mean(0)) / ts.std(0)
    R = x.T @ x / len(x)          # 상관 행렬
    Z = np.arctanh(np.clip(R, -0.999, 0.999)) # 피쳐 z (대각선은 의미 없음)
    S = (1 - shrink) * R + shrink * np.eye(len(R)) # 단위 행렬 쪽으로 축소
    P = np.linalg.inv(S)          # 정밀 행렬
    d = np.sqrt(np.diag(P))
    PC = -P / np.outer(d, d)      # 부분 상관
    np.fill_diagonal(PC, 1.0)
    return R, Z, PC
```

`shrink`를 0으로 두면 정칙화 없는 부분 상관이다. 실제 분석에서는 Nilearn 같은 패키지가 축소 계수를 데이터에서 정해 준다.

흔한 오해: 기능 연결은 배선이다

두 영역의 상관이 높다는 것은 두 신호가 함께 움직인다는 뜻일 뿐이다. 공통 입력(예: 기상), 간접 경로, 같은 혈관 영역, 같은 움직임 인공물이 모두 상관을 만든다. 뇌량 없이 태어난 사람에서도 좌우 상동 영역의 상관이 상당히 남는다는 보고가 있다. "기능 연결성이 줄었다"를 "배선이 끊어졌다"로 읽으면 안 된다. 부분 상관도 측정하지 않은 영역의 공통 입력은 걸러 내지 못한다.

7.3 데이터 기반 방법: ICA와 이중 회귀

칵테일 파티 문제

독립 성분 분석(ICA, independent component analysis)은 씨앗 없이 데이터에서 네트워크를 찾는다. 비유는 칵테일 파티다. 마이크 여러 개에 여러 사람의 목소리가 섞여 녹음되어도, 목소리가 서로 독립이라는 가정 하나로 각 목소리를 되찾는다(9장의 EEG 인공물 제거도 같은 원리다).

fMRI 데이터는 시간 $\times$ 복셀 행렬 $\mathbf{X}$ 다. **공간 ICA(spatial ICA)**는 이것을 성분의 시간 경과 $\mathbf{A}$ 와 공간 지도 $\mathbf{S}$ 의 곱으로 나눈다.

$$\mathbf{X} \approx \mathbf{A} \mathbf{S}$$

이때 서로 독립이라고 가정하는 것은 **지도**다. 시간 경과와는 서로 상관해도 된다. fMRI에서 공간 ICA를 쓰는 이유는 복셀(약 10^5 개)이 볼륨(수백 개)보다 훨씬 많아, 복셀을 표본으로 삼아야 독립성을 안정적으로 추정할 수 있기 때문이다. EEG는 반대로 시간 표본이 많아 시간 ICA를 쓴다.

PCA로는 안 되는 이유

주성분 분석(PCA)은 성분이 서로 **직교**하고 분산이 큰 순서이기만 하면 만족하므로, 겹친 네트워크를 각각 되찾을 이유가 없다. ICA는 성분 지도가 정규분포에서 멀어지도록(대부분 0이고 일부만 큰 분포) 회전을 고른다. 실제 네트워크 지도가 그런 모양이다.

그림 7.2는 일부가 겹치는 세 지도를 시간 경과와 섞고 잡음을 더한 데이터다. PCA로 얻은 성분은 참 지도와의 상관이 0.68-0.83에 그치고, 한 성분 안에 여러 네트워크가 양과 음으로 섞여 있다. 공간 ICA는 세 지도를 모두 0.99로 되찾는다.




그림 7.2 공간 ICA로 겹쳐 섞인 지도 풀기(합성 데이터, 300 볼륨). 첫 줄은 참 지도, 둘째 줄은 PCA 성분, 셋째 줄은 공간 ICA 성분이다. 숫자는 참 지도와의 상관이다. PCA는 직교성을 맞추려고 지도를 섞지만, ICA는 겹친 부분이 있어도 각 지도를 되찾는다. 성분 1과 3의 시간 경과를 서로 상관하도록 만들었다.

선택지와 함정

- **차원:** 성분 수는 연구자가 정한다. 20개 안팎이면 큰 네트워크가, 100개 이상이면 잘게 나뉜 하위 네트워크가 나온다. 정답이 아니라 해상도의 선택이다.
- **집단 ICA:** 모든 피험자의 데이터를 시간 축으로 이어 붙여 한 번에 분해한다. FSL MELODIC과 GIFT가 대표 도구다.
- **잡음 성분:** 성분의 상당수는 움직임, 뇌척수액, 혈관 인공물이다. 4장의 ICA-AROMA와 FIX가 이것을 분류해 지운다.
- **불확정성:** 성분의 부호, 크기, 순서는 정해지지 않고 초깃값에 따라 조금씩 달라진다. 여러 번 돌려 안정적인 성분만 고르기도 한다.

이중 회귀

집단 ICA는 집단 지도를 준다. 개인 차이를 보려면 집단 지도를 개인에게 되돌려야 한다. **이중 회귀(dual regression)** 는 회귀를 두 번 한다.

1. **공간 회귀**: 각 볼륨의 뇌 영상을 집단 지도들로 설명한다. 회귀 계수가 그 피험자의 성분별 시간 경과가 된다.
2. **시간 회귀**: 그 시간 경과들을 설명 변수로 각 복셀의 시계열을 회귀한다. 계수가 그 피험자의 성분별 지도가 된다.

두 번째 단계에 모든 성분을 함께 넣으므로 각 지도는 다른 성분의 영향을 통제된 값이다. 이 개인 지도를 6장의 순열 검정으로 집단 비교한다. 집단 ICA에는 두 집단을 같은 비율로 넣어야 한쪽에 유리한 성분이 생기지 않는다.

```
import numpy as np

def dual_regression(X, G):
    """X: (T, V) 한 피험자의 데이터, G: (K, V) 집단 ICA 지도. 개인 시간 경과와 지도를 돌려준다."""
    Xc = X - X.mean(0) # 복셀마다 시간 평균 제거
    Gc = G - G.mean(1, keepdims=True)
    Xs = Xc - Xc.mean(1, keepdims=True) # 볼륨마다 공간 평균 제거
    tc = np.linalg.lstsq(Gc.T, Xs.T, rcond=None)[0].T # (T, K) 시간 경과
    tc = (tc - tc.mean(0)) / tc.std(0) # 시간 경과 표준화
    maps = np.linalg.lstsq(tc, Xc, rcond=None)[0] # (K, V)
    return tc, maps
```

7.4 그래프 이론

노드와 엣지

연결 행렬을 지하철 노선도처럼 요약하는 것이 **그래프 이론(graph theory)** 이다. 노드는 영역, **엣지(edge)** 는 영역 사이의 연결이다. 엣지를 정하는 방법은 여럿이다.

- **이진 그래프**: 문턱보다 강한 연결만 1, 나머지는 0으로 둔다.
- **가중 그래프**: 연결 세기를 그대로 엣지 무게로 쓴다.
- **음의 연결**: 음의 상관을 버릴지, 절댓값으로 쓸지, 따로 분석할지 정해야 한다. 7.7절에서 보듯 음의 상관은 전처리에 따라 생기기도 한다.

대표 지표

- **차수(degree)**: 노드에 붙은 엣지 수다. 가중 그래프에서는 무게의 합인 **세기(strength)** 를 쓴다.
- **밀도(density)**: 가능한 엣지 $N(N-1)/2$ 개 가운데 실제로 있는 엣지의 비율이다.
- **군집 계수(clustering coefficient)**: 내 이웃끼리도 서로 이웃인 비율이다. 이웃이 k 명이면 가능한 이웃 쌍은 $k(k-1)/2$ 개이고, 그 가운데 실제로 이어진 쌍의 비율이 그 노드의 군집 계수다. "친구의 친구도 친구"인 정도다.
- **특성 경로 길이(characteristic path length)**: 두 노드 사이를 잇는 가장 짧은 경로가 몇 걸음인지를 모든 쌍에 대해 평균한 값이다. 그래프가 끊어져 있으면 무한대가 생기므로, 거리의 역수를 평균한 **전역 효율(global efficiency)** 을 대신 쓰기도 한다.

- **작은 세상(small world):** 군집 계수는 격자처럼 높으면서 경로 길이는 무작위 그래프처럼 짧은 그래프다(Watts와 Strogatz 1998). 같은 노드 수와 밀도의 무작위 그래프로 나눈 군집 계수와 경로 길이를 비교해 판단한다.
- **허브(hub):** 차수가 크거나 많은 최단 경로가 지나가는 노드다. 여러 모듈에 고루 이어진 노드는 **참여 계수(participation coefficient)**가 높은 연결 허브다.

예제 7.3 지표의 크기 감각

(가) 노드 100개 그래프에서 밀도가 10 %면 엮지는 몇 개이고 평균 차수는 얼마인가? (나) 어떤 노드의 이웃이 4개이고, 그 이웃끼리 이어진 쌍이 3개다. 군집 계수는? (다) 노드 수와 밀도가 같은 무작위 그래프의 군집 계수는 대략 얼마인가?

풀이 (가) 가능한 엮지는 $100 \times 99/2 = 4950$ 개, 그 10 %는 495개다. 엮지 하나가 차수를 둘씩 올리므로 평균 차수는 $2 \times 495/100 = 9.9$ 다. (나) 가능한 이웃 쌍은 $4 \times 3/2 = 6$ 이므로 $C = 3/6 = 0.5$ 다. (다) 무작위 그래프에서 이웃 둘이 이어질 확률은 밀도와 같은 약 0.1이다. 군집 계수는 밀도와 비슷하므로, "군집 계수 0.5"는 밀도와 함께 보아야 뜻이 있다.

문턱과 밀도의 함정

이진 그래프는 문턱에 따라 전혀 다른 그래프가 된다. [그림 7.3](#) (가)와 (나)는 모듈 넷짜리 합성 네트워크를 밀도 5-50 %로 자른 결과다. 군집 계수는 밀도 10 %에서 0.37, 30 %에서 0.75로 두 배가 되고, 전역 효율도 0.37에서 0.62로 오른다.

더 심각한 문제는 집단 비교다. (다)의 두 집단은 연결 구조가 똑같고 잡음 크기만 다르다. 잡음이 크면 모든 상관이 조금씩 작아진다(평균 r 0.22 대 0.15). 같은 절대 문턱 $r > 0.3$ 을 쓰면 집단 1의 밀도는 32 %, 집단 2는 15 %가 되고, 군집 계수는 0.70 대 0.47로 크게 갈린다. 이 차이의 대부분은 구조가 아니라 평균 연결 세기의 차이다. 밀도를 15 %로 맞추면 0.59 대 0.47로 차이가 절반쯤 준다. 남은 뒤편은 잡음이 추정된 구조를 실제로 흐린 효과다.




그림 7.3 문턱과 밀도가 그래프 지표를 정한다(48개 노드, 4개 모듈의 합성 네트워크). (가) 군집 계수와 (나) 전역 효율은 밀도에 따라 크게 바뀐다. 회색 점선은 같은 밀도의 무작위 그래프다. (다) 구조는 같고 잡음만 다른 두 집단(각 20명)을 같은 상관 문턱 $r > 0.3$ 으로 자르면 밀도가 두 배 차이 나고 군집 계수 차이가 부풀려진다. 밀도를 맞추면 차이가 줄지만, 잡음이 구조 추정을 흐린 뒤편은 남는다.

그래서 밀도 범위 전체에서 지표를 계산해 곡선 아래 넓이를 비교하고, 가중 지표와 평균 연결 세기 공변량을 함께 보고, 차수 분포를 유지한 채 엣지를 뒤섞은 **영 모형(null model)** 과 비교한다. 엣지별 집단 비교에서는 이어진 엣지 묶음 단위로 순열 검정하는 네트워크 기반 통계(NBS)가 6장의 군집 추론 역할을 한다.

모듈성

모듈(module) 은 안에서는 촘촘하고 밖으로는 성기게 이어진 노드 묶음이다. 휴지기 네트워크가 곧 모듈의 예다. 나눈 정도는 **모듈성(modularity) Q** 로 잰다(Newman 2006).

$$Q = \sum_c \left[\frac{l_c}{m} - \left(\frac{d_c}{2m} \right)^2 \right]$$

m 은 전체 엣지 수, l_c 는 모듈 c 안의 엣지 수, d_c 는 모듈 c 에 속한 노드의 차수 합이다. 첫째 항은 모듈 안에 떨어진 엣지의 실제 비율, 둘째 항은 차수만 같게 무작위로 이었을 때의 기대 비율이다. Q 를 최대로 하는 분할은 루뱅(Louvain) 같은 근사 알고리즘으로 찾는다.

예제 7.4 삼각형 두 개

삼각형 두 개(각 3개 노드, 3개 엣지)가 엣지 하나로 이어진 그래프를 두 삼각형으로 나누었다. Q 는?

풀이 전체 엣지는 $m = 7$ 이다. 각 모듈 안에 엣지 $l_c = 3$ 개가 있고, 차수 합은 $2 + 2 + 3 = 7$ 이다. 한 모듈의 몫은 $3/7 - (7/14)^2 = 0.429 - 0.25 = 0.179$ 이고, 둘을 더하면 $Q \approx 0.36$ 이다.

그림 7.4는 노드 순서를 섞은 인접 행렬에서 모듈을 찾는 과정이다. 알고리즘은 모듈 4개를 찾았고 $Q = 0.56$ 이다. 노드 쌍의 "같은 모듈인가" 판정은 참 모듈과 94 % 일치했다. 그런데 같은 밀도의 무작위 그래프에서도 같은 알고리즘은 $Q = 0.28 \pm 0.02$ 를 찾는다. Q 값 하나로 모듈 구조를 주장할 수 없고, 영 모형의 분포와 비교해야 한다.




그림 7.4 모듈성. (가) 노드 순서를 무작위로 섞은 이진 인접 행렬(밀도 15 %). (나) 찾은 모듈 순서로 다시 정렬하면 대각선의 덩어리가 드러난다. 빨간 상자가 모듈이다. (다) 같은 밀도의 무작위 그래프 100개에서도 Q 는 0.25-0.33이 나온다. 합성 뇌 네트워크의 $Q = 0.56$ 은 그 분포보다 훨씬 크다.

🧠 뇌로 가는 다리: 아틀라스 하나가 바꾸는 그래프

같은 데이터라도 노드를 AAL의 약 90-120개 해부 영역으로 정하느냐, Schaefer의 400개 기능 영역으로 정하느냐에 따라 평균 차수, 경로 길이, 모듈 수, 허브의 위치가 바뀐다. 여러 기능 네트워크에 걸친 큰 해부 영역은 여러 모듈의 신호를 평균해 받으므로 실제보다 "연결 허브"처럼 보일 수 있다. 그래서 "환자군 군집 계수 0.42, 대조군 0.48" 같은 숫자는 같은 아틀라스, 같은 밀도, 같은 전처리 안에서만 비교할 수 있다. 결과가 아틀라스를 바꿔도 남는지 확인하는 것이 1장의 "아틀라스 선택이 결과를 바꾼다"에 대한 실용적인 답이다.

7.5 동적 연결성과 그 함정

미끄럼 창

지금까지는 10분 전체에서 상관 하나를 구했다. 그러나 마음은 10분 동안 가만히 있지 않는다. 연결성이 시간에 따라 바뀐다는 생각이 **동적 기능 연결성(dynamic functional connectivity)** 이다(Hutchison 등 2013의 개관). 가장 흔한 방법은 **미끄럼 창(sliding window)** 이다. 30-60 s 길이의 창을 한 볼륨씩 옮기며 창 안의 상관을 계산하고, 그 연결 행렬들을 k -평균으로 묶어 반복해서 나타나는 "연결 상태"를 찾는다.

잡음만으로도 출렁인다

문제는 표본 수다. 30 s 창에는 볼륨 15개, 유효 표본은 5개 남짓뿐이다(예제 7.1).

그림 7.5는 참 상관이 0.3으로 **내내 일정한** 두 시계열이다. 30 s 창으로 보면 창 상관은 -0.8에서 +0.9까지 오간다. 120 s 창에서도 수십 초씩 높았다 낮아지는 구간이 생긴다. 이것을 "상태 전환"으로 읽으면 잡음에 이야기를 붙이는 셈이다. (나)에서 대역 통과 신호의 창 상관 표준편차는 같은 표본 수의 백색 잡음보다 1.5-1.8배 크다.




그림 7.5 미끄럼 창 상관의 잡음(합성 데이터, TR 2 s, 0.01-0.1 Hz). (가) 참 상관이 0.3으로 일정한데도 창 상관은 크게 출력된다. 창이 짧을수록 출력임이 크다. (나) 창 길이에 따른 창 상관의 표준편차(300번 반복). 대역 통과 신호(파랑)는 같은 표본 수의 백색 잡음(회색)보다 출력임이 크다. 빨간 점선은 가장 느린 주파수 성분의 주기($1/0.01 \text{ Hz} = 100 \text{ s}$)다.

예제 7.5 30 s 창의 기대 출력임

TR 2 s, 30 s 창, 참 상관 $\rho = 0.3$ 이다. (가) 볼륨이 독립이라면 창 상관의 표준편차는 대략 얼마인가? 독립 표본 n 개에서 상관의 표준편차는 약 $(1 - \rho^2)/\sqrt{n}$ 이다. (나) 0.01-0.1 Hz 대역 신호의 유효 표본 수로 보면? (다) 창 상관이 0.3에서 0.8로 올랐다가 내려오는 것을 보았다. 상태 변화라고 말하려면 무엇이 필요한가?

풀이 (가) $n = 15$ 이므로 $0.91/\sqrt{15} \approx 0.23$ 이다. 이미 상관 크기와 비슷하다. (나) 유효 표본은 $2 \times 0.09 \times 30 \approx 5$ 개뿐이다. 이렇게 적으면 어림식이 정확하지 않지만 출력임이 (가)보다 훨씬 크리라는 것은 알 수 있다. 시뮬레이션에서는 0.42였다(그림 7.5 나). (다) 같은 스펙트럼과 같은 평균 상관을 가졌지만 연결이 변하지 않는 대리 데이터(위상 무작위화, 정상 자기회귀 모형)를 만들어 똑같이 분석해야 한다. 실제 데이터의 출력임이 이 영 분포보다 커야 동적 연결성의 증거가 된다.

방어책은 셋이다. 창 길이를 가장 느린 성분의 주기(0.01 Hz라면 100 s) 이상으로 잡거나, 짧은 창에 맞게 고역 필터를 올린다. 정상성 영 모형과 비교한다. 출력임이 움직임, 호흡, 각성 변화와 같이 가는지 확인한다. 스캔 중 줄음이 오가는 것(생리 1권 6장)은 연결성을 실제로 바꾸는 가장 흔한 "상태"다. 은닉 마르코프 모형(HMM)이나 공동 활성 패턴(CAP) 같은 다른 방법에도 영 모형이 필요하다는 점은 같다.

흔한 오해: 동적 연결성의 상태는 마음의 상태다

군집 알고리즘은 상태 수를 정해 주면 잡음만 있는 데이터도 그만큼 나눈다. 상태의 "체류 시간"이나 "전환 횟수"의 집단 차이도 움직임, 줄음, 신호 대 잡음비 차이만으로 생길 수 있다. 상태가 실재한다고 말하려면 영 모형을 넘고, 다른 세션에서 재현되고, 행동이나 생리 측정과 시간적으로 맞아야 한다.

7.6 효과적 연결성

상관에서 방향으로

기능 연결성은 "함께 움직인다"까지만 말한다. "A가 B를 움직인다"는 방향과 인과를 말하는 것이 **효과적 연결성(effective connectivity)**이다. 대표 방법은 둘이다. 데이터에서 시간 순서를 읽는 그레인저 인과와, 생성 모형을 세우고 비교하는 DCM이다. 5장의 PPI도 과제에 따라 연결이 바뀌는지를 보는 단순한 효과적 연결성 모형이다.

그레인저 인과와 HRF 지연

그레인저 인과(Granger causality)의 생각은 단순하다. B의 과거만으로 B의 현재를 예측하는 것보다, A의 과거를 더했을 때 예측이 나아지면 "A가 B를 그레인저 인과한다"고 말한다. 원인은 결과보다 먼저 온다는 직관을 자기회귀 모형으로 옮긴 것이다. 11장에서 EEG/MEG에 쓸 때는 ms 단위의 시간 순서를 다룬다.

fMRI에서는 이 직관이 위험하다. 신경 사이의 전달 지연은 수 ms-수십 ms인데, HRF의 정점 시간은 영역과 사람에 따라 1-2 s씩 다르다(생리 1권 9장). 신경 순서보다 혈관 순서가 훨씬 크게 BOLD의 시간 순서를 정한다.

그림 7.6의 합성 예에서 신경 활동은 A가 B보다 0.1 s 먼저다. 그런데 A의 HRF가 B보다 1 s 느리면, BOLD의 교차 상관 정점은 B가 0.6 s 먼저인 쪽으로 옮겨 간다. TR 0.72 s로 표본화해 그레인저 인과를 검정하면 B→A의 F값(76)이 A→B(22)보다 세 배 넘게 크다. 방향이 거꾸로 나온 것이다. Smith 등(2011)의 시뮬레이션에서도 지연 기반 방법은 방향을 거의 맞히지 못했다.




그림 7.6 HRF의 지역 차이가 시간 순서를 뒤집는다(합성 데이터). (가) 영역 A의 HRF는 정점이 6 s, B는 5 s다. (나) 신경 활동(초록)에서는 B가 A를 0.1 s 늦게 따르지만, BOLD(보라)의 교차 상관 정점은 B가 0.6 s 앞서는 쪽에 있다. 왼쪽 위 숫자는 TR 0.72 s로 표본화한 BOLD에 적용한 그레인저 인과의 F값으로, 거꾸로 된 방향(B→A)이 더 강하게 나온다.

동적 인과 모형

동적 인과 모형(DCM, dynamic causal modelling)은 방향을 데이터에서 직접 읽지 않는다(Friston 등 2003). 대신 "신경 활동이 이렇게 서로 영향을 주고, 그것이 혈류역학을 거쳐 BOLD가 된다"는 생성 모형을

세운다. 신경 부분의 식은 다음과 같다.

$$\frac{dz}{dt} = \left(\mathbf{A} + \sum_j u_j \mathbf{B}^{(j)} \right) \mathbf{z} + \mathbf{C} \mathbf{u}$$

$\mathbf{z}$ 는 영역별 신경 상태, 왼쪽은 그 변화율이다. $\mathbf{A}$ 는 고정된 영역 사이 연결, $\mathbf{B}^{(j)}$ 는 실험 조건 u_j 가 연결을 바꾸는 정도, $\mathbf{C}$ 는 자극이 어느 영역으로 들어오는지도. $\mathbf{z}$ 는 생리 1권 9장의 풍선 모형 같은 혈류역학 모형을 거쳐 영역마다 따로 BOLD를 만든다. 영역마다 혈류역학 변수를 따로 추정하므로 HRF 지연 차이를 모형 안에서 흡수할 수 있다는 것이 그레인저 인과와 다른 점이다.

DCM은 **모형 비교**를 한다. 그럴듯한 연결 구조 여러 개를 세우고 베이지 모형 증거(2장)로 비교한다. 입력이 없는 휴지기 데이터에는 교차 스펙트럼을 맞추는 스펙트럼 DCM을 쓴다. 도구는 SPM에 들어 있다.

한계도 분명하다. 영역은 보통 십여 개 이하다. 결과는 "고른 모형 가운데 가장 나은 것"일 뿐이고, 모형 밖 영역의 공통 입력은 여전히 가짜 연결을 만든다.

뇌로 가는 다리: 'A가 B를 조절한다'는 문장 읽기

"편도체가 전전두피질을 하향 조절했다" 같은 문장이 휴지기 fMRI 논문에 나오면 방법을 확인한다. 그레인저 인과나 지연 상관이라면, HRF 지연이 1 s만 달라도 방향이 뒤집힐 수 있으므로 근거가 약하다. DCM이라면 비교한 모형 집합이 무엇이었는지, 이진 모형의 증거가 얼마나 컸는지(로그 베이지 인자 3 이상을 흔히 "강한" 증거로 본다)를 본다. 방향에 대한 가장 강한 증거는 여전히 개입이다. 동시 TMS-fMRI로 한 영역을 흔들고 다른 영역의 반응을 보거나, 병변 환자를 연구하는 것이 그 예다.

7.7 혼입 요인

머리 움직임

Power 등(2012)은 프레임 사이 움직임(FD, 4장)이 0.5 mm 남짓인 작은 움직임만으로도 연결성이 체계적으로 바뀐다는 것을 보였다. 패턴은 **거리 의존적**이다. 움직임은 가까운 영역의 상관을 부풀리고, 멀리 떨어진 영역의 상관은 상대적으로 덜 부풀리거나 깎는다. 머리가 움직이면 신호 변화가 공간적으로 매끄럽게 퍼져, 가까운 영역에 비슷한 인공물이 함께 들어가기 때문이다.

그림 7.7 (가)는 이것을 흉내 낸 시뮬레이션이다. 머리가 움직인 순간마다 공간적으로 매끄러운 신호 변화를 더하면, 움직임 많은 집단의 연결이 거리 10 mm 근처에서 z 로 약 0.11 커지고, 70 mm에서는 0.04, 130 mm에서는 거의 0이다. 움직임이 큰 볼륨과 그 앞뒤를 지우는 **스크러빙(scrubbing)** 을 하면 차이가 거의 사라진다.

소아, 노인, ADHD, 조현병 환자는 평균적으로 더 많이 움직인다. 움직임이 만드는 "짧은 연결 강화, 긴 연결 약화" 패턴은 발달과 질환 연구에서 흔히 보고된 결과와 닮았다. 그래서 집단 사이 평균 FD, FD와 연결 세기의 상관(QC-FC)과 그 거리 의존성, 쓴 잡음 제거 방법(4장), 스크러빙 뒤 남은 볼륨 수를 확인한다.

전역 신호 회귀

뇌 전체 평균 신호인 **전역 신호(global signal)**에는 호흡과 CO₂, 심박, 각성 수준, 움직임이 섞여 있고, 신경 활동도 일부 들어 있다. 전역 신호를 회귀로 빼는 **전역 신호 회귀(GSR, global signal regression)**는 4장에서 본 대로 오래된 논쟁거리다.

수학적으로 GSR은 연결 분포의 중심을 0 근처로 옮긴다. 공통 성분을 빼면 상관의 합이 대략 0 쪽으로 밀린다(Murphy 등 2009). **그림 7.7** (나)는 참 상관이 0인 두 네트워크에 전역 요동을 더한 예다. 원자료에서는 두 네트워크 사이 상관이 평균 +0.22로 부풀었다. GSR 뒤에는 평균 -0.27로 내려간다. 참 값 0을 지나쳐 음의 상관이 생긴 것이다. Fox 등(2005)이 보고한 디폴트 모드와 과제 양성 네트워크 사이의 음의 상관이 이 논쟁의 중심에 있었다. 음의 상관이 모두 인공물은 아니지만, GSR 뒤의 음의 상관은 그대로 해석하기 어렵다.




그림 7.7 휴지기 연결성의 두 혼입 요인(합성 데이터). (가) 움직임이 많은 집단에서 적은 집단을 뺀 연결 차이(점 하나가 영역 쌍 하나). 움직임 인공물이 가까운 영역에 함께 들어가 짧은 연결을 부풀리고, 움직임 불륨을 지우면(파랑) 차이가 거의 사라진다. (나) 서로 독립인 두 네트워크 사이의 상관 분포. 전역 요동이 섞이면 양으로 치우치고(빨강), 전역 신호 회귀 뒤에는 참 값 0을 지나 음으로 치우친다(파랑).

한편 GSR은 움직임과 호흡 인공물을 가장 강하게 줄이는 방법이기도 하다. 그래서 현재의 권고는 **둘 다 보고하라**에 가깝다. 결과가 GSR 여부에 따라 뒤집힌다면 그 결과는 전역 신호와 얽혀 있다. 집단 사이에 전역 신호 크기가 다르면(각성, 약물) GSR이 집단 차이를 새로 만들 수도 있다.

각성과 생리 상태

생리 1권 5장과 6장에서 본 것처럼 휴지기 스캔 중 상당수의 참가자가 몇 분 안에 얇은 수면에 들어간다. 각성이 떨어지면 전역 신호 진폭이 커지고 시상-피질 연결이 바뀐다. 카페인, 약물, 전날 수면도 결과를 바꾼다. "환자군의 연결성 변화"가 졸음이나 약물의 차이일 수 있으므로 눈 추적이나 졸음 설문을 함께 기록해 둔다.

신뢰도

개인 수준 엷지의 검사-재검사 신뢰도(2장의 ICC)는 대체로 0.2-0.4 안팎으로 낮다는 보고가 많다. 스캔이 길수록, 엷지보다 네트워크 평균을 쓸수록 좋아진다. 신뢰도가 낮으면 행동과의 상관이 깎여 보여 필요한 표본 수가 빠르게 는다.

예제 7.6 신뢰도가 표본 수를 정한다

어떤 연결과 증상 점수의 참 상관이 0.3이다. 연결의 신뢰도는 0.5, 증상 점수의 신뢰도는 0.8이다. (가) 관찰되는 상관의 기댓값은? 측정 상관은 참 상관에 두 신뢰도 곱의 제곱근을 곱한 만큼으로 줄어든다. (나) 양측 $\alpha = 0.05$, 검정력 80 %로 이 상관을 찾으려면 몇 명이 필요한가? 필요 표본 수는 약 $((z_{\alpha/2} + z_{\beta})/\tanh^{-1} r)^2 + 3$ 이다. (다) 참 상관이 0.3인 채 측정이 완벽했다면?

풀이 (가) $0.3 \times \sqrt{0.5 \times 0.8} \approx 0.19$. (나) $z_{\alpha/2} + z_{\beta} = 1.96 + 0.84 = 2.80$ 이고, $\tanh^{-1} 0.19 \approx 0.192$ 다. $(2.80/0.192)^2 + 3 \approx 216$ 명이 필요하다. (다) $\tanh^{-1} 0.3 \approx 0.310$ 이므로 $(2.80/0.310)^2 + 3 \approx 85$ 명이다. 신뢰도 때문에 필요한 표본이 2.5배가 되었다. 실제 뇌-행동 상관은 0.1 안팎인 경우가 많아, 측정이 완벽해도 약 780명이 필요하다. 13장에서 다룰 뇌 전체 연관 연구(Marek 등 2022)의 결론과 같은 방향이다.

뇌로 가는 다리: 정신의학 연결성 바이오마커의 재현성

우울증, 조현병, 자폐 스펙트럼에서 휴지기 연결성으로 환자를 분류하거나 아형을 나누는 연구가 많다. 초기 연구 일부는 수십-100여 명에서 80-90 %대의 분류 정확도를 보고했지만, 더 큰 표본이나 다른 사이트에서는 정확도가 60 %대로 떨어지거나 아형이 재현되지 않는 경우가 많았다. 이유는 이 장의 재료로 설명된다. 엷지 수만 개에 표본 수십 명이면 우연히 맞는 패턴을 찾기 쉽다(13장의 과적합과 데이터 누설). 환자군은 더 움직이고, 약을 먹고, 졸음 정도가 다르다. 사이트가 진단과 얹히고, 엷지 신뢰도가 낮다. 그래서 외부 표본 검증, 움직임 일치, 약물과 사이트 통제를 먼저 확인한다.

핵심 정리

핵심 정리

- 휴지기 fMRI는 0.01-0.1 Hz의 자발적 BOLD 요동에서 영역 사이 상관을 본다(Biswal 1995). 휴지기 네트워크는 사람과 연구실을 넘어 재현되지만(Yeo 2011), 같은 대역에 호흡, 심장, 움직임 잡음이 들어온다.
- 상관은 피서 z 로 바꿔 평균하고 검정한다. 대역 통과한 시계열의 유효 표본은 볼륨 수보다 훨씬 적다(10분, TR 2 s에서 약 108개).
- 상관은 간접 경로와 공통 입력을 직접 연결과 구별하지 못한다. 정밀 행렬의 부분 상관은 이를 걸러 주지만 잡음이 크고 정칙화가 필요하다.
- 공간 ICA는 지도의 독립성을 가정해 겹친 네트워크를 분리하고, 이중 회귀가 집단 지도를 개인에게 되돌린다.
- 그래프 지표는 밀도와 아틀라스에 강하게 의존한다. 절대 상관 문턱은 평균 연결 세기 차이를 구조 차이로 둔갑시킨다. 무작위 그래프도 $Q \approx 0.3$ 을 낸다.
- 미끄럼 창 상관은 잡음만으로도 크게 출렁인다(30 s 창에서 표준편차 약 0.4). 영 모형과 비교해야 한다.
- fMRI의 그레인저 인과는 1-2 s의 HRF 지연 차이 때문에 방향이 뒤집힐 수 있다. DCM은 혈류역학을 모형에 넣고 모형을 비교하지만, 비교한 모형 집합 안에서만 답한다.
- 움직임은 거리 의존적인 가짜 연결을 만들고, 전역 신호 회귀는 음의 상관을 만들 수 있다. 각성, 약물, 엷지의 낮은 신뢰도(ICC 약 0.2-0.4)도 결과를 흔든다.

방법 질 점검표

1. **획득:** 눈 뜨기/잠기, 스캔 길이, TR, 생리 기록, 각성 확인 방법이 적혀 있는가?
2. **잡음 제거:** 움직임 회귀, CompCor/ICA-AROMA, 스크리빙 기준과 남은 볼륨 수, 대역 통과, GSR 여부가 명시되었는가? GSR 유무별 결과가 있는가?
3. **움직임 통제:** 집단 사이 평균 FD를 비교하고 QC-FC와 거리 의존성을 점검했는가?
4. **노드와 엷지:** 아틀라스(이름, 영역 수), 상관인지 부분 상관인지(정칙화 포함), 음의 연결 처리 방식은?
5. **그래프 문턱:** 절대 문턱인가 밀도 문턱인가, 한 값인가 범위인가? 영 모형과 비교했는가?
6. **ICA:** 성분 수, 잡음 성분 판별 기준, 이중 회귀 뒤의 통계와 다중비교 보정이 적혀 있는가?
7. **동적·방향성:** 창 길이와 영 모형, DCM의 모형 공간과 증거 크기가 제시되었는가? 그레인저 인과에서 HRF 지연을 고려했는가?
8. **재현:** 검사-재검사 신뢰도, 외부 표본 검증, 사이트 효과 보정이 있는가?

확인 문제

확인 문제

1. TR 0.72 s로 15분(1250 볼륨) 찍고 0.01–0.1 Hz로 대역 통과한 데이터에서 두 영역의 상관이 0.2였다. 유효 표본 수를 어림하고 피서 z 점수를 구하라. 볼륨 수를 그대로 쓴 z 점수와 비교하라.
2. 세 영역에서 $r_{AB} = 0.6$, $r_{BC} = 0.5$, $r_{AC} = 0.4$ 였다. B를 통제된 A-C 부분 상관을 구하라. A와 C 사이에 직접 연결이 있다고 말할 수 있는가?
3. 환자군과 대조군을 같은 상관 문턱 $r > 0.25$ 로 이진화했더니 환자군의 군집 계수와 전역 효율이 모두 낮았다. 환자군의 평균 상관이 0.05 낮았다면 이 결과를 어떻게 다시 분석해야 하는가?
4. 두 모듈이 각각 노드 4개로 완전 연결(모듈마다 엣지 6개)되어 있고, 두 모듈 사이에 엣지가 1개 있다. 두 모듈로 나눈 Q 를 구하라.
5. 어떤 연구가 45 s 미끄럼 창으로 연결 상태 4개를 찾고, 환자군이 "분리 상태"에 더 오래 머문다고 보고했다. 이 결과가 잡음이나 혼입 요인 때문이 아님을 보이려면 어떤 분석이 필요한가? 세 가지를 들어라.
6. TR 2 s 휴지기 데이터에서 그레이저 인과로 "시상이 피질을 이끈다"는 결과를 얻었다. 이 결론을 의심해야 하는 생리적 이유와, 대안이 될 방법 두 가지를 말하라.
7. GSR 전에는 두 네트워크 사이 상관이 +0.05, GSR 뒤에는 -0.20이었다. 이 음의 상관을 "두 네트워크가 서로 억제한다"고 해석할 때의 문제를 설명하라.

확인 문제 풀이

확인 문제 풀이

1. 길이는 $1250 \times 0.72 = 900$ s이므로 유효 표본은 약 $2 \times 0.09 \times 900 \approx 162$ 개다. $z = \tanh^{-1} 0.2 \approx 0.203$, 표준오차 $1/\sqrt{159} \approx 0.079$, z 점수 약 2.6이다. 볼륨 수를 쓰면 표준오차 $1/\sqrt{1247} \approx 0.028$, z 점수 약 7.2로 크게 부풀려진다. TR을 줄여도 대역폭이 같으면 유효 표본은 늘지 않는다.
2. 분자 $0.4 - 0.6 \times 0.5 = 0.10$, 분모 $\sqrt{(1 - 0.36)(1 - 0.25)} \approx 0.693$ 이므로 $r_{AC \cdot B} \approx 0.14$ 다. B로 설명되지 않는 몫이 조금 남지만, 측정하지 않은 영역의 공통 입력이나 추정 잡음(± 0.1 – 0.2)으로도 생길 수 있으므로 "직접 배선"이라고 말할 수는 없다.
3. 평균 상관이 낮으면 같은 문턱에서 환자군의 밀도가 낮아지고, 밀도가 낮으면 군집 계수와 효율이 낮게 나온다(그림 7.3 다). 밀도 범위에서 지표 곡선을 비교하고, 가중 지표, 평균 연결 세기 공변량, 영 모형으로 정규화한 지표를 함께 본다. 평균 상관 차이가 움직임이나 SNR 차이에서 왔는지도 확인한다.
4. 전체 엣지 $m = 13$. 각 모듈은 $l_c = 6$, 차수 합 $d_c = 4 \times 3 + 1 = 13$ 이다. 한 모듈의 몫은 $6/13 - (13/26)^2 \approx 0.462 - 0.25 = 0.212$ 이고, $Q \approx 0.42$ 다.
5. (1) 같은 스펙트럼과 정적 상관을 가진 대리 데이터(위상 무작위화 등)에서 같은 분석을 해 체류 시간이 영 분포를 넘는지 보인다. (2) 창별 FD, 각성 지표, 호흡 변화와 상태의 관계를 확인하고 집단 사이 움직임과 SNR을 맞춘다. (3) 다른 창 길이, 다른 세션이나 독립 표본에서 재현되는지 보인다. 45 s 창은 100 s보다 짧으므로 고역 필터를 올렸는지도 본다.

6. 시상과 피질의 HRF 정점 시간은 1-2 s까지 다를 수 있지만 신경 지연은 수십 ms 이하이다. BOLD의 시간 순서는 혈관 지연 차이를 반영할 가능성이 크다(그림 7.6). 대안은 혈류역학을 모형에 넣는 스펙트럼 DCM, EEG/MEG나 두개내 기록의 방향성 분석(11장), TMS·병변 같은 개입 연구다.
7. GSR은 연결 분포의 중심을 0 근처로 옮기므로, 참 상관이 0이거나 약한 양이어도 음의 상관을 만들 수 있다(그림 7.7 나, Murphy 등 2009). -0.20은 "억제"의 증거라기보다 GSR 뒤의 상대적인 값이다. CompCor 같은 다른 잡음 제거를 쓴 결과와 동시 전기생리 측정을 함께 보아야 한다.

다음 장으로

이 장의 연결성은 신호가 함께 움직이는지를 통계로 낸 것이었고, 실제 백질 경로에 대해서는 말하지 않았다. 8장에서는 확산 MRI로 물 분자의 움직임을 재고, 트랙토그래피로 백질 경로를 재구성해 구조 연결체를 만든다. 그 연결 행렬에도 이 장의 그래프 지표를 쓸 수 있지만, 스트림라인 수라는 엣지 무게와 가짜 경로라는 새로운 함정이 기다린다.

8장 확산 MRI 분석

이 장에서 배울 것 확산 강조 영상 묶음이 FA 지도, 섬유 방향 분포, 트랙토그래피, 구조 연결체가 되기까지의 단계. 잡음 제거, 왜곡·멤돌이·움직임 보정과 b-벡터 회전, 텐서 적합, TBSS와 트랙 프로파일, 구면 디컨볼루션, 결정적·확률적 추적, 연결 가중치의 편향, 미세구조 모형을 순서대로 다룬다. **뇌 연구자에게 왜 필요한가** 확산 MRI 논문의 결론은 대부분 "어느 다발의 FA가 낮다" 또는 "두 영역의 연결이 약하다"는 꼴이다. 그 숫자는 수십 가지 처리 결정을 거쳐 나온다. 어느 단계가 어떤 가짜 차이를 만들 수 있는지 알아야 결과를 믿을지 판단할 수 있다.

중고등 복습: 벡터의 내적과 회전

크기가 1인 벡터를 **단위 벡터**라 한다. 두 단위 벡터 $\hat{a}$, $\hat{b}$ 의 **내적**은 성분끼리 곱해 더한 값이고, 사이각 θ 의 코사인과 같다: $\hat{a} \cdot \hat{b} = a_x b_x + a_y b_y + a_z b_z = \cos \theta$. 같은 방향이면 1, 직각이면 0이다. 평면에서 벡터 (x, y) 를 각 θ 만큼 돌리면 $(x \cos \theta - y \sin \theta, x \sin \theta + y \cos \theta)$ 가 된다. 이 계산을 표로 묶은 것이 **회전 행렬**이다. 3차원에서는 3×3 행렬이 되고, 머리 움직임의 회전 3개가 이것으로 표현된다(물리 1권 2장). 섬유 방향은 화살표가 아니라 축이다. 앞쪽을 향하든 뒤쪽을 향하든 같은 섬유다. 그래서 두 섬유 방향이 얼마나 비슷한지는 $|\hat{a} \cdot \hat{b}|$ 로 잰다.

8.1 전처리: 원자료에서 쓸 수 있는 영상까지

확산 MRI 한 번의 촬영은 $b = 0$ 영상 몇 장과 $b > 0$ 영상 수십~수백 장으로 이루어진다. 볼륨마다 경사 방향(**b-벡터**)와 세기(**b값**)가 다르다(물리 2권 10장). 이 값은 영상과 별도의 표(bval, bvec 파일)에 들어 있고, 영상과 표가 함께 움직여야 한다.

전처리의 순서는 **그림 8.1** 과 같다. 순서에는 이유가 있다. 잡음 제거는 잡음이 복셀마다 독립인 원자료에서만 제 성질을 쓴다. 보간을 한 번이라도 거치면 이웃 복셀의 잡음이 섞여 이 가정이 깨진다. 왜곡과 움직임 보정은 보간을 여러 번 하지 않도록 하나의 변환으로 합쳐 한 번에 적용한다.




그림 8.1 확산 MRI 분석 파이프라인의 표준 순서. 위 줄(1-4)과 아래 줄의 5-6은 전처리이고, 7-8이 모형 적합과 분석이다. 잡음 제거와 깁스 제거는 보간이 들어가는 보정보다 앞에 둔다. 상자 아래 숫자는 이 장에서 다루는 절이다.

잡음 제거: MP-PCA

왜 하는가. 확산 영상은 신호를 일부러 깎아 만든다. $b = 1000 \text{ s/mm}^2$ 에서 회백질 신호는 $b = 0$ 의 약 45 %로, $b = 3000$ 에서는 약 9 %로 준다. 신호가 잡음 수준에 가까워지면 텐서와 섬유 방향 추정이 흔들리고, 크기 영상의 잡음 바닥 때문에 체계적으로 치우친다(물리 2권 10장).

무엇을 가정하는가. 한 동네(예: $5 \times 5 \times 5$ 복셀) 안의 복셀들은 방향마다 비슷한 모양의 신호를 낸다. 복셀 $\times$ 볼륨 행렬을 주성분으로 나누면 신호는 소수의 큰 성분에 모인다. 잡음은 복셀과 볼륨에 독립이고 분산이 같다고 본다. 이런 순수 잡음 행렬의 고윳값은 **마르첸코-파스투르(Marchenko-Pastur, MP) 분포**라는 정해진 폭 안에 놓인다. 이 폭에 맞는 작은 고윳값들을 잡음으로 보고 버리는 방법이 **MP-PCA**다(Veraart 2016). 문턱을 사람이 고르지 않고, 잡음 크기 σ 도 덤으로 추정한다.

그림 8.2 는 SNR 15($b = 0$ 기준)의 합성 데이터에 적용한 결과다. 5×5 창 25복셀, 66볼륨 행렬의 고윳값 24개 가운데 2개만 MP 띠 위로 솟았다. 나머지를 버리자 회백질(참 FA 0)의 FA가 0.10에서 0.03으로, 백질 FA 오차가 0.036에서 0.022로 줄었다. 추정된 σ 는 0.066으로 참값 0.067과 거의 같았다.




그림 8.2 MP-PCA 잡음 제거(합성 데이터, $b = 1000 \text{ s/mm}^2$ 60방향, $b = 0$ SNR 15). (가) 한 창의 고윳값. 회색 띠는 순수 잡음이 놓일 MP 분포의 범위이고, 그 위로 솟은 2개(빨강)만 신호로 남긴다. (나)~(다) 한 방향의 DWI 영상. 왼쪽 위 원은 뇌실이고 가로·세로 띠는 백질 다발이다. (라) 빼낸 잔차. 구조가 보이지 않는 잡음이어야 한다.

핵심 계산은 몇 줄이다.

```
import numpy as np

def mppca_patch(X):
    """X: (복셀 M, 볼륨 N) 행렬. 잡음 성분을 버린 행렬과 잡음 sigma를 돌려준다."""
    mean = X.mean(0)
    U, s, Vt = np.linalg.svd(X - mean, full_matrices=False)
    M, N = X.shape
    m, n = min(M - 1, N), max(M, N)
    lam = s[:m] ** 2 / n
    for p in range(m):
        rest = lam[p:]
        sig2 = rest.mean()
        if rest[0] - rest[-1] < 4 * np.sqrt((m - p) / n) * sig2:
            break
        # 남은 것이 MP 분포 폭에 들어온다
    Xd = (U[:, :p] * s[:p]) @ Vt[:p] + mean
    return Xd, np.sqrt(sig2)
```

흔한 실수. (1) 움직임 보정이나 재표본화를 먼저 하고 잡음 제거를 한다. (2) 스캐너가 이미 필터나 보간을 한 영상(일부 재구성 옵션, 부분 푸리에, 병렬 영상)에서 잡음 독립 가정이 약해졌다는 것을 잊는다. (3) 잔차 지도를 보지 않는다. 잔차에 해부 구조가 보이면 신호까지 깎은 것이다. 잡음 제거는 크기 영상의 잡음 바닥을 없애지 않는다는 점도 기억한다.

예제 8.1 b값과 잡음 바닥

$b = 0$ 영상의 SNR이 20이다. ADC가 $0.8 \times 10^{-3} \text{ mm}^2/\text{s}$ 인 조직과 $3.0 \times 10^{-3} \text{ mm}^2/\text{s}$ 인 뇌척수액의 SNR을 $b = 1000, 3000 \text{ s/mm}^2$ 에서 구하라. 순수 잡음 크기 영상의 평균은 $\sigma\sqrt{\pi/2}$ 다.

풀이 조직: $e^{-0.8} \approx 0.45$ 이므로 SNR 약 9, $e^{-2.4} \approx 0.091$ 이므로 약 1.8이다. 뇌척수액: $e^{-3} \approx 0.050$ 이므로 $b = 1000$ 에서 SNR 약 1이고, $b = 3000$ 에서는 사실상 0이다. 잡음만 있는 크기 영상의 평균은 약 1.25σ 이므로, $b = 3000$ 의 조직 신호(1.8σ)는 잡음 바닥(1.25σ)과 크게 다르지 않다. 이 영역에서는 신호가 실제보다 크게 읽혀 확산계수가 작게, 비등방성은 크게 추정된다. 고 b값 다중 겹질 자료에서 잡음 제거가 사실상 필수인 이유다.

깁스 링잉 제거

k-공간을 유한하게 자르면 경계 옆에 물결 무늬가 생긴다(물리 2권 7장). 확산 영상에서는 뇌척수액과 뇌량 사이처럼 밝기 차이가 큰 경계에서 문제가 된다. 물결이 MD와 FA 지도에 가짜 띠를 만들고, 침도 같은 고차 지표에서는 음의 값까지 만든다. 국소 부분 복셀 이동으로 링잉을 줄이는 방법(Kellner 2016)이 널리 쓰인다. 이 방법은 영상이 완전한 k-공간에서 재구성되었다고 가정하므로, 부분 푸리에로 찍은 자료에서는 효과가 줄어든다. 잡음 제거 다음, 다른 보정보다 앞에 둔다.

왜곡, 맴돌이 전류, 움직임

확산 EPI에는 세 가지 공간 오류가 겹친다.

- **자화율 왜곡:** B0 불균일이 위상 부호화 방향으로 영상을 늘이고 뭉친다(물리 2권 9장). 볼륨마다 거의 같다. 위상 부호화 방향만 반대로 한 $b = 0$ 영상 한 쌍에서 변위장을 추정한다. 이 방법은 FSL의 `topup` 같은 도구로 한다.
- **맴돌이 전류 왜곡:** 강한 확산 경사를 켜고 끌 때 생긴 맴돌이 전류(물리 1권 8장)가 영상을 늘이고 기울이고 민다. 경사 방향과 세기마다 다르다.
- **머리 움직임:** 볼륨마다 강체 6 파라미터로 추정한다(4장에서 본 fMRI 움직임 보정과 같은 원리다).

맴돌이와 움직임은 따로 풀기 어렵다. $b > 0$ 볼륨은 서로 대비가 달라 단순 정합이 잘 맞지 않기 때문이다. FSL의 `eddy` 같은 도구는 나머지 볼륨에서 각 볼륨이 "있어야 할 모습"을 예측하고, 그 예측과 맞도록 움직임, 맴돌이, 자화율 장을 함께 추정한다. 같은 틀에서 슬라이스 단위 신호 손실도 찾는다. 촬영 중 머리가 급히 움직이면 한 슬라이스의 신호가 통째로 빠진다. 이런 **이상 슬라이스(outlier slice)**를 예측값으로 바꿔 넣고, 몇 개를 바꿨는지를 품질 지표로 보고한다.

b-벡터 회전

머리가 돌아가면 영상은 정합으로 되돌릴 수 있다. 그러나 그 볼륨을 찍을 때 머리 기준으로 본 경사 방향도 함께 돌아가 있었다. 영상만 되돌리고 b-벡터를 그대로 두면, 신호는 머리 좌표의 방향인데 표는 스캐너 좌표의 방향을 적은 셈이다. 그래서 움직임 보정에서 얻은 회전을 b-벡터에도 적용해야 한다(Leemans 2009).

그림 8.3 (가)는 이를 빠뜨렸을 때의 오차다. 모든 볼륨이 θ 만큼 돌아갔다면 주 고유벡터가 정확히 θ 만큼 틀린다. 촬영 동안 0에서 θ 까지 서서히 표류했다면 오차는 이 시뮬레이션에서 θ 의 약 3분의 1이다. 어느 경우에도 FA는 0.80 그대로다. 회전은 타원체의 모양을 바꾸지 않고 방향만 바꾸기 때문이다. FA 지도만 보는 품질 점검으로는 이 오류를 찾을 수 없다.




그림 8.3 b-벡터 오류는 FA가 아니라 방향을 틀리게 한다. (가) 앞뒤 방향 섬유($\lambda = 1.7, 0.3, 0.3 \times 10^{-3} \text{ mm}^2/\text{s}$, 60방향)에서, 머리가 돌아간 만큼 영상은 되돌렸지만 b-벡터를 돌리지 않았을 때의 주 고유벡터 오차. b-벡터도 돌리면 오차는 0이다. (나) 변환 과정에서 b-벡터 x 성분의 부호가 뒤집히면 방향 지도가 거울상이 되어, 휘는 다발에서 방향이 다발을 가로지른다.

더 흔한 사고는 축 부호나 순서 오류다. 변환 프로그램이 영상 축을 뒤집었는데 b-벡터는 그대로 두면 **그림 8.3** (나)처럼 방향이 거울상이 된다. 뇌량 무릎처럼 휘는 곳에서 방향이 다발을 가로지르므로, 주 방향 색 지도를 보거나 트랙토그래피로 뇌량과 피질척수로를 그려 보면 바로 드러난다.

예제 8.2 5° 회전이 경로를 얼마나 비튼는가

머리가 촬영 내내 5° 돌아간 채였고 b-벡터는 돌리지 않았다. 주 방향이 5° 틀린 채로 50 mm를 곧게 추적하면 끝점은 옆으로 얼마나 비켜 가는가?

풀이 $50 \times \sin 5^\circ \approx 4.4 \text{ mm}$ 다. 2 mm 복셀로 두 칸 남짓이다. 실제로는 이웃 복셀의 방향이 경로를 다시 끌어당기기도 하므로 이 값은 어렵이다. 그래도 피질 끝점이 이웃 이랑으로 넘어가기에 충분한 크기다.

🧠 뇌로 가는 다리: 움직임이 집단 차이를 만든다

소아, 노인, 자폐나 ADHD 같은 임상 집단은 대조군보다 많이 움직이는 경우가 많다. 움직임은 이상 슬라이스, 보간 흐림, 맴돌이 보정 오차를 거쳐 FA를 낮추고 MD를 높이는 쪽으로 작용하는 경우가 많다. 그 크기가 환자-대조 FA 차이로 흔히 보고되는 0.01-0.03과 비슷할 수 있다. 그래서 확산 연구는 집단별 움직임 지표(평균 변위, 바뀌 넣은 슬라이스 비율)를 보고하고, 집단 차이가 있으면 공변량으로 넣거나 같은 기준으로 대상자를 제외해야 한다. 움직임 공변량을 넣었더니 효과가 사라졌다면, 그 효과는 처음부터 움직임이었을 가능성이 크다.

편향장, 마스크, 구조 영상 정합

마지막으로 수신 코일 감도에서 오는 밝기 기울기를 보정하고(3장의 편향장 보정), 뇌 마스크를 만들고, $b = 0$ 영상을 T1 영상에 정합한다. 이 정합으로 회백질-백질 경계와 피질 분할을 확산 공간에 가져온다. 8.5절의 해부적 제약과 8.6절의 연결체가 이 정합에 기댄다. 경계 기반 정합이 잘 맞는지 경계선을 겹쳐 보고 확인한다.

8.2 텐서 적합과 스칼라 지도

왜 하는가. 확산 텐서는 복셀의 확산을 타원체 하나로 요약한다(물리 1권 5장, 물리 2권 10장). 미지수가 6개뿐이라 $b = 1000$, 30방향 정도의 임상 자료로도 안정적으로 맞출 수 있다. 고윳값 세 개 $\lambda_1 \geq \lambda_2 \geq \lambda_3$ 에서 네 가지 지도를 만든다.

$$MD = \frac{\lambda_1 + \lambda_2 + \lambda_3}{3}, \quad FA = \sqrt{\frac{3}{2} \frac{\sqrt{(\lambda_1 - MD)^2 + (\lambda_2 - MD)^2 + (\lambda_3 - MD)^2}}{\lambda_1^2 + \lambda_2^2 + \lambda_3^2}}$$

축 방향 확산도(axial diffusivity, AD) 는 λ_1 , **지름 방향 확산도(radial diffusivity, RD)** 는 $(\lambda_2 + \lambda_3)/2$ 다. MD는 평균 확산의 크기, FA는 방향 치우침의 정도(0-1)다. 단위는 FA만 없고 나머지는 $10^{-3} \text{ mm}^2/\text{s}$ 로 쓴다.

적합 방법. 신호의 로그를 취하면 미지수에 대한 일차식이 되므로 최소제곱으로 푼다. 단순 최소제곱은 로그를 취한 뒤 잡음이 신호가 작은 방향에서 커진다는 점을 무시한다. 그래서 신호 크기로 가중하는 **가중 최소제곱(WLS)** 이나 비선형 최소제곱을 기본으로 쓴다. 남은 이상치를 줄이려면 이상치를 자동으로 덜어내는 강건 적합을 쓴다. 대표 도구는 FSL, MRtrix3, DIPY의 텐서 적합 기능이다.

무엇을 가정하는가. 복셀 안의 확산이 하나의 가우스 분포라는 것, 곧 섬유 방향이 하나이고 칸이 하나라는 것이다. b 가 2000 s/mm^2 를 넘으면 신호 감쇠가 단일 지수에서 벗어나므로 텐서는 $b \leq 1000-1500$ 껍질만으로 맞춘다.

예제 8.3 같은 FA, 다른 이야기

정상 백질 복셀의 고윳값이 $(1.7, 0.3, 0.3) \times 10^{-3} \text{ mm}^2/\text{s}$ 다. (가) FA와 MD는? (나) 지름 방향 고윳값만 0.4로 오른 경우와 (다) 축 방향 고윳값만 1.3으로 내린 경우의 FA와 MD는?

풀이 (가) MD = 0.77, FA = 0.80이다. (나) 고윳값 (1.7, 0.4, 0.4)에서 MD = 0.83, FA = 0.73이다. (다) (1.3, 0.3, 0.3)에서 MD = 0.63, FA = 0.73이다. FA는 두 경우 모두 0.80에서 0.73으로 같은 만큼 떨어졌지만 MD는 반대 방향으로 움직였다. FA 하나만 보고하면 이 둘을 구별할 수 없다. 그래서 네 지도를 함께 보고한다. 다만 RD 증가를 곧 "탈수초"로, AD 감소를 곧 "축삭 손상"으로 읽는 것도 단순화다. 교차 섬유가 있는 곳에서는 고유벡터 자체가 섬유와 맞지 않아 AD와 RD의 뜻이 흐려진다(생리 1권 10장).

흔한 실수. 뇌실 옆 복셀의 FA 감소를 해석한다(부분 용적, 생리 1권 10장). 집단 사이 SNR이 다른 것을 무시한다(SNR이 낮으면 FA가 높게 나온다). FA를 "백질 무결성"이라 부른다. 고 b 껍질까지 넣어 텐서를 맞춘다.

8.3 집단 분석: TBSS와 트랙 프로파일

복셀 기반 비교의 문제

FA 지도를 표준 공간으로 정합하고 평활화한 뒤 복셀마다 t-검정을 하는 방법은 3장의 VBM과 같은 발상이다. 문제는 백질 다발이 가늘다는 것이다. 정합이 1-2 mm만 어긋나도 한 사람의 다발 중심이 다른 사람의 다발 가장자리와 겹친다. 다발 가장자리는 FA가 급히 변하므로 정합 오차가 곧 FA 차이가 된다. 평활화 폭을 바꾸면 결과도 바뀐다.

TBSS

TBSS(tract-based spatial statistics) 는 이 문제를 비켜 가려고 만들었다(Smith 2006). 순서는 다음과 같다.

1. 모든 사람의 FA 지도를 공통 표준 FA 영상에 비선형 정합한다.
2. 평균 FA 지도에서 다발의 중심선만 남긴 **골격(skeleton)** 을 만든다. 평균 FA가 문턱(보통 0.2) 아래인 곳은 뺀다.
3. 각 사람의 FA를 골격에 **투영**한다. 골격 복셀마다 그에 수직인 방향으로 근처를 훑어, 그 사람의 가장 큰 FA 값을 골격 값으로 가져온다.
4. 골격 복셀마다 GLM을 맞추고 순열 검정과 TFCE로 다중비교를 보정한다(6장에서).

투영 덕분에 정합이 조금 어긋나도 각자의 다발 중심값을 비교한다. 평활화도 필요 없다. MD, AD, RD는 FA로 정한 같은 투영을 빌려 쓴다.

가정과 한계. "가장 큰 FA가 다발의 중심"이라는 가정이 핵심이다. 두 다발이 가까이 붙은 곳에서는 투영이 이웃 다발의 값을 가져올 수 있다. 다발이 교차하는 곳의 골격은 어느 다발의 것인지 정해지지 않는다. 병변이나 위축으로 다발이 가늘어지면 최댓값 탐색이 다른 구조를 잡는다. 골격 위 유의 군집의 위치는 실제 변화가 일어난 자리와 다를 수 있다.

흔한 오해: TBSS 골격의 유의 복셀이 곧 손상 부위다

TBSS 결과 그림의 빨간 골격 조각은 "그 골격 복셀에 투영된 값"이 집단 사이에 달랐다는 뜻이다. 투영은 수직 방향으로 수 mm를 훑으므로 실제 차이는 그 주변 어디에서든 왔을 수 있다. 교차 지역에서는 골격이 어느 다발을 대표하는지도 정해지지 않는다. 그래서 TBSS 결과를 "상세로속의 손상"처럼 특정 다발 이름으로 보고하려면, 해당 위치의 아틀라스 확률과 교차 여부를 함께 확인하고 표현을 조심해야 한다. 또 TFCE 결과는 군집 단위가 아니라 복셀 단위 추론이지만, 군집의 넓이를 효과의 크기로 읽으면 안 된다(6장).

트랙 프로파일

다른 길은 다발을 먼저 찾고, 그 다발을 따라 지표를 재는 것이다. 사람마다 트랙토프레피나 아틀라스로 공상다발, 피질척수로 같은 다발을 찾고, 다발을 따라 100개 정도의 마디로 나눈다. 마디마다 다발 중심에 가까운 스트림라인일수록 무게를 주어 FA를 평균하면 **트랙 프로파일(tract profile)** 이 된다(Yeatman 2012). 다발 전체 평균에서는 묻히는 국소 변화를 볼 수 있고, 같은 해부 위치끼리 비교하므로 정합 오차에 덜 민감하다. 대신 각 사람의 다발 분할이 정확해야 하고, 다발 끝 쪽 마디는 섬유가 퍼져 값이 불안정하다. 다발을 자동으로 찾는 도구로는 pyAFQ나 딥러닝 기반 다발 분할 도구가 있다.

🧠 뇌로 가는 다리: 다발 하나의 어느 마디가 달라졌는가

읽기 장애 연구에서 왼쪽 공상다발의 평균 FA 차이는 작고 일관되지 않았다. 다발을 따라 프로파일로 보면 차이가 특정 구간(예: 측두-두정 접합부 근처)에 모이는 경우가 있다. 프로파일 분석은 마디가 100개라 다중비교가 다시 생긴다. 마디 사이 상관을 반영한 순열 검정이나 군집 보정을 쓴다. 또 프로파일의 모양 자체가 교차 섬유에 따라 오르내린다. 공상다발이 방사관과 교차하는 마디에서 FA가 뚝 떨어지는 것은 정상 해부의 흔적이지 손상이 아니다.

8.4 섬유 방향 모형

텐서가 실패하는 복셀

텐서는 섬유 방향이 하나라고 가정한다. 그러나 백질 복셀의 대부분에는 방향이 둘 이상이다. 설정에 따라 60-90 %, 많게는 약 90 %의 백질 복셀이 여러 방향의 섬유를 품는다는 추정이 있다(Jeurissen 2013). 반란원 중심에서는 뇌량 섬유, 피질척수로, 상세로속이 한 복셀에서 만난다.

그림 8.4의 윗줄은 교차 복셀에서 텐서가 어떻게 실패하는지 보여 준다. 90° 교차는 FA 0.50의 둥근 타원이 되고, 주 방향은 어느 다발과도 맞지 않는 102°를 가리켰다. 45° 교차에서 주 방향은 두 다발의 한가운데(약 23°)를 가리킨다. 그 방향에는 섬유가 하나도 없다. 30° 교차는 FA 0.82로 한 다발과 구별되지 않는다.

구면 디컨볼루션

구면 디컨볼루션(spherical deconvolution)은 측정 신호를 "한 다발이 내는 신호 모양(응답 함수)"을 여러 방향으로 돌려 더한 것으로 본다. 각 방향에 얼마의 무게가 있는지가 **섬유 방향 분포(fiber orientation distribution, FOD)**다. 측정 신호에서 응답 함수를 풀어내는 일은 시간 축의 디컨볼루션(물리 2권 7장)을

구 위에서 하는 셈이다. 잡음 때문에 그냥 풀면 음의 무게가 생기므로, 음수를 금지하는 제약을 건 것이 **구속 구면 디컨볼루션(constrained spherical deconvolution, CSD)** 이다(Tournier 2007).




그림 8.4 교차 섬유 복셀의 텐서와 섬유 방향 분포(합성 데이터, $b = 3000 \text{ s/mm}^2$, 64방향, SNR 30). 점선은 실제 다발 방향이다. 위줄: 텐서 타원과 주 방향(빨강). 90° 교차는 동근 타원이 되고, 45° 교차에서는 두 다발 사이를 가리키며, 30° 교차는 FA가 한 다발과 같다. 아랫줄: 음이 아닌 구면 디컨볼루션으로 얻은 섬유 방향 분포와 봉우리(빨강). 90°와 45°는 두 봉우리로 풀리지만 30°는 하나로 합쳐진다.

그림 8.4 아랫줄이 그 결과다. 90°와 45° 교차는 봉우리 두 개로 풀렸다. 45°의 봉우리는 실제(0°, 45°)보다 서로 가깝게(약 1°, 37°) 잡혔다. 30° 교차는 봉우리 하나로 합쳐졌다. 이 시뮬레이션은 응답 함수를 정확히 안다고 가정했으므로 낙관적이다. 실제 자료에서 풀리는 교차 각은 대략 40-60°부터다.

가정과 선택지. (1) 응답 함수가 뇌 전체에서 같다고 가정한다. 응답 함수는 FA가 높은 단일 다발 복셀들에서 자료로 추정한다. 축삭 지름이나 수초 차이로 다발마다 응답이 다르면 FOD의 크기와 봉우리가 함께 틀린다. (2) 단일 껍질 CSD는 회백질과 뇌척수액이 섞인 복셀에서 가짜 봉우리를 만든다. 여러 b 값을 쓰는 **다중 조직 CSD**는 백질, 회백질, 뇌척수액의 응답을 따로 두고 복셀 신호를 세 조직으로 나눈다. (3) 다른 계열로, 볼-막대 모형으로 섬유 방향의 사후 분포를 베이지 방식으로 추정하는 방법(FSL의 BEDPOSTX)이 있다. 이 방법은 "방향이 몇 개인가"를 자료가 허락하는 만큼만 늘린다.

흔한 실수. $b = 1000$, 30방향 자료로 CSD를 돌리고 교차가 풀렸다고 믿는다. 이런 자료에서는 FOD가 넓고 봉우리 위치가 불안정하다. FOD의 봉우리 높이를 섬유 밀도로 바로 읽는 것도 조심한다. 응답 함수 크기 정규화와 $b = 0$ 강도 정규화가 집단 사이에 같아야 비교할 수 있다.

8.5 트랙토그래피

원리와 설정

트랙토그래피(tractography) 는 씨앗 점에서 출발해 그 자리의 섬유 방향으로 한 걸음 가고, 새 자리에서 방향을 다시 읽어 또 가는 일을 되풀이한다(물리 2권 10장). 이렇게 만든 선 하나를 **스트림라인(streamline)** 이라 한다. 설정해야 할 값은 다음과 같다.

- **방향을 읽는 모형**: 텐서의 주 고유벡터, 또는 FOD의 봉우리.
- **걸음 크기**: 보통 복셀 크기의 0.1-0.5배(0.2-1 mm).
- **꺾임 각 문턱**: 한 걸음에 꺾일 수 있는 최대 각(보통 30-60°).
- **정지 조건**: FA 또는 FOD 크기가 문턱 아래(예: FA 0.1-0.2), 뇌 마스크 밖, 꺾임 각 초과.
- **씨앗 방식**: 관심 영역에서, 또는 백질 전체나 회백질-백질 경계에서 고르게.

결정적 추적(deterministic tracking) 은 매 걸음 가장 그럴듯한 방향 하나를 따른다. **그림 8.5** 은 활 모양 다발과 세로 다발이 직각으로 만나는 2차원 합성 장에서 두 방식을 비교한다. 교차 복셀에서 세로 다발의 뒀(0.55)이 조금 더 크다. 텐서의 주 방향을 따르면 활에서 출발한 스트림라인 5개 가운데 4개가 교차점에서 세로 다발로 갈아타고, 1개는 멈춘다. FOD 봉우리 가운데 직전 방향에 가장 가까운 것을 고르면 5개 모두 교차를 지나 활을 끝까지 따른다.




그림 8.5 2차원 합성 섬유 장(복셀 2 mm)에서의 결정적 추적. 회색 짧은 선은 복셀마다 섬유 방향(길이는 뒀)이고, 검은 점은 씨앗이다. (가) 텐서 주방향을 따르면 활 다발(파랑)이 교차점에서 뒀이 조금 더 큰 세로 다발로 갈아탄다. 세로 다발(빨강)은 교차를 지나 옆으로 밀린다. (나) 직전 방향에 가장 가까운 섬유 봉우리를 고르면 두 다발 모두 교차를 지난다.

추적의 한 걸음은 짧은 코드로 쓸 수 있다.

```
import numpy as np

def step(p, d, peaks_at, h=0.5, max_angle=45):
    """p: 현재 위치, d: 직전 방향(단위 벡터), peaks_at(p): 그 자리 봉우리 목록."""
    cands = peaks_at(p)
    if not cands:
        return None # 정지: 봉우리 없음(마스크 밖)
    nd = max(cands, key=lambda c: abs(c @ d)) # 직전 방향에 가장 가까운 봉우리
    if nd @ d < 0:
        nd = -nd # 섬유는 축: 진행 방향에 맞춰 뒤집는다
    if nd @ d < np.cos(np.radians(max_angle)):
        return None # 정지: 너무 급히 꺾임
    return p + h * nd, nd
```

예제 8.4 꺾임 각 문턱은 무엇을 막는가

걸음 크기 h , 한 걸음 꺾임 θ 인 경로가 그리는 원의 반지름은 $R = h/(2\sin(\theta/2))$ 다. (가) $h = 0.5$ mm, 문턱 45° 이면 허용되는 가장 작은 반지름은? (나) 반지름 30 mm의 활(그림 8.5)을 따라가려면 한 걸음에 몇 도 꺾이는가?

풀이 (가) $0.5/(2\sin 22.5^\circ) \approx 0.65$ mm다. 반지름 수 mm인 U-섬유보다 훨씬 작으니 이 문턱은 곡률을 거의 제한하지 않는다. 실제로 문턱이 막는 것은 교차점에서 직각으로 갈아타는 것과 잡음으로 인한 급한 꺾임이다. (나) $2\arcsin(0.5/60) \approx 0.95^\circ$ 다. 정상적인 다발은 한 걸음에 1° 안팎으로만 꺾인다. 같은 45° 문턱이라도 걸음이 2 mm면 최소 반지름이 약 2.6 mm로 커진다. 걸음 크기와 각 문턱은 함께 보고해야 뜻이 있다.

확률적 추적

확률적 추적(probabilistic tracking)은 매 걸음 방향의 불확실성을 반영해 방향을 표본으로 뽑는다. 같은 씨앗에서 수천 개를 뿌려, 복셀마다 몇 개가 지나갔는지 세면 **방문 밀도 지도**가 된다. FSL의 확률 추적 도구와 MRtrix3의 FOD 기반 추적이 대표적이다.

그림 8.6은 같은 합성 장에서 매 걸음 방향을 8° 또는 12° (표준편차)만큼 흔들어 5000개를 뿌린 결과다. 불확실성 12° 에서 다발 중간(약 35 mm)까지 간 것은 54 %, 끝(약 70 mm)까지 간 것은 27 %였다. 8° 에서는 97 %와 86 %였다. 방문 밀도는 씨앗에서 멀어질수록 줄고, 교차에서 일부가 세로 다발로 샌다.




그림 8.6 확률적 추적(5000개, 걸음 0.5 mm, 꺾임 문턱 45°). (가) 방향 불확실성 12°일 때 복셀마다 지나간 스트림라인의 비율(로그 눈금). 씨앗(빨간 선)에서 멀수록 밀도가 줄고, 교차에서 일부가 세로 다발로 샌다. (나) 씨앗에서 다발을 따라 각 거리까지 간 스트림라인의 비율. 불확실성이 클수록 빨리 줄어든다.

여기서 두 가지를 읽어야 한다. 첫째, 방문 밀도는 "연결 확률"이 아니다. 같은 경로라도 씨앗에서 멀면 밀도가 낮다. 거리, 곡률, 교차의 수가 밀도에 섞인다. 둘째, 밀도 지도를 어떤 문턱에서 자르느냐에 따라 다발의 크기와 모양이 크게 바뀐다. 1 %에서 자를지 0.1 %에서 자를지는 근거가 있어야 하고, 논문에 적혀 있어야 한다.

해부적 제약과 가짜 경로

스트림라인은 백질 한가운데서 멈추거나 뇌척수액으로 빠져나가기도 한다. 실제 축삭은 그렇지 않다.

해부적 제약 트랙토그래피(anatomically-constrained tractography, ACT) 는 T1 영상의 조직 분할을 써서 스트림라인이 회백질에서 끝나도록 강제하고, 백질 안이나 뇌척수액에서 끝난 것은 버린다(Smith 2012). 회백질-백질 경계에서 씨앗을 뿌리는 방식과 함께 쓴다. 이 제약은 확산 공간과 T1 공간의 정합이 정확하다는 가정에 기댄다(8.1절).

해부적 제약을 써도 근본 문제는 남는다. 국제 대회에서 합성 정답 자료에 20개 연구팀이 낸 96개의 트랙토그램을 평가했다(Maier-Hein 2017). 대부분이 정답 다발의 90 % 정도를 어느 정도 찾았지만, 평균적으로 참 다발의 약 4배에 이르는 가짜 다발을 함께 만들었다. 원인은 **그림 8.5** 의 갈림길과 같다. 교차, 스침, 부채꼴 퍼짐은 복셀 안에서 신호가 같을 수 있고, 국소 정보만으로는 어느 길이 맞는지 정할 수 없다.

흔한 오해: 트랙토그래피가 그렸으니 그 연결이 있다

트랙토그래피는 "물이 잘 퍼지는 방향을 이은 선"이다. 선이 그려졌다는 것은 그런 길이 국소 방향과 모순되지 않는다는 뜻일 뿐이다. 반대로 선이 없다고 연결이 없는 것도 아니다. 교차가 많은 곳이나 다발 끝의 부채꼴 퍼짐에서는 실제 다발이 자주 끊긴다. 새로운 연결을 "발견"했다는 주장은 동물 추적자 연구나 해부와 맞춰 보아야 한다. 트랙토그래피가 가장 믿을 만한 쓰임은 이미 알려진 다발을 사람마다 찾아 그 위의 지표를 재는 일이다(8.3절의 트랙 프로파일).

🧠 뇌로 가는 다리: 수술 계획 트랙토그래피

뇌종양이나 뇌전증 수술 전에 피질척수로, 궁상다발, 시각로(마이어 고리)를 그려 절제 범위를 정한다. 여기서 텐서 기반 결정적 추적의 약점이 바로 위험이 된다. 피질척수로 중 얼굴과 손으로 가는 바깥쪽 섬유는 상세로속, 뇌량 섬유와 교차하므로 텐서 추적에서 자주 빠진다. 그림에 없는 섬유를 "없다"고 읽으면 절제가 너무 가까이 간다. FOD 기반 추적이 이 바깥쪽 섬유를 더 많이 찾는다는 보고가 많다. 부종은 FA를 낮춰 정지 문턱에 먼저 걸리게 하고, 개두술 뒤에는 뇌가 밀려(brain shift) 수술 전 지도와 위치가 1 cm 넘게 어긋날 수 있다. 그래서 많은 센터가 트랙과의 거리에 수 mm의 안전 여유를 두고, 수술 중 피질하 전기 자극으로 확인한다. 트랙토그래피는 안내도이지 경계선이 아니다.

8.6 구조 연결체

구조 연결체(structural connectome) 는 뇌를 영역(노드)으로 나누고, 두 영역을 잇는 스트림라인으로 연결(엣지)의 무게를 정한 행렬이다. 순서는 이렇다. T1에서 피질과 피질하 영역을 분할한다(1장의 아틀라스). 백질 전체에서 수백만 개의 스트림라인을 만든다. 각 스트림라인의 두 끝이 어느 영역에 닿는지 찾아 행렬 칸에 더한다. 그다음 7장의 그래프 지표를 계산한다.

스트림라인 수는 무엇을 세는가

가장 흔한 무게는 두 영역을 잇는 스트림라인의 수다. 이 수는 축삭 수와 비례하지 않는다. 씨앗의 수와 위치, 다발의 길이, 곡률, 교차, 영역의 크기가 모두 들어간다. 길이의 영향만 떼어 보자.

그림 8.7 는 굵기(축삭 수)가 같고 길이만 다른 다발들에서 스트림라인 수를 셸다. 추적은 1 mm마다 일정한 확률로 일찍 멈춘다(평균 생존 길이 $\lambda = 40$ mm). 한쪽 끝 영역에서 씨앗을 뿌리면 반대쪽 끝까지 살아남는 비율이 $e^{-L/\lambda}$ 로 줄어 긴 다발이 불리하다. 백질 전체에 고르게 뿌리면 긴 다발에 씨앗이 길이에 비례해 많이 떨어지므로 $Le^{-L/\lambda}$ 가 된다. 이 곡선은 $L = \lambda$ 에서 최대이고, 아주 짧은 다발과 아주 긴 다발을 모두 과소평가한다. 어느 쪽이든 참값(모두 같음)과 다르다.




그림 8.7 스트림라인 수의 길이 편향(굵기가 같은 다발, 평균 생존 길이 40 mm). 점은 몬테카를로 시뮬레이션, 선은 식이다. (가) 끝 영역에서 씨앗을 뿌리면 수가 길이에 따라 지수로 줄고, 백질 전체에 뿌리면 40 mm 근처에서 가장 많다. (나) 20 mm 다발과 100 mm 다발의 스트림라인 수 비. 참값은 1이다.

예제 8.5 짧은 연결이 7배 강해 보인다

축삭 수가 같은 20 mm 다발과 100 mm 다발이 있다. 평균 생존 길이 40 mm로 추적할 때 (가) 끝 영역 씨앗과 (나) 백질 전체 씨앗에서 두 다발의 스트림라인 수 비는?

풀이 (가) $e^{-20/40}/e^{-100/40} = e^2 \approx 7.4$ 배. (나) $(20e^{-0.5})/(100e^{-2.5}) = 0.2e^2 \approx 1.5$ 배. 같은 해부를 같은 자료로 추적했는데, 씨앗 방식만 바뀌도 짧은 연결이 7.4배 또는 1.5배 강해 보인다. 연결체의 그래프 지표가 영역 사이 거리와 강하게 얽히는 이유다. 실제 정지 확률은 곡률, 교차, 잡음에 따라 다발마다 달라 이렇게 깔끔하게 보정할 수도 없다.

신호에 맞춰 다시 가중하기

SIFT(spherical-deconvolution informed filtering of tractograms) 는 다른 접근을 쓴다(Smith 2013). 스트림라인 밀도가 복셀마다 FOD의 크기(섬유 밀도의 대리 지표)와 맞아야 한다는 조건을 세운다. 그리고 이 조건을 가장 어기는 스트림라인부터 걸러 낸다. 걸러 내는 대신 스트림라인마다 무게를 매기는 후속 방법(SIFT2)도 있다. 이렇게 하면 스트림라인 수가 "단면을 지나는 섬유의 양"에 가까운 단위를 갖게 되고, 길이와 씨앗의 편향이 상당 부분 줄어든다. 그래도 FOD 크기가 섬유 밀도를 바르게 나타낸다는 가정, ACT 같은 해부적 제약, 가짜 경로 문제는 그대로 남는다.

그 밖의 선택지도 결과를 바꾼다. 영역 크기로 나누기, 길이로 나누기, 무게 대신 다발 평균 FA 쓰기, 약한 엷지를 지우는 문턱(7장에서 본 밀도 문제)이 그렇다. 연결체 논문을 읽을 때는 이 선택이 모두 적혀 있는지 본다.

🧠 뇌로 가는 다리: 연결체 허브와 거리

구조 연결체에서는 연합 피질 일부가 서로 촘촘히 이어진 "부자 클럽(rich club)" 허브로 나타난다. 허브는 대개 긴 연결의 끝에 있다. 그런데 위의 길이 편향은 긴 연결을 과소 또는 과대평가할 수 있고, 영역 크기는 연결 수를 늘린다. 그래서 허브 지표를 해석할 때는 거리와 영역 크기를 보존한 무작위 망과 비교한다. 환자 집단에서 긴 연결이 약하다는 결과는 특히 조심해서 읽는다. 환자가 더 많이 움직여 잡음이 크면 정지가 잦아져 긴 연결이 먼저 사라진다.

8.7 미세구조 모형

텐서는 복셀의 확산을 기술할 뿐, 조직이 무엇으로 되어 있는지 말하지 않는다. 미세구조 모형은 생물학적 칸을 가정하고 여러 b값의 신호에 맞춰 그 칸의 비율을 추정한다(생리 1권 10장).

확산 침도 영상(diffusion kurtosis imaging, DKI) 은 신호 감쇠가 단일 지수에서 얼마나 휘는지를 **침도(kurtosis)** 로 잰다. 가우스 확산이면 침도가 0이고, 막과 칸이 많을수록 커진다. b값이 둘 이상(보통 최대 2000–2500 s/mm²) 필요하다. 침도는 특정 모형을 가정하지 않는 기술 지표라는 장점이 있지만, 잡음과 깃스 링잉에 민감해 음수나 터무니없이 큰 값이 쉽게 나온다. 8.1절의 잡음 제거와 깃스 제거가 특히 중요하다.

NODDI(neurite orientation dispersion and density imaging) 는 신호를 세 칸으로 나눈다(Zhang 2012). 신경돌기 안(막대 모양, 지름 0), 신경돌기 밖(장애 확산), 자유 물(뇌척수액)이다. 결과는 **신경돌기**

밀도(NDI), 방향 분산 지수(ODI), 자유 물 분율이다. 다중 겹질 자료(예: $b = 1000$ 과 2000)에서 계산할 수 있어 UK 바이오뱅크 같은 대규모 자료에도 들어 있다.

가정이 결과를 정한다. NODDI는 신경돌기 안의 축 방향 확산도를 $1.7 \times 10^{-3} \text{ mm}^2/\text{s}$ 로 고정하고, 바깥쪽의 확산도를 안쪽 칸 비율과 정해진 식으로 묶고, 칸 사이 물 교환을 무시한다. 이 고정값이 맞지 않는 조직에서는 NDI가 확산도의 변화를 대신 떠안는다. 회백질, 발달 중인 뇌, 병변이 그렇다. 고정을 풀면 모형이 자료로 구별되지 않는 해를 여럿 갖는다는 것도 알려져 있다. 그래서 NDI를 "축삭 밀도"로, ODI를 "수상돌기 복잡도"로 바로 옮기는 것은 지나친 해석이다. 모형 지표는 FA보다 "더 생물학적인" 숫자처럼 보이지만, 그 생물학은 모형이 가정한 만큼만 들어 있다.

흔한 실수. 모형이 요구하는 b 값과 방향 수보다 적은 자료로 맞춘다. 피질에서 백질용 고정값을 그대로 쓴다. 여러 모형 지표와 FA, MD를 모두 검정하고 다중비교를 보정하지 않는다. 적합 잔차와 지표의 재검사 신뢰도를 보고하지 않는다.

핵심 정리

핵심 정리

- 확산 전처리 순서는 원자료 점검 → 잡음 제거 → 깃스 제거 → 왜곡(역위상 $b = 0$ 쌍) → 맴돌이·움직임 보정(+ b -벡터 회전, 이상 슬라이스 대체) → 편향장·마스킹·T1 정합이다. 잡음 제거와 깃스 제거는 보간 전에 한다.
- MP-PCA는 순수 잡음 고윳값이 마르첸코-파스투르 범위에 놓인다는 것을 이용해 문턱 없이 잡음 성분을 버리고 σ 를 추정한다. 합성 자료에서 회백질 FA의 잡음 바닥이 0.10에서 0.03으로 줄었다. 잔차에 구조가 보이면 안 된다.
- 움직임 회전을 b -벡터에 적용하지 않으면 주 방향이 회전각만큼 틀리지만 FA는 그대로다. 축 부호 오류는 방향 지도를 거울상으로 만든다. 방향 색 지도와 알려진 다발로 확인한다.
- FA, MD, AD, RD는 함께 본다. 같은 FA 감소($0.80 \rightarrow 0.73$)가 MD 증가에서도 감소에서도 생긴다. 백질 복셀의 60-90 %가 교차 섬유를 품으므로 AD·RD의 생물학적 해석은 제한적이다.
- TBSS는 FA 최댓값을 골격에 투영해 정합 오차를 비켜 가지만, 골격 위치는 손상 위치가 아니다. 트랙 프로파일은 다발을 따라 국소 변화를 본다.
- 텐서는 교차 복셀에서 등글어지거나 두 다발 사이의 빈 방향을 가리킨다. CSD는 응답 함수를 풀어 섬유 방향 분포를 얻고, 실제 자료에서 대략 $40-60^\circ$ 이상의 교차를 푼다.
- 결정적 추적은 교차에서 다발을 갈아탈 수 있고, 확률적 추적의 방문 밀도는 거리에 따라 줄어 연결 확률이 아니다. 합성 정답 대회에서 트랙토그램은 참 다발의 약 4배에 이르는 가짜 다발을 만들었다.
- 스트림라인 수는 길이와 씨앗 방식에 따라 수 배씩 바뀐다(예: 20 mm 대 100 mm 다발이 7.4배 또는 1.5배). SIFT 같은 재가중이 편향을 줄이지만 축삭 수와 같은 양은 아니다.
- DKI와 NODDI는 다중 겹질 자료로 미세구조를 기술하지만, 지표의 생물학적 뜻은 고정된 가정만큼만 믿을 수 있다.

방법 절 점검표

방법 절 점검표

1. **획득:** b값, 방향 수, 꺾질 수, 복셀 크기, 역위상 $b = 0$ 영상 유무가 적혀 있는가? 쓰려는 모형(텐서, CSD, NODDI)에 맞는 자료인가?
2. **전처리 순서:** 잡음 제거와 깃스 제거가 보간 전에 있는가? 왜곡, 맴돌이, 움직임을 어떤 도구로 보정했고, b-벡터를 회전했는가?
3. **움직임과 품질:** 집단별 움직임 지표와 바꿔 넣은 슬라이스 비율을 보고했는가? 집단 차이가 있으면 공변량이나 제외 기준으로 다뤘는가?
4. **모형 적합:** 텐서 적합 방법(WLS 등)과 사용한 b 꺾질, CSD의 응답 함수 추정 방법과 단일/다중 조직 여부가 적혀 있는가?
5. **집단 분석:** TBSS라면 골격 문턱, 투영 방식, 다중비교 방법(순열·TFCE)이 있는가? 결과를 특정 다발 이름으로 부를 근거가 있는가?
6. **트랙토그래피:** 결정적/확률적, 방향 모형, 걸음 크기, 꺾임 각, 정지 문턱, 씨앗 방식, 해부적 제약 여부가 모두 적혀 있는가? 밀도 지도의 문턱은 무엇인가?
7. **연결체:** 엣지 무게가 스트림라인 수인가, SIFT 계열로 보정한 값인가, FA 같은 지표인가? 영역 크기와 길이를 어떻게 다뤘는가?
8. **해석:** FA나 NDI 변화를 "무결성", "수초", "축삭 밀도"로 바로 옮기지 않았는가? 교차 섬유와 부분 용적을 대안 설명으로 검토했는가?

확인 문제

확인 문제

1. MP-PCA를 움직임 보정 뒤에 적용하면 왜 효과가 떨어지는가? 잡음 제거가 제대로 되었는지 확인하는 간단한 방법은 무엇인가?
2. $b = 0$ SNR이 25인 자료에서 $ADC\ 0.8 \times 10^{-3}\text{ mm}^2/\text{s}$ 인 조직의 SNR을 $b = 2000\text{ s/mm}^2$ 에서 구하라. 이 값을 잡음 바닥(1.25σ)과 비교하라.
3. 한 연구가 움직임 보정 뒤 b-벡터를 돌리지 않았다. FA 집단 비교 결과와 트랙토그래피 결과 가운데 어느 쪽이 더 크게 오염되는가? 이유를 설명하라.
4. 고윳값 $(1.6, 0.5, 0.5) \times 10^{-3}\text{ mm}^2/\text{s}$ 인 복셀의 MD, FA, AD, RD를 구하라.
5. TBSS에서 "투영"이 무엇을 하는지 설명하고, 그 때문에 생기는 해석상의 함정을 하나 들어라.
6. 45° 교차 복셀에서 텐서의 주 방향은 어디를 가리키는가? 이 복셀을 텐서 기반 결정적 추적이 지나가면 어떤 일이 생길 수 있는가?
7. 걸음 크기 1 mm, 꺾임 문턱 60° 일 때 허용되는 가장 작은 곡률 반지름은 얼마인가?
8. 평균 생존 길이 50 mm로 백질 전체에서 씨앗을 뿌렸다. 축삭 수가 같은 30 mm 다발과 120 mm 다발의 스트림라인 수 비는 얼마인가? 이 결과로 "짧은 연결이 강하다"고 결론 내리면 무엇이 틀렸는가?

확인 문제 풀이

확인 문제 풀이

1. MP-PCA는 잡음이 복셀과 볼륨마다 독립이고 분산이 같다고 가정한다. 움직임 보정의 보간은 이웃 복셀의 잡음을 섞어 상관을 만들고 분산을 줄인다. 그러면 잡음 고윳값이 MP 분포를 따르지 않아 신호와 잡음의 경계를 잘못 잡는다. 원자료와 잡음 제거 결과의 차이(잔차) 지도를 보아 해부 구조가 보이지 않는지 확인하고, 추정 σ 지도가 매끄러운지 본다.
2. $e^{-1.6} \approx 0.20$ 이므로 SNR은 $25 \times 0.20 \approx 5.0$ 이다. 잡음 바닥 1.25σ 의 약 4배라 아직 쓸 만하지만, 크기 잡음의 치우침이 무시할 수준은 아니다.
3. 트랙토그래피다. 회전은 타원체의 모양을 바꾸지 않으므로 FA는 거의 그대로다(그림 8.3). 방향은 회전각만큼 틀리고, 그 오차가 걸음마다 쌓여 경로가 옆으로 비켜 간다. 다만 볼륨마다 회전이 크게 다르면 텐서 모양도 흐트러져 FA가 조금 바뀐다. 집단별 움직임이 다르면 FA에도 작은 체계적 차이가 생길 수 있다.
4. $MD = (1.6 + 0.5 + 0.5)/3 \approx 0.87$, $AD = 1.6$, $RD = 0.5$ ($10^{-3} \text{ mm}^2/\text{s}$). FA는 분자 $\sqrt{0.733^2 + 2 \times 0.367^2} \approx 0.898$, 분모 $\sqrt{1.6^2 + 2 \times 0.5^2} \approx 1.749$ 이므로 $\sqrt{1.5} \times 0.898/1.749 \approx 0.63$ 이다.
5. 각 골격 복셀에서 수직 방향으로 근처를 훑어 그 사람의 가장 큰 FA를 골격 값으로 가져온다. 정합이 조금 어긋나도 다발 중심값끼리 비교하려는 것이다. 함정: 유의한 골격 복셀의 위치가 실제 변화의 위치와 다를 수 있다. 붙어 있는 다른 다발의 값을 가져왔을 수도 있고, 교차 지역에서는 골격이 어느 다발을 대표하는지 정해지지 않는다.
6. 두 다발 방향의 한가운데(약 22.5°)를 가리킨다(그림 8.4). 그 방향에는 섬유가 없으므로, 스트림라인이 교차를 지나며 한쪽 다발에서 다른 쪽 다발로 비스듬히 넘어가거나 엉뚱한 곳으로 빠질 수 있다. 뭉치 않으면 큰 다발 쪽으로 끌려간다(그림 8.5).
7. $R = 1/(2 \sin 30^\circ) = 1.0 \text{ mm}$ 다. 이 문턱은 정상 다발의 곡률을 거의 제한하지 않고, 급한 꺾임만 막는다.
8. 백질 전체 씨앗에서 수는 $Le^{-L/\lambda}$ 에 비례한다. $(30 e^{-0.6})/(120 e^{-2.4}) = 0.25 e^{1.8} \approx 1.5$ 배로 짧은 다발이 많다. 축삭 수는 같으므로 이 차이는 추적의 길이 편향이다. 스트림라인 수를 연결 세기로 읽으려면 SIFT 같은 재가중이나 길이에 대한 검토가 필요하다.

다음 장으로

이 장으로 MRI 분석의 큰 줄기를 마친다. 구조 영상, fMRI, 확산 영상 모두에서 같은 교훈이 되풀이되었다. 처리 순서에는 이유가 있고, 모든 지표는 모형의 가정을 거친 숫자이며, 움직임과 잡음은 집단 차이로 둔갑할 수 있다. 9장부터는 시간 해상도가 ms인 EEG와 MEG로 넘어간다. 기록 설계, 필터, 나쁜 채널, 눈 깜빡임과 근전도 같은 인공물, 그리고 ICA로 인공물을 떼어 내는 방법을 다룬다. 필터가 신호를 어떻게 바꾸는지, 인공물 제거가 무엇을 가정하는지라는 질문은 이 장의 잡음 제거와 같은 꼴이다.

9장 EEG/MEG 전처리

이 장에서 배울 것 EEG와 MEG 원자료가 분석에 들어가기 전에 거치는 단계들이다. 기록 설계, 필터(FIR과 IIR, 인과와 영위상), 나쁜 채널과 재기준, 인공물, ICA, MEG의 신호 공간 분리와 머리 위치 추적, 에포크와 기저선 보정, 시행 거부, 파이프라인 표준화를 차례로 본다. **뇌 연구자에게 왜 필요한가** 전처리의 선택은 결과의 모양을 직접 바꾼다. 고역 통과 필터 하나가 느린 성분을 절반으로 깎고 없던 음전위를 만들며, 기준을 바꾸면 지형도가 달라진다. 방법 절의 "0.1-30 Hz, 평균 기준, ICA, $\pm 100 \mu V$ 거부"라는 한 줄이 무엇을 가정하는지 알아야 결과를 믿을 수 있다.

☞ 중고등 복습: 주기, 주파수, 이동 평균

1초에 10번 되풀이되는 진동의 **주파수**는 10 Hz이고 **주기**는 0.1 s다. 둘은 서로 역수다. 복잡한 파형도 주파수가 다른 사인파들의 합으로 쓸 수 있다(물리 2권 7장의 푸리에 변환). 매일의 기온을 앞뒤 3일씩 평균하는 **이동 평균**은 하루하루의 들쭉날쭉함을 줄이고 계절의 흐름을 남긴다. 빠른 변화를 깎는 저역 통과 필터다. 원래 기온에서 이동 평균을 빼면 느린 흐름이 사라지는 고역 통과 필터가 된다. 대가도 있다. 지난 7일만 평균하면 갑작스런 추위가 며칠 늦게 나타난다. 앞뒤를 똑같이 평균하면 늦어지지 않지만, 추위가 오기 전날부터 기온이 내려간 것처럼 보인다. 이 장의 필터 이야기는 이 두 가지 대가를 다룬다.

9.1 기록 설계

표본화율이 낮아 접혀 들어온 잡음, 이벤트 표시의 어긋남, 전극이 떨어진 구간은 나중에 되살리지 못한다. 전처리 설계는 기록 설계에서 시작한다.

표본화율

표본화율(sampling rate) f_s 는 1초에 전압을 몇 번 재는가다. 물리 2권 7장의 표본화 정리에 따라 나이퀴스트 주파수 $f_s/2$ 보다 빠른 성분은 낮은 주파수로 접혀 들어온다. 그래서 증폭기는 디지털로 바꾸기 전에 아날로그 **에일리어싱 방지 필터**를 건다. 이 필터는 $f_s/2$ 보다 꽤 낮은 곳부터 깎으므로 실제로 쓸 수 있는 대역은 그보다 좁다.

250 Hz면 4 ms마다 한 점이다. ERP 연구는 보통 250-1000 Hz로 기록하고, 감마(30-100 Hz) 이상을 보려면 1000 Hz 이상, 뇌간 청각 유발 전위처럼 ms 이하의 파형은 수 kHz가 필요하다. 나중에 표본화율을 낮출 때(**다운샘플링**)는 새 나이퀴스트 주파수 아래로 저역 통과 필터를 먼저 건다. 점을 그냥 속으면 에일리어싱이 생긴다.

기준, 접지, 임피던스

EEG 채널 하나는 언제나 두 점의 전위차다(물리 1권 6장, 물리 2권 11장). 모든 채널이 공유하는 점이 **기록 기준(recording reference)** 으로, Cz, FCz, 코끝, 유양돌기가 흔하다. **접지(ground)** 는 몸과 증폭기의 공통 전위를 맞추는 별도의 전극이다. 일부 능동 전극 장비는 피드백 회로(CMS/DRL)로 몸 전위를 잡고

사실상 기준이 없는 원자료를 주므로, 분석 전에 반드시 재기준해야 한다. 기록 기준은 나중에 바꿀 수 있지만(9.3절), 기준 전극이 흔들리면 그 잡음이 모든 채널에 들어간다.

접촉 임피던스는 수동 전극에서 대략 5-10 kΩ 아래, 능동 전극에서는 수십 kΩ까지가 관례다(물리 2권 11장 예제 11.3). 임피던스가 높으면 전원 잡음이 차동 신호로 새고, 땀 전위와 움직임 잡음이 커진다. 낮을 뿐 아니라 채널 사이에 고르게 맞추어야 한다.

이벤트 표시

실험 프로그램이 보내는 **트리거(trigger)**와 실제 자극 사이에는 지연이 있다. 60 Hz 모니터는 16.7 ms마다 화면을 다시 그리므로 그림이 뜨는 순간이 한 프레임 안에서 어긋나고, 소리는 음향 장치의 버퍼 때문에 수십 ms 늦을 수 있다. 화면 구석의 **광센서(photodiode)**나 음향 출력을 보조 채널로 함께 기록해 실제 자극 시각을 데이터에서 찾는다. 일정한 지연은 빠면 되지만, 시행마다 흔들리는 **지터**는 ERP를 흐린다.

예제 9.1 트리거 지터가 ERP를 깎는다

트리거와 실제 자극의 어긋남이 0-16.7 ms 사이에 고르게 퍼져 있다. (가) 지터의 표준편차는? (나) 정점 주변이 표준편차 10 ms인 가우스 모양 성분(예: P1)과 20 ms인 성분(예: N1)의 평균 정점은 몇 % 줄어드는가? 가우스와 지터를 합성곱하면 넓이는 그대로이고 표준편차가 약 $\sqrt{\sigma^2 + \sigma_j^2}$ 가 된다.

풀이 (가) 폭 w 인 균등 분포의 표준편차는 $w/\sqrt{12}$ 이므로 약 4.8 ms다. (나) 정점은 $\sigma/\sqrt{\sigma^2 + \sigma_j^2}$ 배가 된다. 10 ms 성분은 $10/\sqrt{123} \approx 0.90$ 으로 약 10 %, 20 ms 성분은 $20/\sqrt{423} \approx 0.97$ 로 약 3 % 준다. 날카로운 초기 성분일수록 지터에 약하다. 평균 지연(약 8 ms)은 잠복기를 그대로 늦추므로 광센서로 재서 빼야 한다.

9.2 필터

왜 거는가, 무엇을 말하는가

EEG의 큰 잡음은 뇌 신호와 다른 주파수에 많다. 전극 표류와 땀 전위는 0.5 Hz 아래, 근전도는 20 Hz 위, 전원 잡음은 60 Hz(유럽 50 Hz)에 있다. **필터(filter)**는 주파수마다 다른 비율로 신호를 남긴다. 시간 영역에서는 신호에 필터의 **충격 응답(impulse response)**를 합성곱하고, 주파수 영역에서는 스펙트럼에 이득을 곱한다(물리 2권 7장의 합성곱 정리).

통과 대역은 거의 그대로 남기는 주파수, **저지 대역**은 깎는 주파수, 그 사이가 **전이 대역**이다. **차단 주파수(cutoff)**는 전이 대역 안의 한 점인데, 버터워스 IIR은 보통 -3 dB(진폭 71 %), 창 함수 FIR은 보통 -6 dB(진폭 50 %)를 쓴다. 같은 "0.1 Hz 고역 통과"라도 뜻이 다를 수 있다. 전이 대역이 가파를수록 충격 응답이 길어진다("짧은 것 ↔ 넓은 것", 물리 2권 7장).

FIR과 IIR

- **FIR(유한 충격 응답) 필터**는 입력의 가중 평균으로 출력을 만든다. 이동 평균의 일반형이다. 좌우 대칭으로 설계하면 모든 주파수가 $(N-1)/2$ 표본만큼 똑같이 늦어지므로(**선형 위상**) 그만큼 당겨 지연을 없앨 수 있다. 대가로 가파른 필터는 수천-수만 점이 된다.

- **IIR(무한 충격 응답) 필터**는 과거의 출력까지 되먹여 쓴다. 버터워스가 대표다. 적은 계수로 가파르게 깎지만 주파수마다 지연이 다르고(**비선형 위상**), 충격 응답이 비대칭이며, 차수가 높고 차단 주파수가 낮으면 수치적으로 불안정해질 수 있다.




그림 9.1 500 Hz 자료에 거는 두 가지 30 Hz 저역 통과 필터. (가) 해밍 창 FIR(221탭, 통과 대역 끝 30 Hz, -6 dB 점 33.75 Hz)은 전이 대역이 좁고 저지 대역에서 50 dB 이상 깎는다. 4차 버터워스 IIR은 30 Hz에서 -3 dB이고 완만하게 떨어진다. (나) FIR의 충격 응답은 220 ms를 중심으로 대칭이고 IIR은 시작 직후에 몰려 있다. (다) 한 방향으로만 걸면 FIR은 모든 주파수가 220 ms, IIR은 주파수마다 약 14-21 ms 늦어진다.

해밍 창 FIR의 길이는 전이 대역 폭 Δf 에서 정해진다.

$$N \approx 3.3 \frac{f_s}{\Delta f}$$

N 은 탭 수, f_s 와 Δf 의 단위는 Hz다. 전이 대역을 절반으로 좁히면 길이가 두 배가 된다(그림 9.1).

예제 9.2 0.1 Hz 고역 통과 FIR은 얼마나 긴가

500 Hz 자료에 해밍 창 FIR 고역 통과 필터를 건다. 통과 대역 끝 0.1 Hz, 전이 대역 0.1 Hz(-6 dB 점 0.05 Hz)다. (가) 길이는? (나) 지연을 보정하지 않으면 얼마나 늦어지는가? (다) 전이 대역 7.5 Hz짜리 30 Hz 저역 통과는?

풀이 (가) $3.3 \times 500/0.1 = 16\,500$, 대칭을 위해 홀수로 16 501점, 33 s다. (나) 8250점, 16.5 s다. (다) $3.3 \times 500/7.5 = 220$, 221점(0.44 s)이고 지연은 220 ms다. (가)의 필터는 2 s짜리 에포크보다 훨씬 길다. 고역 통과는 에포크로 자르기 전에 연속 자료에 걸어야 한다. 에포크에 걸면 필터가 없는 자료를 메우며 가장자리를 크게 왜곡한다.

인과 필터와 영위상 필터

과거와 현재 시점만 쓰는 필터가 **인과(causal) 필터**다. 증폭기의 하드웨어 필터와 실시간 처리는 미래를 모르므로 인과 필터일 수밖에 없다. 인과 필터는 신호를 늦추고 뒤쪽으로 번지게 한다. 녹화된 자료에서는 대칭 FIR의 지연을 보정하거나 IIR을 앞뒤로 두 번 걸어(크기 응답이 제공되어 감쇠가 두 배가 된다)

지연이 0인 **영위상(zero-phase) 필터**를 만든다. 영위상 필터는 정점을 제자리에 두지만, 충격 응답이 좌우 대칭이라 신호를 앞쪽으로도 번지게 한다.

그림 9.2는 합성 ERP에 10 Hz 저역 통과를 건 결과다. 인과 IIR은 P1과 N1 정점을 약 51 ms, 48 ms 늦춘다. 영위상 IIR은 정점을 1-3 ms 안에 두지만 0.5 μV 문턱으로 켜 시작점을 65 ms에서 51 ms로 당기고, 더 가파른 영위상 FIR은 32 ms까지 당기며 실제 시작 앞(0-60 ms)에 약 $-0.5 \mu\text{V}$, 자극 앞에도 약 $-0.2 \mu\text{V}$ 의 물결을 만든다. 실제 활동은 60 ms 전에 없었다.




그림 9.2 합성 ERP(60 ms에 갑자기 시작하는 P1, 165 ms의 N1, 350 ms의 P3)에 10 Hz 저역 통과 필터를 건 결과. (가) 4차 버터워스를 한 방향으로 걸면 정점이 40-50 ms 늦어지고 뒤로 변진다. (나) 앞뒤로 두 번 걸거나 가파른 FIR을 지연 보정해 걸면 정점은 제자리이지만 앞으로도 번져 시작점이 앞당겨지고 자극 앞에 작은 물결이 생긴다.

흔한 오해: 영위상 필터는 시간 왜곡이 없다

영위상 필터는 정점의 **위치**만 보존한다. 시간 해상도는 여전히 충격 응답 길이만큼 흐려지고, 그 흐림이 앞뒤로 퍼진다. 그래서 반응 시작 시각이나 "조건 차이가 처음 유의해지는 시각"을 재는 분석에서는 효과가 실제보다 이르게 보인다. 자극 전 구간의 효과나 너무 이른 잠복기는 필터 인공물을 먼저 의심한다. 반대로 인과 필터를 쓰면 모든 정점이 늦어진다. 어느 쪽이든 필터 종류, 길이, 차수, 차단 주파수의 정의, 방향(한 번/앞뒤)을 보고해야 비교가 된다. Widmann 2015는 이 설계 절차와 보고 항목을 정리한 실용 지침이다.

고역 통과 필터와 느린 성분

고역 통과는 표류를 지우는 데 꼭 필요하지만 느린 뇌 신호도 깎는다. P3, N400, P600, 후기 양전위(LPP), 수반 음성 변동(CNV), 준비 전위처럼 수백 ms-수 초에 걸친 성분은 에너지가 0.5-2 Hz 아래에 많다.

그림 9.3에서 느린 양전위의 300-700 ms 평균 진폭은 0.1 Hz 필터 뒤 89 %, 0.5 Hz 뒤 51 %, 1 Hz 뒤 23 %만 남는다. 필터는 느린 양전위 앞뒤에 **없던 음전위**도 만들고, 그것이 N1에 겹쳐 N1 정점이 $-2.8 \mu\text{V}$ 에서 $-5.2 \mu\text{V}$ (0.5 Hz)로 커진다. Acunzo 2012는 고역 통과 필터가 초기 ERP와 ERF 성분에 이런 체계적 편향을 만든다는 것을 보였다.




그림 9.3 느린 양전위를 가진 합성 ERP에 차단 주파수를 바꾸며 영위상 고역 통과 필터(2차 버터워스, 앞뒤로)를 걸었다. (가) 차단 주파수가 높을수록 느린 양전위가 작아지고 그 앞뒤에 가짜 음전위가 생기며 N1이 커진다. (나) 300-700 ms 평균 진폭이 남는 비율.

예제 9.3 차단 주파수 고르기

두 연구실이 같은 N400 과제를 했다. A는 0.1 Hz, B는 1 Hz 고역 통과를 썼다. 필터 전 N400 효과가 $-4 \mu V$ 이고 모양이 그림 9.3의 느린 성분과 비슷하다. (가) 각자 보고할 효과는? (나) B의 결과에서 N400 효과 앞 200 ms 무렵에 반대 부호의 작은 효과가 보였다. 어떻게 읽어야 하는가?

풀이 (가) A는 약 $-4 \times 0.89 \approx -3.6 \mu V$, B는 약 $-4 \times 0.23 \approx -0.9 \mu V$ 다. 같은 뇌 반응인데 4배 가까이 다르고, 잡음이 같다면 B의 검정력이 크게 떨어진다. (나) 1 Hz 필터가 큰 느린 성분 앞에 만든 반대 부호 물질일 가능성이 높다. 필터를 낮추거나 빼고 다시 분석해 효과가 남는지 확인해야 한다. ERP 연구의 고역 통과는 흔히 0.1 Hz 안팎이고, 느린 성분이 주 관심이면 0.01-0.05 Hz까지 낮춘다. 0.5-1 Hz 이상은 ICA 학습용 사본(9.5절)처럼 느린 성분이 관심 밖일 때 쓴다.

뇌로 가는 다리: 느린 전위 연구의 필터 함정

준비 전위는 자발적 움직임 1-2 s 전부터 쌓이는 음전위로, "의도보다 뇌가 먼저 준비한다"는 논쟁의 출발점이었다. 이런 성분은 필터와 기저선 창에 매우 민감하다. 0.1 Hz 고역 통과만으로도 1-2 s 경사의 모양이 바뀌고, 1 Hz면 대부분 사라진다. CNV나 작업 기억 유지 중의 지속 음전위(CDA)도 같다. 이런 논문에서는 증폭기의 하드웨어 필터(시간 상수로 적혀 있기도 하다)와 소프트웨어 필터를 모두 확인하고, DC 기록 결과와 비교했는지 본다.

노치 필터와 그 대안

전원 잡음은 60 Hz와 그 배수에 날카로운 선으로 나타난다. 그 주파수만 좁게 깎는 것이 **노치(notch) 필터**다. 폭은 품질 계수 Q 로 정하며 f_0/Q 다. 60 Hz에서 $Q = 30$ 이면 2 Hz, $Q = 5$ 면 12 Hz다.

좁은 노치는 60 Hz 근처에서 오래 울리는 충격 응답을 갖는다. 극파나 전극 튜 같은 날카로운 사건에 걸면 앞뒤에 60 Hz 진동이 생긴다(그림 9.4). 울림의 포락선은 대략 시간 상수 $1/(\pi \times \text{폭})$ 으로 줄어든다. $Q =$

30이면 약 0.16 s(진폭 약 1.6 μV), $Q = 5$ 면 약 27 ms이지만 진폭이 약 8.6 μV 다. 감마 대역에서 극파나 근육 틱 주변의 60 Hz "진동 폭발"은 노치의 올림일 수 있다.




그림 9.4 전원 잡음이 없는 신호에 60 Hz 노치를 걸었다. (가) 앞뒤로 건 노치의 크기 응답. $Q = 30$ 은 폭 2 Hz, $Q = 5$ 는 12 Hz다. (나) 바닥 폭 20 ms, $-100 \mu\text{V}$ 인 극파에 $Q = 5$ 노치를 걸면 파형이 약간 일그러진다. (다) 필터 출력에서 원래 신호를 뺀 것. $Q = 30$ 의 울림은 작지만 수백 ms 이어지고, $Q = 5$ 는 짧지만 크다.

분석 대역이 60 Hz보다 충분히 낮으면(예: ERP의 30-40 Hz 저역 통과) 노치가 필요 없다. 감마를 보려면 짧은 창마다 60 Hz 정현파의 진폭과 위상을 추정해 빼는 **회귀 방식**, 60 Hz 근처 스펙트럼을 이웃 값으로 메우는 **스펙트럼 보간**, 전원 잡음의 공간 패턴을 빼는 공간 필터가 덜 울린다.

코드로 보는 필터

numpy와 scipy만으로 예제 9.2의 30 Hz FIR을 만들고, 지연을 보정한 출력과 보정하지 않은 출력을 비교한다.

```
import numpy as np
from scipy import signal

fs = 500.0
N = int(3.3 * fs / 7.5) | 1 # 해밍 창 FIR 길이(홀수): 221
b = signal.firwin(N, 30 + 7.5 / 2, window="hamming", fs=fs) # -6 dB 점 33.75 Hz

t = np.arange(-1, 2, 1 / fs)
erp = -5 * np.exp(-0.5 * ((t - 0.17) / 0.02) ** 2) # N1 비슷한 파형
causal = signal.lfilter(b, 1, erp) # 한 방향: 지연 있음
zero = np.convolve(erp, b, mode="same") # 지연 보정: 영위상

peak = lambda x: round(t[np.argmin(x)] * 1000)
print("지연 (ms):", (N - 1) / 2 / fs * 1000) # 220.0
print("정점 (ms):", peak(erp), peak(causal), peak(zero)) # 170 390 170
```

9.3 나쁜 채널, 보간, 재기준

나쁜 채널 찾기와 보간

전극이 떨어졌거나 젤이 말랐거나 이웃과 젤로 이어진 채널은 흔하다. 탐지 기준은 다음과 같다.

- **평평함**: 일정 시간 이상 거의 변하지 않는다.
- **이상한 진폭**: 중앙값과 사분위 범위 같은 강건한 통계로 표준화한 분산이 대략 3-5를 넘는다.
- **이웃과의 낮은 상관**: 두피 전위는 공간적으로 매끄러우므로(물리 2권 11장) 정상 채널은 이웃과 상관이 높다. 0.4 아래 구간이 많으면 의심한다.
- **예측 불가능**: 다른 채널의 무작위 부분집합으로 여러 번 예측해 보고(RANSAC 방식) 자주 빗나가면 나쁘다.
- **고주파 잡음과 젤 다리**(이웃 두 채널의 차이가 거의 0).

자동 탐지 뒤에도 원자료를 눈으로 본다. 나쁜 채널을 버리면 채널 수가 참가자마다 달라지므로, 두피 위에 매끄러운 곡면을 맞추는 **구면 스플라인 보간**으로 채운다. 보간된 채널은 다른 채널의 가중 합일 뿐이므로 자료의 **랭크**(독립 정보의 개수)가 그만큼 준다(9.5절).

재기준

새 기준 전위를 모든 채널에서 빼면 기준이 바뀐다.

- **평균 기준**: 모든 채널의 평균을 뺀다. 64채널 이상에서 흔하다. 전극이 머리를 고르게 덮을수록 무한히 먼 기준에 가까워진다(물리 2권 11장의 흔한 오해 상자).
- **연결 유양돌기**: 양쪽 귀 뒤 전극의 평균. 고전 ERP 문헌과 비교할 때 쓴다.
- **코끝 기준**: 측두-후두 성분(N170, MMN)의 극성 반전을 보기 좋아 일부 분야의 관례다.
- **REST**: 머리 모형으로 무한히 먼 점을 기준으로 한 전위를 추정한다(Yao 2001). 머리 모형의 정확도에 의존한다.
- **양극 몽타주와 표면 라플라시안(전류원 밀도)**: 기준에 무관하고 국소적이지만 넓게 퍼진 깊은 소스는 약해진다.

어느 기준도 정답은 아니지만, 같은 자료의 지형도와 진폭이 기준에 따라 달라진다(그림 9.5). 기준 근처 전극은 진폭이 작아지고, 기준이 활동이 있는 자리에 있으면 그 활동이 모든 채널에 반대 부호로 실린다.




그림 9.5 좌우 후두-측두의 쌍극자(N170 같은 반응)가 만든 같은 두피 전위를 네 가지 기준으로 그렸다(구 모형, 위에서 본 지형도, 파랑은 양, 빨강은 음, 검은 선은 0). (가) 무한히 먼 기준(참값)에서 P8 부근은 $-6.0 \mu\text{V}$ 다. (나) Cz 기준은 정수리의 작은 양전위가 빠져 $-6.9 \mu\text{V}$. (다) 연결 유양돌기 기준은 유양돌기가 음전위 자리에 가까워 $-4.2 \mu\text{V}$ 로 작아지고 머리 대부분이 양이 된다. (라) 전극 65개 평균 기준은 $-6.3 \mu\text{V}$ 로 참값에 가깝다.

예제 9.4 나쁜 채널 하나가 평균 기준을 오염시킨다

64채널 중 T8에 $200 \mu\text{V}$ 의 느린 흔들림이 있다. 이 채널을 둔 채 평균 기준을 하면 다른 채널에 무엇이 생기는가?

풀이 흔들림이 평균에 기여하는 몫은 $200/64 \approx 3.1 \mu\text{V}$ 이고, 이것이 다른 63개 채널 모두에 반대 부호로 실린다. 모든 채널에 같은 모양이라 뇌 신호처럼 보이기도 한다. 그래서 **나쁜 채널 탐지 → 보간(또는 평균에서 제외) → 평균 기준** 순서를 지킨다. PREP 파이프라인(Bigdely-Shamlo 2015)은 나쁜 채널을 빼고 강건한 평균을 구한 뒤 그 평균으로 다시 나쁜 채널을 찾는 과정을 되풀이해 이 순환 문제를 푼다.

🧠 뇌로 가는 다리: 기준이 바꾼 N170

얼굴 자극의 N170은 P7/P8, PO7/PO8에서 가장 크고, 정수리 쪽에서는 극성이 반대인 양전위(VPP)로 보인다. 유양돌기 기준은 N170 쌍극자의 음전위 자리에 가까워 N170을 줄이고 VPP를 키운다. 코끝이나 평균 기준에서는 N170이 크고 VPP가 작다. 오래전 문헌이 VPP와 N170을 다른 성분처럼 다루기도 한 이유다. **그림 9.5**에서는 같은 반응이 기준에 따라 $-4.2 \mu\text{V}$ 와 $-6.3 \mu\text{V}$ 로 50 % 가까이 다르다. N170 진폭이나 반구 비대칭을 연구 사이에서 비교하려면 기준부터 확인한다. 유양돌기에서 극성이 반전되는 MMN도 유양돌기 기준에서 작아진다.

9.4 인공물

인공물(artifact) 은 뇌가 아닌 곳에서 온 신호다. 크기가 뇌 신호와 같거나 훨씬 크고 주파수도 겹쳐 필터만으로 지우지 못한다. 시간 모양, 주파수, 두피 분포를 알면 눈으로 가려낼 수 있다.

인공물	출처	크기·주파수	분포와 모양
눈 깜빡임	눈꺼풀이 각막 위를 지나며 안구 주변 전위를 바꿈	앞이마에서 약 100~200 μV , 200~400 ms	Fp1/Fp2에서 가장 큰 양의 봉우리
안구 운동	각막(+)과 망막(-) 사이 쌍극자의 회전	1°당 대략 10~20 μV , 계단 모양	수평 운동은 F7/F8에서 반대 부호
미세 단속 운동	안구 근육의 짧은 수축(극파 전위)	수십 ms 극파, 넓은 대역	눈 주변, 가짜 감마 반응
근전도	이마, 관자, 목 근육	약 20~300 Hz 넓은 대역	측두와 가장자리, 이 악물기·말하기
심전도·맥박	심장 전기 활동, 혈관 박동	약 1~1.2 Hz 반복	왼쪽 유양돌기·아래쪽, MEG에서 뚜렷
전원 잡음	전원선과의 용량 결합	60 Hz(유럽 50 Hz)와 배수	임피던스가 높은 전극
땀·피부 전위	땀샘 활동	0.5 Hz 아래의 큰 흔들림	넓은 영역, 더운 방
전극 튼·움직임	전극 접촉 변화, 케이블 흔들림	계단, 극파, 느린 큰 파형	한 전극 또는 여러 채널 동시

대응은 세 가지다. **예방**(고정점 응시, 깜빡임을 허락하는 쉬는 구간, 턱 힘 빼기, 고른 임피던스, 시원한 방)이 가장 효과적이다. **거부**는 오염된 구간이나 시행을 버린다(9.7절). **보정**은 인공물만 추정해 뺀다. ICA가 대표이고(9.5절), 안전도(EOG) 채널을 회귀해 빼는 방법은 EOG 채널에 섞인 뇌 신호까지 빼게 된다.

근전도와 미세 단속 운동은 특히 까다롭다. 어려운 과제에서 턱에 힘이 들어가면 "과제 관련 감마 증가"가 근육에서 나올 수 있다. 미세 단속 운동의 극파 전위는 자극 뒤 200~300 ms 무렵에 몰려 감마 대역의 유발 반응처럼 보인 사례가 보고되었다. 고주파 결과는 이 인공물이 조건 사이에 같은지 확인한 뒤에만 믿는다.

9.5 ICA로 인공물 분리하기

원리: 섞인 소리 풀기

여러 사람이 동시에 말하는 방에 마이크를 여러 개 두면 마이크마다 목소리가 다른 비율로 섞인다. 목소리들이 서로 **독립**이라는 것만 알면 원래 목소리를 되찾을 수 있다. 이것이 **독립 성분 분석(ICA)** 이다. 비유가 깨지는 곳도 있다. 뇌에는 독립된 "화자"가 몇 개인지 정해져 있지 않다.

채널 n 개의 기록 $\mathbf{x}(t)$ 가 원천 n 개 $\mathbf{s}(t)$ 의 선형 혼합이라고 가정한다.

$$\mathbf{x}(t) = \mathbf{A} \mathbf{s}(t), \quad \hat{\mathbf{s}}(t) = \mathbf{W} \mathbf{x}(t)$$

혼합 행렬 $\mathbf{A}$ 의 열 하나가 원천 하나의 두피 지형도다. 체적 전도는 즉각적이고 선형이라(물리 2권 11장의 리드필드) 이 가정이 잘 맞는다. ICA는 $\hat{\mathbf{s}}$ 의 성분들이 최대한 독립이 되도록 **분리 행렬 $\mathbf{W}$** 를 찾는다.

독립의 척도는 중심 극한 정리에서 나온다. 독립인 신호를 더하면 합은 가우스에 가까워진다. 거꾸로, 잘 풀린 성분일수록 가우스에서 멀다. 대부분 0이다가 가끔 크게 튀는 깜빡임은 **첨도**(뽕죽함)가 커서 가우스와

거리가 멀다. ICA는 성분의 비가우스성을 최대로 만든다. EEG에서는 Infomax(Bell 1995)와 고정점 반복의 FastICA(Hyvärinen 1999)가 흔하다. EEGLAB(Delorme 2004)은 Infomax ICA를 EEG 분석의 표준 단계로 만든 도구이고, MNE-Python, FieldTrip, Brainstorm도 ICA를 제공한다.

그림 9.6은 6채널 합성 EEG(깜빡임, 측두 근전도, 후두 알파, 배경 활동 셋을 섞음) 60 s에 아래 코드의 FastICA를 적용한 결과다. 척도 순으로 늘어놓으니 근전도와 깜빡임이 맨 앞 두 성분으로 분리되었다. 깜빡임 성분과 실제 깜빡임의 상관은 0.999이고, 이 성분만 빼고 되돌리면 Fp1의 깜빡임(최대 120 μ V)이 사라지며 참값과의 차이는 rms 약 1.0 μ V다. 같은 계산을 10 s로 하면 상관이 0.99로 떨어지고 잔차가 약 3.9 μ V로 커진다. ICA는 자료가 많을수록 잘 쏜다.




그림 9.6 6채널 합성 EEG에 ICA를 적용했다(앞 10 s만 표시). (가) 기록된 EEG. 앞이마에 깜빡임, T7에 근전도 폭발, O1에 알파가 있다. (나) FastICA 성분을 척도 순으로 늘어놓았다. 성분 1은 근전도, 성분 2(빨강)는 깜빡임, 성분 6은 알파다. (다) 깜빡임 성분 하나를 빼고 되돌린 EEG(파랑)과 원래 EEG(회색). 깜빡임만 사라지고 근전도와 알파는 남는다.

```
import numpy as np

def fastica(X, n_iter=300, seed=0):
    """대칭 FastICA. X: 채널 × 시점. 분리 행렬과 혼합 행렬을 돌려준다."""
    Xc = X - X.mean(axis=1, keepdims=True)
    d, E = np.linalg.eigh(np.cov(Xc))
    K = E @ np.diag(d ** -0.5) @ E.T          # 백색화: 상관 제거, 분산 1
    Z = K @ Xc
    W = np.random.default_rng(seed).standard_normal((len(X), len(X)))
    for _ in range(n_iter):
        G = np.tanh(W @ Z)                  # 비가우스성을 키우는 고정점 갱신
        W = G @ Z.T / Z.shape[1] - np.diag((1 - G ** 2).mean(axis=1)) @ W
        u, _, vt = np.linalg.svd(W)
        W = u @ vt                          # 성분끼리 직교하게
    unmix = W @ K
    return unmix, np.linalg.inv(unmix)

# S = unmix @ Xc; 깜빡임 성분 k를 빼고 되돌리기: X_clean = A[:, keep] @ S[keep]
```

성분 판별과 실전 설정

ICA는 성분에 이름을 붙이지 않는다. 깜빡임 성분은 앞이마에 몰린 지형도와 드문드문 큰 봉우리, 수평 안구 운동은 F7과 F8에서 부호가 반대인 지형도와 계단 모양, 근육은 가장자리 지형도와 20 Hz 위로 평평한 스펙트럼, 심장은 1초 남짓 간격의 QRS 모양을 보인다. 뇌 성분은 쌍극자 하나로 설명되는 매끄러운 지형도와 $1/f$ 위에 알파 같은 봉우리가 얹힌 스펙트럼을 가진다. 평가자마다 판단이 다르므로 자동 분류기를 쓴다. ICLabel(Pion-Tonachini 2019)은 성분마다 뇌, 근육, 눈, 심장, 전원 잡음, 채널 잡음, 기타의 일곱 범주 확률을 준다. 제거 문턱은 연구자가 정하고 보고한다.

실전 설정은 가정에서 나온다.

- **정상성:** 혼합 행렬이 기록 내내 같아야 한다. 모자를 고쳐 쓰면 깨진다.
- **느린 표류에 약하다:** 흔히 1 Hz 안팎으로 고역 통과한 **사본**에서 학습하고, 분리 행렬을 0.1 Hz로 필터한 원래 자료에 적용한다(그림 9.8). 혼합 행렬은 주파수에 무관하므로 이렇게 해도 된다. 큰 움직임 구간은 학습에서 뺀다.
- **자료의 양:** 추정할 값이 n^2 개이므로 표본 수가 n^2 의 수십 배는 되어야 한다는 경험칙이 흔하다.
- **랭크:** 평균 기준은 랭크를 1, 보간은 채널마다 1씩 줄인다. 랭크보다 많은 성분을 구하면 분해가 불안정하므로 주성분 분석으로 차원을 먼저 줄인다.

예제 9.5 ICA에 필요한 자료

(가) 64채널, 250 Hz에서 표본 $20n^2$ 개를 얻으려면 몇 분이 필요한가? 128채널이면? (나) 64채널에서 3개를 보간하고 평균 기준을 했다. 성분은 몇 개까지 구하는가?

풀이 (가) $20 \times 64^2 = 81920$ 표본, 약 328 s(5.5분)다. 128채널이면 327680 표본, 약 22분이다. 표본화율을 높여도 이웃 표본끼리 비슷해 정보가 비례해 늘지 않는다. (나) $64 - 3 - 1 = 60$ 개다.

흔한 오해: 인공물 성분을 빼면 인공물만 사라진다

ICA는 독립을 최대로 할 뿐 완벽하게 분리하지 않는다. 깜빡임 성분에 섞인 앞이마의 뇌 활동도 함께 빠지고, 깜빡임의 일부는 다른 성분에 남는다. 인공물이 과제와 시간이 묶여 있으면(자극 직후마다 깜빡임) 독립 가정이 약해져 분리가 나빠진다. 근전도는 여러 근육에서 와서 여러 성분에 흩어진다. 뺀 성분의 수와 판별 기준을 보고하고, 조건 사이에 뺀 성분 수가 다르지 않은지 확인하고, 설계로 인공물 자체를 줄여야 한다.

🧠 뇌로 가는 다리: 인공물은 집단마다 다르다

소아, ADHD, 조현병, 노인 집단은 대체로 깜빡임과 움직임이 많다. 그러면 거부되는 시행 수, 제거되는 성분 수, 남은 인공물이 집단마다 달라진다. 환자 집단에서 앞이마 세타 파워가 크게 나왔다면 남은 안구 인공물이 아닌지 먼저 따져야 한다. 시행을 더 많이 버린 집단은 평균 ERP의 잡음이 커진다(예제 9.7). 집단 비교 연구에는 집단별 남은 시행 수, 제거 성분 수, 보간 채널 수가 있어야 하고, 이 수치가 집단 차이와 상관하면 그 차이는 전처리로 설명될 수도 있다.

9.6 MEG 특유의 처리

신호 공간 분리(SSS)와 tSSS

MEG는 기준 전극 문제가 없고 두개골에 의한 흐림도 작다(물리 2권 11장). 대신 뇌 신호(약 10-1000 fT)보다 10^8 배쯤 큰 지구 자기장(약 50 μ T)과 환경 잡음 속에서 켜다. 차폐실을 지나 남은 잡음도 뇌 신호보다 크다.

센서가 놓인 껍질 공간에는 전류가 없으므로, 거기서의 자기장은 껍질 **안쪽**(뇌) 소스의 성분과 **바깥**(환경) 소스의 성분으로 나뉘고, 각각 모양이 다른 구면 조화 함수 급수로 쓸 수 있다. **신호 공간 분리(SSS)**는 측정을 두 급수로 맞추고 바깥 성분을 버린다. 차수 L 까지의 항 수는 $\sum_{l=1}^L (2l+1) = L(L+2)$ 다.

치아 교정기나 자극기처럼 센서 껍질 안쪽이지만 뇌 바깥에 있는 잡음은 SSS에서 "안쪽"으로 들어간다. **시간 확장 SSS(tSSS)**는 이런 잡음이 안쪽과 바깥 성분에 **같은 시간 모양**으로 함께 나타난다는 점을 쓴다(Taulu 2006). 수 초-10 s 구간마다 두 성분의 시간 파형에서 상관이 높은(흔히 0.98 안팎이 문턱) 부분을 찾아 안쪽에서도 뺀다.

예제 9.6 SSS 뒤의 차원

306채널 MEG에 SSS를 $L_{in} = 8$, $L_{out} = 3$ 으로 적용한다. (가) 안쪽과 바깥 성분은 몇 차원인가? (나) SSS 뒤 ICA에서 조심할 점은?

풀이 (가) 안쪽 $8 \times 10 = 80$, 바깥 $3 \times 5 = 15$ 차원이다. (나) 채널이 306개여도 랭크는 80 이하이고, 정칙화 때문에 실제로는 대략 60-75다. 주성분 분석으로 실제 랭크까지 줄인 뒤 ICA를 한다. 소스 분석(11장)의 잡음 공분산도 이 차원 감소를 반영해야 한다.

머리 위치, 빈 방 기록, 심장

SQUID MEG는 헬멧이 고정되고 머리가 그 안에서 움직이므로, 머리가 1 cm 움직이면 같은 소스가 다른 센서에 잡힌다. 머리에 **HPI 코일** 3-5개를 붙이고 코일마다 고유한 수백 Hz 전류를 흘려 위치를 계속 추적한다. 이 정보로 움직임이 큰 구간을 찾고(흔히 5 mm 안팎이 경고 기준), SSS에서 매 순간의 머리 위치를 반영해 **움직임 보정**을 하며, 여러 세션을 같은 기준 머리 위치로 옮긴다.

빈 방 기록(empty-room recording)은 사람 없이 몇 분 기록한 자료로, 그날의 센서와 환경 잡음을 보여 주어 나쁜 센서 탐지와 잡음 공분산 추정에 쓴다. 나쁜 센서는 SSS **전에** 표시한다. SSS가 모든 센서를 함께 맞추므로 나쁜 센서의 잡음이 다른 센서로 번지기 때문이다. 심장의 자기장은 MEG에서 상대적으로 크게 보여, 심전도 성분을 ICA나 신호 공간 투영(SSP)으로 빼는 단계가 거의 늘 들어간다. 두피에 붙이는 OPM-MEG는 센서가 머리와 함께 움직여 처리 절차가 다르며, 표준이 아직 만들어지는 중이다.

MEG는 뇌전증 수술 전 평가에서 극파의 발생 위치를 찾는 데 쓰인다. 이 환자들에게는 미주신경 자극기, 두개 내 전극의 고정 금속, 치과 보철이 흔하다. 이런 물체는 센서 가까이에서 수천 fT의 잡음을 만들고, 숨이나 심박에 따라 흔들려 극파나 서파처럼 보이기도 한다. tSSS는 바로 이런 상황을 위해 만들어졌고, 깊은 뇌 자극기를 단 파킨슨병 환자의 MEG도 tSSS 없이는 어렵다. 다만 상관 문턱을 너무 낮추면 뇌 신호도 지워질 수 있으므로 설정을 보고하고 결과가 설정에 민감한지 확인한다.

기저선 보정과 고역 통과는 같은 문제(표류)를 푸는 두 방법이다. 고역 통과는 아주 낮게 하고 기저선 보정에 맡기면 느린 성분이 보존되지만 잡음이 커지고, 고역 통과는 높이면 잡음은 줄지만 성분이 왜곡된다(그림 9.3).

시행 거부

ICA 보정 뒤에 남은 큰 인공물이 있는 시행을 버린다. 보정 전에 거부하면 깜빡임이 있는 시행을 거의 다 잃는다. 흔한 기준은 진폭 문턱(예: $\pm 100 \mu V$), 봉우리-골 차이(예: 200 ms 창에서 $150 \mu V$ 이상), 평평함이며, 참가자와 채널마다 자료에서 문턱을 정하는 자동 방법도 있다. 평균의 잔여 잡음은 시행 수의 제곱근에 반비례하므로(물리 2권 7장, 10장) 거부에는 값이 든다.

예제 9.7 시행을 버리는 값

조건마다 60시행을 기록했다. 환자 집단에서 30 %, 대조 집단에서 10 %를 거부했다. 평균 ERP의 잔여 잡음은 거부 전보다 각각 몇 배이고, 두 집단의 비는?

풀이 환자는 42시행이 남아 $\sqrt{60/42} \approx 1.20$ 배, 대조는 54시행으로 $\sqrt{60/54} \approx 1.05$ 배다. 비는 $\sqrt{54/42} \approx 1.13$, 환자 쪽 잡음이 약 13 % 크다. 정점 진폭은 잡음이 클수록 커 보이므로 이 차이만으로 집단 차이가 생길 수 있다(10장). 시행 수를 무작위로 맞춰 뽑거나, 시행 수를 보고하고 통계 모형에 반영한다.

파이프라인 표준화

단계를 순서대로 놓으면 그림 9.8과 같다. 나쁜 채널을 찾기 전에 평균 기준을 하면 오염이 퍼지고(예제 9.4), 표류가 남은 채 ICA를 하면 분해가 나빠지며, 에포크로 자른 뒤 필터를 걸면 가장자리가 망가진다.




그림 9.8 EEG/MEG 전처리의 흔한 단계 순서. 회색 숫자는 이 장의 절이다. 점선 상자는 MEG에만 있는 단계다. ICA는 1 Hz 고역 통과한 사본에서 학습하고 분리 행렬은 원래 자료에 적용한다. 보간과 재기준의 위치는 파이프라인마다 다르다.

PREP 파이프라인(Bigdely-Shamlo 2015)은 전원 잡음 제거, 강건한 평균 기준, 나쁜 채널 탐지와 보간을 정해진 순서와 기준으로 자동화하고 보고서를 남긴다. 대규모 자료에서 사람의 판단 차이를 줄이는 것이 목적이다. **BIDS-EEG**와 **BIDS-MEG**(1장)는 표본화율, 기록 기준, 전원 주파수, 하드웨어 필터, 나쁜 채널, 이벤트 표를 정해진 사이드카 파일에 적게 해 재현을 돕는다. MNE-Python, EEGLAB, FieldTrip, Brainstorm은 이 형식을 읽고 쓰며 위 단계들을 제공한다. 도구의 기본값은 버전에 따라 바뀌기도 하므로, 무엇이 쓰였는지 연구자가 확인하고 보고해야 한다.

9.8 임상 EEG와 연구 EEG

임상 EEG는 숙련된 판독자가 원파형을 눈으로 읽는다. 깜빡임과 근전도는 모양으로 알아보고 걸러 내며, 몽타주(종단 양극 "이중 바나나", 기준 몽타주, 평균 기준)를 바꿔 가며 극파의 위상 역전으로 위치를 찾는다. 필터는 화면 표시용이라 원자료는 그대로 둔다. 연구 EEG는 수십-수백 시행을 평균하고 수치를 통계에 넣으므로, 필터와 기준과 인공물 처리가 숫자 자체를 바꾸고 모든 결정이 방법 질에 적혀야 한다.

뇌로 가는 다리: 임상 판독 화면의 필터 설정

임상 장비는 저주파 필터를 "시간 상수"로 표시하기도 한다. 물리 1권 7장의 RC 회로에서 $f_c = 1/(2\pi\tau)$ 이므로, 시간 상수 0.3 s는 약 0.53 Hz, 0.1 s는 약 1.6 Hz다. 흔한 표시 설정(대략 0.5-1 Hz 고역 통과, 70 Hz 저역 통과, 60 Hz 노치)은 극파와 리듬을 읽기에 좋지만, 그림 9.3에서 본 것처럼 느린 파의 진폭과 모양을 바꾼다. 저주파 필터를 높이면 병변을 시사하는 국소 델타가 약해 보이고, 노치를 켜면 근육 인공물을 알아보기 어려워진다. 표시용 필터가 걸린 채 내보낸 자료를 정량 분석(qEEG, 10장)에 쓰면 연구 자료와 비교할 수 없으므로, 원래 기록 설정부터 확인한다.

핵심 정리

핵심 정리

- 전처리는 기록 설계에서 시작한다. 표본화율은 넉넉히, 임피던스는 낮고 고르게, 이벤트 지연은 광센서로 켜다. 60 Hz 모니터의 프레임 지터(표준편차 약 4.8 ms)는 날카로운 성분의 정점을 약 10 % 깎는다.
- 필터는 충격 응답과의 합성곱이다. FIR은 선형 위상이라 지연($(N-1)/2$ 표본)을 보정할 수 있지만 길고(해밍 창 $N \approx 3.3f_s/\Delta f$), IIR은 짧지만 주파수마다 지연이 다르다. 고역 통과는 연속 자료에 건다.
- 인과 필터는 신호를 늦추고, 영위상 필터는 정점을 지키지만 앞으로 번져 시작 시각을 앞당긴다. 필터 종류, 길이, 차단 주파수 정의, 방향을 보고한다.
- 고역 통과는 느린 성분을 깎고 반대 부호 물결을 만든다(합성 예에서 0.1, 0.5, 1 Hz 뒤 89, 51, 23 %). 좁은 노치는 날카로운 사건 앞뒤에 60 Hz 울림을 만든다.
- 나쁜 채널을 찾아 보간한 뒤 재기준한다. 순서를 바꾸면 200 μ V 채널 하나가 64채널 평균 기준을 통해 모든 채널에 약 3 μ V를 퍼뜨린다. 기준 선택은 지형도와 진폭을 바꾼다.
- 인공물은 시간 모양, 주파수, 분포로 알아보며, 예방이 거부와 보정보다 효과가 크다.
- ICA는 선형 혼합을 가정하고 비가우스성을 최대화 하는 분리 행렬을 찾는다. 1 Hz 사본에서 학습하고, 랭크와 자료 양(n^2 의 수십 배)을 맞추며, 판별 기준을 보고한다.
- MEG는 SSS/tSSS로 바깥과 가까운 잡음을 빼고(SSS 뒤 랭크 80 이하), HPI로 머리 움직임을 보정하며, 빈 방 기록으로 센서를 확인한다.
- 기저선 보정은 기저선 구간에 조건 차이가 없다고 가정한다. 시행 거부는 잡음을 시행 수의 제곱근에 반비례해 키우므로 집단·조건별 남은 시행 수를 보고한다.

방법 절 점검표

방법 절 점검표

1. 표본화율, 하드웨어 필터, 기록 기준과 접지, 임피던스 기준이 있는가? 이벤트 지연을 측정해 보정했는가?
2. 필터마다 종류(FIR/IIR), 길이나 차수, 차단 주파수와 정의(-3/-6 dB), 인과/영위상 여부가 있고, 연속 자료에 걸었는가?
3. 고역 통과 차단 주파수가 관심 성분의 시간 규모에 맞는가? 이른 효과나 반대 부호 효과가 필터 인공물일 가능성을 검토했는가?
4. 나쁜 채널의 탐지 기준, 개수, 보간 방법이 있고, 재기준은 보간 뒤에 했는가? 분석 기준이 비교할 선행 연구와 같은가?
5. ICA의 알고리즘, 학습 자료, 랭크 처리, 성분 판별 기준(분류기와 문턱), 집단·조건별 제거 성분 수가 있는가?
6. MEG라면 SSS/tSSS 설정, 나쁜 센서 처리, 머리 움직임의 크기와 보정, 빈 방 기록이 있는가?
7. 에포크 구간, 기저선 창, 시행 거부 기준이 있고, 자극 전 구간에 조건 차이가 없는지 확인했는가?
8. 집단·조건별 남은 시행 수, 보간 채널 수, 제거 성분 수가 보고되었고, 이것이 비교하는 효과와 얹혀 있지 않은가?

확인 문제

확인 문제

1. 250 Hz로 기록한 EEG에서 80 Hz 감마를 분석하려 한다. 나이퀴스트 주파수는 얼마이고 무엇이 문제인가? 이 자료를 125 Hz로 다운샘플링하려면 무엇을 먼저 하는가?
2. 1000 Hz 자료에 통과 대역 끝 0.5 Hz, 전이 대역 0.5 Hz인 해밍 창 FIR 고역 통과를 건다. 길이와 한 방향 지연은? 1 s 에포크에 거는 것이 왜 안 되는가?
3. 한 연구는 증폭기의 온라인 저역 통과(인과 IIR)만, 다른 연구는 같은 차단 주파수의 영위상 필터를 썼다. N1 정점 잠복기와 반응 시작 시각에서 어떤 방향의 차이를 예상하는가?
4. 32채널 기록의 한 채널에 300 μ V 표류가 있다. 이 채널을 둔 채 평균 기준을 하면 다른 채널에 얼마의 오염이 생기는가?
5. 유양돌기 기준으로 보고한 N170이 평균 기준으로 보고한 다른 연구보다 작았다. "이 집단은 얼굴 처리 반응이 약하다"고 해석하기 전에 무엇을 생각해야 하는가?
6. 32채널, 500 Hz 기록에서 표본 $20n^2$ 개를 얻으려면 몇 초가 필요한가? 2채널을 보간하고 평균 기준을 했다면 ICA 성분은 몇 개까지 구하는가?
7. 단서 과제에서 "유효 단서" 조건만 자극 전 CNV가 컸다. -200-0 ms로 기저선 보정했더니 P3 구간에서 이 조건이 더 양으로 나왔다. 무엇이 문제일 수 있고 어떻게 확인하는가?
8. 조건마다 80시행 중 25 %를 거부했다. 잔여 잡음은 몇 배가 되는가?

확인 문제 풀이

확인 문제 풀이

1. 125 Hz다. 80 Hz는 그 아래이지만 에일리어싱 방지 필터가 나이퀴스트보다 꽤 낮은 곳부터 깎으므로 이미 감쇠되었을 수 있고, 근전도도 겹친다. 500-1000 Hz로 기록하는 것이 안전하다. 125 Hz로 줄이려면 새 나이퀴스트 62.5 Hz보다 낮게 저역 통과를 먼저 걸어야 하며, 그러면 80 Hz 분석은 불가능하다.
2. $3.3 \times 1000 / 0.5 = 6600$, 6601점(6.6 s)이고 지연은 3.3 s다. 필터가 에포크보다 6배 이상 길어 출력 대부분이 가장자리를 메운 값의 영향을 받는다. 연속 자료에 건 뒤 자른다.
3. 인과 IIR은 정점과 시작이 모두 늦게 나온다(그림 9.1의 4차 30 Hz 필터는 낮은 주파수에서 약 14 ms, 차단 주파수가 낮을수록 더 크다). 영위상 필터는 정점을 거의 보존하지만 시작을 앞당긴다. 이 차이를 뇌의 차이로 읽으면 안 된다.
4. $300/32 \approx 9.4 \mu V$ 의 반대 부호 표류가 모든 채널에 생긴다. 먼저 보간하거나 평균에서 뺀다.
5. 기준이 다르다. 유양돌기는 N170의 음전위 자리에 가까워 그것을 빼면 N170이 작아진다(그림 9.5에서 $-6.3 \mu V$ 대 $-4.2 \mu V$). 같은 기준으로 다시 계산해 비교해야 한다.
6. $20 \times 32^2 = 20480$ 표본, 약 41 s다. 이웃 표본이 비슷하므로 실제로는 몇 분이 좋다. 랭크는 $32 - 2 - 1 = 29$ 이므로 29개까지 구한다.
7. 기저선 창 CNV(음전위)를 빼면서 그 조건 전체가 양으로 끌어올려졌을 수 있다(그림 9.7 다). 보정 전 파형과 기저선 구간의 조건 차이를 보고, 기저선을 단서 앞으로 옮기거나 기저선 값을 공변량으로 넣어 효과가 남는지 확인한다.
8. 60시행이 남아 $\sqrt{80/60} \approx 1.15$ 배, 약 15 % 커진다. 한 집단만 많이 거부되었다면 집단별 남은 시행 수를 보고하고 시행 수를 맞춘 분석으로 확인한다.

다음 장으로

이 장에서는 원자료를 분석할 수 있는 상태로 만드는 과정과, 필터와 기준과 ICA가 무엇을 지우고 무엇을 새로 만드는지를 보았다. 10장에서는 깨끗해진 자료에서 무엇을 재는지를 다룬다. 시행을 평균해 ERP를 얻고 진폭과 잠복기를 재는 법, 시간 창 선택의 순환성과 군집 순열 검정, 스펙트럼과 $1/f$ 성분, 웨이블릿으로 보는 시간-주파수 분석이다. 이 장의 필터에서 본 시간과 주파수의 맞바꿈은 10장에서 웨이블릿의 해상도 문제로 다시 나타난다.

10장 ERP와 시간-주파수 분석

이 장에서 배울 것 전처리를 마친 EEG/MEG 에포크에서 사건 관련 전위(ERP)를 만들고 재는 법, 시간 축 전체를 검정하는 군집 순열 검정, 웰치 방법으로 파워 스펙트럼을 구하고 비주기 1/f 성분과 진동 봉우리를 나누는 법, 모를레 웨이블릿으로 시간-주파수 지도를 그리고 유발·유도 파워와 시행 간 위상 일치도(ITC)를 가르는 법, 그리고 진동 분석의 함정. **뇌 연구자에게 왜 필요한가** "P300 진폭이 줄었다", "전두 세타가 늘었다", "알파 파워가 낮다"는 문장은 모두 이 장의 분석 단계를 거친 결과다. 같은 데이터라도 피크를 재는지 평균을 재는지, 시간 창을 어떻게 골랐는지, 1/f 배경을 뺐는지에 따라 결론이 달라진다. 방법 절의 몇 줄로 그 선택을 알아보는 눈이 필요하다.

📖 중고등 복습: 평균, 사인파, 로그 그래프

여러 값을 더해 개수로 나눈 것이 **평균**이다. 값마다 제멋대로 섞인 오차는 더하면 서로 일부를 지우므로, 평균은 한 번의 값보다 믿을 만하다. 사인파 $A \sin(2\pi ft + \varphi)$ 는 세 수로 정해진다. **진폭** A 는 높이, **주파수** f 는 1초에 도는 횟수(단위 Hz), **위상** φ 는 출발점이다. 주기는 $T = 1/f$ 이다. 10 Hz면 한 주기가 100 ms다. $y = x^{-2}$ 처럼 거듭제곱으로 줄어드는 곡선은 보통 그래프에서 급히 꺾인 곡선이지만, 가로와 세로를 모두 로그 눈금으로 그리면 기울기 -2인 직선이 된다. 로그를 취하면 곱셈이 덧셈이 되고 지수가 기울기가 되기 때문이다. 이 장의 1/f 스펙트럼은 이 성질로 읽는다.

10.1 ERP: 평균으로 꺼내는 반응

왜 평균하는가

ERP는 자극이나 반응 같은 사건에 시간이 묶인 뇌 전위다. 크기는 대개 수 μV 에서 10 μV 남짓이고, 그 위에 수십 μV 의 배경 EEG가 얹혀 있다. 그래서 같은 종류의 사건을 수십-수백 번 반복하고 사건 시점에 맞춰 잘라 낸 에포크(9장)를 평균한다. 생리 1권 6장과 물리 2권 7장에서 본 것처럼, 독립인 잡음은 N 번 평균하면 표준편차가 $1/\sqrt{N}$ 로 준다(그림 10.1 가).

이 단순한 연산에는 세 가지 가정이 숨어 있다.

1. 반응은 시행마다 같은 모양과 크기다.
2. 배경 활동은 사건과 무관하다. 위상이 사건에 묶이지 않는다.
3. 반응의 잠복기가 시행마다 같다.

세 번째 가정이 가장 자주 깨진다. 반응 시간이 시행마다 수백 ms씩 다르면, 판단과 관련된 성분의 잠복기도 함께 흔들린다.




그림 10.1 ERP 평균과 잠복기 흔들림(합성 데이터). (가) P1, N1, P3로 된 ERP(빨간 점선)에 1/f 모양의 배경 EEG(표준편차 20 μV)를 더했다. 시행 하나에서는 보이지 않던 ERP가 16번, 400번 평균하면 드러난다. 세로 눈금이 패널마다 다르다. (나) 잡음 없이 잠복기만 시행마다 흔들렸을 때의 평균 ERP. 폭이 좁은 N1은 흔들림 30 ms에서 이미 절반 가까이 무너지지만, 폭이 넓은 P3는 덜 줄어든다.

잠복기 흔들림은 평균을 뭉갬다

잠복기가 표준편차 σ_j 로 흔들리면, 평균 ERP는 참 ERP를 잠복기 분포로 흐린 것이 된다(물리 2권 7장의 합성곱). 성분이 폭 σ_c 인 가우스 모양이고 흔들림도 가우스라면, 평균한 성분의 폭과 정점은

$$\sigma_{\text{평균}} = \sqrt{\sigma_c^2 + \sigma_j^2}, \quad \frac{\text{평균 ERP 정점}}{\text{참 정점}} = \frac{\sigma_c}{\sqrt{\sigma_c^2 + \sigma_j^2}}$$

이다. 넓이(진폭 $\times$ 시간)는 그대로 남고 정점만 낮아진다. 그래서 폭이 좁은 초기 성분일수록 흔들림에 약하다(그림 10.1 나).

예제 10.1 흔들림이 성분을 얼마나 깎는가

N1의 폭이 $\sigma_c = 20$ ms, P3의 폭이 60 ms다. (가) 잠복기 흔들림이 30 ms일 때와 60 ms일 때 각 성분의 평균 정점은 참 정점의 몇 배인가? (나) P3(정점 8 μV , 350 ms)를 300–400 ms 평균 진폭으로 잴 때와 200–500 ms 평균 진폭으로 잴 때, 흔들림 60 ms가 측정값을 얼마나 바꾸는가?

풀이 (가) N1은 $20/\sqrt{20^2 + 30^2} \approx 0.55$ 배, $20/\sqrt{20^2 + 60^2} \approx 0.32$ 배다. P3는 $60/\sqrt{60^2 + 30^2} \approx 0.89$ 배, $60/\sqrt{60^2 + 60^2} \approx 0.71$ 배다. (나) 흔들림이 없을 때 300–400 ms 평균은 약 7.2 μV , 흔들림 60 ms에서는 약 5.4 μV 로 25 % 준다. 200–500 ms 평균은 약 4.0 μV 에서 3.7 μV 로 7 %만 준다. 넓은 창은 평균이 넓어질수록 흔들림에 덜 민감하다. 두 집단의 P3 차이가 진폭 차이인지 잠복기 변동성 차이인지 가리려면 넓은 창을 평균 진폭과 단일 시행 분석을 함께 본다.

ERP 성분

ERP 파형의 봉우리와 골에는 극성과 대략의 잠복기로 이름을 붙인다. N은 음성, P는 양성이다. 대표 성분은 다음과 같다.

성분	잠복기 (대략)	주로 보이는 곳	무엇과 관련되는가
P1	80-130 ms	후두부	초기 시각 처리, 공간 주의
N170	140-200 ms	후두-측두부	얼굴과 단어 같은 범주 처리
MMN	100-250 ms	전두-중심부	반복 소리 속의 이탈 감지(전주의 단계)
P300 (P3b)	300-600 ms	두정부	드문 표적의 평가, 맥락 갱신
N400	300-500 ms	중심-두정부	의미 기대와 어긋남

여기서 주의할 점이 있다. 파형의 봉우리는 **성분(component)** 과 같지 않다. 두피 전위는 여러 피질 원천의 전위가 체적 전도로 겹친 합이다(물리 2권 11장). 하나의 봉우리 아래 여러 원천이 겹쳐 있고, 한 원천이 커지면 이웃 봉우리의 모양과 정점 위치가 함께 바뀐다(Luck 2014). "N170이 커졌다"는 "N170 시간대의 전위가 더 음이었다"는 관찰이고, 원천의 해석은 그다음 단계다.

무엇을 잴 것인가: 피크와 평균

ERP를 숫자 하나로 줄이는 방법은 크게 둘이다.

- **피크 진폭(peak amplitude)**: 정해 둔 탐색 창에서 가장 높은(또는 낮은) 값. 그 시점이 **피크 잠복기**다.
- **평균 진폭(mean amplitude)**: 정해 둔 창 안의 값을 평균한 것.

피크 진폭은 직관적이지만 통계적으로 나쁜 성질이 있다. 잡음이 섞인 곡선에서 최댓값을 고르면, 잡음이 위로 튼 점이 뽑힌다. 그래서 잡음이 클수록, 곧 시행 수가 적을수록 피크는 체계적으로 커진다(그림 10.2). 평균 진폭은 잡음의 평균이 0이므로 치우침이 없다. 피크 잠복기도 잡음에 따라 크게 흔들린다. 잠복기는 대신 **부분 넓이 잠복기(fractional area latency)**, 곧 창 안 넓이의 50 %에 이르는 시점으로 재는 편이 안정적이다.




그림 10.2 피크 진폭과 평균 진폭(합성 데이터). (가) 한 사람의 20시행 평균. 참 P3의 정점은 8 μV (350 ms)인데, 250–500 ms 창에서 찾은 피크는 잡음이 위로 튼 390 ms의 12.3 μV 다. 300–400 ms 평균 진폭은 5.1 μV (참값 7.2 μV)로, 이번 표본에서는 아래로 빗나갔지만 평균적으로는 치우치지 않는다. (나) 실험을 1500번 되풀이했을 때 추정값과 참값의 차이(점: 평균, 막대: 표준편차). 피크 진폭은 시행이 10개일 때 약 12 μV , 80개일 때도 약 3 μV 위로 치우친다. 평균 진폭은 시행 수와 관계없이 치우침이 0이다.

대표 도구는 MNE-Python, EEGLAB과 그 ERP 확장인 ERPLAB, FieldTrip, Brainstorm이다. 어느 것이나 에포크 평균, 기저선 보정, 창 평균과 피크 측정을 제공한다. 흔한 실수는 셋이다. 첫째, 0.1 Hz보다 훨씬 높은 고역 통과 필터(예: 1 Hz)를 쓰면 P300과 N400 같은 느린 성분이 깎이고 앞뒤에 가짜 반대 극성 봉우리가 생긴다(9장). 둘째, 기준 전극을 바꾸면 성분의 두피 분포와 크기가 바뀐다. 평균 기준과 유양돌기 기준의 N170은 다른 숫자다. 셋째, 조건이나 집단 사이에 남은 시행 수가 다른데 피크 진폭을 비교한다.

🧠 뇌로 가는 다리: 환자 집단의 ERP와 시행 수의 함정

조현병에서 MMN과 P300 진폭이 줄어 있다는 결과는 가장 재현이 잘 되는 ERP 소견 가운데 하나다. 그런데 환자 집단은 눈 깜빡임, 움직임, 졸음 때문에 버려지는 시행이 더 많다. **그림 10.2** 나의 시뮬레이션으로 보면, 환자 40시행, 대조군 80시행이 남았을 때 피크 진폭의 치우침은 각각 약 5.1 μV 와 3.4 μV 다. 참 진폭이 같아도 환자의 피크가 약 1.7 μV 커 보인다. 진폭 감소를 찾는 연구에서 이 치우침은 효과를 가리는 쪽으로 작용하고, 진폭 증가를 주장하는 연구에서는 가짜 효과를 만든다. 평균 진폭을 쓰고, 집단별 남은 시행 수를 보고하고, 필요하면 시행 수를 맞춰 무작위로 뽑아 비교한다. 임상 시험에서 MMN을 표지자로 쓰려는 시도가 이 점검을 표준 절차로 넣는 이유다.

10.2 ERP 통계

시간 창은 어디서 오는가

ERP 통계의 가장 큰 자유도는 시간 창과 전극 선택이다. 두 조건의 차이파를 먼저 보고 차이가 가장 큰 구간을 창으로 고른 뒤 같은 데이터로 검정하면, 6장에서 본 **순환 분석(double dipping)** 이 된다. 잡음만 있어도 어딘가에는 차이가 큰 구간이 있으므로, 그 구간을 고르는 순간 1종 오류율이 0.05를 크게 넘는다.

정직한 창 선택 방법은 다음과 같다.

- **선행 연구나 사전 등록:** "N400은 300-500 ms, Cz·CPz·Pz 평균"처럼 데이터를 보기 전에 정한다.
- **조건을 합친 평균:** 두 조건을 합친 총평균 파형에서 성분의 위치를 찾는다. 조건 차이와 독립인 정보로 창을 고르는 셈이다. 다만 두 조건의 시행 수가 다르면 완전히 독립은 아니다.
- **독립 데이터:** 별도 참가자나 별도 회기의 데이터로 창을 정한다.
- **시간 축 전체 검정:** 창을 고르지 않고 모든 시점을 검정한 뒤 다중비교를 보정한다. 아래의 군집 순열 검정이 대표다.

질량 단변량 검정과 군집 순열 검정

질량 단변량(mass univariate) 분석은 모든 시점(그리고 모든 전극)마다 t 검정을 한다. 1 s 에포크를 250 Hz로 표본화하면 시점이 250개이고, 64채널이면 16,000개다. 6장의 다중비교 문제가 그대로 온다. 그러나 EEG는 시간과 공간에서 매끈하므로 이웃한 검정들이 강하게 상관되어 있다. 본페로니 보정은 지나치게 보수적이다.

군집 기반 순열 검정(cluster-based permutation test) 은 이 상관을 이용한다(Maris & Oostenveld 2007). 절차는 다음과 같다.

1. 시점마다 t 값을 구한다.
2. **군집 형성 문턱**(예: 양측 $p < 0.05$ 에 해당하는 $|t|$)을 넘는 이웃 시점들을 묶어 군집을 만든다. 군집의 t 값을 더해 **군집 질량**을 구한다.
3. 조건 이름표를 무작위로 바꾼다. 참가자 내 설계라면 참가자마다 차이파의 부호를 무작위로 뒤집는다. 귀무가설이 참이면 부호는 의미가 없기 때문이다. 이렇게 만든 가짜 데이터마다 1-2단계를 하고 **가장 큰 군집 질량**을 기록한다.
4. 수천 번 되풀이해 얻은 최대 군집 질량의 분포가 귀무 분포다. 실제 군집의 질량이 이 분포의 상위 5 %에 들면 유의하다.

"가장 큰 군집"의 분포와 비교하므로, 검정 전체의 가족 단위 오류율(FWE)이 통제된다. 가정은 교환 가능성 하나다. 귀무가설에서 이름표를 바꾸어도 데이터의 분포가 같아야 한다.




그림 10.3 시간 축 군집 순열 검정(합성 데이터, 참가자 20명). (가) 시점마다 구한 대응 t 값(파랑). 참 효과는 300~500 ms에만 넣었다. 문턱 $|t| = 2.09$ 를 넘는 구간이 세 군데 생겼는데, 효과가 있는 352~452 ms 군집(빨강)만 유의하고, 잡음이 만든 20~68 ms와 에포크 시작점의 군집(보라)은 유의하지 않다. (나) 부호를 2000번 무작위로 뒤집어 얻은 최대 군집 질량의 분포. 95번째 백분위(점선, 약 49)를 넘은 것은 질량 101인 군집 하나다. 0 근처의 높은 막대는 문턱을 넘는 시점이 하나도 없던 순열이다.

그림 10.3의 데이터에서 문턱을 넘는 시점은 250개 가운데 45개였다. 보정 없이 시점마다 보고했다면, 자극 직후 20~68 ms의 음의 차이도 "유의한 초기 효과"로 보고되었을 것이다.

예제 10.2 순열 횟수는 몇 번이면 충분한가

참가자 20명의 대응 설계에서 부호 뒤집기 순열 검정을 한다. (가) 가능한 부호 조합은 모두 몇 개인가? (나) 순열을 1000번 할 때 얻을 수 있는 가장 작은 p 값과, 참 p가 0.05 근처일 때 순열 추정 p의 표준오차는 얼마인가? (다) 5000번이면 표준오차는 얼마가 되는가?

풀이 (가) 참가자마다 +1 또는 -1이므로 $2^{20} = 1,048,576$ 개다. 모두 계산하기는 어려우므로 무작위로 일부를 뽑는다(몬테카를로 순열). (나) 실제 데이터도 하나의 순열로 세어 $p = (\text{귀무 질량} \geq \text{관측 질량인 횟수} + 1) / (1000 + 1)$ 로 쓰므로 가장 작은 값은 $1/1001 \approx 0.001$ 이다. p 추정값은 이항 비율이므로 표준오차는 $\sqrt{0.05 \times 0.95/1000} \approx 0.007$ 이다. p = 0.045와 0.055를 가리기 어렵다. (다) $\sqrt{0.05 \times 0.95/5000} \approx 0.003$ 이다. 경계에 걸린 결과라면 순열 수를 늘리고 그 수를 보고한다.

흔한 오해: 유의한 군집의 시작 시점이 효과의 시작 시점이다

군집 순열 검정이 통제하는 것은 "어딘가에 차이가 있다"는 주장의 오류율이다. 군집에 속한 개별 시점이나 전극 하나하나가 유의하다는 뜻은 아니다. 군집의 경계는 군집 형성 문턱, 신호 대 잡음비, 필터가 만든 시간 번짐에 따라 앞뒤로 움직인다. 그래서 "효과는 152 ms에 시작했다", "효과는 왼쪽 측두에 국한되었다"는 군집 검정으로 뒷받침되지 않는다(Sassenhagen & Draschkow 2019). 잠복기 자체가 질문이라면 부분 넓이 잠복기를 참가자마다 재서 비교하거나, 잭나이프 방법처럼 잠복기를 위해 만든 검정을 쓴다. 군집 형성 문턱도 결과를 바꾸므로 데이터를 보기 전에 정하고 보고한다. 문턱을 고르지 않는 TFCE(6장)도 선택지다.

10.3 스펙트럼 분석

웰치 방법

휴지기 EEG나 긴 과제 구간에서는 사건에 묶인 파형보다 **어떤 주파수의 리듬이 얼마나 있는가**가 질문이다. 이것을 파워 스펙트럼으로 답한다. 60 s 기록 전체를 한 번에 푸리에 변환하면 주파수 간격은 1/60 Hz로 촘촘하지만, 주파수마다의 파워 추정값이 심하게 출렁인다(물리 2권 7장). 표준 해법은 **웰치 방법(Welch's method)** 이다.

1. 기록을 길이 T 의 구간으로 나눈다. 보통 절반씩 겹친다.
2. 구간마다 한(Hann) 창을 씌워 양끝을 부드럽게 줄인다. 스펙트럼 누출을 줄이기 위해서다.
3. 구간마다 파워 스펙트럼을 구해 평균한다.

주파수 해상도는 구간 길이가 정한다. $\Delta f = 1/T$ 다. 2 s 구간이면 0.5 Hz, 4 s 구간이면 0.25 Hz다. 구간 수 K 가 많을수록 추정값의 출렁임이 준다. 구간 하나의 파워 추정값은 상대 표준편차가 약 100 %이고, 독립인 구간 K 개를 평균하면 대략 $1/\sqrt{K}$ 로 준다. 같은 기록 길이에서 해상도와 안정성은 맞바꾼다.

예제 10.3 구간 길이 정하기

휴지기 EEG 60 s를 웰치 방법으로 분석한다. (가) 2 s 구간, 50 % 겹침이면 구간은 몇 개이고 주파수 간격은 얼마인가? (나) 4 s 구간이면? (다) 알파 봉우리 주파수를 0.25 Hz 단위로 보고하려면 어느 쪽을 써야 하고 대가는 무엇인가?

풀이 (가) 구간 시작점이 1 s 간격이므로 $(60 - 2)/1 + 1 = 59$ 개, $\Delta f = 0.5$ Hz다. (나) 시작점이 2 s 간격이므로 $(60 - 4)/2 + 1 = 29$ 개, $\Delta f = 0.25$ Hz다. (다) 4 s 구간이 필요하다. 구간 수가 59개에서 29개로 반쯤 줄어 출렁임이 약 $\sqrt{59/29} \approx 1.4$ 배 커진다. 겹친 구간은 완전히 독립이 아니므로 실제 이득은 이보다 조금 작다. 기록을 늘리거나, 봉우리 주변을 곡선으로 적합해 봉우리 주파수를 구간 간격보다 정밀하게 추정한다.

대역 파워

스펙트럼을 공통 대역(델타 0.5-4, 세타 4-8, 알파 8-13, 베타 13-30, 감마 30-100 Hz)별로 더한 것이 **대역 파워(band power)** 다. 대역 파워를 전체 파워로 나눈 **상대 파워**도 흔히 쓴다. 상대 파워는 두개골 두께나 임피던스 같은 사람마다의 전체 크기 차이를 지우지만, 한 대역이 늘면 다른 대역이 저절로 줄어 보이는 단점이 있다. 대표 도구로 SciPy의 `welch`, MNE-Python의 스펙트럼 계산, FieldTrip의 주파수 분석이 있다. 집단 통계에서는 파워 분포가 오른쪽으로 길게 늘어지므로 로그(dB)를 취해 평균하는 것이 보통이다.

10.4 비주기 성분과 봉우리

1/f 배경

EEG 스펙트럼은 낮은 주파수일수록 파워가 커지는 매끈한 배경 위에 알파 같은 봉우리가 얹힌 모양이다. 배경은 대략 거듭제곱 법칙을 따른다.

$$P(f) = \frac{10^b}{f^\chi}, \quad \log_{10} P = b - \chi \log_{10} f$$

b 는 **오프셋(offset)**, χ 는 **지수(exponent)** 이고 로그-로그 그래프의 기울기 $-\chi$ 다. 사람 두피 EEG에서 χ 는 대략 1-2다. 이 배경을 특정 주기가 없다는 뜻에서 **비주기 성분(aperiodic component)** 이라 하고, 봉우리를 **주기 성분(periodic component)** 이라 한다.

문제는 고정 대역 파워가 두 성분을 구별하지 못한다는 것이다. 8-13 Hz 파워는 알파 봉우리와 그 아래 깔린 배경을 함께 더한다. 배경의 기울기만 바뀌어도 대역 파워가 바뀐다.

봉우리를 분리하는 모형

FOOOF(fitting oscillations and one-over-f, 지금은 specparam이라는 이름으로 배포된다)는 로그 파워 스펙트럼을 비주기 직선과 가우스 봉우리들의 합으로 적합한다(Donoghue 2020).

$$\log_{10} P(f) = b - \chi \log_{10} f + \sum_k a_k \exp\left(-\frac{(f - c_k)^2}{2w_k^2}\right)$$

봉우리마다 높이 a_k (비주기 배경 위로 솟은 log 파워), 중심 주파수 c_k , 폭 w_k 가 나온다. 적합은 세 단계로 한다. 먼저 직선을 맞추고, 봉우리를 피해 낮은 점들로 다시 맞춘다. 다음으로 직선을 뺀 평탄한 스펙트럼에서 가장 높은 점부터 가우스를 하나씩 찾는다. 잡음 출렁임보다 낮은 봉우리는 버린다. 마지막으로 모든 모수를 함께 다시 맞춘다. [그림 10.4](#) 는 이 절차를 `scipy.optimize.curve_fit` 으로 직접 구현한 결과다.




그림 10.4 웰치 스펙트럼과 비주기·주기 성분의 분리(합성 EEG 60 s, 2 s 한 창, 50 % 겹침). (가) 로그-로그 스펙트럼 (파랑)과 적합한 모형(빨강), 그 비주기 부분(회색 점선). 지수는 참값 1.5에 대해 1.51로 추정되었다. (나) 비주기 부분을 뺀 평탄한 스펙트럼. 알파 봉우리의 중심 10.1 Hz, 높이 0.33(참값 0.35), 폭 1.0 Hz가 복원된다. (다) 알파 봉우리는 같고 비주기 지수만 1.5와 2.0으로 다른 두 스펙트럼(30 Hz에서 배경이 같도록 맞췄다). 8-13 Hz 대역 파워는 1.8배 차이 나지만 봉우리 높이는 거의 같다.

이 모형의 가정과 선택지도 알아야 한다. 적합 주파수 범위(예: 1-40 Hz 또는 3-40 Hz)에 따라 지수가 달라진다. 넓은 범위에서는 스펙트럼이 저주파에서 꺾이는 **무릎(knee)**이 있어 직선 대신 무릎 모형을 쓴다. 최대 봉우리 수, 최소 봉우리 높이, 봉우리 폭 한계도 결과를 바꾼다. 적합 오차(R^2)를 참가자마다 확인하고, 설정을 보고한다. 전원 잡음(60 Hz)이나 그 고조파가 적합 범위에 들어오면 먼저 범위에서 뺀다.

예제 10.4 기울기 변화가 대역 파워를 얼마나 바꾸는가

비주기 배경이 30 Hz에서 같은 크기를 갖도록 고정한 채 지수가 1.5에서 2.0으로 바뀌었다. 알파 봉우리는 그대로다. (가) 10 Hz에서 배경 파워는 몇 배가 되는가? (나) 이 사람의 8-13 Hz 대역 파워가 "알파가 늘었다"고 보고되면 무엇이 잘못된가?

풀이 (가) 배경은 $(f/30)^{-x}$ 이므로 비는 $(10/30)^{-2.0}/(10/30)^{-1.5} = (1/3)^{-0.5} = \sqrt{3} \approx 1.73$ 배다. 8-13 Hz 전체를 넓이로 더해도 약 1.73배다. (나) 늘어난 것은 배경이지 진동이 아니다. 봉우리를 분리하면 알파 높이는 그대로다(그림 10.4 다). 지수가 커지면(스펙트럼이 가팔라지면) 저주파 대역은 모두 커지고 고주파 대역은 작아지므로, 세타·알파 증가와 베타·감마 감소가 한꺼번에 "발견"된다.

🧠 뇌로 가는 다리: 비주기 지수는 무엇을 반영하는가

비주기 성분은 한때 잡음으로 여겨 버렸지만, 지금은 그 자체가 관심 지표다. 시냅스 전류 모형에서는 억제성 전류가 상대적으로 많을수록 스펙트럼이 가팔라진다는 결과가 있어, 지수를 흥분-억제 균형의 간접 지표로 쓰자는 제안이 나왔다(Gao 외 2017). 나이가 들수록 스펙트럼이 평평해진다(지수가 작아진다)는 보고, 마취와 수면에서 가팔라진다는 보고가 이어졌다. 이 결과들은 고정 대역 파워로 보고된 노화와 질환 연구를 다시 읽게 한다. 노인에서 "알파가 줄었다"는 결과의 일부는 알파 봉우리가 아니라 배경 기울기의 변화일 수 있다. 다만 지수가 곧 흥분-억제 비라는 해석은 모형에 기댄 가설이다. 지수는 적합 범위, 기준 전극, 근전도 오염에도 반응하므로 해석 전에 이 요인들을 확인한다.

10.5 시간-주파수 분석

단시간 푸리에 변환

과제 중의 리듬은 시간에 따라 바뀐다. 자극 뒤 알파가 잠깐 줄고, 운동 뒤 베타가 되튀어 오른다. 스펙트럼을 시간마다 보려면 짧은 창을 시간 축을 따라 밀면서 창마다 푸리에 변환을 하면 된다. 이것이 **단시간 푸리에 변환(STFT, short-time Fourier transform)** 이다. 창 길이 T 가 시간 해상도를, $1/T$ 가 주파수 해상도를 정한다. 물리 2권 7장의 "시간에서 좁으면 주파수에서 넓다"가 여기서 피할 수 없는 맞바꿈이 된다. STFT는 모든 주파수에 같은 창을 쓰므로, 4 Hz 세타에 맞춘 긴 창은 40 Hz 감마의 빠른 변화를 뭉개고, 감마에 맞춘 짧은 창은 세타를 한 주기도 담지 못한다.

모를레 웨이블릿

모를레 웨이블릿(Morlet wavelet) 은 주파수마다 창 길이를 바꾸는 방법이다. 복소 사인파에 가우스 창을 곱한 짧은 파형이다.

$$w(t) = \exp(2\pi i f t) \exp\left(-\frac{t^2}{2\sigma_t^2}\right), \quad \sigma_t = \frac{n}{2\pi f}, \quad \sigma_f = \frac{f}{n}$$

n 은 웨이블릿 안에 담긴 주기 수다. n 을 고정하면 높은 주파수일수록 창이 짧아진다. 시간 폭 σ_t 와 주파수 폭 σ_f 의 곱은 항상 $1/(2\pi) \approx 0.16$ 이다. n 을 키우면 주파수가 날카워지고 시간이 흐려진다(아래 [그림 10.5](#)). 신호를 이 웨이블릿과 합성곱하면 시점마다 복소수가 나오고, 그 크기의 제곱이 파워, 각도가 위상이다.

실제로는 n 을 3-10 사이로 두고, 낮은 주파수에서 작게, 높은 주파수에서 크게 늘리는 경우가 많다(Cohen 2014).

예제 10.5 세타와 감마에 같은 7주기를 쓰면

7주기 모를레 웨이블릿을 쓴다. (가) 6 Hz와 40 Hz에서 σ_t 와 σ_f 는 각각 얼마인가? (나) 반치폭은 표준편차의 2.355배다. 6 Hz에서 시간 반치폭은 얼마이고, 이것이 기저선 구간 설계에 어떤 뜻을 갖는가?

풀이 (가) 6 Hz: $\sigma_t = 7/(2\pi \times 6) \approx 186$ ms, $\sigma_f = 6/7 \approx 0.86$ Hz. 40 Hz: $\sigma_t \approx 28$ ms, $\sigma_f \approx 5.7$ Hz. (나) $2.355 \times 186 \approx 440$ ms다. 6 Hz의 파워 값 하나는 앞뒤 수백 ms의 신호를 섞은 것이다. 기저선을 -200-0 ms로 잡으면 자극 뒤의 반응이 기저선으로 새어 들어온다. 저주파를 볼 때는 기저선 구간을 자극에서 충분히 떨어뜨리고(예: -500 ~ -300 ms), 에폭 양끝에 웨이블릿 절반 길이 이상의 여유(이 경우 0.5 s 이상)를 둔다. 끝부분의 값은 가장자리 효과로 믿을 수 없다.

이것을 numpy만으로 쓰면 다음과 같다. 시행마다 파워를 구해 평균하고, 위상만 남긴 단위 벡터를 평균해 아래에서 설명할 ITC도 함께 구한다.

```
import numpy as np

def morlet_power(x, fs, freqs, n_cycles=7):
    """x: (시행 수, 표본 수) 배열. 시행 평균 파워와 ITC를 (주파수, 시간)으로 돌려준다."""
    power = np.zeros((len(freqs), x.shape[1]))
    itc = np.zeros_like(power)
    for i, f in enumerate(freqs):
        sd = n_cycles / (2 * np.pi * f) # 웨이블릿의 시간 표준편차 (s)
        tw = np.arange(-3 * sd, 3 * sd, 1 / fs)
        g = np.exp(-tw**2 / (2 * sd**2))
        w = g * np.exp(2j * np.pi * f * tw) / g.sum() * 2 # 진폭 1 사인파 → 1
        c = np.array([np.convolve(tr, w, mode="same") for tr in x])
        power[i] = np.mean(np.abs(c)**2, axis=0) # 시행마다 파워 → 평균
        itc[i] = np.abs(np.mean(c / np.abs(c), axis=0)) # 위상만 남겨 평균
    return power, itc

fs = 250
t = np.arange(-1, 1.5, 1 / fs) # 앞뒤로 넉넉한 에포크
rng = np.random.default_rng(0)
x = rng.standard_normal((60, t.size)) + np.sin(2 * np.pi * 10 * t) * (t > 0) # 60시행
power, itc = morlet_power(x, fs, np.arange(4, 31))
```

`np.convolve`의 `mode="same"`은 웨이블릿이 에포크보다 짧아야 제대로 동작한다. 위 예에서 4 Hz, 7주기 웨이블릿은 $\pm 3\sigma$ 로 자르면 약 1.7 s이고 에포크는 2.5 s다.




그림 10.5 모를레 웨이블릿의 시간-주파수 맞바꿈(합성 신호). (가) 0.6–1.4 s에는 10 Hz와 14 Hz가 함께 있고, 2.00 s와 2.12 s에는 40 Hz 짧은 버스트가 하나씩 있다. (나) 3주기 웨이블릿은 두 40 Hz 버스트를 시간에서 나누지만, 10 Hz와 14 Hz를 하나의 덩어리로 합치고 버스트를 20–60 Hz로 길게 번지게 한다. (다) 12주기 웨이블릿은 10 Hz와 14 Hz를 두 줄로 나누지만, 두 40 Hz 버스트를 하나로 합친다. 색은 진폭(최댓값 = 1)이다.

ERSP와 기저선 정규화

시간-주파수 파워는 주파수가 낮을수록 크다($1/f$). 그대로 그리면 저주파만 보인다. 그래서 주파수마다 기저선 구간의 평균 파워로 나눈 **사건 관련 스펙트럼 변화(ERSP, event-related spectral perturbation)**를 그린다. 데시벨 $10\log_{10}(P/P_{\text{기저}})$, 백분율 변화, 기저선 분포로 나눈 z 점수가 흔한 선택이다. 파워가 줄면 **사건 관련 비동기화(ERD)**, 늘면 **사건 관련 동기화(ERS)**라 부른다. 기저선 선택은 결과의 일부다. 조건마다 기저선이 다르거나(예: 직전 시행의 반응이 섞인 경우), 기저선 자체가 집단마다 다르면, 정규화가 차이를 만들거나 지운다.

유발 파워, 유도 파워, ITC

자극 뒤 시간-주파수 지도에 보이는 파워에는 두 종류가 섞여 있다.

- **유발(evoked) 활동**: 위상이 자극에 고정된 활동. ERP가 곧 이것이다. 시행을 평균해도 남는다.
- **유도(induced) 활동**: 자극 뒤에 나타나지만 위상이 시행마다 제멋대로인 활동. 시행을 평균하면 서로 지워져 ERP에는 남지 않는다.

시행마다 파워를 구한 뒤 평균한 **전체 파워**에는 둘이 모두 있다. ERP의 파워만 구하면 유발 부분이 된다. 각 시행에서 ERP를 빼고 파워를 구하면 유도 부분에 가까워진다. 단, 이 빼기는 반응 크기와 잠복기가 시행마다 같다는 가정에 기댄다. 잠복기가 흔들리면 남은 유발 활동이 유도 활동으로 오인된다.

위상의 일관성은 따로 잴다. 시행마다 위상만 남긴 단위 벡터 $e^{i\varphi_k}$ 를 평균한 길이가 **시행 간 위상 일치도(ITC, inter-trial coherence)**이다. 위상 고정 인자(phase-locking factor)라고도 한다.

$$\text{ITC}(f, t) = \left| \frac{1}{N} \sum_{k=1}^N e^{i\varphi_k(f, t)} \right|$$

모든 시행의 위상이 같으면 1, 제멋대로면 0에 가깝다. ITC는 진폭과 무관하므로, 파워 변화 없이 위상만 재정렬되는 반응도 잡아낸다.

ITC에는 시행 수에 따른 치우침이 있다. 위상이 완전히 무작위여도 N 개 단위 벡터의 평균 길이는 0이 아니라 약 $\sqrt{\pi/(4N)}$ 이다. 레일리 검정으로 근사하면, 위상이 무작위인데도 관측한 값 이상의 ITC가 나올 확률(p 값)은 약 $e^{-N \cdot \text{ITC}^2}$ 이다.




그림 10.6 유발 활동과 유도 활동(합성 데이터, 100시행, 5주기 웨이블릿). 자극 뒤 약 150 ms의 5 Hz 파형은 매 시행 같은 위상이고, 300~700 ms의 20 Hz 버스트는 시행마다 위상이 무작위다. (가) 시행마다 구한 파워를 평균하면(기저선 대비 dB) 둘 다 보인다. (나) 평균 파형(ERP)의 파워에는 5 Hz 유발 활동만 남는다. (다) ITC는 5 Hz에서 약 0.84로 높고, 20 Hz 버스트 자리에서는 우연 수준(약 0.1)이다.

예제 10.6 시행 수가 다른 두 조건의 ITC

(가) 위상이 무작위일 때 시행 25개와 100개의 기대 ITC는 각각 얼마인가? (나) $p < 0.05$ 의 문턱 ITC는? (다) 조건 A는 100시행, 조건 B는 25시행(드문 자극)이다. 두 조건의 ITC를 그대로 비교하면 무엇이 문제인가?

풀이 (가) $\sqrt{\pi/100} \approx 0.18$, $\sqrt{\pi/400} \approx 0.089$ 다. (나) $e^{-N \cdot \text{ITC}^2} = 0.05$ 에서 $\text{ITC} = \sqrt{-\ln 0.05/N} = \sqrt{3.0/N}$ 이다. 25시행이면 약 0.35, 100시행이면 약 0.17이다. (다) 위상 고정이 전혀 없어도 B의 ITC가 A보다 약 0.09 높게 나온다. 드문 자극에서 "위상 재정렬이 더 강했다"는 결론이 시행 수만으로 생길 수 있다. 시행 수를 맞춰 무작위로 뽑아 반복 계산하거나, 시행 수 치우침을 보정한 지표(예: 쌍별 위상 일치도)를 쓴다. 같은 치우침은 11장의 PLV 같은 위상 연결성 지표에도 있다.

🧠 뇌로 가는 다리: 40 Hz 청각 정상 상태 반응

클릭 소리를 1초에 40번 들려주면 청각 피질이 40 Hz로 따라 진동하는 **청각 정상 상태 반응(ASSR)** 이 생긴다. 반응은 자극에 위상이 고정되어 있으므로 ITC와 유발 파워로 잰다. 조현병 환자에서 40 Hz ASSR의 ITC와 파워가 줄어 있다는 결과가 여러 연구실에서 반복되었고, 억제성 인터뉴런(생리 1권 6장의 감마 발생 기전)의 기능 이상과 연결해 해석된다. 동물 모형에서도 같은 자극으로 같은 지표를 잴 수 있어 번역 연구의 표지자로 주목받는다. 이 비교가 의미를 가지려면 집단 사이에 남은 시행 수(예제 10.6), 근전도가 섞이기 쉬운 감마 대역의 오염(생리 1권 6장), 청력 차이를 함께 통제해야 한다.

10.6 진동의 함정

비정현 파형

푸리에 분석은 신호를 사인파의 합으로 나타낸다. 뇌의 리듬은 사인파가 아니다. 감각운동 피질의 뮤 리듬은 아치 모양이고, 해마 세타는 톱니 모양에 가깝다. 사인파가 아닌 주기 신호는 기본 주파수의 정수배에 **고조파(harmonic)** 를 만든다(물리 1권 4장). 10 Hz 아치 모양 리듬은 20 Hz와 30 Hz에

붕우리를 만들고, 20 Hz 대역 통과 필터를 거치면 그럴듯한 "베타 진동"이 나온다(그림 10.7). 이 베타는 10 Hz 리듬의 모양을 다르게 쓴 것일 뿐 별도의 진동이 아니다.




그림 10.7 비정현 파형이 만드는 가짜 고조파(합성 데이터). (가) 주기가 같은 10 Hz 사인파와 아치 모양 파형. (나) 웰치 스펙트럼에서 아치 모양 파형은 10 Hz 외에 20 Hz와 30 Hz에도 붕우리를 만든다. (다) 아치 모양 신호를 17-23 Hz로 대역 통과하면 10 Hz 주기에 묶인 '베타'가 나온다. 같은 필터를 사인파 신호에 쓰면 출력의 실효값이 약 6분의 1이다.

파형 모양은 그 자체로 정보다. 붕우리와 골의 뽀죽함, 오름과 내림의 시간 비 같은 모양 지표는 파킨슨병의 베타 리듬처럼 생리 상태를 반영할 수 있다(Cole & Voytek 2017). 모양을 무시하고 사인파 분해만 하면 두 가지 오류가 생긴다. 고조파를 별도 대역의 진동으로 보고하고, 서로 다른 대역 사이의 위상이나 진폭이 묶여 있다고 잘못 결론 낸다. 후자는 11장의 교차 주파수 결합에서 다시 만난다. 대안은 시간 영역에서 주기를 하나씩 찾아 모양과 진폭을 재는 주기별 분석이다.

버스트

시행 평균한 시간-주파수 지도에서 베타 파워가 300 ms 동안 고르게 줄었다면, 개별 시행에서도 그렇게 보일 것 같다. 그러나 단일 시행을 보면 베타는 100-200 ms의 짧은 **버스트(burst)** 로 드문드문 나타나는 경우가 많다. 평균 파워의 "지속적 감소"는 버스트가 나타날 확률이 준 결과일 수 있다. 진폭이 일정하게 준 것과 버스트 빈도가 준 것은 다른 기전이다. 단일 시행에서 문턱(예: 중앙값 파워의 몇 배)을 넘는 구간을 버스트로 세어, 빈도, 지속 시간, 진폭을 따로 보고하는 분석이 늘고 있다. 버스트를 켤 때도 문턱과 웨이블릿 주기 수가 결과를 바꾼다.

대역 정의의 개인 차

알파 붕우리 주파수는 사람마다 다르다. **개인 알파 주파수(IAF, individual alpha frequency)** 는 건강한 성인에서 대략 8-12 Hz이고, 아동기에 높아졌다가 노년에 낮아진다. IAF가 8.5 Hz인 사람의 알파 붕우리는 반쯤 고정 대역 "8-13 Hz" 밖으로 나가 세타로 세어진다. 붕우리의 높이가 같아도 IAF가 낮은 집단은 "알파 감소, 세타 증가"로 보인다. 그래서 IAF를 먼저 구하고(붕우리 적합 또는 무게중심), 대역을 IAF 기준으로 정의한다. 예를 들어 $IAF \pm 2$ Hz를 알파로 둔다.

흔한 오해: 대역 파워가 늘었으면 그 대역의 진동이 늘었다

대역 파워의 변화에는 적어도 네 가지 원인이 있다. (1) 진동 봉우리가 실제로 커졌다. (2) 비주기 배경의 오프셋이나 기울기가 바뀌었다(예제 10.4). (3) 다른 대역 리듬의 고조파가 들어왔다. (4) 봉우리 주파수가 옮겨 가 대역 경계를 넘었다. 여기에 근전도와 눈 움직임 같은 인공물(9장)이 더해진다. 스펙트럼에 봉우리가 없는 대역에서 "진동"을 말하려면 먼저 그 대역에 비주기 배경 위로 솟은 봉우리가 있는지 확인한다. 봉우리가 없으면 그 대역의 파워 변화는 진동이 아니라 배경의 변화로 읽는 것이 기본값이다.

뇌로 가는 다리: 임상 정량 EEG(qEEG)를 읽을 때

정량 EEG는 휴지기 EEG의 대역 파워, 상대 파워, 좌우 비대칭, 결맞음을 계산해 표준 데이터베이스와 z 점수로 비교한다. 19채널 $\times$ 5대역 $\times$ 2지표(절대, 상대 파워)만 해도 190개의 z 점수가 나온다. 모두 정상인 사람도 $|z| > 1.96$ 을 넘는 값이 평균 9.5개 나오고, 하나 이상 "비정상"이 나올 확률은 사실상 100 %다. 6장의 다중비교 문제가 임상 보고서에 그대로 들어 있다. 세타/베타 비를 ADHD 진단 보조 지표로 쓰는 장비가 미국 FDA의 시판 허가를 받은 적이 있지만, 이후 연구들은 이 비가 집단 간에 일관되게 다르지 않고 졸음과 각성 수준, 나이에 크게 흔들린다고 보고했다. 이 장의 함정이 모두 여기 있다. 세타/베타 비는 비주기 기울기에 민감하고, IAF가 낮은 아동은 알파 일부가 세타로 세어지며, 근긴장은 베타를 부풀린다. qEEG 보고서를 읽을 때는 기록 상태(눈 감음/뜸, 각성, 약물), 인공물 처리, 표준 데이터베이스의 나이 범위, 다중비교 처리를 확인하고, 단일 지표의 z 점수를 진단으로 읽지 않는다.

핵심 정리

핵심 정리

- ERP 평균은 반응이 시행마다 같고, 배경이 사건과 무관하며, 잠복기가 고정되어 있다고 가정한다. 잡음은 $1/\sqrt{N}$ 로 준다.
- 잠복기 흔들림 σ_j 는 폭 σ_c 인 성분의 정점을 $\sigma_c/\sqrt{\sigma_c^2 + \sigma_j^2}$ 배로 낮추고 넓이는 보존한다. 폭이 좁은 초기 성분이 더 약하다.
- 피크 진폭은 잡음이 클수록(시행이 적을수록) 위로 치우친다. 평균 진폭과 부분 넓이 잠복기가 더 안정적이며, 집단별 시행 수가 다를 때 특히 중요하다.
- 데이터를 보고 시간 창을 고르면 순환 분석이 된다. 사전 정의, 조건을 합친 평균, 독립 데이터, 또는 시간 축 전체 검정으로 피한다.
- 군집 순열 검정은 이웃 시점의 상관을 이용해 FWE를 통제한다. 유의한 군집은 "어딘가에 효과가 있다"는 뜻이지, 군집의 시작 시점이나 범위가 정확하다는 뜻이 아니다.
- 웰치 방법에서 주파수 해상도는 $1/T$ (구간 길이), 안정성은 구간 수가 정한다. 2 s 구간이면 0.5 Hz다.
- 파워 스펙트럼은 비주기 배경($\log P = b - \chi \log f$)과 진동 봉우리의 합이다. 고정 대역 파워는 둘을 섞으므로, 지수가 1.5에서 2.0으로 바뀌기만 해도 알파 대역 파워가 약 1.7배 바뀐다. FOOOF/specparam으로 나누어 본다.
- 모를레 웨이블릿에서 $\sigma_t = n/(2\pi f)$, $\sigma_f = f/n$ 이고 곱은 $1/(2\pi)$ 로 고정이다. 주기 수 n 이 시간과 주파수 해상도를 맞바꾼다. 저주파는 기저선과 에포크 가장자리로 번진다.
- 전체 파워 = 유발 + 유도. ERP의 파워는 유발만, ITC는 위상 일관성만 잔다. 무작위 위상의 ITC 기대값은 약 $\sqrt{\pi/(4N)}$ 이므로 시행 수가 다른 조건은 그대로 비교하지 않는다.
- 비정현 파형은 고조파를, 버스트는 평균에서 지속적 변화처럼 보이는 착시를, 개인 알파 주파수 차이는 대역 경계를 넘는 가짜 차이를 만든다.

방법 절 점검표

방법 절 점검표

- ERP 측정이 평균 진폭인가 피크 진폭인가? 시간 창과 전극은 데이터를 보기 전에 정했는가, 아니면 어떤 독립 정보로 골랐는가?
- 조건별·집단별로 남은 시행 수를 보고했는가? 차이가 크면 피크 진폭과 ITC의 치우침을 어떻게 처리했는가?
- 고역 통과 필터 차단 주파수와 기준 전극은 무엇인가? 느린 성분을 다루면서 0.1 Hz보다 높은 고역 필터를 쓰지 않았는가?
- 시간(·전극) 축 전체를 검정했다면 다중비교를 어떻게 보정했는가? 군집 형성 문턱, 순열 횟수, 군집 질량 정의를 밝혔는가? 군집 경계로 잠복기나 위치를 주장하지 않았는가?
- 스펙트럼 방법(구간 길이, 창, 겹침)과 그에 따른 주파수 해상도를 밝혔는가? 절대·상대 파워 중 무엇이고 로그 변환을 했는가?
- 대역 파워 차이를 보고할 때 비주기 성분을 분리했는가? 적합 범위, 무릎 여부, 봉우리 설정, 적합 품질을 보고했는가? 대역은 고정인가, 개인 알파 주파수 기준인가?
- 시간-주파수 분석의 웨이블릿 주기 수(주파수별), 기저선 구간과 정규화 방식(dB, %, z), 에포크 가장자리 여유를 밝혔는가?
- 유발, 유도, 전체 파워 가운데 무엇을 보고했는가? 고조파, 버스트, 근전도 같은 대안 설명을 검토했는가?

확인 문제

확인 문제

1. 배경 EEG의 표준편차가 $25 \mu\text{V}$ 다. (가) 64시행을 평균하면 잔여 잡음은 얼마인가? (나) 잔여 잡음을 $1.5 \mu\text{V}$ 로 낮추려면 몇 시행이 필요한가?
2. 폭 $\sigma_c = 25 \text{ ms}$ 인 성분이 있다. 반응 시간과 함께 잠복기가 표준편차 40 ms 로 흔들리면 평균 ERP의 정점은 참 정점의 몇 배가 되는가? 이 성분의 크기를 비교하는 데 어떤 측정이 더 나은가?
3. 환자군은 평균 35시행, 대조군은 평균 90시행이 남았다. 피크 진폭으로 P300을 비교했더니 차이가 없었다. 이 결과를 "환자의 P300은 정상이다"로 읽으면 무엇이 문제인가?
4. 휴지기 EEG 2분을 기록했다. 주파수 해상도 0.25 Hz 의 웰치 스펙트럼을 50 % 겹침으로 구하면 구간 길이와 구간 수는 얼마인가?
5. 30 Hz 에서 6주기 모를레 웨이블릿을 쓰면 σ_t 와 σ_f 는 얼마인가? σ_f 를 2 Hz 이하로 하려면 주기 수가 얼마 이상이어야 하고, 그때 σ_t 는 얼마인가?
6. 36시행에서 어떤 시간-주파수 점의 ITC가 0.25였다. 위상이 무작위일 때 기대되는 ITC와 레일리 근사 p 값은 얼마인가? 유의하다고 할 수 있는가?
7. 약물 투여 뒤 4-8 Hz 세타 대역 파워가 늘고 20-30 Hz 베타 대역 파워가 줄었다. 두 결과를 하나의 원인으로 설명할 수 있는 가능성은 무엇이며, 어떻게 확인하는가?

확인 문제 풀이

확인 문제 풀이

1. (가) $25/\sqrt{64} \approx 3.1 \mu\text{V}$. (나) $25/\sqrt{N} = 1.5$ 에서 $N = (25/1.5)^2 \approx 278$ 시행이다.
2. $25/\sqrt{25^2 + 40^2} \approx 0.53$ 배다. 정점이 반 가까이 깎이지만 넓이는 보존되므로, 흔들림 폭을 덮는 넓은 창
평균 진폭(또는 넓이)이 크기 비교에 더 낮다. 흔들림 자체를 줄이려면 반응 시점에 맞춘 에포크나 단일
시행 잠복기 추정을 쓴다.
3. 시행이 적은 환자군의 피크는 잡음 때문에 더 크게 위로 치우친다(그림 10.2 나). 실제로는 환자의 P300이
작아도 치우침이 그 차이를 가려 "차이 없음"이 나올 수 있다. 평균 진폭으로 다시 재고, 시행 수를 맞춘
무작위 표본으로 확인한다.
4. $\Delta f = 1/T$ 이므로 $T = 4 \text{ s}$ 다. 50 % 겹침이면 시작점이 2 s 간격이므로 $(120 - 4)/2 + 1 = 59$ 개다.
5. $\sigma_t = 6/(2\pi \times 30) \approx 32 \text{ ms}$, $\sigma_f = 30/6 = 5 \text{ Hz}$ 다. $30/n \leq 2$ 에서 $n \geq 15$ 이고, 그때 $\sigma_t = 15/(2\pi \times 30) \approx 80 \text{ ms}$ 다.
6. 기대 ITC는 $\sqrt{\pi/(4 \times 36)} \approx 0.15$ 다. $p \approx e^{-36 \times 0.25^2} = e^{-2.25} \approx 0.11$ 이므로 0.05 수준에서 유의하지 않다.
문턱은 $\sqrt{3.0/36} \approx 0.29$ 다. 게다가 시간-주파수 점이 많다면 다중비교 보정도 필요하다.
7. 비주기 배경이 가팔라지면(지수 증가) 저주파 대역은 모두 커지고 고주파 대역은 작아진다. 세타 증가와
베타 감소가 진동 변화 없이 하나의 기울기 변화로 설명될 수 있다. 스펙트럼을 비주기 성분과 봉우리로
나누어, 지수가 바뀌었는지와 세타·베타 봉우리가 실제로 배경 위에 있는지를 확인한다. 약물이
근긴장이나 각성을 바꾸었는지도 함께 본다.

다음 장으로

이 장에서는 채널 하나에서 사건에 묶인 파형과 리듬의 파워와 위상을 재는 법을 다뤘다. 그런데 연구
질문은 대개 "어느 영역이 어느 영역과 함께 움직이는가"로 넘어간다. 두 채널의 위상이 맞는다고 두 영역이
소통한다고 말할 수 있을까? 두피 센서는 같은 원천을 함께 보기 때문에 연결이 없어도 상관관계가 생긴다.
11장에서는 결맞음, 위상 고정값(PLV), 허수 결맞음과 wPLI, 포락선 상관, 그레인저 인과 같은 연결성
지표와 체적 전도의 함정, 그리고 센서 신호를 소스 공간으로 옮기는 파이프라인을 다룬다. 이 장의 ITC
치우침과 비정현 파형의 함정이 그곳에서 다시 나온다.

11장 EEG/MEG 연결성과 소스 수준 분석

이 장에서 배울 것 EEG/MEG에서 두 신호가 "함께 움직인다"를 재는 방법들(결맞음, 허수 결맞음, PLV, wPLI, 포락선 상관, 그레인저 인과, 위상-진폭 결합)이 각각 무엇을 가정하는지, 한 소스가 여러 센서와 영역에 퍼지는 체적 전도와 소스 누설이 어떤 가짜 결합을 만드는지, 그리고 센서 데이터에서 영역 시계열을 뽑아 연결성을 계산하는 소스 수준 파이프라인의 단계와 선택지를 다룬다. **뇌 연구자에게 왜 필요한가** "전두-두정 세타 결맞음이 늘었다", "알파 대역 연결성이 환자에서 낮다" 같은 결과는 측정 하나와 보정 하나만 바뀌도 생기거나 사라진다. 이 장의 모의실험은 결합이 전혀 없는 데이터에서 그럴듯한 연결성이 나오는 경로를 하나씩 보여 준다. 그 경로를 알아야 자기 분석을 설계하고 남의 방법 절을 판단할 수 있다.

☞ 중고등 복습: 위상, 복소수, 상관계수

사인파 $A \cos(2\pi ft + \phi)$ 에서 A 는 진폭, f 는 주파수, ϕ 는 **위상(phase)**이다. 위상은 "한 주기 중 어디쯤에 있는가"를 각도로 말한다. 주기의 4분의 1만큼 늦으면 위상이 90° 늦다. 그래서 주파수 f 에서 시간 지연 τ 는 위상차 $360^\circ \times f\tau$ 가 된다(물리 1권 4장). 복소수 $z = a + bi$ 는 평면 위의 화살표로 볼 수 있다. 길이 $|z|$ 가 진폭이고, 실수축에서 잰 각도가 위상이다. 물리 2권 7장에서 푸리에 변환이 주파수마다 이런 화살표 하나를 돌려준다는 것을 보았다. 실수부는 "같은 위상(0° 나 180°)" 성분, 허수부는 " 90° 어긋난" 성분이다. 상관계수 r 은 두 변수가 함께 오르내리는 정도를 -1 에서 1 사이로 나타낸다. 상관은 인과가 아니고, 둘을 함께 움직이는 제3의 원인이 있어도 크게 나온다. 이 장의 거의 모든 함정은 그 "제3의 원인"이 같은 소스의 퍼짐이라는 데서 온다.

11.1 센서 수준 연결성과 체적 전도

연결성은 무엇을 재는가

7장에서 fMRI의 **기능 연결성(functional connectivity)**을 두 영역 시계열의 통계적 의존성으로 정의했다. EEG/MEG도 같다. 다만 시간 해상도가 ms 단위이므로 질문이 더 세밀하다. 위상의 관계(11.2절), 진폭의 공동 요동(11.3절), 예측의 방향(11.4절), 주파수 사이의 결합(11.6절)을 따로 물을 수 있다.

분석은 9장의 전처리와 10장의 시간-주파수 분해를 마친 데이터에서 시작한다. 그 뒤의 순서는 대략 이렇다. 센서 수준에서 할지 소스 수준에서 할지 정한다. 주파수 대역과 측정을 고른다. 체적 전도나 누설을 처리한다. 대리 데이터나 순열로 통계 검정을 한다. 단계마다 가짜 결합이 들어올 틈이 있다.

하나의 소스, 여러 센서

물리 1권 6장에서 머리를 **체적 전도체(volume conductor)**로 보았다. 피질의 한 소스가 만든 전위는 두피 전도체로 퍼진다. 물리 2권 11장의 준정적 근사에 따라 이 퍼짐에는 시간 지연이 없다. 두 센서가 같은 소스를 서로 다른 비율로 받으면, 두 센서 신호는 정확히 같은 위상으로 함께 움직인다.

이 상황을 식으로 쓰면 간단하다. 소스 $s(t)$ 와 센서마다 독립인 잡음 n_1, n_2 가 있을 때

$$x_1 = a_1 s + n_1, \quad x_2 = a_2 s + n_2$$

다. a_1, a_2 는 리드필드의 값으로, 실수다. 두 센서 사이에는 아무 "소통"이 없지만 상관과 결맞음은 크게 나온다.

EEG에는 원인이 하나 더 있다. 모든 채널이 같은 기준 전극을 빼서 기록하므로, 기준 전극 자리의 활동이 모든 채널에 같은 위상으로 섞인다(물리 1권 6장). 평균 기준이나 표면 라플라시안으로 바꾸면 줄어들지만 없어지지 않는다(9장).

예제 11.1 혼합만으로 생기는 결맞음

한 소스($P_s = 1$)가 센서 1에 $a_1 = 1$, 센서 2에 $a_2 = 0.6$ 의 비율로 들어간다. 각 센서의 독립 잡음 파워는 그 주파수에서 $P_n = 0.5$ 다. (가) 결맞음 크기는 얼마인가? (나) 위상차는?

풀이 (가) 교차 스펙트럼은 $a_1 a_2 P_s = 0.6$, 두 센서의 파워는 $1 + 0.5 = 1.5$ 와 $0.36 + 0.5 = 0.86$ 이다. 결맞음은 $0.6 / \sqrt{1.5 \times 0.86} \approx 0.53$ 이다. (나) $a_1 a_2$ 가 양의 실수이므로 위상차는 0이다. a_2 가 음수(쌍극자의 반대쪽 극을 보는 센서)였다면 180° 였을 것이다. 어느 쪽이든 허수부는 0이다. 이 "허수부가 0"이라는 성질이 11.2절의 출발점이다.

🧠 뇌로 가는 다리: 축삭 지연이 만드는 위상차

실제 신경 상호작용은 축삭을 거치므로 시간이 걸린다. 공통 수치표의 전도 속도 0.5-120 m/s를 쓰면, 10 cm 떨어진 두 영역 사이를 10 m/s로 가는 신호는 10 ms 늦는다. 10 Hz 알파에서 이 지연은 $360^\circ \times 10 \times 0.01 = 36^\circ$ 의 위상차다. 40 Hz 감마라면 144° 다. 체적 전도의 위상차는 0° 또는 180° 뿐이고, 축삭을 통한 상호작용은 그 사이의 값을 가질 수 있다. 다만 주파수와 지연이 맞물려 위상차가 정확히 180° (예: 40 Hz에서 12.5 ms)가 되면 실제 상호작용도 체적 전도와 구별되지 않는다. 시상 같은 공통 입력이 두 영역을 함께 움직이면 지연 0의 진짜 동기화도 생길 수 있다. 지연 0 성분을 버리는 지표는 이런 진짜 결합도 함께 버린다.

11.2 위상 기반 측정

교차 스펙트럼과 결맞음

연결성 측정의 원재료는 시행(또는 짧은 구간) k 마다 구한 두 신호의 푸리에 계수 $X_k(f)$, $Y_k(f)$ 다(10장의 웰치 방법이나 웨이블릿). 둘의 곱 $X_k Y_k^*$ 를 **교차 스펙트럼(cross-spectrum)**이라 한다. 크기는 두 진폭의 곱이고, 각도는 그 시행의 위상차다. 시행에 걸쳐 평균하고 두 파워로 나누면 **결맞음 함수(coherency)**가 된다.

$$C_{xy}(f) = \frac{\langle XY^* \rangle}{\sqrt{\langle |X|^2 \rangle \langle |Y|^2 \rangle}}$$

$\langle \cdot \rangle$ 은 시행 평균이다. C_{xy} 는 복소수이고, 그 크기 $|C_{xy}|$ 가 흔히 말하는 **결맞음(coherence)**이다. 위상차가 시행마다 일정하면 화살표들이 한 방향으로 모여 결맞음이 1에 가깝고, 위상차가 제멋대로면 화살표가 서로 지워져 0에 가깝다.

허수 결맞음

예제 11.1처럼 지연 0의 혼합은 결맞음 함수의 실수부만 키운다. 그러면 허수부만 보면 된다. 이것이 **허수 결맞음(imaginary coherency, ImCoh)** 이다(Nolte 2004).

$$\text{ImCoh} = \text{Im } C_{xy} = |C_{xy}| \sin \Delta\phi$$

허수부는 독립 소스들이 지연 0으로 섞이는 것만으로는 생기지 않는다. 0이 아닌 허수부는 어딘가에 시간 지연이 있다는 증거다. 대가도 있다. 위상차가 0°나 180°에 가까운 진짜 상호작용은 놓친다. 크기가 $\sin \Delta\phi$ 에 비례하므로 같은 결합도 위상차에 따라 크게 또는 작게 보인다. 분모는 전체 파워이므로, 지연 결합이 그대로여도 섞인 공통 소스가 커지면 ImCoh가 작아진다.

PLV와 시행 수

진폭을 버리고 위상만 쓰면 **위상 고정 값(phase-locking value, PLV)** 이 된다. 시행마다 위상차 $\Delta\phi_k$ 를 구하고 단위 화살표 $e^{i\Delta\phi_k}$ 를 평균한 길이다.

$$\text{PLV} = \left| \frac{1}{N} \sum_{k=1}^N e^{i\Delta\phi_k} \right|$$

PLV는 0과 1 사이이고, 체적 전도에는 결맞음만큼 약하다. 덜 알려진 약점은 **시행 수에 따른 편향**이다. 위상차가 완전히 무작위여도 화살표 N 개의 평균은 정확히 0이 되지 않는다. 기댓값은 대략 $\sqrt{\pi/(4N)}$ 다. **그림 11.1**의 모의실험에서 결합이 없을 때 평균 PLV는 $N = 10$ 에서 0.28, $N = 30$ 에서 0.16, $N = 100$ 에서 0.09였다. $N = 10$ 에서는 95 %가 0.54 아래였다. 곧 0.5짜리 PLV도 시행 10개로는 우연과 구별하기 어렵다.




그림 11.1 PLV의 시행 수 편향(합성 위상, 반복 2만 번). (가) 위상차가 무작위일 때 PLV의 분포. 시행이 적을수록 분포가 오른쪽으로 밀린다. (나) 실제 PLV가 0.2인 경우(파랑)와 0인 경우(빨강)의 평균 추정값. PLV는 시행이 적을수록 커 보이지만, 쌍 위상 일관성(PPC)의 제공근은 시행 수와 무관하게 실제 값(점선) 근처에 있다.

이 편향은 조건 사이의 비교를 망친다. 오답 시행 20개와 정답 시행 200개의 PLV를 비교하면, 결합이 같아도 오답 쪽이 커 보인다. 해결책은 둘이다. 조건마다 시행 수를 무작위로 맞춰 뽑거나, 편향이 없는 **쌍 위상 일관성(pairwise phase consistency, PPC)** 을 쓴다(Vinck 2010). PPC는 모든 시행 쌍의 위상차 코사인의 평균이며, $PPC = (N \text{PLV}^2 - 1)/(N - 1)$ 으로 PLV에서 바로 계산된다. 기댓값이 실제 PLV의 제곱이고 시행 수에 의존하지 않는다.

PLI와 wPLI

PLV도 지연 0 혼합에 둔감하지 않다. **위상 지연 지수(phase lag index, PLI)** 는 허수 결맞음의 생각을 위상에 적용한다(Stam 2007). 위상차가 0°와 180° 사이(한쪽이 앞섬)인 시행과 180°와 360° 사이인 시행이 얼마나 치우쳤는지만 본다. **가중 PLI(weighted PLI, wPLI)** 는 시행마다 교차 스펙트럼 허수부의 크기로 가중해, 0° 근처에서 잡음 때문에 부호가 흔들리는 시행의 영향을 줄인다(Vinck 2011).

$$PLI = |\langle \text{sign}(\text{Im } S_k) \rangle|, \quad wPLI = \frac{|\langle \text{Im } S_k \rangle|}{\langle |\text{Im } S_k| \rangle}$$

$S_k = X_k Y_k^*$ 는 시행 k 의 교차 스펙트럼이다. **그림 11.2** 은 네 가지 상황을 비교한다. 혼합만 있을 때 결맞음은 0.58이지만 ImCoh는 0.01, wPLI는 0.04다. 한 소스가 15 ms 늦게 다른 자리를 움직이는 지연 결합에서는 ImCoh 0.50, wPLI 0.83이다. 같은 지연 결합에 큰 공통 소스를 섞으면 결맞음은 0.69로 오히려 커진다. 그러나 이 값은 결합이 아니라 혼합을 반영한다. ImCoh는 0.30으로 줄고, wPLI는 0.65로 비교적 잘 버틴다.




그림 11.2 체적 전도의 모의실험(알파 대역 소스, 시행 200개, 10 Hz). (가) 혼합만 있으면 시행별 위상차가 0° 근처에 모이고, 15 ms 지연 결합이면 54° 근처에 모인다. (나) 결맞음 크기(|Coh|)는 혼합과 결합을 구별하지 못한다. 허수 결맞음과 wPLI는 지연 0 혼합을 무시하며, 큰 공통 소스가 섞였을 때 wPLI가 덜 줄어든다.

이 측정들은 numpy 몇 줄로 계산된다. 이미 대역 필터를 거친 에포크 배열을 FFT한다고 하자.

```
import numpy as np

def phase_measures(x, y, fs, f0):
    """x, y: (시행, 표본) 배열. 주파수 f0에서 |Coh|, ImCoh, PLV, wPLI를 돌려준다."""
    n = x.shape[1]
    win = np.hanning(n)
    k = int(round(f0 * n / fs))
    X = np.fft.rfft(x * win, axis=1)[:n // 2, k]
    Y = np.fft.rfft(y * win, axis=1)[:n // 2, k]
    S = X * np.conj(Y) # 시행별 교차 스펙트럼
    coh = S.mean() / np.sqrt(np.mean(abs(X)**2) * np.mean(abs(Y)**2))
    plv = abs(np.mean(S / abs(S)))
    wpli = abs(S.imag.mean()) / np.mean(abs(S.imag))
    return abs(coh), coh.imag, plv, wpli
```

wPLI에도 표본 편향이 있다. 그림의 "결합 없음"에서 시행 200개의 wPLI는 0.10이었다. 편향을 줄인 변형(MNE-Python의 `wpli2_debiased`)이 있고, 어떤 변형을 썼는지 방법 절에 적어야 한다. MNE-Python의 `mne-connectivity`, `FieldTrip`, `Brainstorm`이 위 측정들을 모두 제공한다.

예제 11.2 위상차를 시간으로, 시간을 위상차로

(가) 10 Hz에서 ImCoh의 위상차가 0.5 rad이다. 시간 지연은 몇 ms인가? (나) 결합이 크기가 0.4일 때 ImCoh는? (다) 40 Hz에서 두 영역이 12.5 ms의 지연으로 결합해 있다면 ImCoh는 얼마인가?

풀이 (가) $\tau = \Delta\phi / (2\pi f) = 0.5 / (2\pi \times 10) \approx 8.0$ ms다. (나) $0.4 \times \sin 0.5 \approx 0.19$ 다. (다) 위상차는 $360^\circ \times 40 \times 0.0125 = 180^\circ$ 이므로 $\sin 180^\circ = 0$, ImCoh는 0이다. 결합이 강해도 지표는 아무것도 보지 못한다. 위상차에서 시간 지연을 읽을 때는 주의가 필요하다. 위상은 360° 마다 되풀이되므로 54° 의 위상차는 15 ms일 수도, 115 ms일 수도 있다. 여러 주파수에 걸친 위상 기울기를 보면 이 모호함이 줄어든다.

예제 11.3 시행 20개의 PLV 0.25

한 참가자의 오답 시행 20개에서 PLV가 0.25였다. (가) 결합이 없을 때의 기댓값은? (나) 레일리 검정의 근사 $p \approx e^{-N \text{PLV}^2}$ 로 유의성을 판단하라. (다) 같은 PLV가 시행 200개에서 나왔다면? (라) 시행 20개의 PPC는?

풀이 (가) $\sqrt{\pi / (4 \times 20)} \approx 0.20$ 이다. (나) $N \text{PLV}^2 = 20 \times 0.0625 = 1.25$, $p \approx e^{-1.25} \approx 0.29$ 다. 우연과 구별되지 않는다. (다) $200 \times 0.0625 = 12.5$, $p \approx e^{-12.5} \approx 4 \times 10^{-6}$ 이다. (라) $(1.25 - 1) / 19 \approx 0.013$ 이고, 제공근은 약 0.11이다. 편향을 걸어 내면 0.25가 아니라 0.1 근처다.

흔한 오해: 허수 결합음이나 wPLI가 크면 두 영역이 직접 소통한다

지연 0 성분을 버리는 지표는 "한 소스가 두 센서에 퍼졌다"는 가장 단순한 가짜만 막는다. 서로 다른 시각에 활동하는 여러 소스가 섞이면 혼합 신호의 위상차가 0이 아니게 되어, 실제 상호작용 없이도 허수부가 생길 수 있다. 두 영역을 함께 움직이는 제3의 영역(공통 입력)이 시간차를 두고 입력을 주어도 그렇다. 또 진짜 결합 하나는 체적 전도를 타고 그 주변 센서 쌍 여러 개에서 함께 보인다. 지표가 크다는 것은 "어딘가에 지연된 상호작용이 있다"는 뜻이지, 그 두 자리가 직접 소통한다는 뜻이 아니다. 파워 차이도 함정이다. 위상은 신호 대 잡음비가 높을 때 더 정확히 추정된다. 한 조건에서 알파 파워가 크면, 결합이 같아도 그 조건의 PLV와 wPLI가 높게 나온다. 연결성 차이를 보고할 때는 파워 차이를 함께 보고하고, 파워를 맞춘 하위 표본이나 공변량으로 확인해야 한다.

11.3 진폭 기반 측정

포락선 상관

위상 대신 **진폭 포락선(amplitude envelope)** 을 볼 수 있다. 10장의 웨이블릿이나, 대역 필터를 거친 신호의 해석 신호를 만드는 **힐베르트 변환(Hilbert transform)** 으로 순간 진폭을 구한 뒤, 두 영역의 포락선 사이 상관을 계산한다. 이것이 **진폭 포락선 상관(amplitude envelope correlation, AEC)** 이다. 포락선은 수 초에서 수십 초에 걸쳐 느리게 오르내리므로, 보통 0.5 Hz 안팎 이하로 거르거나 다운샘플링한 뒤 상관을 구한다.

AEC는 위상 결합이 없어도 "두 영역이 같은 때 함께 활발해지는" 관계를 잡는다. 위상은 수십 ms 단위로 맞물리지만 포락선은 각성, 주의, 휴지기 네트워크의 느린 요동을 따른다. 그래서 fMRI의 휴지기 연결성(7장)과 비교하기 좋다.

직교화

AEC도 누설에 약하다. 두 신호가 서로를 λ 만큼 섞어 받으면($y_1 = s_1 + \lambda s_2$, $y_2 = s_2 + \lambda s_1$), 각 포락선이 상대 소스의 진폭 변화를 따라간다. [그림 11.3](#) 에서 결합이 전혀 없는 두 베타 소스의 AEC는 $\lambda = 0.4$ 에서 0.45, $\lambda = 0.6$ 에서 0.76까지 오른다.

해결책은 상관을 구하기 전에 자연 0 성분을 지우는 **직교화(orthogonalization)** 다. 짝별 직교화(Hipp 2012)는 복소 해석 신호 z_1, z_2 에서 시점마다 z_2 중 z_1 과 같은 위상인 성분을 버린다.

$$z_{2\perp 1}(t) = \text{Im} \left(z_2(t) \frac{z_1^*(t)}{|z_1(t)|} \right)$$

그리고 $|z_1|$ 과 $|z_{2\perp 1}|$ 의 포락선 상관을 구한다. 방향을 바꿔 한 번 더 계산해 평균한다. 시간 영역에서 한 시계열을 다른 시계열에 회귀해 잔차를 쓰는 방식(Brookes 2012)도 같은 생각이다.




그림 11.3 포락선 상관과 직교화(베타 대역 두 소스, 300 s). (가) 포락선이 서로 독립인 두 소스라도 $\lambda = 0.6$ 만큼 섞이면 두 자리의 느린 포락선(굵은 선)이 비슷하게 움직인다. (나) 원래 AEC(실선)은 누설과 함께 커진다. 짝별 직교화(파선)는 가짜를 줄이지만 누설이 크면 일부 남는다. 대칭 직교화(점선)는 이 장난감 문제에서 실제 값을 되찾는다.

그림의 (나)는 짝별 직교화가 만능이 아님을 보여 준다. 결합이 없을 때 $\lambda = 0.4$ 에서 0.45였던 가짜 AEC가 0.24로 줄었지만, 0이 되지는 않았다. 두 소스의 진폭이 크게 요동하면, 직교화한 신호의 크기가 여전히 상대 소스의 진폭에 조금 의존하기 때문이다. 결합이 있는 경우에도 원래 0.44인 값이 0.65로 부풀었다.

대칭 직교화(symmetric orthogonalization) 는 모든 영역 시계열을 한꺼번에 다룬다(Colclough 2015). 원래 시계열과 가장 가까우면서 서로 직교인 시계열 묶음을 찾는다. 특잇값 분해 $Y = U\Sigma V^T$ 에서 UV^T 를 쓰면 된다. 그림의 장난감 문제는 소스 둘, 신호 둘이고 혼합이 대칭이어서, 대칭 직교화가 원래 소스를 정확히 되찾는다(결합 없음 -0.07, 결합 있음 0.44로 $\lambda = 0$ 일 때와 같다). 실제 데이터에서는 소스가 영역보다 훨씬 많아 이렇게 깨끗하지 않다. 또 영역 수는 데이터의 계수(rank)보다 작아야 한다. MEG에서 SSS를 거친 데이터의 계수는 수십에 그치므로(9장) 영역을 수십 개 이하로 묶는 이유가 된다.

모든 직교화는 지연 0의 진짜 결합도 지운다. 이 점은 허수 결합율과 같다. 또 결합이 있는 두 영역의 이웃들까지 결합된 것처럼 보이는 문제는 직교화 뒤에도 남는다.

🧠 뇌로 가는 다리: MEG 휴지기 네트워크와 fMRI 네트워크의 대응

MEG 휴지기 데이터를 빔형성기로 소스 공간에 옮기고, 알파와 베타 대역(대략 8-30 Hz) 포락선을 직교화한 뒤 상관을 구하면, fMRI 휴지기 네트워크와 닮은 지도가 나온다(Brookes 등 2011, Hipp 등 2012). 감각운동 네트워크는 베타 대역에서, 후두-두정 네트워크는 알파 대역에서 두드러진다. 디폴트 모드 네트워크나 배측 주의 네트워크와 닮은 구조도 보고되었다. 대응의 열쇠는 시간 척도다. 생리 1권 6장에서 본 것처럼, BOLD 요동(0.01-0.1 Hz)은 진동 그 자체가 아니라 대역 파워 포락선의 느린 변화와 맞는다. 그래서 위상 기반 지표보다 포락선 상관이 fMRI와 더 비슷한 지도를 그린다. 반면 차이도 있다. MEG 연결성은 주파수마다 다른 지도를 주고, 깊은 구조(해마, 시상)의 연결은 소스 해상도 때문에 믿기 어렵다. 같은 사람을 두 번 재었을 때의 신뢰도도 측정마다 다르다. 직교화한 AEC는 비교적 재현성이 좋고, 위상 기반 측정은 대체로 낮다는 보고가 있다. 두 모달리티를 비교하는 논문을 읽을 때는 대역, 직교화 여부, 아틀라스, 개인 신뢰도를 함께 확인한다.

11.4 방향성: 그레인저 인과

과거가 미래를 예측하는가

결맞음과 AEC에는 방향이 없다. **그레인저 인과(Granger causality, GC)**는 "X의 과거를 알면 Y의 미래를 더 잘 예측하는가"를 묻는다. 먼저 Y의 과거 p 개만으로 Y를 예측하는 자기회귀(AR) 모델을 맞춘다. 다음에 X의 과거 p 개를 더한 모델을 맞춘다. 예측 오차(잔차)의 분산이 얼마나 줄었는지를 로그 비로 나타낸다.

$$F_{X \rightarrow Y} = \ln \frac{\text{var}(\varepsilon_{Y\text{만}})}{\text{var}(\varepsilon_{Y\text{와 } X})}$$

$F = 0$ 이면 X의 과거가 쓸모없다는 뜻이다. 여러 영역을 함께 넣은 **다변량 자기회귀(MVAR)** 모형에서 다른 영역들의 과거를 조건으로 넣으면, 제3의 영역을 거친 간접 경로를 일부 걸러 낼 수 있다(조건부 GC).

주파수 영역으로 옮기면 "어느 대역에서 영향이 가는가"를 볼 수 있다. MVAR 계수를 푸리에 변환해 **스펙트럼 그레인저 인과**를 구한다. **부분 방향 결맞음(partial directed coherence, PDC)**과 **방향 전달 함수(directed transfer function, DTF)**는 같은 MVAR 모형에서 나오는 정규화된 지표다. PDC는 직접 경로를, DTF는 간접 경로까지 포함한 전체 흐름을 강조한다는 차이가 있다. 도구로는 MVGC 툴박스, FieldTrip, EEGLAB의 SIFT 확장이 있다. 방법론 개관은 Bastos & Schoffelen 2016이 좋다.

그림 11.4 (나)는 약 32 Hz에서 진동하는 두 AR 과정에서 X가 10 ms 늦게 Y를 미치는 경우다. $F_{X \rightarrow Y}$ 는 결합 세기 c 와 함께 커져 $c = 0.5$ 에서 0.42가 되고, $F_{Y \rightarrow X}$ 는 귀무 문턱(0.0009) 근처에 머문다. 데이터가 모형의 가정에 맞으면 GC는 방향을 정확히 찾는다.

가정과 함정

GC는 신호가 선형 AR 과정이고 **정상적(stationary)**이며, 관련된 변수가 모두 측정되었다고 가정한다. EEG/MEG에서는 이 가정들이 자주 깨진다.

- **모형 차수**: p 가 너무 작으면 지연을 못 잡고, 너무 크면 추정이 불안정하다. AIC나 BIC로 고르고 보고한다.
- **비정상성**: 자극 직후의 ERP처럼 평균이 급히 바뀌면 GC가 왜곡된다. 유발 반응을 빼거나 짧은 창을 쓴다.
- **필터**: 좁은 대역 필터는 신호의 예측 가능성을 인위적으로 바꾼다. GC는 넓은 대역 데이터에서 맞추고 결과를 주파수로 나누어 보는 것이 원칙이다.
- **혼합과 잡음**: 가장 심각하다. **그림 11.4** (다)에서 결합이 전혀 없는 두 소스를 센서에 섞고, 센서 1에 작은 잡음, 센서 2에 큰 잡음을 더했다. 혼합 비율 0.5에서 센서 1 → 2 방향의 GC가 0.155로, 문턱의 100배를 넘는다. 깨끗한 센서가 섞인 소스의 "과거"를 더 잘 담고 있어서, 잡음 많은 센서를 예측하는 데 도움이 되기 때문이다.




그림 11.4 그래인저 인과의 모의실험(표본화 200 Hz, 60 s, 모형 차수 5). (가) X가 10 ms 늦게 Y를 미치는 AR 과정. (나) 결합 세기에 따라 $X \rightarrow Y$ 만 커지고 $Y \rightarrow X$ 는 귀무 문턱(점선) 근처에 남는다. (다) 결합이 없는 두 소스를 섞고 센서마다 다른 잡음을 더하면, 신호 대 잡음비가 높은 센서에서 낮은 센서 쪽으로 가짜 방향이 생긴다.

이 함정을 점검하는 방법이 몇 가지 있다. 소스 수준에서 계산해 혼합을 줄인다. 데이터를 시간 순서로 뒤집어 다시 계산한다. 진짜 시간 지연 때문이라면 뒤집은 데이터에서 방향이 바뀌어야 하고, 혼합과 잡음 때문이라면 그대로 남는 경향이 있다. 두 영역의 신호 대 잡음비 차이를 보고한다. fMRI에서는 영역마다 HRF 지연이 다르다는 점이 GC를 더 어렵게 만든다(7장).

예제 11.4 통계적으로 유의한 것과 타당한 것

60 s, 200 Hz(표본 12 000개) 데이터에서 차수 5의 모형을 맞췄다. X의 과거를 넣자 Y의 잔차 분산이 1.00에서 0.85로 줄었다. (가) $F_{X \rightarrow Y}$ 는? (나) 귀무가설 아래에서 NF는 대략 자유도 p 의 카이제곱 분포를 따른다. 유의한가?

풀이 (가) $\ln(1.00/0.85) \approx 0.16$ 이다. (나) $12\,000 \times 0.16 \approx 1950$ 이고, 자유도 5 카이제곱의 95 % 점은 약 11.1이다. 비교할 수 없을 만큼 유의하다. 표본이 수만 개인 EEG/MEG에서는 아주 작은 GC도 유의하게 나온다. 질문은 "0과 다른가"가 아니라 "혼합, 잡음 차이, 비정상성으로 설명되지 않는가"다. 시간 뒤집기, 대리 데이터, 조건 간 비교처럼 이 대안들을 겨냥한 검정이 필요하다.

흔한 오해: 그래인저 인과는 X가 Y를 일으킨다는 뜻이다

그래인저 인과는 예측의 개선이다. 측정하지 않은 제3의 영역이 X를 먼저, Y를 나중에 움직이면 $X \rightarrow Y$ 가 나온다. 신호 대 잡음비의 차이만으로도 방향이 생긴다(그림 11.4 다). 반대로 진짜 영향이 비선형이거나 측정 표본 간격보다 빠르면 놓친다. "그래인저 의미에서 X가 Y를 예측한다"고 쓰고, 해부학적 경로, 자극이나 병변 실험, 동물 연구 같은 다른 근거와 함께 해석해야 한다.

🧠 뇌로 가는 다리: 주파수별 방향과 피질 위계

원숭이의 시각 피질 여러 영역에 전극을 넣은 연구들은 스펙트럼 그레이더 인과로 흥미로운 규칙을 보고했다. 위계의 아래에서 위로 가는 앞먹임 방향(예: V1 → V4)은 감마 대역(대략 40-90 Hz)에서 강하고, 위에서 아래로 가는 되먹임 방향은 알파와 베타 대역(대략 10-20 Hz)에서 강하다. 해부학으로 정한 위계와 이 주파수 비대칭이 잘 맞았다. 사람 MEG에서도 비슷한 결과가 보고되지만, 두피 측정에서는 혼합과 잡음 함정이 훨씬 크고 감마는 근전도에도 오염된다(생리 1권 6장). 이런 논문을 읽을 때는 소스 수준 분석인지, 시간 뒤집기 같은 점점이 있는지, 두 영역의 신호 대 잡음비가 비슷한지를 본다.

11.5 소스 수준 파이프라인

왜 소스로 가는가

센서 수준 연결성은 해석이 어렵다. 센서 하나는 여러 영역의 합이고, 이웃 센서는 거의 같은 것을 본다. 소스 수준으로 옮기면 "어느 영역과 어느 영역"이라는 해부학적 질문을 할 수 있고, 혼합도 줄어든다. 다만 물리 2권 11장에서 본 것처럼 역문제는 답이 하나가 아니고, 소스 추정에는 해상도 행렬로 흐린 그림이다. 혼합은 줄어들 뿐 사라지지 않는다. [그림 11.5](#)은 단계를 정리한 것이다.




그림 11.5 소스 수준 연결성 분석의 단계. 위 줄은 순문제를 준비한다. 머리와 센서를 정합하고, 머리 모형과 소스 공간을 만들고, 리드필드를 계산한다. 아래 줄은 역해로 소스를 추정하고, 영역 시계열을 뽑고, 누설을 보정한 뒤 연결성을 계산한다. 회색 글자는 단계마다 흔히 쓰는 선택이다.

정합

- **왜:** 리드필드는 센서와 뇌의 상대 위치로 정해진다. 이 위치를 알려면 센서 좌표계를 개인 MRI 좌표계로 옮겨야 한다(1장의 좌표 변환).
- **가정:** 기준점(코뿌리, 양쪽 귀앞점)과 디지털라이저로 찍은 머리 표면 점이 MRI의 두피와 강체 변환으로 맞는다.
- **도구:** MNE-Python의 정합 도구, FieldTrip, Brainstorm. MEG에서는 머리 위치 표시 코일로 기록 중 머리 위치를 계속 켜다(9장).

- **흔한 실수:** 기준점을 잘못 찍거나, 개인 MRI 없이 표준 머리를 쓰고 그 사실을 적지 않는다. 정합 오차 5 mm 안팎이 흔하고, 이 오차는 깊이와 방향 추정을 바꾼다. EEG에서 전극 위치를 디지털라이저로 재지 않고 표준 배치를 쓰면 오차가 더 크다.

머리 모형, 소스 공간, 리드필드

- **왜:** 각 소스 자리의 단위 쌍극자가 각 센서에 만드는 신호(리드필드 L)를 계산해야 역해를 구할 수 있다.
- **가정:** 머리를 몇 개의 균일한 전도체 층으로 근사한다. EEG는 두피·두개골·뇌의 3층 경계 요소 모형(BEM)이 표준이고, 두개골 전도율 값(공통 수치표의 0.01-0.02 S/m)에 민감하다. MEG는 두개골의 영향이 작아 뇌 내부 한 층으로도 충분하다(물리 2권 11장). 소스 공간은 FreeSurfer로 만든 피질 표면 위의 수천 개 점이 흔하다. 쌍극자 방향을 피질 면에 수직으로 고정할지, 자유롭게 돌지도 정한다. 빔형성기는 3차원 격자를 쓰기도 한다.
- **흔한 실수:** EEG에 구 모형을 쓰거나 두개골 전도율을 적지 않는다. 피질 표면 재구성의 오류(3장)를 확인하지 않는다.

역해

- **왜:** 센서 데이터 $\mathbf{y}$ 에서 소스 활동을 추정한다. 선형 역해는 모두 $\hat{\mathbf{j}} = \mathbf{K}\mathbf{y}$ 꼴이다.
- **가정:** 최소 노름 계열(MNE, dSPM, sLORETA, eLORETA)은 소스가 넓게 퍼진 작은 전류라는 사전 가정과 정칙화 값을 쓴다. LCMV 빔형성기와 그 주파수 영역 판인 DICS는 자리마다 공간 필터를 만들고, 서로 다른 소스의 시간 경과가 상관되지 않는다고 가정한다.
- **도구와 기본 설정:** 잡음 공분산은 빈 방 기록(MEG)이나 자극 전 기저선으로 추정한다. 정칙화는 MNE 계열에서 신호 대 잡음비 3 정도의 기본값이 흔하고, 빔형성기에서는 공분산 대각선에 몇 %를 더한다.
- **흔한 실수:** 빔형성기의 가정이 연결성 질문과 충돌한다는 것을 잊는다. 강하게 상관된 두 소스(예: 양쪽 청각 피질)를 빔형성기는 서로 지운다. 연결성을 보려는 바로 그 상관이 추정을 약하게 만드는 셈이다. 조건마다 다른 공분산으로 필터를 만들면 필터 차이가 연결성 차이처럼 보이므로, 조건을 합친 공분산으로 공통 필터를 만든다.

영역 시계열 추출

수천 개 소스점의 연결성은 계산도 해석도 어렵다. 그래서 아틀라스(1장의 Desikan-Killiany 68영역 등)로 영역을 정하고 영역마다 시계열 하나를 만든다. 피질이 접혀 있어 한 영역 안에서도 쌍극자 방향이 고랑 양쪽으로 반대일 수 있다. 그대로 평균하면 서로 지워진다. 그래서 주된 방향에 맞춰 부호를 뒤집고 평균하거나(MNE-Python의 `mean_flip`), 영역 안 시계열의 첫 주성분을 쓴다. 대표 시계열 방법을 바꾸면 결과가 바뀌므로 반드시 적어야 한다.

누설과 그 보정

역해의 점 퍼짐 함수(물리 2권 11장)는 한 소스를 수 cm까지 번지게 한다. [그림 11.6](#) (가)의 장난감 모형에서 점 소스의 반치폭은 약 2 cm다. 폭 1 cm ROI 여럿을 나란히 놓으면 한 소스가 이웃 ROI 두세 개에 함께 나타난다. 이것이 **소스 누설(source leakage)** 이다.

(나)는 ROI마다 서로 독립인 베타 소스를 두고, 4 cm 떨어진 한 쌍만 포락선을 실제로 결합시킨 결과다. 원래 ROI 시계열에서 1 cm 이웃의 포락선 상관은 0.73이다. 실제 소스의 값은 0.07이다. 반대로 진짜 결합한 4 cm 쌍은 실제 0.64가 0.40으로 줄었다. 각 ROI에 이웃의 독립 소스가 섞여 들어 희석되었기 때문이다. 대칭 직교화 뒤에는 1 cm 이웃이 0.12, 4 cm 쌍이 0.58로 실제 값에 가까워진다.




그림 11.6 소스 누설의 장난감 모형(깊이 2.5 cm의 1차원 피질, 센서 33개, 최소 노름 역해). (가) 0 cm와 3 cm 점 소스의 추정 지도. 음영은 폭 1 cm의 ROI다. 한 소스가 이웃 ROI까지 번진다. (나) 0 cm ROI와 다른 ROI 사이의 포락선 상관. 원래 ROI 시계열(빨강)은 1 cm 이웃에서 가짜 결합이 크고, 4 cm의 진짜 결합은 줄어든다. 대칭 직교화(파랑) 뒤에는 실제 소스의 값(회색)에 가까워진다.

예제 11.5 누설 0.5가 만드는 상관

서로 독립이고 분산이 같은 두 소스 A, B가 있다. 역해 뒤 ROI 시계열이 $\hat{a} = A + 0.5B$, $\hat{b} = B + 0.5A$ 가 되었다. (가) 두 ROI 시계열의 지연 0 상관은? (나) 이 상관의 허수 결맞음은?

풀이 (가) 공분산은 $0.5 \text{var}(A) + 0.5 \text{var}(B) = 1$ (분산을 1로 두면), 각 분산은 $1 + 0.25 = 1.25$ 다. 상관은 $1/1.25 = 0.8$ 이다. **그림 11.6** 에서 1 cm 이웃의 지연 0 상관이 0.78이었던 것과 같은 크기다. (나) 혼합 계수가 실수이므로 교차 스펙트럼에 허수부가 생기지 않는다. 허수 결맞음은 기댓값 0이다. 누설은 크지만 지연 0이라는 표식을 남긴다.

통계와 다중 비교

Desikan-Killiany 68영역이면 영역 쌍이 $68 \times 67/2 = 2278$ 개다. 주파수 대역 다섯 개와 조건 둘을 곱하면 검정이 2만 개를 넘는다. 6장의 다중 비교 문제가 그대로 온다. 네트워크 기반 통계(NBS)처럼 연결된 엣지 묶음에 순열 검정을 하는 방법이나, 사전에 정한 소수의 영역 쌍만 검정하는 방법을 쓴다. 귀무 분포는 시행 순서나 조건 이름을 섞는 순열, 또는 위상을 무작위로 바꾼 대리 데이터로 만든다.

11.6 교차 주파수 결합

위상-진폭 결합

지금까지는 같은 주파수의 두 신호를 비교했다. **교차 주파수 결합(cross-frequency coupling)** 은 한 신호 안에서 서로 다른 주파수가 맺는 관계다. 가장 많이 연구된 것이 **위상-진폭 결합(phase-amplitude coupling, PAC)** 이다. 느린 진동의 특정 위상에서 빠른 진동의 진폭이 커지는 현상이다. 생리 1권 6장에서 본 해마의 세타-감마 결합이 대표적이다.

계산은 세 단계다. 원신호를 느린 대역(예: 5-7 Hz)으로 걸러 위상 $\phi(t)$ 를 구한다. 빠른 대역(예: 50-70 Hz)으로 걸러 진폭 $A(t)$ 를 구한다. 위상을 18개 구간으로 나누고 구간마다 진폭의 평균을 구해 분포 $P(j)$ 로 정규화한다. 결합이 없으면 P 는 평평하다. **변조 지수(modulation index, MI)** 는 이 분포가 평평한 분포에서 얼마나 벗어났는지를 엔트로피로 잰다(Tort 2010).

$$MI = \frac{\ln N + \sum_j P(j) \ln P(j)}{\ln N}$$

N 은 위상 구간의 수다. 평평하면 0, 한 구간에 몰리면 1이다.

```
import numpy as np
from scipy.signal import butter, sosfiltfilt, hilbert

def bandpass(x, fs, lo, hi, order):
    sos = butter(order, [lo, hi], btype="band", fs=fs, output="sos")
    return sosfiltfilt(sos, x)

def tort_mi(x, fs, f_phase=(5, 7), f_amp=(50, 70), nbins=18):
    phase = np.angle(hilbert(bandpass(x, fs, *f_phase, 2)))
    amp = np.abs(hilbert(bandpass(x, fs, *f_amp, 3)))
    edges = np.linspace(-np.pi, np.pi, nbins + 1)
    idx = np.clip(np.digitize(phase, edges) - 1, 0, nbins - 1)
    mean_amp = np.bincount(idx, amp, nbins) / np.bincount(idx, minlength=nbins)
    P = mean_amp / mean_amp.sum() # 위상 구간별 진폭 분포
    return (np.log(nbins) + np.sum(P * np.log(P))) / np.log(nbins)
```

그림 11.7 는 세타 마루에서 감마 진폭이 커지는 합성 신호다. 결합한 신호의 MI는 1.1×10^{-2} , 결합이 없는 신호는 5×10^{-5} 이다. 위상 주파수와 진폭 주파수를 바꿔 가며 MI를 지도로 그린 **공동변조도(comodulogram)** 에서 봉우리가 정확히 6 Hz와 60 Hz에 선다.




그림 11.7 위상-진폭 결합의 모의실험(500 Hz, 120 s, 1/f 배경 잡음). (가) 원신호, 세타 성분, 감마 성분과 그 포락선. 감마 포락선은 세타 마루에서 커진다. (나) 세타 위상 구간별 감마 진폭 분포. 결합한 신호(파랑)는 0° 근처에 봉우리가 있고, 결합 없는 신호(빨강)는 평평하다. (다) 공동변조도. 6 Hz 위상과 60 Hz 진폭에만 봉우리가 있다.

MI의 절댓값은 신호 길이, 필터, 잡음에 따라 달라서 그 자체로는 해석하기 어렵다. 그래서 대리 데이터로 귀무 분포를 만든다. 진폭 시계열을 무작위 시간만큼 돌려 위상과의 관계를 깨뜨린 뒤 MI를 수백 번 다시 계산한다. 그림의 결합 신호에서 이런 대리 데이터의 95 % 점은 2.2×10^{-4} 로, 실제 MI보다 50배쯤 작다. 진폭 대역의 폭도 중요하다. 6 Hz로 조절된 60 Hz 진폭은 54 Hz와 66 Hz에 옆띠를 만든다. 진폭 필터의 폭이 위상 주파수의 두 배(여기서 12 Hz)보다 좁으면 결합을 놓친다. 도구로는 *tensorpac*, *pactools*, *FieldTrip*, *Brainstorm*이 PAC를 계산한다.

예제 11.6 MI의 크기 감각

18개 위상 구간의 평균 진폭이 $1 + m \cos \theta_j$ 꼴이다. (가) $m = 0.1$ 일 때 가장 큰 구간과 가장 작은 구간의 비, MI는? (나) $m = 0.5$ 이면?

풀이 구간 중심을 넣어 계산하면, (가) 비는 약 1.22, MI는 약 8.7×10^{-4} 이다. (나) 비는 약 2.9, MI는 약 0.022다. 진폭이 위상에 따라 20 % 넘게 달라져도 MI는 0.001이 안 된다. MI가 작은 숫자로 보고되는 이유이고, "MI = 0.003"이 약한 결합이라는 뜻은 아니다. 대리 분포에 비춘 z값이나 백분위수로 보고하는 것이 비교하기 쉽다.

가짜 PAC: 날카로운 파형

PAC의 가장 큰 함정은 **비정현 파형(non-sinusoidal waveform)** 이다(10장). 푸리에 분해는 모든 신호를 사인파의 합으로 쓴다. 톱니처럼 날카로운 모서리를 가진 8 Hz 리듬은 8 Hz 하나가 아니라 16, 24, 32 Hz... 의 고조파를 함께 가진다. 이 고조파는 감마 대역까지 이어진다. 감마 대역 필터는 모서리가 올 때마다 짧게 울리고, 그 울림은 언제나 8 Hz 주기의 같은 위상에서 생긴다. 감마 진동은 전혀 없는데 "8 Hz 위상에 묶인 감마 진폭"이 나타난다.

그림 11.8 가 이 상황이다. 감마 성분을 전혀 넣지 않은 톱니 모양 8 Hz 리듬에서, 8 Hz 위상과 50-70 Hz 진폭의 MI는 2.7×10^{-2} 였다. 진짜 결합을 넣은 그림 11.7 의 값(1.1×10^{-2})보다 크다. 공동변조도의 모양이 단서다. 진짜 PAC는 특정 진폭 주파수에 봉우리를 만들지만, 가짜 PAC는 진폭 주파수 축을 따라 길게 번지고 낮은 주파수 쪽일수록 강하다.




그림 11.8 날카로운 파형이 만드는 가짜 PAC. (가) 천천히 내려갔다가 약 6 ms 만에 되돌아오는 톱니 모양 8 Hz 리듬 (감마 성분 없음)과, 그것을 50-70 Hz로 거른 출력. 필터 출력의 포락선이 모서리마다 커진다. (나) 파워 스펙트럼. 8 Hz의 고조파가 감마 대역까지 이어진다. (다) 공동변조도. 8 Hz 위상에서 진폭 주파수 전체로 길게 번진 가짜 결합이 나타난다.

느린 대역의 파워 차이(위상 추정)의 질, 근전도나 눈 깜빡임 같은 순간적 인공물(9장), 자극에 묶인 과도 반응도 가짜 결합을 만든다. 그래서 PAC를 보고하려면 원신호의 파형을 직접 보여 주고, 파형 비대칭 (봉우리와 골의 날카로움, 오름과 내림의 시간 비)을 재고, 진폭 대역에 진짜 봉우리(1/f 배경 위로 솟은 파워)가 있는지 확인해야 한다.

🧠 뇌로 가는 다리: 해마 세타-감마와 두피 PAC

설치류 해마와 사람 두개강 내 기록(생리 1권 6장의 ECoG와 SEEG)에서는 세타-감마 결합이 반복해서 관찰되었고, 기억 부호화와 관련된다는 보고가 많다. 이 신호는 두개골을 거치지 않아 감마가 크고 깨끗하다. 두피 EEG/MEG의 PAC는 사정이 다르다. 두피의 감마는 작고 근전도에 쉽게 오염된다. 감각운동 피질의 뮤 리듬(약 10 Hz)은 아치 모양으로 알려져 있고, 뇌전증의 극파-서파나 수면의 정점 예파도 날카롭다. 이런 파형은 모두 가짜 PAC를 만들 수 있다. 두피 PAC를 주장하는 논문을 읽을 때는 파형 모양 분석, 근전도 처리, 대리 데이터 방법, 진폭 대역의 실제 봉우리를 확인하고, 가능하면 두개강 내 기록과 비교했는지 본다.

핵심 정리

핵심 정리

- 체적 전도는 지연 없이 퍼지므로, 한 소스가 여러 센서에 섞이면 위상차 0(또는 180°)의 가짜 결합이 생긴다. EEG는 공통 기준 전극도 같은 효과를 낸다.
- 결맞음은 교차 스펙트럼의 시행 평균을 파워로 나눈 크기다. 허수 결맞음, PLI, wPLI는 지연 0 성분을 버려 혼합에 강하지만, 지연 0의 진짜 결합도 버린다. 위상차가 180°에 가까운 결합도 놓친다.
- PLV는 시행 수가 적을수록 커 보인다(결합이 없을 때 기댓값 약 $\sqrt{\pi/(4N)}$). 조건 간 시행 수를 맞추거나 PPC처럼 편향 없는 측정을 쓴다. 파워가 다르면 위상 측정도 달라진다.
- 진폭 포락선 상관은 느린 공동 요동을 보며 fMRI 휴지기 네트워크와 잘 대응한다. 누설에 약하므로 직교화를 한다. 짝별 직교화는 큰 누설에서 가짜를 다 지우지 못하고, 대칭 직교화는 모든 영역을 함께 다루지만 영역 수가 데이터 계수보다 적어야 한다.
- 그레이저 인과는 과거에 의한 예측 개선을 로그 분산비로 잰다. 혼합과 신호 대 잡음비 차이만으로 가짜 방향이 생기며, 표본이 많으면 아주 작은 값도 유의하다. 시간 뒤집기, 소스 수준 분석, 신호 대 잡음비 보고로 점검한다.
- 소스 수준 파이프라인은 정합, 머리 모형과 소스 공간, 리드필드, 역해, 영역 시계열 추출, 누설 보정, 연결성과 통계의 순서다. 단계마다 선택(두개골 전도율, 역해 방법, 정칙화, 부호 정렬, 직교화)을 보고해야 한다.
- 역해 뒤에도 점 소스는 수 cm 번진다. 이웃 ROI 사이에는 큰 가짜 결합이, 먼 ROI 사이의 진짜 결합에는 희석이 생긴다.
- PAC는 토르트 MI와 공동변조도로 재고, 대리 데이터로 검정한다. 날카로운 비정현 파형의 고조파는 감마 진동 없이도 큰 가짜 PAC를 만든다. 파형, 진폭 대역의 실제 붐우리, 인공물을 확인해야 한다.

방법 절 점검표

방법 절 점검표

- 센서 수준인가 소스 수준인가? EEG라면 어떤 기준 전극을 썼는가? 체적 전도나 누설을 어떤 방법으로 다루었는가(지연 0을 버리는 지표, 직교화의 종류, 표면 라플라시안)?
- 연결성 측정의 정확한 정의와 변형(예: wPLI인가 편향 보정 wPLI인가), 주파수 대역, 창 길이, 시행 수가 적혀 있는가? 조건 간 시행 수와 파워 차이를 맞추거나 보고했는가?
- 소스 분석의 정합 방법(디지털라이저 사용 여부), 머리 모형과 전도율, 소스 공간과 쌍극자 방향, 역해 방법과 정착화, 잡음 공분산의 출처가 적혀 있는가? 빔형성기라면 조건 공통 필터를 썼는가?
- 아틀라스와 영역 수, 영역 시계열 추출 방법(부호 뒤집기 평균, 첫 주성분)은 무엇인가? 영역 수가 데이터 계수보다 작은가?
- 방향성 분석이라면 모형 차수 선택 기준, 정상성 처리, 조건부(다변량) 여부, 시간 뒤집기 같은 점검이 있는가?
- PAC라면 위상·진폭 대역과 필터 폭, 대리 데이터 방법, 원신호 파형과 진폭 대역 봉우리의 확인, 인공물 처리가 보고되었는가?
- 귀무 분포를 어떻게 만들었고(순열, 대리 데이터), 영역 쌍×대역×조건의 다중 비교를 어떻게 보정했는가?

확인 문제

확인 문제

1. 두 EEG 채널의 10 Hz 결맞음이 0.7이고, 시행별 위상차가 모두 0° 근처에 모여 있다. 이 결과에서 두 영역이 소통한다고 결론 내릴 수 없는 이유를 두 가지 들어라.
2. 20 Hz에서 두 영역 사이 지연이 5 ms라면 위상차는 몇 도인가? 같은 지연으로 결맞음 크기가 0.5라면 허수 결맞음은 얼마인가?
3. 정답 시행 150개와 오답 시행 15개에서 PLV를 비교했더니 오답 쪽이 0.12 더 컸다. 결합이 전혀 없을 때 두 조건의 평균 PLV는 대략 얼마인가? 이 비교를 어떻게 바꾸어야 하는가?
4. [그림 11.3](#) 에서 결합이 없는 두 소스의 원래 AEC와 짝별 직교화 AEC는 $\lambda = 0.4$ 에서 각각 얼마인가? 대칭 직교화가 이 문제를 정확히 푸는 이유와, 실제 데이터에서 그렇지 않은 이유를 말하라.
5. 그레이저 인과로 "전두엽이 두정엽을 이끈다"는 결과를 얻었다. 전두 센서의 신호 대 잡음비가 두정 센서보다 훨씬 높았다면 이 결과는 어떻게 해석해야 하는가? 점검 방법 두 가지를 들어라.
6. LCMV 빔형성기로 양쪽 청각 피질의 연결성을 보려 한다. 무엇이 문제가 될 수 있는가?
7. 소스 수준에서 이웃한 두 ROI(중심 거리 1 cm)의 포락선 상관이 0.7이었다. [그림 11.6](#) 를 근거로 이 값을 해석하라.
8. 어떤 두피 EEG 연구가 운동 과제 중 알파 위상과 감마 진폭 사이의 PAC 증가를 보고했다. 가짜 PAC 가능성을 확인하려면 무엇을 보아야 하는가? 세 가지를 들어라.

확인 문제 풀이

확인 문제 풀이

1. 위상차 0은 체적 전도로 한 소스가 두 채널에 섞인 경우의 특징이다. 또 EEG에서는 공통 기준 전극의 활동이 모든 채널에 같은 위상으로 들어간다. 시상 같은 공통 입력이 두 영역을 함께 움직이는 경우도 있다. 허수 결맞음이나 wPLI, 또는 소스 수준 분석과 직교화로 확인해야 한다.
2. $360^\circ \times 20 \times 0.005 = 36^\circ$ 다. 허수 결맞음은 $0.5 \times \sin 36^\circ \approx 0.29$ 다.
3. $\sqrt{\pi/(4 \times 150)} \approx 0.072$, $\sqrt{\pi/(4 \times 15)} \approx 0.23$ 이다. 차이는 약 0.16으로, 결합이 같아도 오답 쪽이 0.12 이상 커 보일 수 있다. 정답 시행에서 15개씩 무작위로 여러 번 뽑아 평균하거나, PPC처럼 시행 수 편향이 없는 측정을 쓴다.
4. 원래 0.45, 짝별 직교화 0.24다. 장난감 문제는 소스 둘이 신호 둘에 대칭으로 섞였으므로, 서로 직교인 가장 가까운 시계열이 원래 소스 자체다. 실제 데이터에서는 소스가 영역보다 훨씬 많고, 혼합이 대칭이 아니며, 소스들이 완전히 독립이지도 않아 누설이 완전히 지워지지 않는다.
5. 그림 11.4 (다)처럼, 결합이 없어도 혼합된 신호에서 신호 대 잡음비가 높은 쪽이 낮은 쪽을 "이끄는" 것처럼 보일 수 있다. 결과는 신호 대 잡음비 차이로 설명될 가능성이 있다. 점검: 시간 순서를 뒤집어 방향이 바뀌는지 본다. 소스 수준에서 다시 계산한다. 두 신호의 신호 대 잡음비를 맞춘 조건에서 비교한다.
6. 빔형성기는 서로 다른 소스의 시간 경과가 상관되지 않는다고 가정한다. 양쪽 청각 피질처럼 강하게 상관된 두 소스는 서로 지워져 약하게 추정되고, 그 상관 자체가 줄어든다. 두 소스를 함께 통과시키는 이중 소스 빔형성기나 최소 노름 계열 방법을 쓰거나, 모의실험으로 영향을 확인해야 한다.
7. 그림의 장난감 모형에서 1 cm 이웃은 실제 결합이 없어도(실제 0.07) 원래 ROI 시계열에서 0.73이 나왔다. 0.7은 누설만으로 설명될 수 있는 크기다. 직교화한 AEC나 지연 0을 버리는 지표로 다시 계산하고, 해당 역해의 점 퍼짐 함수 폭과 비교해야 한다.
8. 원신호 파형에서 알파(뮤 리듬)의 아치 모양이나 날카로운 모서리가 있는지 본다. 파워 스펙트럼에서 감마 대역에 $1/f$ 배경 위로 솟은 진짜 봉우리가 있는지, 아니면 알파의 고조파만 있는지 본다. 운동 중 근전도 증가와 조건 간 알파 파워 차이를 확인하고, 공동변조도가 진폭 주파수 축으로 길게 변했는지 본다.

다음 장으로

이 장으로 EEG/MEG 분석의 세 장(9-11장)을 마쳤다. 전처리로 신호를 정리하고, ERP와 시간-주파수 분석으로 한 자리의 반응을 읽고, 이 장에서 자리 사이의 관계를 읽었다. 12장에서는 다시 영상으로 돌아가 PET 데이터의 전처리와 정량 지도, 부분 용적 보정을 다룬다. 이어서 EEG와 fMRI를 동시에 기록하는 방법처럼 서로 다른 모달리티를 결합하는 분석을 본다. 이 장에서 본 "해상도가 다른 신호를 비교할 때의 함정"이 그곳에서 다시 나온다.

12장 PET 분석과 다중 모달 결합

이 장에서 배울 것 재구성된 동적 PET 영상이 숫자가 되기까지의 순서(프레임 움직임 보정, MRI 정합, 영역 정의, 시간-방사능 곡선 추출, 동적 모형 적합, 부분 용적 보정), 아밀로이드·타우 PET의 표준 지표인 센틸로이드와 브라크 단계 ROI, 그리고 두 모달을 함께 쓰는 방법(동시 EEG-fMRI의 인공물 제거, 공동 ICA). 뇌 연구자에게 왜 필요한가 "선조체 BP_{ND} 가 8 % 줄었다", "센틸로이드 25", "위축을 보정해도 후대상 FDG 저하가 남았다" 같은 문장은 모두 이 장의 단계를 거친 숫자다. 움직임 몇 mm, 정합 1 mm, 잡음 수십 %가 이 숫자를 효과 크기만큼 흔든다. 단계마다 무엇을 가정하는지 알아야 방법 절에서 그 크기를 어렵할 수 있다.

☞ 중고등 복습: 두 점을 지나는 직선과 연립일차방정식

두 점 (x_1, y_1) , (x_2, y_2) 를 지나는 직선은 하나뿐이다. 기울기는 $a = (y_2 - y_1)/(x_2 - x_1)$ 이고, 직선은 $y = y_1 + a(x - x_1)$ 이다. 섭씨를 화씨로 바꾸는 식 $F = 1.8C + 32$ 도 물의 어는점과 끓는점, 두 점으로 정한 직선이다. 12.4절의 센틸로이드가 바로 이런 눈금 바꾸기다. 미지수가 둘인 일차방정식 두 개는 한 번에 풀 수 있다. 예를 들어 $0.5g + 0.3w = 2.3$, $0.25g + 0.7w = 1.7$ 이면 첫 식에 0.5를 곱해 둘째 식에서 빼는 식으로 $g = 4.0$, $w = 1.0$ 을 얻는다. 미지수가 많아져도 원리는 같고, 컴퓨터는 행렬로 푼다. 12.3절의 GTM 부분 용적 보정은 "흐려서 섞인 값"을 이런 연립방정식으로 되돌린다. 마지막으로 평균이다. 같은 모양이 잡음과 함께 N 번 반복되면, N 번을 평균한 모양에서 잡음은 $1/\sqrt{N}$ 로 줄고 반복되는 모양만 남는다(물리 2권 7장). 12.5절에서 EEG의 인공물을 지우는 방법이 이 성질을 거꾸로 쓴다.

12.1 PET 전처리: 움직임, 정합, 영역

파이프라인의 순서

PET 분석은 스캐너가 감쇠·산란·우연 동시 계수를 보정해 재구성한 영상(물리 2권 3장)에서 시작한다. 동적 PET라면 이 영상은 프레임 수십 장의 4차원 배열이다. 이 장의 예에서는 30초 프레임 6장, 1분 3장, 3분 3장, 5분 15장, 모두 27장으로 90분을 찍는다. 처음에는 농도가 빨리 변하므로 프레임을 짧게, 나중에는 계수를 모으려고 길게 잡는다.

이후의 순서는 대략 다음과 같다.

1. 프레임 사이 움직임 보정
2. 평균 PET 영상을 같은 사람의 T1 MRI에 강체 정합
3. MRI에서 목표 영역과 참조 영역을 정의
4. 영역마다 시간-방사능 곡선(TAC)을 뽑는다
5. 동적 모형을 적합하거나, 정해진 시간 창의 SUVR을 구한다
6. 필요하면 부분 용적 보정을 한다
7. 영역 값 또는 파라메트릭 지도로 집단 통계를 한다

대표 도구로는 동적 모형 전용 상용 프로그램인 PMOD, FreeSurfer에 들어 있는 PET 처리 도구 (PETSurfer), 부분 용적 보정 모음인 PETPVC가 있다. 정합과 움직임 보정에는 SPM, FSL, ANTs 같은 MRI 도구를 그대로 쓰기도 한다.

프레임 움직임 보정

왜 하는가. 90분 동안 머리를 가만히 두기는 어렵다. 4장의 fMRI와 같은 강체 6 파라미터 움직임이 PET에도 생긴다. 그런데 PET의 관심 구조는 해상도에 비해 작다. 선조체의 조가비핵은 폭이 1 cm 남짓이고, PET 해상도는 FWHM 4-6 mm다. 몇 mm만 밀려도 MRI로 그린 ROI 밖으로 신호가 빠져나간다.

그림 12.1은 이것을 합성 데이터로 보인다. 물리 2권 3장과 같은 $BP_{ND} = 3$ 추적자로 TAC를 만들고, 폭 10 mm 타원 모양 선조체를 FWHM 5 mm로 흐렸다. 머리가 47.5분에 3 mm 움직이고 70분부터 6 mm까지 천천히 밀리면, 선조체 TAC가 처지면서 SRTM(12.2절)으로 구한 BP_{ND} 가 2.24에서 1.82로 19 % 낮아진다. 로건 도표로는 2.22에서 1.69로 24 % 낮아진다. 마지막 프레임 값은 41 % 낮다.




그림 12.1 프레임 움직임과 TAC. (가) 머리가 4 mm 움직인 프레임에서 활동(파랑)이 MRI로 그린 ROI(빨강)를 반쯤 벗어났다. (나) 실제 머리 위치(회색)와 프레임마다 정합으로 찾은 위치(파랑). 움직임이 프레임 중간에 일어나면 그 프레임은 두 위치의 평균이 된다. (다) 선조체 TAC. 보정하지 않으면 움직인 뒤부터 처진다. 프레임 정합 뒤에는 움직이지 않은 곡선을 거의 되찾지만, 움직임이 일어난 45-50분 프레임(열은 띠)은 4 % 낮게 남는다. 움직임이 없어도 BP_{ND} 는 부분 용적 때문에 참값 3보다 낮은 2.24다(12.3절).

무엇을 가정하는가. 프레임 정합은 "프레임 안에서는 머리가 가만히 있었다"고 가정한다. 5분 프레임 중간에 움직이면 그 프레임은 두 위치가 겹친 흐린 영상이 되고, 정합으로 고칠 수 없다(그림 12.1 다의 45-50분 프레임). 또 정합은 프레임 사이에 방사능 분포가 비슷하다고 가정한다. 처음 몇 분은 혈류를 따라 분포가 빠르게 바뀌고 계수도 적어서, 늦은 프레임을 기준으로 맞추면 정합이 엉뚱하게 움직인다. 그래서 흔히 앞쪽 프레임을 묶어 따로 맞추거나 보정에서 뺀다.

흔한 실수. 감쇠 지도를 잊는다. 감쇠 보정용 CT나 MR 영상은 대개 촬영 처음에 한 번 찍는다. 그 뒤 머리가 움직이면 방출 영상과 감쇠 지도가 어긋나, 정합으로 영상을 옮겨도 감쇠 보정 오차가 영역별 치우침으로

남는다. 움직임이 크면 정렬한 감쇠 지도로 다시 재구성해야 한다. 외부 광학 추적기로 머리 위치를 기록해 사건마다 응답선을 옮기는 방법도 있다.

예제 12.1 움직임이 지운 특이 신호

그림 12.1의 선조체 ROI에서, 흐린 특이 신호 가운데 ROI 안에 남은 비율이 움직임이 없을 때 0.742, 3 mm 밀렸을 때 0.584, 4 mm에서 0.488이다. (가) 3 mm 움직임은 특이 신호를 몇 % 지우는가? (나) 55-60분 프레임의 TAC 값은 움직임이 없을 때 10.97, 3 mm 밀린 뒤 9.26이었다. 전체 TAC의 감소율이 (가)보다 작은 이유는?

풀이 (가) $0.584/0.742 = 0.787$ 이므로 특이 신호의 약 21 %가 ROI 밖으로 나갔다. (나) $9.26/10.97 = 0.844$, 약 16 % 감소다. TAC에는 비특이 결합과 유리 추적자의 몫이 섞여 있다. 이 몫은 선조체 주변에도 비슷한 농도로 있으므로 머리가 움직여도 ROI에 거의 그대로 남는다. 특이 신호만 빠져나가므로 전체 감소율은 특이 신호의 감소율보다 작다. BP_{ND} 는 특이 신호의 비이므로 TAC보다 크게 흔들린다.

MRI 정합과 영역 정의

평균 PET 영상(흔히 낮은 프레임 합)을 같은 사람의 T1 MRI에 강제로 맞춘다. 같은 사람의 뇌이므로 늘이거나 휘지 않는다. 두 영상의 밝기 관계가 다르므로 3장에서 본 **상호 정보량(mutual information)**을 비용 함수로 쓴다. 그다음 MRI에서 영역을 그린다. FreeSurfer 분할이나 아틀라스를 개인 공간으로 옮겨 쓰는 방법이 흔하다.

참조 영역은 추적자에 따라 다르다. 라클로프라이드는 소뇌 회백질, 아밀로이드 추적자는 전체 소뇌나 소뇌 회백질이나 뇌교, 타우 추적자는 흔히 소뇌 아래쪽 회백질을 쓴다. 참조 영역은 특이 결합이 없어야 하고, 시야 가장자리나 정맥동처럼 정량이 불안한 곳에서 떨어져 있어야 한다.

정합 오차는 작은 구조에서 증폭된다. 12.3절에서 보듯 1 mm 정합 오차만으로 부분 용적 보정 결과가 20 % 바뀔 수 있다. 정합 결과는 숫자만 믿지 말고 PET를 MRI 위에 겹쳐 눈으로 확인한다.

12.2 정량 지도: SUVR, 동적 모형, 파라메트릭 지도

SUVR: 정해진 시간 창의 비

가장 단순한 지표는 정해진 시간 창(아밀로이드라면 주사 뒤 50-70분 따위)의 목표 영역 평균을 참조 영역 평균으로 나눈 **SUVR**이다. 주사량과 몸무게가 약분되고, 짧게 찍어도 된다. 대신 그 시간 창에서 추적자가 평형에 가깝다고 가정한다. 물리 2권 3장에서 본 것처럼 이 가정은 근사이고, 혈류가 바뀌면 같은 결합에서도 SUVR이 바뀐다.

단순화 참조 조직 모형(SRTM)

동적 촬영을 했다면 TAC 전체를 모형으로 맞춘다. 동맥 채혈 없이 가장 널리 쓰는 모형이 **단순화 참조 조직 모형(simplified reference tissue model, SRTM)**이다(Lammertsma & Hume 1996). 목표 TAC C_T 를 참조 TAC C_R 로 쓴다.

$$C_T(t) = R_1 C_R(t) + \left(k_2 - \frac{R_1 k_2}{1 + BP_{ND}}\right) C_R(t) \otimes e^{-k_2 t / (1 + BP_{ND})}$$

$R_1 = K_1/K'_1$ 은 목표와 참조의 전달 속도 비, k_2 는 목표 영역에서 추적자가 빠져나가는 속도 상수(1/분), $\otimes$ 는 합성곱이다. 합성곱은 "들어온 양마다 지수적으로 빠져나가는 꼬리를 붙여 모두 더한 것"이다(물리 2권 7장). 첫째 항은 목표가 참조와 똑같이 행동할 때의 몫이고, 둘째 항은 결합 때문에 목표에서 더 늦게 빠져나가는 몫이다. 겉보기 유출 속도 $k_{2a} = k_2/(1 + BP_{ND})$ 가 작을수록 결합이 크다.

이 모형의 가정은 네 가지다. (1) 참조 영역에는 특이 결합이 없다. (2) 비특이 분포 부피 V_{ND} 가 목표와 참조에서 같다. (3) 목표 영역에서 유리 칸과 결합 칸이 빨리 교환되어, 하나의 칸처럼 행동한다. (4) 혈액 속 방사능은 무시할 만하다. (3)이 어긋나면 작은 치우침이 생긴다. 이 장의 시뮬레이션은 목표를 2-조직 모형으로 만들었으므로, 잡음이 없어도 SRTM은 3이 아니라 3.04를 낸다(그림 12.2 나의 왼쪽 끝).

매개변수 셋을 비선형 최소제곱으로 맞출 수도 있지만, 복셀마다 하려면 느리고 불안하다. **기저 함수법 (basis function method)**은 k_{2a} 후보 수십-수백 개마다 $C_R \otimes e^{-k_{2a}t}$ 를 미리 계산해 두고, 각 후보에서 선형 회귀를 한 뒤 잔차가 가장 작은 후보를 고른다(Gunn 1997). 선형 회귀는 2장의 GLM과 같다. 아래 코드가 그 전부다.

```
import numpy as np

def srtm_basis(t, cr, ct, thetas=np.geomspace(0.01, 1.0, 100)):
    """t: 프레임 끝 시각(분), cr·ct: 참조·목표 TAC. BP_ND, R1, k2를 돌려준다."""
    dt = np.diff(t, prepend=0)
    best = (np.inf, None, None)
    for th in thetas:
        # 기저 함수 B = C_R ⊗ exp(-θt): 넓이를 직사각형 합으로 어렵한다
        B = np.array([np.sum(cr[:i+1] * np.exp(-th * (t[i] - t[:i+1]))) * dt[:i+1]]
                      for i in range(len(t))])
        X = np.column_stack([cr, B])
        beta, *_ = np.linalg.lstsq(X, ct, rcond=None)
        rss = np.sum((ct - X @ beta) ** 2)
        if rss < best[0]:
            best = (rss, beta, th)
    _, (R1, b2), k2a = best
    k2 = b2 + R1 * k2a
    return k2 / k2a - 1, R1, k2

t = np.arange(1.0, 91.0, 1.0)          # 1분 프레임 90개
cr = 10 * t * np.exp(-t / 6)          # 참조 TAC (임의 모양)
k2, k2a = 0.4, 0.4 / 3                # BP_ND = k2/k2a - 1 = 2
B = np.array([np.sum(cr[:i+1] * np.exp(-k2a * (t[i] - t[:i+1]))) for i in range(len(t))])
ct = cr + (k2 - k2a) * B               # R1 = 1
print(srtm_basis(t, cr, ct))           # 약 (1.99, 0.98, 0.40)
```

BP_{ND} 가 2가 아니라 1.99로 나오는 것은 k_{2a} 후보를 100개만 두었기 때문이다. 실제 분석에서는 잡음이 이보다 훨씬 큰 오차를 만든다.

예제 12.2 SRTM 매개변수에서 점유율까지

선조체 TAC에 SRTM을 맞추어 $R_1 = 1.05$, $k_2 = 0.42$ /분, $k_{2a} = 0.105$ /분을 얻었다. (가) BP_{ND} 와 참조 영역의 유출 속도 $k'_2 = k_2/R_1$ 은? (나) 약물 복용 뒤 k_2 는 그대로이고 k_{2a} 가 0.19 /분이 되었다. 점유율은?

풀이 (가) $BP_{ND} = k_2/k_{2a} - 1 = 0.42/0.105 - 1 = 3.0$ 이다. $k'_2 = 0.42/1.05 = 0.40$ /분이다. 참조 영역의 k'_2 는 영역과 관계없이 한 사람에서 하나여야 하므로, 여러 영역에서 구한 k'_2 가 크게 다르면 모형 가정을 의심한다. 이 값을 고정하고 다시 맞추는 2단계 방법(SRTM2, MRTM2)이 복셀 지도의 잡음을 줄인다. (나) $BP_{ND} = 0.42/0.19 - 1 = 1.21$ 이다. 화학 1권 6장의 식으로 점유율은 $1 - 1.21/3.0 = 0.60$, 약 60 %다.

잡음이 만드는 치우침

그림 12.2 은 같은 TAC에 잡음 수준을 바꿔 가며 SRTM 기저 함수법과 참조 로건 도표(물리 2권 3장)를 400번씩 맞춘 결과다. 잡음은 실제처럼 계수가 적을수록, 프레임이 짧을수록, 붕괴가 진행될수록 커지게 넣었다. 마지막 프레임 변동계수 2 %는 큰 ROI의 평균, 20-40 %는 복셀 하나에 해당한다.




그림 12.2 SRTM과 잡음. (가) 잡음 5 %의 ROI TAC(파랑)와 SRTM 적합(빨강). 기저 함수법은 $BP_{ND} = 3.01$ 을 낸다. (나) 마지막 프레임의 변동계수를 2 %에서 40 %로 키우며 400번씩 맞춘 평균(선)과 ± 1 표준편차(띠). SRTM은 평균이 3.04-3.06으로 거의 그대로이고 퍼짐만 커진다. 로건 도표는 잡음이 커질수록 평균이 낮아져, 40 %에서 2.61로 13 % 작다.

로건 도표가 낮아지는 이유는 축에 있다. 가로축과 세로축이 모두 잡음 섞인 C_T 로 나눈 값이라 가로축에도 잡음이 들어간다. 가로축이 흔들리는 회귀는 기울기가 0 쪽으로 줄어든다. 2장의 회귀에서 설명변수의 측정 오차가 기울기를 줄이는 것과 같은 현상이다. SRTM은 목표 TAC를 종속 변수로만 쓰므로 이런 치우침이 작다. 대신 잡음이 크면 퍼짐이 커지고, 일부 복셀은 터무니없는 값으로 된다.

파라메트릭 지도

복셀마다 모형을 맞추면 BP_{ND} **파라메트릭 지도(parametric map)**가 된다. 이 지도는 SPM 같은 복셀 기반 통계에 바로 넣을 수 있어 편리하다. 그러나 그림 12.3 에서 보듯 복셀 잡음이 지도 전체를 치우치게 할 수 있다. 선조체의 마지막 프레임 변동계수가 25 %인 합성 영상에서, 로건 지도의 선조체 평균은 2.78로 참값보다 7 % 낮다. 같은 복셀들의 TAC를 먼저 평균한 뒤 맞추면 2.98이다. 결합이 낮은 피질 띠($BP_{ND} =$

0.5)에서는 계수가 적어 잡음이 더 크므로, 로건 지도가 0.43으로 14 % 낮다. SRTM 지도는 두 영역에서 각각 3.04와 0.53이다.




그림 12.3 파라메트릭 BP_{ND} 지도. 2 mm 복셀의 합성 영상에서 선조체(참값 3), 피질 띠(0.5), 나머지(0)의 TAC에 복셀 잡음을 넣고 복셀마다 맞추었다. (가) 참값. (나) 복셀별 로건 지도는 잡음 때문에 선조체가 얼룩지고 전체적으로 낮다. (다) 복셀별 SRTM 지도. (라) 선조체 평균. 로건은 "지도 만들기 뒤 ROI 평균"(빨강)이 "ROI TAC를 평균한 뒤 적합"(파랑)보다 0.2 낮다.

교훈은 두 가지다. 첫째, 같은 방법이라도 "복셀 먼저"와 "ROI 먼저"의 결과가 다르다. 방법 절에 어느 쪽인지 적어야 한다. 둘째, 잡음이 다른 두 집단을 비교할 때는 치우침이 집단 차이로 보일 수 있다. 계수율이 낮은 환자군, 주사량이 적은 소아, 움직임 때문에 프레임을 버린 사람은 복셀 잡음이 크다.

🧠 뇌로 가는 다리: 과제로 재는 도파민 방출과 움직임

[^{11}C]라클로프라이드로 보상 과제나 스트레스 과제 중의 도파민 방출을 재면, 선조체 BP_{ND} 의 변화는 대략 수 %에서 10 % 남짓이다(화학 1권 6장). 이 장의 시뮬레이션에서 3-6 mm 움직임은 BP_{ND} 를 19 % 낮췄다. 효과보다 두 배 큰 인공물이다. 문제는 과제를 할 때 더 움직인다는 데 있다. 휴지 스캔과 과제 스캔을 비교하는 설계라면, 과제 조건의 BP_{ND} 감소가 도파민 방출이 아니라 움직임일 수 있다. 같은 스캔 안에서 과제 시점을 모형에 넣는 방법(시간에 따라 바뀌는 참조 모형, lp-ntPET 등)도 그 시점의 움직임에 민감하다. 논문을 읽을 때는 프레임별 움직임 크기를 조건별로 보고했는지, 움직임이 큰 사람을 제외하는 기준을 미리 정했는지 확인한다.

12.3 부분 용적 보정

위축은 저대사처럼 보인다

물리 2권 3장에서 PET 해상도보다 얇은 피질은 흐려지면서 낮아진다는 것을 보았다. 분석에서 이것이 문제가 되는 곳은 위축이다. 세포마다의 대사는 그대로인데 피질이 얇아지면 회백질 ROI의 평균이 낮아진다.

그림 12.4 가 이것을 1차원 팬텀으로 보인다. 뇌척수액(농도 0), 회백질(4), 백질(1)을 이랑과 고랑 모양으로 늘어놓고 FWHM 6 mm로 흐렸다. 회백질이 3.0 mm에서 2.2 mm로 얇아지면 회백질 ROI 평균이 2.34에서 1.77로 24 % 낮아진다. 같은 두께에서 농도를 20 % 낮춘 진짜 저대사는 1.93으로 17.5 % 낮아질

뿐이다. 위축만으로 생긴 저하가 진짜 20 % 저대사보다 크다. 보정 없이 이 값을 같은 두께에서 해석하면 약 28 % 저대사에 해당한다.




그림 12.4 부분 용적과 그 보정. (가) 같은 농도(회백질 4, 백질 1, 뇌척수액 0)에서 회백질만 3.0 mm(파랑)에서 2.2 mm(빨강 점선)로 얇아졌다. 가는 선은 참 농도, 굵은 선은 FWHM 6 mm로 흐린 PET 측정이다. (나) 회백질 농도 추정. 보정 전 ROI 평균(회색)은 위축(1.77)이 진짜 20 % 저대사(1.93)보다 낮다. GTM과 Müller-Gärtner 보정은 세 경우 모두 참값(빨간 점선)을 되찾는다. 단 분할과 정합이 완벽하다는 조건에서다.

세 가지 대표 방법

2구획 방법(Meltzer 방법) 은 뇌 조직과 뇌척수액만 나눈다. 뇌 조직 마스크를 PET 해상도로 흐린 영상으로 PET를 나눈다. 뇌척수액으로 새어 나간 몫만 되돌리고, 회백질과 백질은 섞인 채로 둔다.

Müller-Gärtner 방법(Müller-Gärtner 1992)은 회백질을 따로 푼다. 먼저 백질의 농도를 따로 추정한다 (흔히 깎아 낸 백질 안쪽의 평균). 그 값으로 백질에서 새어 들어온 몫을 빼고, 흐린 회백질 마스크로 나눈다. 복셀 단위의 회백질 영상이 나온다.

기하 전달 행렬(geometric transfer matrix, GTM) 방법(Rousset 1998)은 ROI 수준에서 연립방정식을 푼다. 영역 j 에만 농도 1을 넣고 흐렸을 때 ROI i 에 들어오는 평균을 G_{ij} 라 하자. 측정한 ROI 평균 t_i 는 모든 영역의 참 농도 c_j 가 섞인 것이다.

$$t_i = \sum_j G_{ij} c_j \iff \mathbf{t} = \mathbf{G} \mathbf{c}, \quad \mathbf{c} = \mathbf{G}^{-1} \mathbf{t}$$

$\mathbf{G}$ 의 대각 성분은 제자리에 남는 몫(회복 계수), 비대각 성분은 이웃 영역에서 새어 들어오는 몫이다. **그림 12.4**의 정상 패턴에서 회백질 행은 뇌척수액 0.19, 회백질 0.51, 백질 0.30이다. 회백질 ROI 평균의 절반 가까이 다른 조직에서 온다는 뜻이다.

예제 12.3 GTM을 손으로 풀기

회백질과 백질 두 영역만 있다고 하자. 흐림 모형에서 $G = \begin{pmatrix} 0.5 & 0.3 \\ 0.25 & 0.7 \end{pmatrix}$ 을 얻었고(행: ROI, 열: 원천 영역), 측정된 ROI 평균은 회백질 2.3, 백질 1.7이었다. (가) 참 농도는? (나) 보정하지 않은 회백질 값은 참값을 몇 % 낮게 보는가?

풀이 (가) $0.5g + 0.3w = 2.3$, $0.25g + 0.7w = 1.7$ 이다. 행렬식은 $0.5 \times 0.7 - 0.3 \times 0.25 = 0.275$ 다. $g = (2.3 \times 0.7 - 0.3 \times 1.7)/0.275 = 1.10/0.275 = 4.0$, $w = (0.5 \times 1.7 - 0.25 \times 2.3)/0.275 = 0.275/0.275 = 1.0$ 이다. (나) $2.3/4.0 = 0.575$ 이므로 42.5 % 낮다. 백질 값 1.7은 반대로 참값 1.0보다 70 % 높다. 회백질에서 새어 들어온 몫 때문이다.

무엇을 가정하는가

세 방법 모두 (1) 스캐너와 재구성의 점 퍼짐 함수(PSF)를 안다, (2) MRI 분할이 정확하다, (3) PET와 MRI가 정확히 정합되어 있다, (4) 각 영역 안의 농도는 고르다고 가정한다. 이 가정이 깨질 때의 크기를 같은 팬텀으로 재면 다음과 같다. 회백질 두께가 2.2 mm인 위축 팬텀에서 분할이 회백질을 0.2 mm 얇게 (2.0 mm) 또는 두껍게(2.4 mm) 잡으면, GTM 결과는 참값 4.0 대신 4.21과 3.84로 $\pm 5\%$ 어긋난다. Müller-Gärtner는 4.41과 3.65로 $\pm 10\%$ 어긋난다. PET와 MRI의 정합이 0.5 mm 어긋나면 GTM이 3.79, 1 mm 어긋나면 3.21로 20 % 낮아진다. 보정 전 위축 효과(24 %)와 맞먹는 크기다.

PSF를 실제보다 크게 넣으면 과보정, 작게 넣으면 덜 보정한다. 실제 PSF는 재구성 알고리즘, 반복 횟수, 후처리 필터, 시야 안의 위치에 따라 바뀐다. 그래서 같은 사람을 다른 스캐너로 찍으면 PSF 값도 다시 정해야 한다.

흔한 오해: 부분 용적 보정을 하면 언제나 더 정확하다

보정은 흐림을 되돌리는 과정이라 잡음과 오차도 함께 키운다. GTM 행렬은 영역이 작을수록 대각 성분이 작아져 역행렬이 불안해진다. 해마나 편도체처럼 작은 구조에서 분할이 1-2 복셀 어긋나면 보정 값이 크게 흔들린다. 또 보정은 "영역 안의 농도가 고르다"고 가정하므로, 타우 PET에서 맥락얼기의 비특이 결합처럼 영역 경계에 걸친 신호는 보정 뒤에도 남거나 오히려 엉뚱한 영역으로 옮겨 간다. 그래서 대부분의 연구는 보정 전 결과를 주 결과로 두고, 보정 후 결과를 민감도 분석으로 함께 보고한다. "보정 뒤에도 차이가 남았다"는 말은 위축이 결과를 모두 설명하지 못한다는 뜻이지, 보정 값이 참값이라는 뜻은 아니다.

🧠 뇌로 가는 다리: 알츠하이머병 FDG 저하는 위축인가

알츠하이머병의 FDG-PET에서는 후대상, 췌기앞소엽, 측두-두정 피질의 저하가 전형적이다(생리 1권 7장). 같은 영역에 위축도 있다. 이 장의 팬텀에서 피질이 27 % 얇아지자 보정 전 값이 24 % 낮아졌다. 그러면 FDG 저하 가운데 얼마가 진짜 시냅스 활동 감소인가? 여러 연구가 보정 전후를 비교했고, 대체로 보정 뒤에도 저하의 상당 부분이 남는다고 보고한다. 그러나 남는 비율은 영역, 질병 단계, 보정 방법에 따라 크게 다르다. 해마는 보정 전후 차이가 가장 크다. 실용적인 방법은 세 가지다. MRI 회백질 부피나 두께를 공변량으로 넣는 방법, 부분 용적 보정, 그리고 12.6절의 다중 모달 분석으로 두 모달의 공통 성분과 고유 성분을 나누는 방법이다. 방법마다 가정이 달라서 셋을 함께 보는 연구가 많다.

12.4 아밀로이드·타우 PET 분석

센틸로이드: 직선 하나로 눈금 맞추기

아밀로이드 PET의 SUVR은 추적자, 기준 영역, 표적 ROI, 분석 프로그램마다 눈금이 다르다. [^{11}C]PiB의 SUVR 1.5와 어떤 ^{18}F 추적자의 SUVR 1.5는 같은 양의 아밀로이드가 아니다. **센틸로이드(Centiloid, CL)**는 이 차이를 직선 하나로 맞춘다(Klunk 2015). 젊은 정상인 집단의 평균을 0, 전형적인 알츠하이머병 집단의 평균을 100으로 놓는다. 장 첫머리의 복습처럼 두 점으로 정한 직선이다.

$$\text{CL} = 100 \times \frac{\text{SUVR} - \text{SUVR}_{\text{YC}}}{\text{SUVR}_{\text{AD}} - \text{SUVR}_{\text{YC}}}$$

표준 PiB 분석(정해진 표준 공간 표적 ROI, 전체 소뇌 기준)에서 고정점은 $\text{SUVR}_{\text{YC}} = 1.009$, $\text{SUVR}_{\text{AD}} = 2.076$ 이다.

과정은 두 단계다. 첫째, 자기 분석 파이프라인이 공개된 표준 PiB 데이터에서 표준 값을 재현하는지 확인한다. 재현한 CL을 표준 CL에 회귀했을 때 기울기가 1에 가깝고(대략 0.98–1.02), 설명된 분산이 매우 높아야(R^2 0.98 이상) 한다. 둘째, 새 추적자는 같은 사람들을 PiB와 새 추적자로 모두 찍어, 새 추적자의 SUVR을 "PiB였다면 얻었을 SUVR"로 옮기는 직선을 구한다. **그림 12.5**가 가상의 추적자 X로 이 과정을 보인다.




그림 12.5 센틸로이드 변환. (가) 젊은 정상인(초록), 노인(빈 원), 전형적 알츠하이머병(빨강) 40명을 PiB와 가상의 ^{18}F 추적자 X로 모두 찍은 합성 데이터. 추적자 X는 동적 범위가 좁아 기울기가 1.60이다. (나) PiB SUVR, 추적자 X SUVR, 센틸로이드의 세 눈금을 나란히 놓았다. 세로선은 같은 아밀로이드 양을 가리킨다. 추적자 X의 SUVR 1.10은 PiB SUVR로는 약 1.14이고, 둘 다 약 12 CL이다(파란 점선).

예제 12.4 센틸로이드 계산

(가) 표준 PiB 분석에서 SUVR 1.50인 사람의 CL은? (나) 추적자 X는 짝 촬영에서 $PiB_{calc} = 1.598 SUVR_X - 0.616$ 을 얻었다. 추적자 X SUVR 1.20은 몇 CL인가? (다) 양성 경계로 12 CL과 25 CL을 쓰는 두 연구가 있다면 (나)의 사람은 각각 어떻게 분류되는가?

풀이 (가) $100 \times (1.50 - 1.009) / (2.076 - 1.009) = 100 \times 0.491 / 1.067 = 46.0$ CL이다. (나) $PiB_{calc} = 1.598 \times 1.20 - 0.616 = 1.302$ 다. $CL = 100 \times (1.302 - 1.009) / 1.067 = 27.4$ CL이다. 두 식을 합치면 $CL = 149.8 SUVR_X - 152.3$ 이다. 추적자 X의 SUVR 0.1이 15 CL에 해당한다. (다) 두 기준 모두에서 양성이다. 그러나 SUVR이 0.02만 낮아도(1.18) 24.4 CL이 되어 25 CL 기준에서는 음성이 된다. 경계 근처의 판정은 12.1-12.3절의 수 % 오차로 뒤집힐 수 있다.

센틸로이드는 눈금을 맞추는 뿐 추적자의 성질까지 같게 만들지는 않는다. 백질 비특이 결합의 크기, 잡음, 동적 범위가 다르면, 같은 CL 값에서도 측정 정밀도가 다르다. 종단 연구에서 추적자를 바꾸면 CL 변화의 일부가 추적자 차이일 수 있다. 종단 변화를 썰 때는 깎아 낸 백질 같은 다른 기준 영역이 잡음을 줄인다는 보고도 있다. 기준 영역 선택을 미리 정해 두는 것이 좋다.

타우 PET: 브라크 단계 ROI

타우 PET는 아밀로이드처럼 넓게 고르게 쌓이지 않고, 정해진 순서로 퍼진다. 부검 병리의 **브라크 단계 (Braak stage)**를 영상 ROI로 옮겨 쓴다. I-II 단계는 내후각 피질과 해마, III-IV 단계는 해마겔이랑, 방추상회, 하측두, 편도 같은 변연계와 측두엽 바닥, V-VI 단계는 넓은 신피질이다. 이 ROI들을 FreeSurfer 분할의 조합으로 정의하고, 각 ROI의 SUVR이 문턱을 넘는지로 영상 단계를 매긴다.

이 분석의 함정은 비특이 결합이다. [^{18}F]플로르타우시피르는 맥락얼기, 선조체, 뇌막에, 일부 2세대 추적자는 뇌막이나 두개골에 붙는다. 맥락얼기는 해마 바로 옆이므로, 해마 값은 부분 용적으로 오염되기 쉽다. 그래서 브라크 I-II ROI에서 해마를 빼고 내후각 피질만 쓰기도 한다. 기준 영역은 흔히 소뇌 아래쪽 회백질이다. 소뇌 위쪽은 후두엽 피질의 신호가 새어 들어올 수 있기 때문이다.

뇌로 가는 다리: 타우 PET 문턱과 임상 판독

타우 PET의 양성 문턱은 추적자, 기준 영역, ROI 정의, 부분 용적 보정 여부에 따라 다르고, 아밀로이드의 센틸로이드 같은 공통 척도는 아직 자리 잡는 중이다. 같은 영상도 "측두엽 복합 ROI의 SUVR"로 불지 "브라크 단계별 ROI"로 불지에 따라 양성 비율이 달라진다. 교육적 배경으로 임상 판독의 흐름을 보면, 숙련된 판독자는 정량 값과 함께 영상을 눈으로 읽는다. 측두엽 바깥쪽이나 뒤쪽 신피질까지 섭취가 퍼졌는지를 보고, 맥락얼기와 뇌막 신호를 실제 결합과 구별한다. 연구 논문의 정량 결과를 읽을 때도 어떤 ROI 정의와 문턱을 썼는지, 비특이 결합 영역을 어떻게 처리했는지가 해석의 핵심이다.

12.5 동시 EEG-fMRI

두 인공물

EEG의 ms 해상도와 fMRI의 mm 해상도를 함께 얻으려고 스캐너 안에서 EEG를 기록한다. 물리 2권 11장에서 본 두 인공물이 문제다. 하나는 경사 코일이 바뀔 때 전극 선이 만드는 고리에 유도되는 **경사**

인공물(gradient artifact) 로, mV 단위여서 EEG보다 수백 배 이상(조건에 따라 수천 배) 크다. 다른 하나는 심장 박동에 맞춰 머리와 혈관이 주자기장 속에서 움직여 생기는 **심탄도 인공물(ballistocardiogram, BCG)** 로, 3 T에서 수십~수백 μV 에 이른다.

평균 인공물 빼기

두 인공물에 쓰는 기본 방법은 같다. 인공물은 반복되고 EEG는 반복되지 않는다는 점을 쓴다. 인공물이 시작하는 시점(경사는 슬라이스나 볼륨 표지, BCG는 심전도 R파)마다 구간을 잘라, 이웃 구간 k 개를 평균하면 EEG는 $1/\sqrt{k}$ 로 줄고 인공물 모양만 남는다. 이 평균을 각 구간에서 뺀다. 이것이 **평균 인공물 빼기(average artifact subtraction, AAS)** 다. BCG에는 Allen 1998이, 경사 인공물에는 Allen 2000이 이 원리를 썼다. [그림 12.6](#) 가 합성 데이터에 이 방법을 적용한 결과다.




그림 12.6 동시 EEG-fMRI의 인공물 제거(합성 데이터). (가) 5 kHz로 기록한 원 신호. 57 ms마다 반복되는 경사 인공물이 약 3 mV에 이르고, 참 EEG(약 $\pm 0.05 \text{ mV}$)는 보이지 않는다. (나) 25개 슬라이스 구간의 평균을 빼고 40 Hz 저역 통과한 결과. 스캐너와 EEG 시계를 동기화하면(파랑) 참 EEG(회색)와 거의 겹치지만, 동기화하지 않으면(빨강) 표본화 위치가 구간마다 달라져 큰 차이가 남는다. (다) 경사 인공물을 지운 뒤에도 R파(보라 점선) 약 0.2 s 뒤마다 심탄도 인공물이 남는다. (라) 이웃 박동 21개의 평균을 빼면 대부분 사라지지만, 박동마다 다른 크기와 모양이 잔차로 남는다.

핵심 부분은 몇 줄이다.

```
import numpy as np

def aas(x, onsets, L, k=25):
    """x: 한 채널, onsets: 인공물 시작 표본 번호(정수 배열), L: 구간 길이, k: 평균할 구간 수."""
    y = x.copy()
    onsets = onsets[onsets + L <= len(x)]
    E = np.array([x[s:s + L] for s in onsets])          # 구간 × 표본
    for i, s in enumerate(onsets):
        lo = max(0, min(i - k // 2, len(onsets) - k))  # 이웃 k개 구간
        y[s:s + L] -= E[lo:lo + k].mean(axis=0)         # 평균 모양을 뺀다
    return y
```

이웃 구간만 평균하는 이유는 인공물 모양이 천천히 바뀌기 때문이다. 머리가 조금 움직이면 고리 넓이가 바뀌어 경사 인공물이 달라지고, 심박이 바뀌면 BCG 모양이 달라진다.

경사 인공물: 시계를 맞춰라

AAS는 모든 구간에서 인공물을 같은 자리에서 표본화했다고 가정한다. 경사 인공물은 경사의 변화율에 비례하므로 0.1 ms 안팎의 날카로운 뽀족파로 이루어진다. 5 kHz 표본화의 간격은 0.2 ms다. 표본화 시점이 구간마다 0.1 ms만 어긋나도 같은 뽀족파가 정점으로 찍히기도 하고 거의 안 찍히기도 한다. 그러면 평균 모양이 실제 각 구간의 모양과 맞지 않는다.

그림 12.6의 시뮬레이션에서 슬라이스 간격이 표본 간격의 정수배(57.000 ms = 285 표본)이고 시계가 동기화되어 있으면, AAS 뒤 잔차는 0.71 μ V다. 슬라이스 간격이 57.037 ms여서 정수배가 아니면 잔차가 8.9 μ V로, 참 EEG의 표준편차 약 11 μ V와 비슷해진다. 그래서 MR 호환 증폭기는 스캐너 시계에 EEG 표본화 시계를 묶는 장치를 쓰고, TR을 표본 간격의 정수배로 고른다. 동기화할 수 없을 때는 구간마다 템플릿과의 상관이 가장 커지도록 시점을 표본 이하 단위로 다시 맞춘 뒤 뺀다.

예제 12.5 표본화 시계의 어긋남

EEG를 5 kHz로 기록하고 슬라이스 간격이 57.037 ms다. (가) 슬라이스 하나는 몇 표본인가? (나) 슬라이스 시작을 가장 가까운 표본에 맞춘다면, 표본 이하 어긋남은 몇 슬라이스마다 한 바퀴 도는가? (다) 25개 구간을 평균하는 템플릿에는 어떤 어긋남들이 섞이는가?

풀이 (가) $57.037 \text{ ms} \times 5 \text{ 표본/ms} = 285.185$ 표본이다. (나) 슬라이스마다 0.185 표본씩 밀리므로 $1/0.185 \approx 5.4$ 슬라이스마다 한 표본만큼 밀린다. 가장 가까운 표본에 맞추면 어긋남이 -0.5에서 +0.5 표본 (± 0.1 ms) 사이를 5.4 슬라이스 주기로 돈다. (다) 25개 구간이면 이 주기를 네 번 넘게 돌므로, 템플릿은 -0.1 ms에서 +0.1 ms의 모든 어긋남이 평균된 흐린 모양이다. 어느 구간에서 빼도 뽀족파 부분이 맞지 않는다. 3 mV 인공물의 0.3 %만 남아도 9 μ V이고, 이것이 그림의 잔차 8.9 μ V와 같은 크기다.

심전도 인공물

BCG는 심전도 R파 약 0.2 s 뒤에 나타나므로 심전도 채널로 시점을 잡는다. 스캐너 안의 심전도도 경사 인공물과 자기 유체 효과로 일그러지므로, R파 검출을 눈으로 확인해야 한다. 그림 12.6 다·라에서 BCG(표준편차 17 μ V)는 21개 박동 평균을 빼면 잔차 5.5 μ V로 준다. 남는 잔차에는 두 출처가 있다. 하나는 박동마다 다른 크기(이 시뮬레이션에서 12 %)와 길이(4 %)다. 다른 하나는 템플릿에 섞여 들어간 EEG다. EEG 표준편차 11 μ V를 21개 평균하면 $11/\sqrt{21} \approx 2.4 \mu$ V가 남고, 이만큼이 매 박동에서 빠진다.

박동마다의 변화를 따라가려고, 구간 행렬의 주성분 몇 개를 박동마다 맞추어 빼는 **최적 기저 집합(optimal basis set, OBS)**이나 ICA(9장)를 쓰기도 한다. 이 방법들은 성분을 많이 뺄수록 인공물이 더 지워지지만, 알파파처럼 박동 구간 안에 늘 있는 EEG도 함께 지울 위험이 있다. 무엇을 쓰든 제거 전후의 스펙트럼과 ERP를 비교하고, 스캐너 밖에서 같은 과제로 기록한 EEG와 견주어 보는 것이 좋다.

결합 분석

깨끗해진 EEG를 fMRI와 묶는 방법은 크게 둘이다. **EEG 정보 fMRI 분석**은 EEG에서 사건 시점(뇌전증 극파)이나 시간에 따라 변하는 특징(알파 파워, ERP 진폭의 시행별 변동)을 뽑고, HRF와 합성곱해 5장의

GLM 회귀자로 넣는다. 반대로 **fMRI 제약 EEG 소스 분석**은 fMRI 활성 지도를 11장 역문제의 사전 정보로 쓴다. 두 신호가 같은 신경 활동을 반영한다는 가정이 강하므로, fMRI에는 보이지만 EEG에는 안 보이는 (또는 반대인) 활동이 있을 수 있음을 염두에 둔다.

뇌로 가는 다리: 뇌전증 수술 전 평가의 EEG-fMRI

국소 뇌전증의 수술 전 평가에서, 스캐너 안에서 기록한 발작 사이 극파의 시점을 회귀자로 넣으면 극파와 함께 BOLD가 변하는 영역을 찾을 수 있다. 20-40분 기록에서 극파가 충분히 나와야 하고, 극파가 드물면 분석 자체가 안 된다. 찾은 영역이 두개 내 전극이나 수술 절제 부위와 맞는지가 임상 가치의 기준이다. 이 분석은 인공물 제거의 질에 직접 묶여 있다. BCG 잔차는 심박에 맞춰 0.2 s 간격으로 되풀이되는 날카로운 파형이어서 극파처럼 보일 수 있다. 극파 표시는 인공물 제거 뒤 EEG에서 하되, 원 기록과 심전도를 함께 보며 확인한다. 극파 시점의 BOLD 반응은 표준 HRF보다 빠르거나 늦을 수 있으므로, 여러 지연의 HRF를 함께 넣는 설계가 흔하다.

12.6 다중 모달 융합

해상도가 다른 지도 맞추기

MRI 회백질 지도와 FDG-PET를 복셀마다 비교하려면 먼저 두 지도를 같은 공간, 같은 해상도로 맞춰야 한다. 구조 MRI의 복셀은 약 1 mm이고 PET의 해상도는 FWHM 4-6 mm다. 날카로운 MRI 지도와 흐린 PET 지도를 그대로 상관하면, 상관의 크기가 생리가 아니라 흐림의 차이로 정해진다. 흔한 방법은 MRI 쪽을 PET 해상도까지 흐리는 것이다. 가우스 흐림은 제공해서 더해지므로(물리 2권 3장), 더할 흐림의 FWHM은 $\sqrt{F_{\text{PET}}^2 - F_{\text{MRI}}^2}$ 이다.

예제 12.6 해상도 맞추기

VBM 회백질 지도를 이미 FWHM 4 mm로 평활화했다. 해상도 6 mm인 FDG-PET와 같은 해상도로 맞추려면 얼마의 가우스 커널을 더 씌워야 하는가? 6 mm 커널을 그대로 씌우면 결과는 몇 mm인가?

풀이 $\sqrt{6^2 - 4^2} = \sqrt{20} \approx 4.5$ mm 커널을 더한다. 6 mm를 그대로 씌우면 $\sqrt{4^2 + 6^2} = \sqrt{52} \approx 7.2$ mm로, PET보다 더 흐려진다.

시간 축에서도 같은 문제가 있다. EEG는 ms, BOLD는 수 s, PET는 수십 분의 평균이다. 빠른 모달의 특징을 느린 모달의 시간 눈금으로 옮겨야 한다. EEG 알파 파워를 HRF와 합성곱하고 TR마다 표본화하는 것이 그 예다.

상관 분석과 공동 ICA

가장 단순한 융합은 피험자 사이 상관이다. 복셀마다 회백질 부피와 FDG의 상관을 구하거나, 한 모달을 다른 모달 GLM의 공변량으로 넣는다. 그러나 이 방법은 미리 정한 복셀 쌍만 본다. 해마의 위축과 후대상의 저대사처럼 떨어진 영역 사이의 관계는 놓친다.

공동 ICA(joint ICA)는 피험자마다 두 모달의 특징을 한 줄로 이어 붙이고, 7장의 공간 ICA를 한 번에 푼다 (Calhoun 2006). 핵심 가정은 **두 모달이 같은 피험자 가중치를 공유한다**는 것이다. 성분 하나는 "회백질

지도의 이 패턴과 FDG 지도의 저 패턴이 피험자마다 같은 크기로 함께 나타난다"는 뜻이다.

그림 12.7의 장난감 예에서 피험자 80명(대조 40, 환자 40)마다 회백질 특징 100개와 FDG 특징 100개를 만들었다. 성분 1은 해마 위축과 후대상 저대사를 묶었고 환자에서 가중치가 크다. 성분 2는 전두 위축과 후두 저대사를 묶었고 집단과 무관하다. 두 모달을 각각 크기로 정규화하고, 주성분 2개로 줄인 뒤 ICA를 돌리면 두 성분의 공간 패턴을 상관 0.99 이상으로 되찾는다. 성분 1의 가중치는 집단 차이가 $t = 15.4$, 성분 2는 $t = -0.1$ 이다.




그림 12.7 공동 ICA 장난감 예. (가) 회백질 특징(왼쪽 절반)과 FDG 특징(오른쪽 절반)을 이어 붙인 참 성분 두 개. 성분 1(빨강)은 해마 위축과 후대상 저대사, 성분 2(파랑)는 전두 위축과 후두 저대사를 묶었다. (나) 80명의 데이터에서 공동 ICA가 찾은 성분. 두 성분 모두 참 패턴과 상관이 0.99 이상이다. (다) 성분마다 피험자 가중치. 성분 1만 환자(채운 네모)가 대조(빈 원)보다 크다($t = 15.4$).

흔한 실수. 첫째, 모달 사이 크기 정규화를 빠뜨린다. 한 모달의 분산이 10배 크면 ICA는 그 모달의 구조만 찾고 다른 모달은 덤으로 붙인다. 둘째, 공유 가중치 가정을 결과로 착각한다. 공동 ICA는 정의상 두 모달이 함께 움직이는 성분만 찾으므로, "두 모달이 연결되어 있다"는 결론은 방법의 가정을 다시 말한 것일 수 있다. 모달마다 가중치를 따로 두고 그 상관을 보는 병렬 ICA나 다중 집합 정준 상관 분석(mCCA)이 이 가정을 느슨하게 한다. 셋째, 성분 수와 ICA의 무작위 초깃값에 결과가 흔들린다. 여러 번 돌려 안정한 성분만 보고하는 것이 좋다. 넷째, 성분을 찾은 같은 데이터에서 집단 차이를 검정하면 6장의 순환성 문제가 생길 수 있다. 위 예처럼 집단 정보를 쓰지 않고 성분을 찾은 뒤 검정하는 것이 원칙이다.

🧠 뇌로 가는 다리: 치매 연구의 다중 모달 파이프라인(ADNI)

알츠하이머병 신경영상 계획(ADNI) 같은 대규모 코호트는 한 사람에게 T1 MRI, FLAIR, 아밀로이드 PET, 타우 PET, FDG-PET, 혈액·뇌척수액 생체 지표를 반복해서 얻는다. 아밀로이드(A), 타우(T), 신경 퇴행(N)으로 사람을 나누는 틀에서, 이 장의 단계가 모두 한 파이프라인에 들어간다. 아밀로이드는 센틸로이드, 타우는 브라크 단계 ROI의 SUVR, 신경 퇴행은 MRI 피질 두께나 FDG로 잰다. 여러 사이트와 스캐너가 섞이므로, PET 영상은 공통 해상도로 맞추는 평활화를 거쳐 배포되고, MRI는 3장의 조화 방법으로 사이트 차이를 줄인다. 이런 데이터로 "아밀로이드 양성인 사람에서 타우가 해마 바깥으로 퍼질수록 피질이 얇아진다"는 식의 다중 모달 결론을 낸다. 각 고리마다 부분 용적, 기준 영역, 정합의 오차가 따라오므로, 두 PET 값의 상관관계는 같은 MRI 분할과 같은 부분 용적 오차를 공유한 데서 일부 생길 수 있다.

핵심 정리

핵심 정리

- PET 분석의 순서는 프레임 움직임 보정 → MRI 강체 정합 → MRI 기반 영역 정의 → TAC 추출 → SUVR 또는 동적 모형 → (부분 용적 보정) → 통계다. 선조체 같은 작은 구조에서 3-6 mm 움직임은 BP_{ND} 를 19-24 % 낮출 수 있다. 프레임 안의 움직임과 감쇠 지도 어긋남은 프레임 정합으로 고쳐지지 않는다.
- SRTM은 참조 TAC로 목표 TAC를 맞추어 R_1 , k_2 , $BP_{ND} = k_2/k_{2a} - 1$ 을 구한다. 참조 영역에 특이 결합이 없고, V_{ND} 가 같고, 목표가 한 칸처럼 행동한다고 가정한다. 기저 함수법은 이것을 선형 회귀의 반복으로 바꾼다.
- 복셀 잡음은 로건 도표를 체계적으로 낮춘다(변동계수 40 %에서 13 %). "복셀 지도를 만든 뒤 평균"과 "TAC를 평균한 뒤 적합"은 결과가 다르다.
- 위축은 저대사처럼 보인다. 피질이 3.0 mm에서 2.2 mm로 얇아지면 회백질 ROI 값이 24 % 낮아져, 진짜 20 % 저대사보다 크다. GTM은 ROI 수준 연립방정식 $\mathbf{t} = \mathbf{G}\mathbf{c}$ 를, Müller-Gärtner는 복셀 수준에서 백질 뭉치를 빼고 회백질 마스크로 나눈다. 보정은 분할 오차(± 0.2 mm에서 $\pm 5-10$ %)와 정합 오차(1 mm에서 20 %)를 키운다.
- 센틸로이드는 젊은 정상인 0, 전형적 알츠하이머병 100의 두 점 직선이다. 표준 PiB에서 $CL = 100(SUVR - 1.009)/1.067$ 이고, 새 추적자는 짝 촬영으로 PiB 눈금에 옮긴다. 타우 PET는 브라크 단계 ROI와 비특이 결합 처리가 관건이다.
- 동시 EEG-fMRI의 경사 인공물(mV)과 심탄도 인공물(수십 μV)은 반복을 이용한 평균 인공물 빼기로 지운다. 경사 인공물은 시계 동기화가 없으면 잔차가 EEG만큼 남고, BCG는 박동마다의 변동과 템플릿에 섞인 EEG가 잔차를 남긴다.
- 다중 모달 융합 전에 공간·시간 해상도를 맞춘다. 공동 ICA는 두 모달이 같은 피험자 가중치를 공유한다고 가정하고, 모달 사이 정규화와 성분 수에 결과가 흔들린다.

방법 절 점검표

방법 절 점검표

- 프레임 구성과 움직임 보정 방법을 밝혔는가? 프레임별 움직임 크기를 조건이나 집단별로 보고했는가? 감쇠 지도의 어긋남을 어떻게 처리했는가?
- PET-MRI 정합 방법과 정합 확인 절차, ROI 정의(분할 도구, 아틀라스)와 참조 영역의 선택 근거가 있는가?
- 정량 지표가 SUVR이라면 시간 창과 기준 영역을, 동적 모형이라면 모형(SRTM, 로건, MRTM2 등), 적합 시작 시간 t^* , k_2' 처리를 적었는가?
- 파라메트릭 지도를 썼다면 복셀 잡음에 따른 치우침을 어떻게 다뤘는가? 집단마다 계수율이나 잡음이 다르지 않은가?
- 부분 용적 보정을 했다면 방법(Meltzer, Müller-Gärtner, GTM 등), 가정한 PSF, 보정 전 결과를 함께 보고했는가?
- 아밀로이드라면 센틸로이드 변환식과 파이프라인 재현 확인 결과를, 타우라면 브라크 ROI 정의와 비특이 결합 영역 처리 방법을 밝혔는가? 양성 문턱의 출처는 어디인가?
- 동시 EEG-fMRI라면 시계 동기화, 경사·BCG 인공물 제거 방법과 매개변수(평균 구간 수, 성분 수), 제거 뒤 품질 확인을 보고했는가?
- 다중 모달 융합이라면 해상도 맞춤, 모달 사이 정규화, 성분 수 선택과 안정성 확인, 성분 추정과 검정에 같은 정보를 쓰지 않았는지를 확인했는가?

확인 문제

확인 문제

1. 예제 12.1의 선조체 ROI에서 머리가 촬영 내내 4 mm 밀려 있었다면, 특이 신호는 움직임이 없을 때의 몇 %만 남는가? 움직임이 없을 때 BP_{ND} 가 2.24였다면 대략 얼마로 보이겠는가?
2. SRTM 적합으로 $R_1 = 0.9$, $k_2 = 0.36$ /분, $k_{2a} = 0.09$ /분을 얻었다. BP_{ND} 와 k'_2 는? 다른 영역에서 구한 k'_2 가 0.25 /분이었다면 무엇을 의심해야 하는가?
3. 복셀별 로건 지도가 같은 영역의 ROI TAC로 구한 값보다 체계적으로 낮은 이유를 설명하라. 이 치우침이 집단 비교에서 문제가 되는 상황을 하나 들어라.
4. 두 영역 GTM에서 $G = \begin{pmatrix} 0.6 & 0.25 \\ 0.2 & 0.75 \end{pmatrix}$, 측정 ROI 평균이 회백질 2.0, 백질 1.2다. 참 농도를 구하라.
5. 표준 PiB 분석에서 SUVR 1.25인 사람의 센틸로이드는? 이 사람을 양성으로 볼지는 어떤 문턱을 쓰느냐에 따라 어떻게 달라지는가?
6. BCG를 이웃 박동 21개의 평균으로 지웠다. EEG 표준편차가 11 μV 라면 템플릿에 섞인 EEG 때문에 매 박동에서 얼마의 EEG가 잘못 빠지는가? 박동 수 k 를 키우면 이 몫은 줄지만 무엇이 나빠지는가?
7. 공동 ICA에서 FDG 특징의 분산이 회백질 특징보다 10배 크게 들어갔다. 결과가 어떻게 달라지겠는가? 어떻게 막는가?
8. 환자군에서 FDG 회백질 ROI 값이 15 % 낮았고 같은 영역 피질 두께가 10 % 얇았다. "시냅스 활동이 15 % 줄었다"고 쓰기 전에 해야 할 분석을 둘 이상 들어라.

확인 문제 풀이

확인 문제 풀이

1. $0.488/0.742 = 0.658$ 로 특이 신호의 약 66 %만 남는다. BP_{ND} 는 특이 신호의 비에 거의 비례하므로 $2.24 \times 0.66 \approx 1.5$ 로 보인다. 이 사람의 참값은 그대로 3이다.
2. $BP_{ND} = 0.36/0.09 - 1 = 3.0$, $k'_2 = 0.36/0.9 = 0.40$ /분이다. k'_2 는 참조 영역의 성질이라 영역마다 같아야 한다. 값이 크게 다르면 그 영역에서 SRTM 가정(한 칸처럼 행동, V_{ND} 가 같음)이 깨졌거나 잡음과 움직임 때문에 적합이 불안정한 것이다. 신뢰할 만한 영역의 k'_2 로 고정한 2단계 방법을 고려한다.
3. 로건 도표의 가로축은 참조 TAC 적분을 잡음 섞인 목표 TAC로 나눈 값이라 가로축에 잡음이 들어간다. 설명변수에 잡음이 있으면 회귀 기울기가 0 쪽으로 줄어든다. 복셀은 잡음이 커서 치우침이 크고, 먼저 평균한 ROI TAC는 잡음이 작아 치우침이 작다. 예를 들어 환자군의 주사량이 적거나 움직임 때문에 프레임을 더 버렸다면, 환자군의 복셀 잡음이 더 커서 결합이 같아도 BP_{ND} 가 낮게 나온다.
4. 행렬식은 $0.6 \times 0.75 - 0.25 \times 0.2 = 0.40$ 이다. $g = (2.0 \times 0.75 - 0.25 \times 1.2)/0.40 = 1.2/0.40 = 3.0$, $w = (0.6 \times 1.2 - 0.2 \times 2.0)/0.40 = 0.32/0.40 = 0.8$ 이다.
5. $100 \times (1.25 - 1.009)/1.067 = 22.6$ CL이다. 약 12 CL 문턱이면 양성, 24-30 CL 문턱이면 음성이다. 두 문턱 사이의 사람은 흔히 "경계" 또는 "초기 축적"으로 따로 다루며, 정량 오차 수 %로도 분류가 바뀐다.
6. $11/\sqrt{21} \approx 2.4$ μV 가 매 박동에서 함께 빠진다. k 를 키우면 이 몫은 줄지만, 템플릿이 더 긴 시간(박동 수십 개, 수십 초)의 평균이 되어 심박 변화나 머리 움직임에 따른 BCG 모양 변화를 따라가지 못한다.

그만큼 인공물 잔차가 커진다.

7. ICA가 분산이 큰 FDG 쪽의 구조에 끌려가, 성분이 거의 FDG 패턴만으로 정해지고 회백질 쪽은 덩으로 붙는다. 회백질만의 구조는 잘 드러나지 않는다. 모달마다 전체 크기(노름)나 분산으로 나누어 같은 무게로 맞춘 뒤 이어 붙인다. 정규화 방식에 결과가 흔들리는지도 확인한다.
8. (1) MRI 분할로 부분 용적 보정(GTM, Müller-Gärtner 등)을 하고 보정 전후 결과를 함께 본다. (2) 회백질 부피나 두께를 공변량으로 넣은 분석을 한다. (3) 정합과 분할의 질을 확인하고 정합 오차에 대한 민감도를 본다. (4) 공동 ICA나 상관 분석으로 위축과 공유되지 않는 FDG 성분이 있는지 본다. 이 장의 팬텀에서는 피질이 10 % 얇아지자(3.0 mm에서 2.7 mm) 대사가 그대로인데도 회백질 ROI 값이 약 10 % 낮아졌다. 관찰된 15 % 저하의 상당 부분이 위축일 수 있다.

다음 장으로

이 장에서는 PET 영상이 숫자가 되기까지의 단계와, 두 모달을 함께 쓰는 방법을 보았다. 움직임 몇 mm, 정합 1 mm, 기준 영역 하나, 성분 수 하나가 결과를 효과 크기만큼 바꿀 수 있었다. 이런 선택이 수십 개 쌓이면 같은 데이터에서도 다른 결론이 나온다. 13장에서는 이 문제를 정면으로 다룬다. 뇌영상으로 개인을 예측하는 기계학습 모형, 교차 검증과 데이터 누설, 표본 크기와 효과 크기의 현실, 분석 유연성을 드러내는 다중 우주 분석, 그리고 결과를 다른 사람이 재현할 수 있게 하는 BIDS, 컨테이너, 사전 등록을 본다.

13장 기계학습, 재현성, 열린 과학

이 장에서 배울 것 뇌 특징으로 진단이나 점수를 예측하는 모형(정칙화 회귀와 분류기)을 세우고 평가하는 법, 교차 검증이 데이터 누설로 무너지는 경로, 표본 크기가 정확도와 효과 크기 추정을 얼마나 흐트러는지, 분석 유연성과 다중 우주 분석, 그리고 결과를 남이 다시 만들 수 있게 하는 작업 방식과 임상 적용의 조건. **뇌 연구자에게 왜 필요한가** "fMRI 연결성으로 우울증을 85 % 정확도로 분류했다"는 문장은 표본 크기, 검증 방식, 누설 여부를 모르면 읽을 수 없다. 이 장의 시뮬레이션은 순수한 잡음에서도 97 % 정확도가 나오고, 참 상관 0.1이 작은 표본에서 0.47로 보고되는 과정을 보여 준다. 박사과정 연구를 설계할 때 가장 먼저 내리는 결정들이 여기에 있다.

☞ 중고등 복습: 미지수와 방정식, 그리고 시험 문제 유출

미지수가 2개인 연립방정식은 식이 2개 있으면 답이 하나로 정해진다. 식이 1개뿐이면 답이 직선 위에 무수히 많다. 미지수가 식보다 많으면 "식을 모두 만족하는 답"은 언제나 있지만, 그중 어느 것이 참인지는 식만으로 알 수 없다. 뇌영상 예측에서는 미지수(특징마다 붙는 가중치)가 수천-수십만 개이고 식(참가자)은 수십-수백 개다. 그래서 훈련 데이터를 완벽하게 맞히는 모형은 늘 만들 수 있다. 그 모형이 새 사람에게도 맞는지가 문제다. 시험 문제가 미리 새어 나가면 점수는 실력을 재지 못한다. 기계학습의 **데이터 누설(data leakage)** 이 바로 이것이다. 평가에 쓸 데이터의 정보가 모형을 만드는 과정 어딘가에 스며들면, 정확도는 모형이 아니라 유출을 쥔다. 6장의 순환성(double dipping)과 같은 문제를 예측의 언어로 다시 쓴 것이다.

13.1 예측 모형

설명에서 예측으로

5장의 GLM은 "이 복셀의 신호가 조건에 따라 달라지는가"를 묻는다. 복셀 하나하나가 결과 변수이고, 설계 행렬이 설명 변수다. 예측 모형은 방향을 뒤집는다. 사람마다 뇌 특징 수백-수천 개(ROI 부피, 연결성 행렬의 칸, 복셀 값)를 설명 변수로 놓고, 진단이나 인지 점수 하나를 결과로 맞힌다. 결과가 연속값이면 **회귀(regression)**, 범주면 **분류(classification)** 다.

목표도 다르다. GLM은 효과가 0이 아니라는 증거를 찾는다. 예측 모형은 **새 사람**에게서 얼마나 잘 맞히는지, 곧 **일반화 성능(generalization performance)** 을 쥔다. 훈련에 쓴 사람을 다시 맞히는 것은 성능이 아니다. 이 구분이 이 장 전체를 끌고 간다.

정칙화: 가중치를 누른다

특징 수 p 가 사람 수 n 보다 많으면 최소제곱 해가 하나로 정해지지 않는다. 복습 상자의 "식보다 많은 미지수"다. 그래서 가중치의 크기에 벌점을 준다. 가장 흔한 것이 **능형 회귀(ridge regression)** 다.

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \lambda \|\mathbf{w}\|^2 \implies \hat{\mathbf{w}} = \mathbf{X}^\top (\mathbf{X}\mathbf{X}^\top + \lambda \mathbf{I})^{-1} \mathbf{y}$$

X 는 사람 $\times$ 특징 행렬, y 는 결과, λ 는 **정칙화 세기**다. 첫 항은 데이터를 맞히려는 요구, 둘째 항은 가중치를 작게 하려는 요구다. 오른쪽 끝은 $n \times n$ 행렬만 풀면 되므로 특징이 수만 개여도 빠르다. 물리 2권 11장에서 MEG 역문제를 풀 때 쓴 최소 노름 정칙화와 같은 식이다. 소스가 특징으로, 센서가 사람으로 바뀌었을 뿐이다.

가중치의 절댓값 합에 벌점을 주면 **LASSO**가 된다. 많은 가중치를 정확히 0으로 만들어 특징을 고르는 효과가 있다. 둘을 섞은 것이 **엘라스틱 넷(elastic net)**이다. 분류에서는 **서포트 벡터 기계(support vector machine, SVM)**가 오래 쓰였다. 두 집단 사이의 경계 가운데 가장 가까운 점들과의 여백이 가장 넓은 것을 고른다. 선형 SVM과 능형 분류기, 로지스틱 회귀는 뇌영상 데이터에서 성능이 대개 비슷하다. 모형 종류보다 검증 방식과 표본 크기가 결과를 훨씬 크게 바꾼다.

그림 13.1는 특징 300개, 훈련 200명으로 인지 점수를 예측한 시뮬레이션이다. 참 신호는 분산의 절반을 설명한다. λ 가 거의 0이면 훈련 데이터는 완벽히 맞지만($R^2 = 1$) 새 데이터의 R^2 는 -0.37 로, 평균으로 찍는 것보다 못하다. $\lambda \approx 245$ 에서 새 데이터 R^2 가 0.16 으로 가장 높다. 이론 최고 0.5 에는 한참 못 미친다. 200명으로는 가중치 300개를 제대로 추정할 수 없기 때문이다.




그림 13.1 능형 회귀의 정칙화. 특징 300개, 훈련 200명, 참 신호가 분산의 50 %를 설명하는 합성 데이터다. (가) λ 가 작으면 훈련 R^2 는 1에 가깝지만 새 데이터(2000명)의 R^2 는 음수다. 알맞은 λ 에서 일반화 성능이 가장 높고, λ 가 너무 크면 둘 다 떨어진다. (나) 참 가중치와 추정 가중치. 작은 λ (회색)의 추정은 크게 흩어지고, 최적 λ (파랑)는 0 쪽으로 눌린다. 어느 쪽이든 개별 가중치는 참값을 거의 따라가지 못한다.

예제 13.1 능형 회귀가 가중치를 줄이는 정도

표준화된 특징 하나(평균 0, 분산 1)와 결과로 $n = 100$ 명을 모았다. 보통 최소제곱 기울기는 0.30이다. (가) $\lambda = 100$ 인 능형 회귀의 기울기는? (나) $n = 1000$ 명이면 같은 λ 에서 기울기는?

풀이 특징이 하나면 $\hat{w} = \sum x_i y_i / (\sum x_i^2 + \lambda)$ 다. 분산이 1이므로 $\sum x_i^2 \approx n$ 이고, 최소제곱 기울기는 $\sum x_i y_i / n = 0.30$ 이다. (가) $\hat{w} = 0.30 \times 100 / (100 + 100) = 0.15$. 절반으로 눌린다. (나) $0.30 \times 1000 / 1100 \approx 0.27$. 데이터가 많을수록 같은 벌점의 영향이 작아진다. 정칙화는 "데이터가 부족한 만큼 0 쪽으로 당기는" 장치다. 2장의 혼합 효과 모형이 데이터가 적은 사람의 추정을 집단 평균 쪽으로 당긴 것과 같은 생각이다.

해석 가능성

예측이 잘 되면 다음 질문은 "뇌의 어디가 예측에 기여했는가"다. 여기서 조심할 점이 셋이다.

첫째, [그림 13.1](#) 나에서 보듯 개별 가중치는 불안정하다. 표본을 조금 바꾸면 크게 달라진다. 부트스트랩이나 교차 검증 접힘마다 가중치가 얼마나 일관되는지를 함께 보고해야 한다. 둘째, 선형 모형의 가중치는 "그 특징이 결과와 관련 있다"는 뜻이 아니다. 잡음을 상쇄하려고 결과와 무관한 특징에 큰 가중치가 붙을 수 있다. 예를 들어 두 ROI가 같은 움직임 잡음을 공유하면, 모형은 한 ROI에서 다른 ROI를 빼서 잡음을 지운다. 이때 결과와 무관한 ROI도 큰 음의 가중치를 받는다. 가중치를 공분산으로 되돌린 **활성 패턴(activation pattern)** 을 따로 그려야 해석할 수 있다. 셋째, 예측에 쓰인 특징이 질환의 원인이라는 뜻은 아니다. 머리 움직임, 약물, 스캐너가 진단과 엮여 있으면 모형은 그것을 배운다(13.2절).

뇌로 가는 다리: 연결체 기반 예측

휴지기 fMRI 연결성 행렬은 영역 268개만 써도 칸이 $268 \times 267/2 = 35,778$ 개다. HCP 데이터를 쓴 초기 연구들은 이 칸들로 유동 지능 같은 점수를 예측해 관측값과 예측값의 상관 약 0.2-0.5를 보고했다. 그러나 표본이 크고 검증이 엄격할수록 보고되는 상관이 줄어드는 경향이 있다. 특징이 수만 개이고 사람이 수백 명이면, 7장의 연결성 혼입 요인(움직임, 각성 상태)과 이 장의 표본 변동이 모두 정확도에 들어간다.

13.2 교차 검증과 데이터 누설

교차 검증

새 사람을 계속 모을 수는 없으므로, 가진 데이터를 나눠 일부로 훈련하고 나머지로 평가한다. 데이터를 K 개 **접힘(fold)** 으로 나눠 하나씩 돌아가며 평가에 쓰는 것이 **K 겹 교차 검증(K -fold cross-validation)** 이다. 5겹이나 10겹이 흔하다. 한 사람씩 빼는 LOOCV는 추정의 흔들림이 커서 권하지 않는다.

교차 검증의 전제는 하나다. **평가 접힘은 모형이 만들어지는 모든 단계에서 처음 보는 데이터여야 한다.** 특징 선택, 표준화(z 점수), 차원 축소(PCA), 결측치 대체, 사이트 조화(3장의 ComBat), 하이퍼파라미터 선택이 모두 "모형을 만드는 단계"다. 하나라도 전체 데이터로 하면 누설이다.

특징 선택 누설

가장 흔하고 가장 큰 누설은 특징 선택이다. 전체 데이터에서 두 집단 차이가 큰 특징을 먼저 고르고, 그 특징으로 교차 검증을 돌리는 경우다. [그림 13.2](#) 는 40명(환자 20, 대조군 20)에게 순수 잡음 특징 5000개를 주고 이 실수를 재현한 것이다. 참 정확도는 50 %다.

- 전체 데이터로 상위 50개를 먼저 고르면 평균 정확도가 **97.8 %** 다.
- 같은 선택을 훈련 접힘 안에서만 하면 평균 50.2 %다. 반복마다 35-65 % 사이를 오간다.

후보 특징이 많을수록 우연히 집단을 가르는 특징도 많아서 누설이 커진다([그림 13.2](#) 나). 후보가 100개면 약 69 %, 1000개면 약 92 %, 1만 개면 약 98 %다. 후보가 50개뿐이라 고를 것이 없으면 누설도 없다. 뇌영상은 후보가 수만-수십만 개이므로 이 누설에 가장 취약한 분야다.




그림 13.2 특징 선택 누설. 40명에게 순수 잡음 특징을 주고 상위 50개를 골라 능형 분류기로 5겹 교차 검증을 했다. (가) 특징 5000개, 200번 반복. 전체 데이터로 먼저 고르면(빨강) 정확도가 거의 100 %에 몰리고, 훈련 집합 안에서 고르면(파랑) 우연 수준 주변에 퍼진다. (나) 후보 특징이 많을수록 누설 정확도가 오른다. 띠는 반복 사이 표준편차다.

다음 코드는 이 실험을 numpy만으로 한 번 돌린다. `leak=True`와 `False`의 차이는 `top_k`에 넘기는 데이터 한 줄뿐이다.

```
import numpy as np

rng = np.random.default_rng(0)
n, p, k = 40, 5000, 50
X = rng.standard_normal((n, p)) # 순수 잡음 '뇌 특징'
y = np.repeat([1.0, -1.0], n // 2) # 환자 +1, 대조군 -1

def top_k(X, y, k):
    # 두 집단 평균 차가 큰 특징 k개
    d = X[y > 0].mean(0) - X[y < 0].mean(0)
    return np.argsort(-np.abs(d))[:k]

def cv_acc(X, y, leak):
    hit, idx = 0, rng.permutation(n)
    for te in np.array_split(idx, 5): # 5겹 교차 검증
        tr = np.setdiff1d(idx, te)
        s = top_k(X, y, k) if leak else top_k(X[tr], y[tr], k)
        A = X[tr][:, s]
        w = A.T @ np.linalg.solve(A @ A.T + np.eye(len(tr)), y[tr]) # 능형 회귀
        hit += np.sum(np.sign(X[te][:, s] @ w) == y[te])
    return hit / n

print(cv_acc(X, y, leak=True), cv_acc(X, y, leak=False))
```

이 시드로 돌리면 누설 쪽은 0.95, 올바른 쪽은 0.375가 나온다. 올바른 쪽이 50 %보다 한참 낮은 것도 정상이다. 40명짜리 교차 검증은 우연만으로 그만큼 흔들린다(13.3절).

예제 13.2 40명에서 우연이 만드는 정확도

40명(20 대 20)을 분류해 정확도 65 %를 얻었다. 모형이 아무것도 배우지 못했을 때 이만큼 나올 확률은? 이항 분포로 어렵하랴.

풀이 맞힌 수가 이항 분포 $B(40, 0.5)$ 를 따른다고 보면 $P(\text{맞힘} \geq 26) \approx 0.040$ 이다. 65 % (26/40)가 겨우 $p < 0.05$ 경계다. 100명이려면 59 % 이상일 확률이 약 0.044다. 교차 검증의 접힘들은 같은 데이터를 돌려 쓰므로 서로 독립이 아니고, 실제 귀무 분포는 이항 분포보다 넓다. 그래서 표지를 섞어 전체 교차 검증을 수백-수천 번 다시 돌리는 **순열 검정**(6장)으로 p 값을 구하는 것이 표준이다.

하이퍼파라미터와 중첩 교차 검증

특징 수, λ , SVM의 비용 상수 같은 **하이퍼파라미터(hyperparameter)**도 데이터로 고른다. 여러 설정을 교차 검증으로 비교한 뒤 가장 좋은 점수를 그대로 보고하면, 그 점수는 "여러 번 던져 가장 잘 나온 주사위 눈"이다. **그림 13.3** 나는 순수 잡음 데이터에서 24개 설정(특징 수 6가지 $\times$ λ 4가지) 가운데 최고 점수를 보고한 결과다. 특징 선택은 접힘 안에서 올바르게 했는데도 평균 정확도가 62 %로 부풀었다.

해법은 **중첩 교차 검증(nested cross-validation)**이다(**그림 13.3** 가). 바깥 고리는 성능 평가만 한다. 바깥 접힘마다 훈련 부분을 다시 나눠 안쪽 고리에서 설정을 고르고, 고른 설정으로 훈련 부분 전체를 다시 적합한 뒤 바깥 평가 접힘을 한 번만 맞힌다. 같은 잡음 데이터에서 중첩 교차 검증의 평균은 52 %였다. 계산량은 크게 늘었다. 이 시뮬레이션에서 반복 한 번에 바깥 5 $\times$ 안쪽 4 $\times$ 설정 24 = 480번 적합했다.




그림 13.3 중첩 교차 검증. (가) 바깥 고리의 평가 접힘(빨강)은 끝까지 손대지 않는다. 바깥 훈련 부분만 다시 나눠 안쪽 고리에서 설정을 고른다. (나) 40명, 잡음 특징 2000개로 100번 반복했다. 24개 설정 중 가장 좋은 교차 검증 점수를 그대로 보고하면(빨강) 평균 62 %, 중첩 교차 검증(파랑)은 평균 52 %다.

사이트 누설과 사람 누설

누설은 특징 선택만이 아니다. 데이터의 **구조**가 평가 접힘과 훈련 접힘을 잇는 경우도 있다.

사이트 누설: 여러 병원 데이터를 합치면 스캐너마다 영상 강도, 잡음, 왜곡이 다르다. 사이트마다 환자 비율도 다르기 쉽다. 그러면 모형은 질환 대신 스캐너를 배워도 점수를 탄다. **그림 13.4**는 질환 신호가 전혀 없고 사이트 차이만 있는 특징으로 이를 재현했다. 사이트 A는 환자 75 %, 사이트 B는 25 %다. 사람을

무작위로 섞은 5겹 교차 검증의 균형 정확도는 71 %다. 한 사이트로 훈련하고 다른 사이트로 평가하는 **사이트 남겨 두기(leave-site-out)** 검증에서는 51 %로 내려간다. 훈련 집합에서 구한 사이트 평균을 빼고 검증해도 50 %다.

조화를 할 때도 같은 원칙이 적용된다. 이 시뮬레이션에서 사이트 평균을 **전체 데이터**로 구해 빼고 무작위 5겹을 돌리면 균형 정확도가 약 37 %로 우연보다 크게 떨어졌다. 평가 집합의 사람이 자기 사이트 평균에 들어가 있기 때문에 생기는 왜곡이다. ComBat 같은 조화도 훈련 집합에서 추정하고 평가 집합에는 그 추정을 적용해야 한다.




그림 13.4 사이트 누설. 질환 신호는 없고 사이트 차이만 있는 특징 200개, 사이트마다 60명. (가) 첫 두 주성분에서 두 사이트가 갈리고, 사이트 A(○)에 환자(빨강)가 많다. (나) 200번 반복한 균형 정확도의 평균과 5-95 % 범위. 무작위로 섞은 교차 검증은 71 %로 질환을 맞히는 것처럼 보이지만, 사이트를 남겨 두거나 훈련 집합 안에서 사이트 평균을 빼면 우연 수준이다.

사람 누설: 한 사람의 여러 회차, 여러 시행, 여러 슬라이스가 훈련과 평가에 나뉘어 들어가면, 모형은 사람을 알아보는 것만으로 점수를 탄다. 쌍둥이와 형제가 많은 데이터(HCP)에서는 가족 단위로 집합을 나눠야 한다. 영상 슬라이스 단위로 섞은 딥러닝 논문에서 비현실적으로 높은 정확도가 나온 사례가 많다.

흔한 오해: 교차 검증을 했으니 과적합은 없다

교차 검증은 절차가 올바를 때만 과적합을 잡는다. 전체 데이터로 특징을 고르거나, z점수를 매기거나, PCA를 돌리거나, 여러 모형 중 가장 좋은 점수를 고르면 교차 검증 점수는 부풀다. 더 은밀한 누설도 있다. 같은 데이터로 여러 해 동안 파이프라인을 바꿔 가며 교차 검증 점수가 오를 때까지 손보면, 연구자 자신이 바깥 고리의 하이퍼파라미터 선택기가 된다. 이것을 막는 방법은 하나다. 분석을 시작하기 전에 **잠가 둔 시험 데이터(held-out test set)** 나 완전히 독립된 외부 표본을 정해 두고, 마지막에 한 번만 연다.

13.3 표본 크기와 효과 크기

정확도의 오차 막대

교차 검증 정확도도 표본 통계량이다. 표본이 작으면 크게 흔들린다. Varoquaux(2018)는 뇌영상 분류 연구를 모아, 100명 안팎의 표본에서 교차 검증 정확도의 오차 막대가 약 $\pm 10\%p$ 라는 것을 보였다. 그림 13.5는 같은 결론을 시뮬레이션으로 확인한다. 참 신호가 있어 큰 표본에서는 약 71%까지 맞힐 수 있는 모집단에서 표본을 300번 다시 뽑았다.

- 20명이면 정확도가 35%에서 85%까지(5-95%) 흩어진다.
- 100명이면 54-74%다. 교차 검증 값과 그 모형의 참 정확도 차이의 95% 범위는 약 $\pm 12\%p$ 다.
- 1000명이 되어야 $\pm 3\%p$ 로 줄어든다.

이 흩어짐은 대략 이항 분포 공식 $1.96\sqrt{p(1-p)/n}$ 을 따른다. $p = 0.7$, $n = 100$ 이면 약 $\pm 9\%p$ 다. 작은 표본의 정확도 80%는 60%의 모형에서 우연히 나온 값일 수 있다. 출판 편향이 높은 값만 골라 실으면 문헌 전체가 부른다. 실제로 뇌영상 분류 문헌에서는 표본이 작은 연구일수록 보고된 정확도가 높은 역설적인 경향이 반복해서 관찰되었다.




그림 13.5 교차 검증 정확도의 표본 변동. 특징 20개, 큰 표본에서 약 71%까지 맞힐 수 있는 모집단에서 크기마다 표본을 300번 뽑았다. (가) 점 하나가 한 표본의 5겹 교차 검증 정확도, 검은 선이 95% 범위, 빨간 가로줄은 그 크기에서 훈련한 모형의 참 정확도다. (나) 교차 검증 값과 참 정확도 차이의 95% 범위 반폭. 100명에서 약 $\pm 12\%p$ 이고, 이항 분포 공식(점선)이 좋은 어림이다.

뇌 전체 연관 연구와 승자의 저주

예측이 아닌 단순 연관에서도 같은 문제가 있다. 피질 두께나 연결성 같은 뇌 지표와 인지·정신병리 점수의 상관을 뇌 전체에서 찾는 연구를 **뇌 전체 연관 연구(brain-wide association study, BWAS)**라 한다. Marek 외(2022)는 ABCD, HCP, UK Biobank의 약 5만 명을 써서 이런 연관의 참 크기가 매우 작다는 것을 보였다. 중앙값은 $|r| \approx 0.01$ 이고, 반복해서 재현된 가장 큰 연관도 $r \approx 0.16$ 정도였다. 25명 표본에서는 99% 신뢰 구간이 대략 $r \pm 0.5$ 였다. 표본이 수천 명은 되어야 연관이 안정적으로 재현되었다.

그림 13.6는 참 상관이 0.1인 연관을 여러 표본 크기에서 4000번씩 다시 뽑은 시뮬레이션이다.

- 25명이면 표본 r 의 95 %가 -0.31에서 0.47 사이에 흩어진다. 부호조차 정해지지 않는다.
- 25명에서 양의 방향으로 유의한($p < 0.05$) 결과만 모으면 평균 r 은 0.47로, 참값의 4.7배다. 이때 검정력은 약 6 %다.
- 100명에서도 유의한 결과의 평균은 0.25(2.5배)다. 1000명이 되어야 0.11로 참값에 가까워진다.

유의성 문턱을 넘은 결과만 보면 효과가 체계적으로 부푸는 현상을 **승자의 저주(winner's curse)** 라 한다. 2장에서 검정력이 낮으면 유의한 효과가 부풀려진다고 한 것을 숫자로 본 것이다. Button 외(2013)는 신경과학 연구의 검정력 중앙값이 약 20 % 수준이라고 추정했다. 작은 연구의 유의한 효과를 다음 연구의 검정력 계산에 그대로 쓰면, 다음 연구도 검정력이 모자라게 설계된다.




그림 13.6 참 상관 0.1인 뇌-행동 연관 연구의 표본 변동. (가) 크기마다 표본 300개의 r (빨강은 $p < 0.05$ 로 유의한 것), 파란 띠는 95 % 범위, 빨간 점선은 유의성 문턱이다. 작은 표본에서는 문턱을 넘은 값이 모두 참값보다 훨씬 크다. (나) 유의한 결과만 모은 r 의 평균(빨강)과 검정력(파랑). 25명에서 0.47, 100명에서 0.25이고, 검정력이 80 %를 넘는 1000명 부근에서야 참값 0.1에 가까워진다.

예제 13.3 참 상관 0.1을 찾는 데 필요한 표본

양측 $\alpha = 0.05$, 검정력 80 %로 $r = 0.1$ 을 찾으려면 몇 명이 필요한가? $r = 0.2$ 와 $r = 0.05$ 라면?

풀이 피셔 z 변환 $z = \text{artanh}(r)$ 의 표준오차는 $1/\sqrt{n-3}$ 이다. 그래서 $n \approx [(1.96 + 0.84)/\text{artanh}(r)]^2 + 3$ 이다. $r = 0.1$ 이면 $\text{artanh}(0.1) = 0.1003$ 이므로 $n \approx (2.80/0.1003)^2 + 3 \approx 783$ 명이다. $r = 0.2$ 면 약 194명, $r = 0.05$ 면 약 3137명이다. 효과가 절반이 되면 표본은 약 4배가 든다. 뇌 전체에서 수만 개를 검정하고 6장의 다중비교 보정까지 하면 필요한 표본은 더 커진다. 측정 신뢰도가 낮으면(2장) 관측 상관이 깎여 더 커진다.

학습 곡선과 큰 데이터

예측 모형의 성능은 표본이 커질수록 오른다. 훈련 표본 크기에 따른 성능을 그린 것이 **학습 곡선(learning curve)** 이다(그림 13.7). 특징 500개로 참 신호가 분산의 20 %를 설명하는 점수를 예측했다. 훈련 R^2 는 작은 표본에서 높고 큰 표본에서 내려온다. 새 데이터 R^2 는 500명에서 0.02, 2000명에서 0.09, 1만 명에서 0.16으로 천천히 오른다. 수천 명이 되어도 아직 상한에 닿지 않는다.

결과 변수의 측정 신뢰도도 상한을 정한다. 행동 점수의 신뢰도가 0.5면 설명할 수 있는 분산의 상한이 절반(0.10)으로 줄고, 1만 명에서도 0.06에 머문다. 큰 표본은 신뢰도 낮은 측정을 구해 주지 못한다. 2장의

ICC가 여기서 다시 중요해진다.




그림 13.7 예측 모형의 학습 곡선. 특징 500개, 참 신호가 분산의 20 %를 설명한다. λ 는 훈련 표본 안의 검증 분할로 골랐고, 새 데이터 5000명으로 평가했다. 실선은 새 데이터, 점선은 훈련 데이터의 R^2 다. 행동 측정 신뢰도가 0.5면(빨강) 상한이 0.10으로 줄고, 1만 명에서도 그 상한에 이르지 못한다.

🧠 뇌로 가는 다리: 큰 공개 데이터

표본 크기 문제에 대한 분야의 답은 공동 데이터다. **HCP**(Human Connectome Project)는 건강한 젊은 성인 약 1,200명을 고해상도 다중 모달로 찍었다. **ABCD** 연구는 9-10세 아동 약 1만 1,900명을 미국 21개 사이트에서 모아 10년 동안 추적한다. **UK Biobank**는 중년·노년 수만 명의 뇌영상을 모았고 목표는 10만 명이다. 이 데이터에서는 작은 효과도 정밀하게 썰 수 있지만, 새로운 함정도 생긴다. 표본이 크면 $r = 0.03$ 도 유의하므로 "유의하다"보다 효과 크기와 임상적 의미를 물어야 한다. 사이트가 수십 개이므로 사이트 누설과 조화 문제가 커진다. 참가자가 일반 인구에 가까우므로 중증 환자 집단으로 결과를 바로 옮기기 어렵다. 박사과정 연구라면 큰 데이터에서 가설을 세우고 작은 임상 표본에서 검증하거나, 그 반대로 설계하는 길이 있다.

13.4 분석 유연성

같은 데이터, 다른 결론

머리말에서 소개한 NARPS(Botvinik-Nezer 외 2020)는 같은 과제 fMRI 데이터(108명)를 70개 팀에 주고 미리 정한 가설 9개를 검정하게 했다. 똑같은 파이프라인을 쓴 팀은 둘도 없었다. 일부 가설에서는 팀들이 "유의함"과 "유의하지 않음"으로 크게 갈렸다. 흥미롭게도 문턱을 적용하기 전의 통계 지도들은 서로 상당히 비슷했다. 결론의 차이는 영상의 공간 평활도, 사용한 소프트웨어, 다중비교 보정 방법 같은 선택과 관련되어 있었다. 같은 증거를 문턱과 보정 단계에서 다르게 잘라 낸 셈이다.

이 장 앞부분의 하이퍼파라미터 문제와 같은 구조다. 합리적인 선택지가 단계마다 몇 개씩 있으면 경로의 수는 곱으로 늘어난다. 연구자가 결과를 본 뒤 "가장 그럴듯한" 경로를 고르면, 의도하지 않아도 유의한

쪽으로 기운다. 이것을 **갈림길 정원(garden of forking paths)** 이라 부르고, 의도적으로 $p < 0.05$ 가 될 때까지 바꿔 보는 것을 **p-해킹(p-hacking)** 이라 한다.

다중 우주 분석

해법 가운데 하나는 경로를 하나 고르지 않고 **합리적인 경로를 모두 돌려 함께 보고하는 것**이다. 이것을 **다중 우주 분석(multiverse analysis)** 이라 하고, 결과를 효과 크기 순으로 늘어놓은 그림을 **사양 곡선(specification curve)** 이라 한다.

그림 13.8 는 환자 40명과 대조군 40명의 ROI 연결성을 비교한 합성 데이터에 54개 경로(ROI 3 × 움직임 처리 3 × 이상치 기준 3 × 나이 공변량 2)를 적용했다. 참 효과는 표준화 차 -0.3이고, 환자가 더 많이 움직이며, 움직임은 연결성을 깎는다.

- 표준화 효과는 -0.68에서 -0.32까지 퍼졌고, 54개 중 25개(46 %)만 $p < 0.05$ 였다.
- 움직임을 처리하지 않은 18개 경로는 모두 유의했다. 움직임을 공변량으로 넣거나 많이 움직인 사람을 빼면 유의한 비율이 17-22 %로 떨어졌다.

이 그림은 "이 효과는 있다/없다"보다 많은 것을 말한다. 결과가 어떤 선택에 기대는지가 드러난다. 여기서는 움직임 처리가 결론을 좌우했다. 4장에서 본 움직임과 집단 차이의 혼입이다.




그림 13.8 다중 우주 분석. 같은 합성 데이터(집단당 40명, 참 효과 -0.3)에 54개의 합리적인 분석 경로를 적용했다. 위: 경로마다 표준화 집단 차와 95 % 신뢰 구간을 효과 크기 순으로 늘어놓았다. 빨강은 $p < 0.05$ 다. 아래: 각 경로가 고른 선택지. 움직임을 처리하지 않은 경로는 모두 유의하고, 움직임을 처리한 경로는 대부분 유의하지 않다.

예제 13.4 경로의 수

전처리에서 평활화 3가지(4, 6, 8 mm), 움직임 처리 3가지, 전역 신호 회귀 2가지(한다/안 한다), 통계 문턱 2가지를 고를 수 있다. (가) 경로는 몇 개인가? (나) 경로들이 서로 독립이고 효과가 없다면, 적어도 하나가 $p < 0.05$ 일 확률은?

풀이 (가) $3 \times 3 \times 2 \times 2 = 36$ 개다. (나) $1 - 0.95^{36} \approx 0.84$ 다. 실제 경로들은 같은 데이터를 쓰므로 강하게 상관되어 있어 이보다는 낮다. 그래도 경로를 결과를 본 뒤에 고르면 1종 오류율이 명목 5 %를 크게 넘는다. 경로를 미리 정해 두거나(사전 등록), 모두 보고하거나(다중 우주 분석), 6장처럼 경로 전체에 대한 보정을 해야 한다.

뇌로 가는 다리: 한 연구실 안의 다중 우주

Poldrack 외(2017)는 뇌영상 연구의 재현성을 위협하는 요인으로 낮은 검정력, 분석 유연성, 다중비교, 소프트웨어 오류를 꼽았다. 같은 fMRI 데이터를 FSL, SPM, AFNI로 각각 분석하면 기본 설정의 차이(평활화 방식, 시간 자기상관 모형, 군집 추론)만으로도 결과 지도가 눈에 띄게 달라진다는 비교 연구도 여럿 있다. 연구실 안에서도 같은 일이 일어난다. 선배가 만든 파이프라인을 물려받을 때, 그 안의 수십 가지 설정이 왜 그 값인지 기록이 남아 있는지 확인하는 것이 박사과정의 첫 작업이 될 수 있다.

13.5 재현 가능한 작업

세 가지 "다시 하기"

비슷하지만 다른 개념을 구분하자. **재현 가능성(reproducibility)**은 같은 데이터와 같은 코드로 같은 결과가 나오는가다. **반복 가능성(replicability)**은 새 데이터를 같은 방법으로 모았을 때 같은 결론이 나오는가다. **강건성(robustness)**은 같은 데이터를 합리적인 다른 방법으로 분석해도 결론이 유지되는가다. 13.3절은 반복 가능성을, 13.4절은 강건성을 다뤘다. 재현 가능성은 가장 기본인데도 의외로 자주 실패한다. 같은 연구실에서 1년 전 결과를 다시 만들지 못하는 일이 흔하다.

데이터: BIDS

1장에서 본 **BIDS**(Brain Imaging Data Structure, Gorgolewski 외 2016)는 폴더 이름, 파일 이름, JSON 메타데이터의 규칙이다. `sub-01/ses-01/func/sub-01_ses-01_task-rest_bold.nii.gz`처럼 파일 이름만 보고 무엇인지 알 수 있다. EEG, MEG, PET, 확산 MRI로도 확장되었다. BIDS의 진짜 이점은 도구다. BIDS 검사기가 구조 오류를 잡고, fMRIPrep과 MRIQC 같은 **BIDS 앱**이 폴더 하나를 받아 표준 처리를 한다. OpenNeuro는 BIDS 데이터를 공개하는 저장소이고, NeuroVault는 문턱을 적용하지 않은 통계 지도를 공유하는 곳이다(6장).

코드와 환경: 버전 관리와 컨테이너

분석 코드는 **git**으로 버전을 관리하고, 논문의 결과는 특정 커밋에서 나온 것이라고 적는다. 큰 영상 파일은 git에 넣기 어려우므로 DataLad 같은 도구로 데이터 버전을 함께 관리한다.

같은 코드라도 소프트웨어 버전, 운영 체제, 수치 라이브러리가 바뀌면 결과가 미세하게, 때로는 크게 달라진다. 정합과 분할처럼 반복 최적화를 하는 단계는 부동소수점의 작은 차이가 다른 국소 최솟값으로 이어질 수 있다. **컨테이너(container)** 는 운영 체제와 프로그램 전체를 한 덩어리로 묶어 어디서나 같은 환경을 만든다. 개인 컴퓨터에서는 Docker를, 고성능 계산 클러스터에서는 Apptainer(옛 Singularity)를 흔히 쓴다. fMRIPrep, QSIprep 같은 도구는 컨테이너 형태로 배포된다. 무작위성이 있는 단계(교차 검증 분할, 순열 검정, 확률적 트랙토그래피)는 난수 시드를 고정하고 기록한다.

계획: 사전 등록과 등록 보고서

사전 등록(preregistration) 은 데이터를 보기 전에 가설, 표본 크기와 그 근거, 주된 분석 경로, 제외 기준을 공개 저장소(OSF 등)에 시간 도장과 함께 올려 두는 것이다. 사전 등록은 탐색 분석을 금지하지 않는다. 탐색과 확증을 구분해 보고하게 할 뿐이다. 예측 모형에서는 시험 데이터를 잠가 두는 것과 같은 역할을 한다.

등록 보고서(registered report) 는 한 걸음 더 나간다. 서론과 방법을 데이터 수집 전에 학술지에 내고 심사를 받는다. 심사를 통과하면 결과와 상관없이 게재가 원칙적으로 약속된다. 출판 편향과 승자의 저주를 구조적으로 막는 방법이다. 기존 공개 데이터(ABCD, UK Biobank)를 쓰는 연구도, 해당 변수를 아직 보지 않았다는 조건으로 등록 보고서를 낼 수 있다.

뇌로 가는 다리: 재현 가능한 박사 논문의 최소 구성

현실적인 최소 구성은 다음과 같다. 원자료는 BIDS로 정리하고 BIDS 검사기를 통과시킨다. 전처리는 fMRIPrep 같은 공개 파이프라인의 컨테이너 버전을 쓰고, 버전 번호와 설정 파일을 남긴다. 분석 코드는 git 저장소 하나에 두고, 그림 하나하나를 만드는 스크립트를 따로 둔다. 시각 품질 점검(MRIQC 보고서)과 제외 결정은 이유와 함께 표로 남긴다. 주된 가설과 분석은 사전 등록한다. 이렇게 하면 심사자가 "평활화 폭을 바꾸면 어떻게 되는가"라고 물을 때 몇 시간 안에 답할 수 있다. 이 장의 모든 그림도 같은 원칙으로 만들었다. 스크립트 하나가 고정된 시드로 그림 하나를 만든다.

13.6 임상 적용의 조건

외부 검증

교차 검증 성능이 좋아도 임상에 쓰려면 **외부 검증(external validation)** 이 필요하다. 다른 병원, 다른 스캐너, 다른 시기, 다른 환자 구성의 독립 표본에서 성능을 다시 잰다. [그림 13.4](#) 에서 본 것처럼 사이트가 바뀌면 성능이 크게 떨어지는 경우가 많다. 외부 표본에서 성능이 떨어지는 정도 자체가 모형이 무엇을 배웠는지 알려 준다.

정확도보다 중요한 것들

보정(calibration): 모형이 "환자일 확률 80 %"라고 말한 사람들 가운데 실제로 약 80 %가 환자여야 한다. 분류 정확도나 AUC가 높아도 확률이 체계적으로 과장되거나 축소될 수 있다. 사이트나 유병률이 바뀌면 보정이 먼저 깨진다. 예측 확률과 관측 빈도를 구간별로 비교한 보정 곡선을 함께 보고한다.

기저율(base rate): 연구 표본은 대개 환자와 대조군이 반반이지만 실제 진료실은 그렇지 않다. 민감도와 특이도가 같아도 유병률이 낮으면 양성 판정의 상당수가 거짓 양성이다(예제 13.5).

공정성(fairness): 성별, 나이, 인종, 교육 수준, 스캐너에 따라 성능이 다를 수 있다. 훈련 데이터에 적게 들어간 집단에서 성능이 떨어지는 경우가 흔하다. 부분 집단별 성능을 따로 보고해야 한다.

비교 기준: 뇌영상 모형은 나이, 성별, 기존 임상 척도만으로 만든 단순 모형보다 나아야 한다. 영상이 더하는 몫(증분 타당도)이 작다면 비싼 MRI를 찍을 이유가 약하다.

예제 13.5 유병률이 바꾸는 양성 예측도

민감도 80 %, 특이도 80 %인 분류기가 있다. (가) 환자와 대조군이 반반인 연구 표본에서 양성 판정이 참 환자일 확률(양성 예측도)은? (나) 유병률 2 %인 1차 진료 집단에서는? (다) 민감도와 특이도를 모두 90 %로 올리면?

풀이 양성 예측도 = 민감도 $\times$ 유병률 / [민감도 $\times$ 유병률 + (1 - 특이도) $\times$ (1 - 유병률)]이다. (가) $0.8 \times 0.5 / (0.8 \times 0.5 + 0.2 \times 0.5) = 0.80$. (나) $0.016 / (0.016 + 0.196) \approx 0.075$. 양성 판정 13명 중 1명꼴로만 참 환자다. (다) $0.018 / (0.018 + 0.098) \approx 0.16$. 크게 나아져도 여전히 6명 중 5명이 거짓 양성이다. 연구 표본의 "정확도 80 %"는 선별 검사의 쓸모를 말해 주지 않는다.

뇌로 가는 다리: 임상 예측 모형 논문을 읽을 때

치매 전환 예측, 정신증 고위험군의 발병 예측, 뇌전증 수술 결과 예측은 영상 기계학습이 임상에 가장 가까이 간 분야다. 이런 논문에서는 먼저 표본이 실제 사용 집단(예: 기억 클리닉 방문자)과 같은지 본다. 다음으로 외부 검증이 있는지, 보정 곡선과 부분 집단별 성능을 보고했는지, 임상 변수만 쓴 기준 모형과 비교했는지 본다. 12장의 ADNI 같은 연구 코호트에서 훈련한 모형은 선별 기준이 엄격해 동반 질환이 적다. 그래서 실제 진료실 환자에게는 성능이 떨어지기 쉽다.

핵심 정리

핵심 정리

- 예측 모형은 새 사람에게서의 일반화 성능을 잴다. 특징 수가 사람 수보다 많으면 훈련 데이터는 늘 완벽히 맞으므로 정칙화(능형 회귀, LASSO, 엘라스틱 넷, SVM)가 필요하다. 개별 가중치는 불안정하고 해석에 주의가 필요하다.
- 교차 검증에서는 특징 선택, 표준화, PCA, 조화, 하이퍼파라미터 선택을 모두 훈련 집합 안에서 해야 한다. 순수 잡음 5000개, 40명에서 전체 데이터로 특징을 먼저 고르면 정확도가 약 98 %로 나온다.
- 여러 설정 중 최고 점수를 보고하면 잡음에서도 약 62 %가 나온다. 중첩 교차 검증이나 잠가 둔 시험 데이터로 막는다.
- 사이트와 진단이 엮이면 모형은 스캐너를 배운다. 사이트 남겨 두기 검증, 집합 안의 조화, 사람·가족 단위 분할을 쓴다.
- 교차 검증 정확도의 오차 막대는 100명에서 약 $\pm 10\%$ 다(Varoquaux 2018). 정확도는 순열 검정과 함께 보고한다.
- BWAS의 참 연관은 대개 $|r| \leq 0.1$ 수준이다(Marek 2022). 참 $r = 0.1$ 이면 검정력 80 %에 약 780명이 필요하다. 25명에서 유의한 결과의 평균 r 은 참값의 약 5배로 부풀다(승자의 저주).
- 예측 성능은 수천 명까지 계속 오르고, 결과 변수의 신뢰도가 상한을 짚는다.
- 분석 유연성은 같은 데이터에서 다른 결론을 만든다(NARPS). 다중 우주 분석은 결과가 어떤 선택에 기대는지 드러낸다.
- BIDS, 공개 파이프라인과 컨테이너, git, 고정된 난수 시드, 사전 등록과 등록 보고서는 재현 가능성과 반복 가능성을 높인다.
- 임상 적용에는 외부 검증, 보정, 기저율을 고려한 양성 예측도, 부분 집단별 성능, 임상 변수 기준 모형과의 비교가 필요하다.

방법 절 점검표

방법 절 점검표

- 평가 데이터가 모형 만들기의 어느 단계에도 쓰이지 않았는가? 특징 선택, 표준화, PCA, 조화, 하이퍼파라미터 선택이 훈련 집합 안에서 이루어졌는가?
- 하이퍼파라미터를 골랐다면 중첩 교차 검증이나 별도 시험 데이터로 평가했는가? 여러 모형을 비교했다면 몇 개를 시도했는지 밝혔는가?
- 집합을 사람, 가족, 사이트 단위로 나눴는가? 다중 사이트라면 사이트 남겨 두기 성능을 보고했는가?
- 표본 크기는 몇 명이고, 정확도에 신뢰 구간이나 순열 검정 p 값이 있는가? 불균형 집단이라면 균형 정확도나 AUC를 썼는가?
- 보고한 효과 크기가 작은 표본에서 유의성으로 고른 값은 아닌가? 검정력 계산에 쓴 효과 크기의 출처는 어디인가?
- 주된 분석 경로가 사전 등록되었는가? 대안 경로(다중 우주 분석)나 민감도 분석을 보고했는가?
- 데이터(BIDS), 코드, 소프트웨어 버전, 컨테이너, 난수 시드가 공개되거나 기록되었는가?
- 임상 주장을 한다면 외부 검증, 보정, 부분 집단별 성능, 임상 변수 기준 모형과의 비교가 있는가?

확인 문제

확인 문제

1. 한 논문이 피질 두께 15만 꼭짓점 가운데 환자와 대조군 차이가 가장 큰 1000개를 고른 뒤, 그 특징으로 10겹 교차 검증을 해 정확도 88 %를 보고했다(집단당 30명). 무엇이 문제이고, 어떻게 고쳐야 하는가?
2. 표준화한 특징 하나로 $n = 50$ 명의 최소제곱 기울기가 0.4다. $\lambda = 50$ 인 능형 회귀의 기울기는? 정칙화가 이 기울기를 줄이는 이유를 한 문장으로 말하라.
3. 60명을 분류해 정확도 70 %를 얻었다. 교차 검증 정확도의 95 % 오차 막대를 이항 분포 공식으로 어림하라. 이 결과가 "정확도 60 %인 모형"과 구별되는가?
4. 참 상관인 0.15인 연관성을 검정력 80 % (양측 $\alpha = 0.05$)로 찾으려면 몇 명이 필요한가? 50명 연구에서 이 연관성이 유의하게 나왔다면 보고된 r 은 대략 얼마 이상이어야 하는가?
5. 세 병원에서 우울증 환자와 대조군의 휴지기 fMRI를 모았다. 병원 A는 환자 80 %, 병원 B와 C는 30 %다. 무작위 10겹 교차 검증 정확도가 75 %였다. 이 결과를 질환 신호로 읽기 전에 해야 할 분석 두 가지를 들어라.
6. 분석 선택지가 ROI 4가지, 공변량 조합 4가지, 이상치 기준 3가지다. 경로는 몇 개인가? 이 가운데 유의한 하나만 보고하는 것과 다중 우주 분석으로 모두 보고하는 것은 독자에게 무엇이 다른가?
7. 재현 가능성, 반복 가능성, 강건성을 구분하고, 각각을 높이는 실천을 하나씩 들어라.
8. 민감도 85 %, 특이도 90 %인 MRI 기반 알츠하이머병 분류기를 유병률 10 %인 기억 클리닉 방문자에게 쓴다. 양성 예측도는? 이 모형을 임상에 쓰기 전에 무엇을 더 확인해야 하는가?

확인 문제 풀이

확인 문제 풀이

1. 특징을 전체 데이터로 골랐으므로 평가 집합의 정보가 특징 선택에 새었다. 후보가 15만 개면 잡음만으로도 거의 완벽한 정확도가 나올 수 있다(그림 13.2). 특징 선택을 각 훈련 집합 안에서 다시 하고, 고를 특징 수도 안쪽 고리에서 정하는 중첩 교차 검증을 쓴다. 표지를 섞은 순열 검정으로 우연 수준의 분포도 구한다.
2. $0.4 \times 50 / (50 + 50) = 0.2$ 다. 데이터가 주는 정보($\sum x^2 = 50$)와 벌점($\lambda = 50$)이 같은 크기라서, 추정이 0 쪽으로 절반만큼 당겨진다.
3. $1.96\sqrt{0.7 \times 0.3/60} \approx 0.116$ 이므로 약 $\pm 12\%$ p, 곧 58-82 %다. 60 %가 이 범위 안에 있으므로 구별되지 않는다. 실제 교차 검증의 흔들림은 이보다 크다(그림 13.5).
4. $\text{artanh}(0.15) \approx 0.151$ 이므로 $n \approx (2.80/0.151)^2 + 3 \approx 346$ 명이다. 50명에서 $p < 0.05$ 가 되려면 $|r| \geq 0.28$ 정도여야 한다. 유의하게 나왔다면 보고된 r 은 참값의 약 2배 이상이다. 승자의 저주다.
5. (가) 한 병원을 통째로 빼고 나머지로 훈련해 그 병원을 맞히는 사이트 남겨 두기 검증. (나) 병원만으로 진단을 얼마나 맞히는지 보는 기준 모형(병원 표지만 넣은 분류기). 병원 A의 환자 비율만으로도 상당한 정확도가 나온다. 그 밖에 훈련 집합 안에서 조화를 하거나, 병원마다 환자 비율을 맞춘 부분 표본으로 다시 검증할 수 있다.
6. $4 \times 4 \times 3 = 48$ 개다. 하나만 보고하면 독자는 47개의 대안이 있었다는 것도, 그중 몇 개가 유의했는지도 모른다. 다중 우주 분석은 결과의 분포와 결과를 좌우한 선택을 함께 보여 주어, 효과가 특정 선택에 기대는지 판단하게 한다.
7. 재현 가능성은 같은 데이터와 코드로 같은 결과가 나오는가다. 코드와 컨테이너, 난수 시드를 공개해 높인다. 반복 가능성은 새 데이터에서 같은 결론이 나오는가다. 충분한 표본과 등록 보고서로 높인다. 강건성은 합리적인 다른 분석에서도 결론이 유지되는가다. 다중 우주 분석이나 민감도 분석으로 확인한다.
8. $0.85 \times 0.1 / (0.85 \times 0.1 + 0.1 \times 0.9) = 0.085/0.175 \approx 0.49$ 다. 양성 판정의 절반은 거짓 양성이다. 그 밖에 기억 클리닉 환자로 한 외부 검증, 보정 곡선, 나이·성별·스캐너별 성능, 나이와 인지 검사만 쓴 기준 모형보다 나은지를 확인해야 한다.

다음 장으로

이 책은 여기서 끝난다. 1장에서 영상은 배열이고 좌표계를 가진다는 것에서 출발했다. 구조, 기능, 확산 MRI와 EEG/MEG, PET 데이터가 원자료에서 통계 지도와 연결성 행렬과 소스 시계열이 되기까지의 단계를 차례로 밟았다. 단계마다 무엇을 가정하고 어디서 틀릴 수 있는지를 보았다. 이 장에서는 그 모든 단계 위에 놓이는 질문을 다뤘다. 결과가 새 사람, 새 데이터, 다른 분석에서도 유지되는가.

마지막으로 이 책 전체를 박사과정 연구 설계 점검표로 묶는다. 연구 계획서를 쓸 때, 그리고 데이터를 처음 열기 전에 한 번씩 확인하자.

1. **질문:** 가설은 집단 평균에 관한 것인가, 개인 차이나 예측에 관한 것인가? 후자라면 지표의 신뢰도(2장)와 필요한 표본(이 장)을 먼저 따진다.

2. **표본**: 기대 효과 크기의 출처는 어디이며, 승자의 저주로 부풀려진 값은 아닌가? 큰 공개 데이터로 효과 크기를 미리 잴 수 있는가?
3. **측정**: 시퀀스와 기록 조건이 보려는 신호를 담을 수 있는가(물리 2권 8-10장, 생리 1권 9장)? 사이트와 스캐너가 여럿이면 조화 계획이 있는가(3장)?
4. **전처리**: 파이프라인과 버전, 품질 점검 기준, 제외 기준을 데이터를 보기 전에 정했는가(4장, 8장, 9장)? 움직임과 집단의 혼입을 어떻게 다룰 것인가?
5. **통계**: 주된 모형, 대비, 다중비교 방법, ROI를 미리 정했는가(5장, 6장)? 순환성은 없는가?
6. **예측**: 예측 모형이라면 접힘 단위, 중첩 구조, 잠가 둔 시험 데이터, 외부 검증 표본이 정해졌는가?
7. **강건성**: 결론을 바꿀 수 있는 선택은 무엇이며, 다중 우주 분석이나 민감도 분석으로 보고할 것인가?
8. **공개**: 사전 등록 또는 등록 보고서를 낼 것인가? 데이터(BIDS), 코드, 컨테이너, 통계 지도를 어디에 공개할 것인가?

이 책에서 그림으로 먼저 본 개념들은 수학 시리즈에서 식으로 다시 만난다. 능형 회귀와 정칙화, 주성분 분석, 투영은 선형대수에서, 교차 검증의 흔들림과 승자의 저주, 베イズ 추론은 확률과 통계에서 제대로 다룬다. 시리즈의 다음 권들은 이 책이 이름과 개념으로만 소개한 주제들로 나아간다. 생성 모형과 계산 신경과학, 딥러닝 기반 영상 분석, 그리고 고자기장과 층별 fMRI 같은 최신 획득 방법이 그 예다. 어느 쪽으로 가든 이 책의 질문은 그대로 따라간다. 이 방법은 무엇을 가정하는가, 그 가정이 깨지면 무엇이 보이는가, 그리고 다른 사람이 같은 결과를 다시 만들 수 있는가.